

Sinh Ảnh Trong Thị Giác Máy Tính

Tổng quan về sinh ảnh và các mô
hình GANs, VAEs

1

1

Đâu là mặt thật, đâu là mặt giả?

<http://www.whichfaceisreal.com/>



2

2

Khái Niệm Về Sinh Ảnh

- Sinh ảnh (Image Generation) là quá trình mà máy tính học từ dữ liệu và sinh ra các hình ảnh mới.
- Quá trình này có thể học từ các mẫu hình ảnh thực tế và tạo ra những hình ảnh không tồn tại trong thực tế.

3


3

Ứng Dụng Của Sinh Ảnh

- Sinh ảnh được ứng dụng trong nhiều lĩnh vực:
 - Nghệ thuật và sáng tạo: Tạo ra các tác phẩm nghệ thuật kỹ thuật số
 - Y tế: Tạo ảnh y tế từ dữ liệu chẩn đoán
 - Phim ảnh và giải trí: Tổng hợp nhân vật, cảnh quan từ trí tuệ nhân tạo



Một con rai cá biển theo phong cách của bức tranh 'Cô gái đeo hoa tai ngọc trai' của Johannes Vermeer, được tạo ra bằng DALL-E



Hình ảnh chụp cắt lớp vi tính mạch máu phổi được tạo ra bởi máy tính từ tập hợp các tia X.

4

4

Mô hình sinh

- Mục đích: Nhận đầu vào một tập mẫu huấn luyện sinh ra từ một phân bố nào đó và học một mô hình để có thể biểu diễn lại phân bố đó




- Làm sao để học $p_{\text{model}}(x)$ tương tự với $p_{\text{data}}(x)$?

5

5

Tại sao cần mô hình sinh?




- Sử dụng phân bố ẩn học được để sinh ra dữ liệu đa dạng và cân bằng hơn (debias)

6

6

Tại sao cần mô hình sinh?

- Phát hiện ngoại lệ (outlier): Làm sao để phát hiện một sự kiện mới học hiếm xảy ra?
- Sử dụng mô hình sinh để học phân bố dữ liệu, từ đó xác định ngoại lệ dựa trên phân bố học được.




7

7

Mô Hình Phân Biệt và Mô Hình Tạo Sinh

- Mô hình phân biệt (Discriminative model):
 - Học cách phân loại các điểm dữ liệu dựa trên nhãn.
 - Ví dụ: Phân loại ảnh thành mèo và chó.
- Mô hình tạo sinh (Generative model):
 - Học cách sinh ra dữ liệu mới từ không gian ẩn
 - Ví dụ: Sinh ra hình ảnh mèo hoặc chó mới từ dữ liệu học được




Các mô hình phân biệt học cách xác định ranh giới quyết định giữa các lớp, trong khi các mô hình sinh học cách phân phối đều vào cho từng lớp (Yehoshua)

8

8

Tổng Quan Về GANs

- GANs (Generative Adversarial Networks) là một loại mô hình sinh ảnh
- GANs gồm hai mạng neural đối nghịch nhau:
 - Generator (mạng sinh): Sinh ra dữ liệu mới (hình ảnh)
 - Discriminator (mạng phân loại): Phân biệt giữa dữ liệu thật và dữ liệu giả.
- Cả hai mạng này cạnh tranh để cải thiện chất lượng hình ảnh sinh ra



9


Cơ Chế Cạnh Tranh Của GANs

- GANs hoạt động như một trò chơi cạnh tranh giữa hai mạng neural:
 - Generator cố gắng tạo ra hình ảnh giả để đánh lừa Discriminator.
 - Discriminator cố gắng phân biệt giữa hình ảnh thật và giả.
- Mục tiêu là đạt đến trạng thái mà Generator có thể tạo ra hình ảnh không thể phân biệt với hình ảnh thật.

10

Cơ chế GANs

- Generator tạo dữ liệu giả từ nhiễu



11

11

Cơ chế GANs

- Discriminator nhìn vào dữ liệu thật và giả



12

12

Cơ chế GANs

- Discriminator nhìn vào dữ liệu thật và giả




13

13

Cơ chế GANs


- Discriminator đoán đâu là thật, đâu là giả



14

14

Cơ chế GANs




15

15

Cơ chế GANs

- Discriminator đoán đâu là thật, đâu là giả




16

16

Cơ chế GANs

- Discriminator đoán đâu là thật, đâu là giả



17

17

Cơ chế GANs

- Generator cố gắng cải tiến chất lượng dữ liệu giả




18

18

Cơ chế GANs

- Generator cố gắng cải tiến chất lượng dữ liệu giả




19

19

Cơ chế GANs

- Generator cố gắng cải tiến chất lượng dữ liệu giả




20

20

Cơ chế GANs

- Discriminator đoán đâu là thật, đâu là giả




21

21

Cơ chế GANs

- Discriminator đoán đâu là thật, đâu là giả




22

22

Cơ chế GANs

- Discriminator đoán đâu là thật, đâu là giả




23

23

Cơ chế GANs

- Discriminator đoán đâu là thật, đâu là giả




24

24

Cơ chế GANs

- Generator cố gắng cải tiến chất lượng dữ liệu giả




25

25

Cơ chế GANs

- Generator cố gắng cải tiến chất lượng dữ liệu giả




26

26

Cơ chế GANs

- Generator cố gắng cải tiến chất lượng dữ liệu giả




27

27

Cơ chế GANs

- Discriminator cố gắng phân biệt dữ liệu thật và giả
- Generator cố gắng cải tiến chất lượng dữ liệu giả để lừa discriminator



28

28

Các Phiên Bản Nổi Bật Của GANs

- Một số phiên bản GANs nổi bật:
 - DCGAN (Deep Convolutional GAN): Áp dụng tích chập sâu vào GANs để xử lý dữ liệu hình ảnh.
 - WGAN (Wasserstein GAN): Khắc phục các vấn đề về mode collapse.
 - StyleGAN: Cho phép kiểm soát phong cách hình ảnh sinh ra với chất lượng cao.

29

29

DCGAN


- DCGAN (Deep Convolutional GAN) là một biến thể của GANs, được thiết kế để làm việc tốt hơn với dữ liệu hình ảnh.
 - Sử dụng các lớp mạng tích chập (convolutional layers) thay vì các lớp fully-connected truyền thống.
 - DCGAN có khả năng sinh ra các hình ảnh rõ ràng và chi tiết hơn từ nhiễu ngẫu nhiên.

30


30

DCGAN

- Discrimination: bộ phân loại ảnh sử dụng CNN quen thuộc



- Generator: ngược lại với các kiến trúc CNN thường thấy, đầu vào là 1 vector, qua các lớp convolution để được ảnh đầu ra



31

31

Hạn Chế Của GAN: Mode Collapse

- Một trong những hạn chế chính của GAN là Mode Collapse:
 - Generator có xu hướng sinh ra những hình ảnh tương tự nhau thay vì đa dạng.
 - Điều này xảy ra khi Discriminator không còn có thể phân biệt rõ giữa các mẫu khác nhau, Generator tìm được một số mẫu nhất định để lừa Discriminator nhưng không tạo ra sự đa dạng
- Mode Collapse dẫn đến chất lượng hình ảnh sinh ra kém đa dạng.

32

32

WGAN Giải Quyết Mode Collapse

- WGAN (Wasserstein GAN) là một cải tiến của GAN giúp khắc phục Mode Collapse:
 - Thay thế hàm mất mát bằng Wasserstein Distance để tối ưu hóa
 - Không tập trung vào việc phân biệt rõ ràng từng mẫu ảnh, mà thay vào đó tối ưu hóa khoảng cách giữa hai phân phối tổng thể. Mọi thay đổi nhỏ trong ảnh sinh ra đều ảnh hưởng đến Wasserstein Distance → Generator sinh ra mẫu đa dạng hơn
- Kết quả là các mẫu sinh ra có tính đa dạng và chất lượng cao hơn.

33

33

Sinh Ảnh Chân Dung Với StyleGAN

- StyleGAN là một phiên bản tiên tiến của GAN, cho phép sinh ra các hình ảnh chân dung chân thực.
 - StyleGAN có thể sinh ra chân dung của con người với các thay đổi về phong cách, biểu cảm, và góc nhìn.
 - Ứng dụng nhiều trong việc tạo ra nhân vật ảo và chân dung kỹ thuật số.

34

34

Đặc Điểm Chính Của StyleGAN

- Mapping Network để điều chỉnh phong cách.
 - Mạng nơ-ron: biến đổi vector nhiễu ban đầu (z) thành một vector style w nằm trong một không gian ẩn Style Space.
 - Cho phép điều chỉnh từng phần riêng lẻ của hình ảnh, mỗi w là một style
- Synthesis Network: nơi ảnh sinh ra
 - Nhận vector style w và sử dụng nó để điều khiển quá trình sinh ảnh
 - Sinh ảnh bằng cách sử dụng các lớp tích chập (convolutional layers) với từng lớp nhận đầu vào là vector w để điều khiển các đặc trưng khác nhau của hình ảnh (hình dạng, màu sắc, ánh sáng, kết cấu, v.v.).
 - Các lớp đầu tiên của mạng thường ảnh hưởng đến các yếu tố lớn như hình dáng khuôn mặt, trong khi các lớp sau chịu trách nhiệm điều chỉnh chi tiết như kết cấu da hoặc mái
- Style Mixing: Trộn nhiều w ở các lớp khác nhau của Synthesis Network
 - Các phần khác nhau của ảnh bị ảnh hưởng bởi các style khác nhau

35

Ứng Dụng Của GAN Trong Sinh Ảnh Chân Thực

- GANs được sử dụng để sinh ra các hình ảnh chân thực trong nhiều lĩnh vực:
 - Nghệ thuật số: Tạo ra các bức tranh kỹ thuật số.
 - Chân dung ảo: Sinh ra hình ảnh chân dung của con người.
 - Y tế: Sinh hình ảnh y tế từ các tập dữ liệu để hỗ trợ chẩn đoán.

36

36



https://github.com/zoetrope/GANs_torch/blob/master/02.%20DCGAN/README.md

Ví Dụ Sinh Ảnh Với GAN Từ Bộ Dữ Liệu MNIST

- Ví dụ: GAN được huấn luyện trên bộ dữ liệu MNIST để sinh ra các hình ảnh chữ số.
 - Bộ dữ liệu MNIST chứa các hình ảnh số viết tay từ 0 đến 9.
 - GAN học từ bộ dữ liệu này để sinh ra các số mới với chất lượng cao.

37

37

Autoencoder

- Autoencoder là một mô hình sinh khác giúp học không gian ẩn của dữ liệu.
 - Encoder: Mã hóa dữ liệu thành không gian ẩn (latent space).
 - Decoder: Tái tạo dữ liệu từ không gian ẩn đó.
- Autoencoder giúp sinh ra dữ liệu mới từ các mẫu học được trong quá trình huấn luyện.

38

38

Cấu Trúc Của Autoencoder


- Gồm hai thành phần chính:
 - Encoder: Học cách mã hóa dữ liệu thành không gian ẩn.
 - Decoder: Học cách tái tạo dữ liệu từ không gian ẩn đó.
- Quá trình này cho phép Autoencoder học cách sinh ra dữ liệu từ các đại diện ẩn

39

39

Autoencoder

- Làm sao để học không gian ẩn?
- Huấn luyện mô hình sử dụng đặc trưng ẩn z để khôi phục lại dữ liệu gốc ban đầu
- “Decoder” ánh xạ đặc trưng ẩn z ngược trở lại để khôi phục thông tin dữ liệu đầu vào $\hat{x}$




40

40

Variational Autoencoder

- VAEs: sự khác biệt chính so với autoencoder




41

41

Variational Autoencoder

- VAEs: sự khác biệt chính so với autoencoder truyền thống



42

42

Variational Autoencoder

- **Autoencoder (AE)**
 - AE nén dữ liệu vào một vector điểm cụ thể trong không gian ẩn. Không có tính xác suất trong việc nén.
 - Vector đầu ra của **Encoder** là một điểm duy nhất.
- **Variational Autoencoder (VAE):**
 - VAE học cách biểu diễn dữ liệu trong một **phân phối Gaussian**. Thay vì trả về một điểm cụ thể, **Encoder** trong VAE trả về hai tham số: **mean** và **variance** của một phân phối
 - Từ đó, ta có thể sinh ra các mẫu mới từ không gian ẩn bằng cách rút ra các giá trị ngẫu nhiên từ phân phối Gaussian này.

43

43

Hàm Mất Mát Của VAE

- Hàm mất mát của VAE bao gồm hai thành phần:
 - Reconstruction Loss: Đo lường sự khác biệt giữa dữ liệu gốc và dữ liệu tái tạo.
 - KL-Divergence: Đo lường sự khác biệt giữa phân phối ẩn và phân phối chuẩn.
- Hai thành phần này được tối ưu hóa cùng lúc để cải thiện chất lượng sinh dữ liệu.

44

44

Hàm Mất Mát Của VAE

- **Reconstruction Loss (Lỗi tái tạo)**
 - **Chức năng:** Đảm bảo dữ liệu được tái tạo lại từ không gian ẩn z phải gần giống với dữ liệu gốc x
 - **Cách hoạt động:**
 - Sau khi dữ liệu x được nén thành z và giải nén thành x' thông qua **Decoder**, hàm **Reconstruction loss** đo lường sự khác biệt giữa dữ liệu đầu vào x và dữ liệu tái tạo x' .
 - Hàm này thường sử dụng **Mean Squared Error (MSE)** hoặc **Binary Cross-Entropy (BCE)**, tùy thuộc vào dạng dữ liệu.
 - **MSE** thường được sử dụng cho dữ liệu liên tục.
 - **BCE** thường được sử dụng cho dữ liệu phân loại hoặc nhị phân.
 - **Công thức:**
 - $\text{Reconstruction Loss} = \|x - x'\|^2$
 - Nếu x và x' giống nhau, loss này sẽ bằng 0. Càng khác nhau, giá trị của loss sẽ càng lớn.
 - **Ý nghĩa:** Giúp mô hình học cách tái tạo lại dữ liệu từ không gian ẩn z . Nếu chỉ có phần này, VAE sẽ tương tự như một **Autoencoder** thông thường, chỉ tập trung vào việc khôi phục lại dữ liệu gốc mà không quan tâm đến sự ngẫu nhiên hay phân phối của không gian ẩn.

45

45

Hàm Mất Mát Của VAE

- **KL Divergence (Độ phân kỳ Kullback-Leibler)**
 - **Chức năng:** Đảm bảo phân phối của không gian ẩn z (được xác định bởi **mean** μ và **variance** σ) gần giống với phân phối Gaussian chuẩn $N(0,1)$.
 - **Cách hoạt động:**
 - **KL Divergence** đo lường sự khác biệt giữa hai phân phối xác suất. Trong VAE, nó đo khoảng cách giữa:
 - **Phân phối ẩn** do Encoder sinh ra (có mean μ và variance σ).
 - **Phân phối Gaussian chuẩn** $N(0,1)$ (có mean bằng 0 và variance bằng 1).
 - **Công thức** (cho phân phối Gaussian)
 - $D_{KL}(q(z|x) || p(z)) = \frac{1}{2} \sum (\sigma^2 + \mu^2 - \log(\sigma^2) - 1)$
 - **$q(z|x)$:** Phân phối ẩn được sinh ra bởi Encoder.
 - **$p(z)$:** Phân phối Gaussian chuẩn $N(0,1)$.
- **Ý nghĩa:** KL Divergence khuyến khích phân phối ẩn của VAE phải gần với phân phối Gaussian chuẩn. Điều này đảm bảo rằng không gian ẩn của VAE sẽ "liên tục" và có dạng phân phối chuẩn, giúp VAE có thể sinh ra dữ liệu mới từ không gian này.

46

46

Hàm Mất Mát Của VAE

- **Công thức tổng quát:**
 - $\text{Loss} = \text{Reconstruction Loss} + \beta \cdot D_{\text{KL}}(q(z|x) || p(z))$
 - Trong đó, β là hệ số cân bằng giữa hai phần, có thể điều chỉnh tùy thuộc vào mục tiêu
- **Giải thích:**
 - **Reconstruction Loss:** Giúp mô hình tái tạo lại dữ liệu gốc một cách chính xác nhất
 - **KL Divergence:** Đảm bảo không gian ẩn có dạng phân phối chuẩn Gaussian và liên tục, từ đó cho phép sinh ra dữ liệu mới

47

47

So Sánh Giữa GANs và VAEs

- **GANs:**
 - Sinh ảnh rõ nét và chân thực hơn.
 - Khó huấn luyện và dễ gặp vấn đề mode collapse.
- **VAEs:**
 - Dễ huấn luyện hơn và sinh ảnh ổn định.
 - Ảnh sinh ra mịn nhưng đôi khi kém rõ ràng hơn GANs.

48

48

Kết Hợp Giữa GANs và VAEs: Các Mô Hình Lai

- Sự kết hợp giữa GANs và VAEs tạo ra các mô hình lai:
 - VAE-GAN: Sử dụng cấu trúc VAE để học không gian ẩn và GAN để sinh ra hình ảnh sắc nét
 - Kết hợp này tận dụng ưu điểm của cả hai mô hình để sinh ra ảnh với chất lượng tốt hơn và ổn định hơn
 - Nhờ vào cấu trúc của **VAE**, quá trình học không gian tiềm ẩn trong VAE-GAN ổn định hơn
 - **Chất lượng ảnh cao hơn**: Nhờ vào cơ chế đối nghịch của **GAN**, hình ảnh sinh ra bởi **VAE-GAN** thường sắc nét và chân thực hơn so với hình ảnh sinh ra từ **VAE** thông thường.

49

49

Thách Thức và Cơ Hội Trong Sinh Ảnh

- Sinh ảnh bằng các mô hình như GANs và VAEs có nhiều thách thức:
 - Khó khăn trong việc huấn luyện mô hình ổn định.
 - Cần lượng dữ liệu lớn và sức mạnh tính toán.
 - Cơ hội: Mở rộng khả năng ứng dụng trong sáng tạo nghệ thuật, y tế và truyền thông.

50

50

Xu Hướng Mới Trong Sinh Ảnh

- Các xu hướng mới trong sinh ảnh bao gồm:
 - Diffusion Models: Tạo ra hình ảnh chất lượng cao thông qua khuếch tán ngược.
 - Flow-based Models: Mô hình này học phân phối xác suất trực tiếp từ dữ liệu.
 - Các mô hình mới này đang dần thay thế GANs và VAEs trong một số bài toán phức tạp hơn.

51

51

Xu Hướng Mới Trong Sinh Ảnh

Diffusion Models:

- **Khái niệm:**
 - Mô hình khuếch tán (Diffusion Models) là một xu hướng mới trong việc sinh ảnh.
 - Hoạt động dựa trên việc dần dần **khuếch tán** nhiễu ngẫu nhiên thành các hình ảnh rõ nét và có chất lượng cao thông qua một quá trình ngược lại.
- **Cơ chế hoạt động:**
 - Quá trình huấn luyện bao gồm việc thêm dần nhiễu vào dữ liệu đầu vào (ví dụ: ảnh gốc), tạo thành các phiên bản bị nhiễu.
 - Trong quá trình sinh ảnh, mô hình sẽ bắt đầu từ nhiễu ngẫu nhiên và dần dần **loại bỏ nhiễu** qua từng bước, khôi phục lại ảnh gốc từ nhiễu.
- **Lợi ích:**
 - **Diffusion Models** có thể sinh ra những hình ảnh với chất lượng cao và ít lỗi hơn so với các mô hình truyền thống như **GANs**.
 - Chúng có tính ổn định cao trong huấn luyện, không gặp các vấn đề như **mode collapse** (thường thấy trong GANs).
- **Ví dụ:** Các mô hình như **Denoising Diffusion Probabilistic Models (DDPMs)** hay các phiên bản mở rộng như **Stable Diffusion** là các ví dụ điển hình của khuếch tán ngược trong sinh ảnh.

52

52

Xu Hướng Mới Trong Sinh Ảnh

Flow-based Models

- **Khái niệm:** Mô hình sinh ảnh sử dụng các phép **biến đổi ngược** để sinh ra dữ liệu. Điều này có nghĩa là mô hình học cách **biến đổi dữ liệu** (ví dụ: hình ảnh) thành một dạng phân phối đơn giản (như nhiễu ngẫu nhiên) và ngược lại, biến đổi nhiễu thành hình ảnh.
- **Cơ chế hoạt động:** quá trình biến đổi hai chiều:
 - **Biến đổi từ dữ liệu gốc sang phân phối đơn giản** (quá trình này giống như việc nén dữ liệu, chuyển hình ảnh phức tạp thành một thứ dễ hiểu hơn như phân phối Gaussian).
 - **Biến đổi ngược từ phân phối đơn giản sang dữ liệu gốc** (quá trình này giống như việc giải nén dữ liệu, từ nhiễu ngẫu nhiên có thể sinh ra hình ảnh).
 - Điểm đặc biệt là quá trình này có thể **ngược hoàn toàn**: có thể chuyển đổi từ dữ liệu gốc sang nhiễu và ngược lại mà không mất thông tin.
- **Lợi ích:**
 - **Học xác suất trực tiếp:** Khác với các mô hình như GANs hay VAEs (cần ước lượng phân phối), **Flow-based Models học trực tiếp** phân phối xác suất của dữ liệu → **sinh ra dữ liệu với độ chính xác cao** và không gặp các vấn đề như **mode collapse** (khi mô hình chỉ sinh ra một kiểu dữ liệu nhất định)
 - **Khả năng sinh dữ liệu:** Bởi vì mô hình này có khả năng biến đổi ngược nên có thể sinh ra ảnh mới một cách dễ dàng bằng cách lấy mẫu từ phân phối đơn giản (như nhiễu ngẫu nhiên) rồi biến đổi thành hình ảnh thực.
- **Ví dụ mô hình** Glow và RealNVP là hai mô hình **Flow-based** nổi tiếng

53

53

Ứng Dụng Thực Tế: Text-to-Image (DALL-E, Stable Diffusion)

- Các mô hình sinh như DALL-E và Stable Diffusion đã mở ra khả năng chuyển đổi văn bản thành hình ảnh:
- - Mô hình học cách tạo hình ảnh từ các mô tả văn bản.
- - Ứng dụng trong sáng tạo nghệ thuật, quảng cáo và truyền thông số.
- - Ví dụ: Stable Diffusion có thể sinh ra hình ảnh chất lượng cao từ mô tả chi tiết.

55

55

Vấn Đề Đạo Đức Liên Quan Đến Sinh Ảnh

- Sự phát triển của các mô hình sinh ảnh đặt ra nhiều vấn đề đạo đức:
- - Deepfake: Ứng dụng công nghệ sinh ảnh để tạo ra video giả mạo.
- - Quyền riêng tư: Sử dụng hình ảnh giả mạo cho mục đích không chính đáng.
- - Cần có các biện pháp kiểm soát và luật pháp để ngăn chặn sự lạm dụng.

56

56

Thảo Luận: Tương Lai Của Các Mô Hình Sinh Ảnh

- Các mô hình sinh ảnh đang mở ra những khả năng mới trong tương lai:
- - AI có thể sáng tạo ra các tác phẩm nghệ thuật tự động.
- - Nhiều ứng dụng mới sẽ xuất hiện trong lĩnh vực y tế, giáo dục và giải trí.
- - Những thách thức và cơ hội này cần được thảo luận sâu rộng.

57

57

Tài Liệu Tham Khảo

Dưới đây là một số tài liệu tham khảo chính:

1. Goodfellow et al. (2014). Generative Adversarial Nets.
2. Kingma, D.P., & Welling, M. (2013). Auto-Encoding Variational Bayes.
3. Các bài giảng từ MIT và Stanford về Deep Learning.
4. Các tài liệu về DALL-E và Stable Diffusion từ OpenAI.

58