


In-painting hình ảnh dựa trên
prompt


Giới thiệu

- Thay thế một phần nhất định của một hình ảnh bằng một hình ảnh khác.
- Ví dụ minh họa cho nhiệm vụ in-painting như hình được cung cấp, trong đó phần hình ảnh chứa một chú chó được thay thế bằng một chú mèo màu vàng.



Các bước chính

1. Input: Ảnh gốc có kích thước 512x512 pixel với chú chó ngồi trên ghế.
 2. Mask: Là ảnh đen-trắng 512x512 pixel, trong đó vùng trắng xác định phần cần được thay thế (vị trí của chú chó).
 3. Phần tạo nội dung mới:
 - Bắt đầu từ nhiễu ngẫu nhiên 64x64 và mô tả prompt
 - Kết hợp với thông tin thời gian (timestep)
 - Đưa qua mạng UNet để tạo ra "cat latents" - biểu diễn ẩn của hình mèo
 4. VAE (Variational Autoencoder): Mạng nén hình ảnh gốc 512x512 thành không gian latent 64x64.
 5. Kết hợp latents: Kết hợp latents của hình gốc với latents của mèo
 6. Xử lý: Resize mask từ 512x512 xuống 64x64 để khớp với kích thước latent space.
 7. Next Timestep: Chỉ ra rằng quá trình này lặp lại qua nhiều bước thời gian, đặc trưng cho mô hình khuếch tán.
 8. VAE: Giải nén từ latent space trở lại thành hình ảnh 512x512 pixel với kết quả cuối là hình mèo vàng ngồi trên ghế.
- Kết quả cuối cùng: Output 512x512 với mèo vàng thay thế vào đúng vị trí của chú chó, trong khi vẫn giữ nguyên bối cảnh xung quanh.



Code

- Link:

<https://colab.research.google.com/drive/1D9laiOVqjxH9jHFpNlYd0J0kopC9lo5W?usp=sharing>

Text-to-Video

Giới thiệu

- Từ một văn bản mô tả (text prompt), mô hình sẽ tạo ra video phù hợp
 - Ví dụ “a rocket shooting into the sky” sẽ tạo ra video tên lửa bay lên bầu trời.
- Chú ý cần giải quyết:
 - Tính nhất quán về thời gian (temporal consistency): Đảm bảo các đối tượng trong video không bị thay đổi quá lớn giữa các frame. Ví dụ tên lửa trong hai frame liên tiếp phải giống nhau
 - Tính nhất quán về hành động (action consistency): Đảm bảo hành động diễn ra mượt mà giữa các khung hình. Ví dụ tên lửa phải bay lên theo quỹ đạo liên tục, không bị giật hay thay đổi đột ngột

Unet3DConditionModel

- Phiên bản mở rộng của kiến trúc Unet được thiết kế để xử lý dữ liệu video 3D trong các tác vụ như text-to-video generation. Kiến trúc này được tối ưu hóa để xử lý thông tin không gian (spatial) và thời gian (temporal), giúp duy trì tính nhất quán giữa các khung hình trong video.
- Đặc điểm nổi bật
 - Hỗ trợ dữ liệu 3D (Video):
 - Xử lý đồng thời toàn bộ các khung hình của video thay vì xử lý từng ảnh riêng lẻ.
 - Đầu vào là tensor 5D: [batch_size, frames, channels, height, width].
 - Temporal Dimension:
 - Bổ sung các thành phần đặc biệt để duy trì tính nhất quán thời gian (temporal consistency) và tính nhất quán hành động (action consistency) giữa các khung hình.
- Kiến trúc dựa trên Attention:
 - Tích hợp các module attention để mô hình hóa mối quan hệ giữa các khung hình trong video.
 - Dùng Cross Attention để điều chỉnh đầu ra dựa trên prompt văn bản.
- Sử dụng Diffusion Models:
 - Kết hợp với các mô hình khuếch tán (diffusion models) để dần dần tạo ra video từ nhiễu (noise).

Unet3DConditionModel

- Hai modules mới:
 - temp_conv:
 - Dùng lớp Conv3D để xử lý đồng thời tất cả các khung hình.
 - Duy trì tính nhất quán thời gian bằng cách kết hợp thông tin từ nhiều khung hình → giúp mô hình hiểu được ngữ cảnh theo thời gian.
 - Đảm bảo hình dạng hoặc đặc tính của đối tượng không thay đổi giữa các khung hình
 - temp_attn:
 - Tính toán self-attention trên chiều thời gian (frame)
 - Tập trung vào mối quan hệ giữa các khung hình để duy trì sự mượt mà và liên tục của hành động.

Code

- <https://colab.research.google.com/drive/1-tTC2L7yHIVSOwBcKj9SyWnpQ83caWrs?usp=sharing>