



Chứng cất kiến thức: Một cuộc khảo sát

Jianping Gou^{1,2} · Baosheng Yu² · Stephen J. Maybank³ · DaThành Tao² 

Nhận: 29 tháng 6 năm 2020 / Chấp nhận: 3 tháng 3 năm 2021 © Crown 2021

Tóm tắt

Trong những năm gần đây, mạng nơ-ron sâu đã thành công trong cả ngành công nghiệp và học thuật, đặc biệt là đối với các nhiệm vụ thị giác máy tính. Thành công lớn của học sâu chủ yếu là do khả năng mở rộng để mã hóa dữ liệu quy mô lớn và điều khiển hàng tỷ tham số mô hình. Tuy nhiên, việc triển khai các mô hình sâu công kênh này trên các thiết bị có tài nguyên hạn chế, ví dụ như điện thoại di động và thiết bị nhúng là một thách thức, không chỉ vì độ phức tạp tính toán cao mà còn vì yêu cầu lưu trữ lớn. Vì mục đích này, nhiều kỹ thuật nén và tăng tốc mô hình đã được phát triển. Là một loại nén và tăng tốc mô hình tiêu biểu, chứng cất kiến thức học hiệu quả một mô hình học sinh nhỏ từ một mô hình giáo viên lớn. Nó đã nhận được sự chú ý ngày càng tăng nhanh chóng từ cộng đồng. Bài báo này cung cấp một khảo sát toàn diện về chứng cất kiến thức theo quan điểm của các loại kiến thức, chương trình đào tạo, kiến trúc giáo viên-học sinh, thuật toán chứng cất, so sánh hiệu suất và ứng dụng. Hơn nữa, những thách thức trong chứng cất kiến thức được xem xét ngắn gọn và các bình luận về nghiên cứu trong tương lai được thảo luận và chuyển tiếp.

Từ khóa Mạng nơ-ron sâu · Nén mô hình · Chắt lọc kiến thức · Chuyển giao kiến thức · Kiến trúc giáo viên-học sinh

1 Giới thiệu

Trong vài năm trở lại đây, học sâu đã trở thành nền tảng cho nhiều thành công trong trí tuệ nhân tạo, bao gồm nhiều ứng dụng trong thị giác máy tính (Krizhevsky và cộng sự, 2012), học tăng cường (Silver và cộng sự, 2016; Ashok và cộng sự, 2018; Lai và cộng sự, 2020) và xử lý ngôn ngữ tự nhiên (Devlin và cộng sự, 2020).

Được truyền đạt bởi Minsu Cho.


B Dachen Tao
dachen.tao@sydney.edu.au
Jianping Gou
tran.trong.gjp@gmail.com
Baosheng Yu
baosheng.yu@sydney.edu.au
Stephen J. Maybank
sjmaybank@dcsc.bbk.ac.uk

¹ Khoa Khoa học máy tính và Truyền thông
Kỹ thuật và Phòng thí nghiệm trọng điểm an ninh Giang Tô
Công nghệ cho không gian mạng công nghiệp, Đại học Giang Tô,
Trần Giang 212013, Trung Quốc
² Khoa Khoa học Máy tính, Khoa Kỹ thuật,
Đại học Sydney, Darlington, NSW 2008, Úc
³ Khoa Khoa học máy tính và Hệ thống thông tin,
Cao đẳng Birkbeck, Đại học London, London, Vương quốc Anh

2019). Với sự trợ giúp của nhiều kỹ thuật gần đây, bao gồm kết nối còn lại (He et al. 2016, 2020b) và chuẩn hóa hàng loạt (Ioffe và Szegedy 2015), rất dễ dàng để đào tạo các mô hình rất sâu với hàng nghìn lớp trên các cụm GPU hoặc TPU mạnh mẽ. Ví dụ, chỉ mất chưa đầy mười phút để đào tạo một mô hình ResNet trên một chuẩn mực nhận dạng hình ảnh phổ biến với hàng triệu hình ảnh (Deng et al. 2009; Sun et al. 2019); Chỉ mất không quá một tiếng rưỡi để đào tạo một mô hình BERT mạnh mẽ để hiểu ngôn ngữ (Devlin và cộng sự, 2019; You và cộng sự, 2019). Các mô hình sâu quy mô lớn đã đạt được những thành công vang dội, tuy nhiên độ phức tạp tính toán lớn và yêu cầu lưu trữ lớn khiến việc triển khai chúng trong các ứng dụng thời gian thực trở thành một thách thức lớn, đặc biệt là trên các thiết bị có nguồn lực hạn chế, chẳng hạn như giám sát video và xe tự lái.

Để phát triển các mô hình sâu hiệu quả, các công trình gần đây thường tập trung vào 1) các khối xây dựng hiệu quả cho các mô hình sâu, bao gồm tích chập có thể tách theo chiều sâu, như trong MobileNets (Howard và cộng sự, 2017; Sandler và cộng sự, 2018) và ShuffleNets (Zhang và cộng sự, 2018a; Ma và cộng sự, 2018); và 2) các kỹ thuật nén và tăng tốc mô hình, trong các danh mục sau (Cheng và cộng sự, 2018).

• Cắt tia và chia sẻ tham số: Các phương pháp này tập trung vào việc loại bỏ các tham số không cần thiết khỏi mạng nơ-ron sâu.



Hình 1 Khung chung cho quá trình chất lọc kiến thức giữa giáo viên và học sinh

- hoạt động mà không ảnh hưởng đáng kể đến hiệu suất.
- Thể loại này được chia thành lượng tử hóa mô hình (Wu và cộng sự 2016), nhị phân hóa mô hình (Courbariaux et al. 2015), ma trận cấu trúc (Sindhwani et al. 2015) và chia sẻ tham số (Han và cộng sự 2015; Wang và cộng sự 2019f).
- Phân tích bậc thấp: Các phương pháp này xác định các tham số dự phòng của mạng nơ-ron sâu bằng cách sử dụng sự phân tích ma trận và tenxơ (Yu et al. 2017; Den-ton et al. 2014).
 - Bộ lọc tích chập nhỏ gọn được chuyển giao: Các phương pháp này loại bỏ các tham số không cần thiết bằng cách chuyển giao hoặc nén các bộ lọc tích chập (Zhai và cộng sự, 2016).
 - Chứng cứ kiến thức (KD): Các phương pháp này chứng cứ kiến thức từ một mạng lưới nơ-ron sâu lớn hơn thành một mạng lưới nhỏ hơn (Hinton et al. 2015).

Một đánh giá toàn diện về mô hình nén và tăng tốc nằm ngoài phạm vi của bài báo này. Trọng tâm của bài báo này

Bài báo là sự chất lọc kiến thức, ngày càng nhận được sự quan tâm của cộng đồng nghiên cứu trong những năm gần đây.

Các mạng nơ-ron sâu lớn đã đạt được thành công đáng kể với hiệu suất tốt, đặc biệt là trong thế giới thực các tình huống với dữ liệu quy mô lớn, vì việc tham số hóa quá mức cải thiện hiệu suất tổng quát hóa khi dữ liệu mới


dữ liệu được xem xét (Zhang và cộng sự 2018; Brutzkus và Glocer-son 2019; Allen-Zhu và cộng sự 2019; Arora và cộng sự 2018; Tu và cộng sự. 2020). Tuy nhiên, việc triển khai các mô hình sâu trong thiết bị di động thiết bị và hệ thống nhúng là một thách thức lớn, do khả năng tính toán và bộ nhớ của thiết bị bị hạn chế.

Để giải quyết vấn đề này, Bucilua et al. (2006) lần đầu tiên đề xuất mô hình nén để chuyển thông tin từ một lượng lớn mô hình hoặc một tập hợp các mô hình vào việc đào tạo một mô hình nhỏ mà không làm giảm đáng kể độ chính xác. Việc học một

mô hình từ một mô hình lớn sau đó được phổ biến chính thức như chứng cứ kiến thức (Hinton et al. 2015). Trong kiến thức chứng cứ, một mô hình sinh viên nhỏ thường được giám sát bởi một mô hình giáo viên lớn (Bucilua et al. 2006; Ba và Caru-ana 2014; Hinton et al. 2015; Urban et al. 2017). Chính ý tưởng là mô hình học sinh bắt chước mô hình giáo viên trong để có được hiệu suất cạnh tranh hoặc thậm chí là hiệu suất vượt trội.

Vấn đề chính là làm thế nào để chuyển giao kiến thức từ một mô hình giáo viên lớn cho một mô hình học sinh nhỏ. Về cơ bản, một hệ thống chứng cứ kiến thức bao gồm ba yếu tố chính các thành phần: kiến thức, thuật toán chứng cứ và giáo viên-kiến trúc sinh viên. Một khuôn khổ chung giữa giáo viên và sinh viên để chứng cứ kiến thức được thể hiện ở Hình 1.

Mặc dù thành công lớn trong thực tế, nhưng không có quá nhiều tác phẩm về sự hiểu biết lý thuyết hoặc thực nghiệm về quá trình chứng cứ kiến thức (Cheng et al. 2020; Phuong và Lampert 2019a; Cho và Hariharan 2019). Cụ thể, để hiểu được cơ chế hoạt động của quá trình chứng cứ kiến thức, Phuong & Lampert đã có được sự biện minh về mặt lý thuyết cho một sự tổng quát bị ràng buộc với sự hội tụ nhanh chóng của mạng lưới sinh viên được tinh lọc trong kịch bản tuyến tính sâu phân loại (Phuong và Lampert 2019a). Sự biện minh này trả lời những gì và học sinh học nhanh như thế nào và tiết lộ các yếu tố quyết định sự thành công của quá trình chứng cứ. Quá trình chứng cứ thành công phụ thuộc vào hình học dữ liệu, độ lệch tối ưu hóa của mục tiêu chứng cứ và tính đơn điệu mạnh mẽ của học sinh phân loại. Cheng và cộng sự đã định lượng việc trích xuất các khái niệm trực quan từ các lớp trung gian của mạng nơ-ron sâu, để giải thích quá trình chứng cứ kiến thức (Cheng et al. 2020). Ji và Zhu (2020) đã giải thích về mặt lý thuyết về quá trình chứng cứ kiến thức một mạng lưới nơ-ron rộng từ dữ liệu có liên quan đến rủi ro hiệu quả và giáo viên không hoàn hảo. Cho & Hariharan đã phân tích thực nghiệm chi tiết về hiệu quả của việc chất lọc kiến thức



Hình 2 Cấu trúc sơ đồ của quá trình chứng cật kiến thức và mối quan hệ giữa các phần liên kết. Nội dung của khảo sát này chủ yếu chứa đựng những kiến thức cơ bản về chất lọc kiến thức, các loại kiến thức, chương trình chứng cật, kiến trúc giáo viên-học sinh, thuật toán chứng cật

thuật toán, so sánh hiệu suất, ứng dụng, thảo luận, thách thức, và hướng đi trong tương lai. Lưu ý rằng 'Phần' được viết tắt là 'Phần' trong nhân và t


(Cho và Hariharan 2019). Kết quả thực nghiệm cho thấy rằng mô hình lớn hơn có thể không phải là một giáo viên tốt hơn vì mô hình khoảng cách năng lực (Mirzadeh et al. 2020). Các thí nghiệm cũng cho thấy rằng sự chứng cật ảnh hưởng xấu đến việc học tập của sinh viên. đánh giá thực nghiệm các hình thức khác nhau của sự chất lọc kiến thức về kiến thức, sự chất lọc và tình cảm lẫn nhau giữa giáo viên và học sinh không được Cho và Hari-haran (2019) đề cập. Sự chất lọc kiến thức cũng đã được khám phá để làm mịn nhân, để đánh giá độ chính xác của giáo viên và để có được dữ liệu trước cho hình học lớp đầu ra tối ưu (Tang et al. 2020).

Việc chứng cật kiến thức để nén mô hình tương tự như cách con người học. Lấy cảm hứng từ điều này, phương pháp chứng cật kiến thức gần đây đã được mở rộng học tập giữa giáo viên và học sinh (Hinton và cộng sự, 2015), học tập lẫn nhau (Zhang và cộng sự, 2018b), trợ giảng (Mirzadeh và cộng sự, 2020), học tập suốt đời (Zhai et al. 2019) và tự học (Yuan và cộng sự, 2020). Hầu hết các phần mở rộng của quá trình chất lọc kiến thức đều tập trung vào việc nén các mạng nơ-ron sâu. Các mạng lưới sinh viên nhẹ kết quả có thể dễ dàng được triển khai trong các ứng dụng như nhận dạng hình ảnh, giọng nói nhận dạng và xử lý ngôn ngữ tự nhiên (NLP). Hơn nữa, việc chuyển giao kiến thức từ mô hình này sang mô hình khác trong việc chất lọc kiến thức có thể được mở rộng sang các nhiệm vụ khác, chẳng hạn như các cuộc tấn công đối đầu (Papernot et al. 2016), tăng cường dữ liệu (Lee et al. 2019a; Gordon và Duh 2019), quyền riêng tư dữ liệu và an ninh (Wang et al. 2019a). Được thúc đẩy bởi kiến thức chứng cật để nén mô hình, ý tưởng về kiến thức


chuyển giao đã được áp dụng thêm trong việc nén đào tạo dữ liệu, tức là, chứng cật tập dữ liệu, chuyển giao kiến thức từ một tập dữ liệu lớn thành một tập dữ liệu nhỏ để giảm quá trình đào tạo nhiều mô hình sâu (Wang et al. 2018c; Bohdal et al. 2020). Trong bài báo này, chúng tôi trình bày một cuộc khảo sát toàn diện về chứng cật kiến thức. Các mục tiêu chính của cuộc khảo sát này là 1) cung cấp tổng quan về quá trình chứng cật kiến thức, bao gồm một số kiến thức, quá trình chứng cật và kiến trúc điển hình; 2) xem xét tiến trình gần đây của quá trình chất lọc kiến thức, bao gồm các thuật toán và ứng dụng cho các thể giới thực khác nhau các kịch bản; và 3) giải quyết một số rào cản và cung cấp thông tin chi tiết để chất lọc kiến thức dựa trên các góc nhìn khác nhau của việc chuyển giao kiến thức, bao gồm các loại kiến thức khác nhau, các chương trình đào tạo, thuật toán và cấu trúc chứng cật, và các ứng dụng. Gần đây, cũng có một cuộc khảo sát tương tự về chứng cật kiến thức (Wang và Yoon. 2020), trong đó trình bày tiến trình toàn diện từ nhiều góc độ khác nhau của việc học tập của giáo viên và học sinh về tầm nhìn và những thách thức của nó. Khác với Wang và Yoon. (2020), khảo sát của chúng tôi chủ yếu tập trung vào việc chất lọc kiến thức từ góc nhìn rộng của các loại kiến thức, các sơ đồ chứng cật, thuật toán chứng cật, so sánh hiệu suất và các ứng dụng khác nhau khu vực.

Tổ chức của bài báo này được thể hiện trong Hình 2. Các loại kiến thức và chứng cật khác nhau được tóm tắt trong Phần 2 và 3, tương ứng. Các nghiên cứu hiện có về Cấu trúc giáo viên-học sinh trong quá trình chất lọc kiến thức được minh họa trong Phần 4. Các phương pháp chất lọc kiến thức mới nhất

Hình 3. Minh họa sơ đồ các nguồn kiến thức dựa trên phản hồi, kiến thức dựa trên đặc điểm và kiến thức dựa trên mối quan hệ trong mạng giáo viên sâu



được tóm tắt toàn diện trong Phần 5. So sánh hiệu suất của chúng cắt kiến thức được báo cáo trong Phần 6. Nhiều ứng dụng của chúng cắt kiến thức được minh họa trong Phần 7. Các vấn đề thách thức và định hướng tương lai trong chúng cắt kiến thức được thảo luận và kết luận được đưa ra trong Phần 8.



Hình 4. Chất lọc kiến thức dựa trên phản hồi chung

2 Kiến thức

Trong quá trình chúng cắt kiến thức, các loại kiến thức, chiến lược chúng cắt và kiến trúc giáo viên-học sinh đóng vai trò quan trọng trong việc học của học sinh. Trong phần này, chúng tôi tập trung vào các loại kiến thức khác nhau để chúng cắt kiến thức. Một quá trình chúng cắt kiến thức vani sử dụng logit của một mô hình sâu lớn làm kiến thức của giáo viên (Hinton et al. 2015; Kim và cộng sự. 2018; Ba và Caruana 2014; Mirzadeh và cộng sự. 2020). Các hoạt động, nơ-ron hoặc các đặc điểm của các lớp trung gian cũng có thể được sử dụng làm kiến thức để hướng dẫn việc học của mô hình học sinh (Romero và cộng sự, 2015; Huang và Wang , 2017; Ahn và cộng sự, 2019; Heo và cộng sự, 2019c; Zagoruyko và Komodakis , 2017). Các mối quan hệ giữa các hoạt động, nơ-ron hoặc cặp mẫu khác nhau chứa thông tin phong phú mà mô hình giáo viên học được (Yim và cộng sự, 2017; Lee và Song , 2019; Liu và cộng sự, 2019g; Tung và Mori , 2019; Yu và cộng sự, 2019). Hơn nữa, các tham số của mô hình giáo viên (hoặc các kết nối giữa các lớp) cũng chứa một kiến thức khác (Liu et al. 2019c). Chúng tôi thảo luận về các dạng kiến thức khác nhau trong các danh mục sau: kiến thức dựa trên phản hồi, kiến thức dựa trên đặc điểm và kiến thức dựa trên mối quan hệ. Một


Ví dụ trực quan về các loại kiến thức khác nhau trong mô hình giáo viên được thể hiện ở Hình 3.

2.1 Kiến thức dựa trên phản hồi

Kiến thức dựa trên phản hồi thường đề cập đến phản hồi thần kinh của lớp đầu ra cuối cùng của mô hình giáo viên. Ý tưởng chính là mô phỏng trực tiếp dự đoán cuối cùng của mô hình giáo viên. Chúng cắt kiến thức dựa trên phản hồi đơn giản nhưng hiệu quả đối với việc nén mô hình và đã được sử dụng rộng rãi trong các tác vụ và ứng dụng khác nhau. Với một vectơ logit làm đầu ra của lớp kết nối đầy đủ cuối cùng của một mô hình sâu, tồn tại chúng cắt đối với kiến thức dựa trên phản hồi có thể được xây dựng như sau

$$L_{ResD}(z_t, z_s) = LR(z_t, z_s), \tag{1}$$

trong đó $LR(.)$ biểu thị sự mất mát phân kỳ của logit, và z_t và z_s lần lượt là logit của giáo viên và học sinh. Một mô hình KD dựa trên phản hồi điển hình được thể hiện trong Hình 4. Kiến thức dựa trên phản hồi có thể được sử dụng cho các loại khác nhau



Hình 5 Kiến trúc cụ thể của quá trình chứng cứ kiến thức chuẩn mực (Hinton et al. 2015)

của các dự đoán mô hình. Ví dụ, phản ứng trong đối tượng nhiệm vụ phát hiện có thể chứa các logit cùng với độ lệch của một hộp giới hạn (Chen et al. 2017). Trong các nhiệm vụ định vị mốc ngữ nghĩa, ví dụ, ước tính tư thế của con người, phản hồi của mô hình giáo viên có thể bao gồm bản đồ nhiệt cho mỗi mốc (Zhang và cộng sự 2019a). Gần đây, kiến thức dựa trên phản ứng đã được khám phá sâu hơn để giải quyết thông tin của nhân thực tế như các mục tiêu có điều kiện (Meng và cộng sự, 2019).

Kiến thức dựa trên phản hồi phổ biến nhất cho hình ảnh phân loại được gọi là mục tiêu mềm (Hinton et al. 2015; Ba và Caruana 2014). Cụ thể, mục tiêu mềm là xác suất mà đầu vào thuộc về các lớp và có thể được ước tính bằng một hàm softmax như


$$p(z_i, T) = \frac{\text{biểu thức}(z_i / T)}{j \exp(z_j / T)}, \quad (2)$$

trong đó z_i là logit cho lớp thứ i và nhiệt độ yếu tố T được đưa vào để kiểm soát tầm quan trọng của từng phần mềm mục tiêu. Như đã nêu trong Hinton et al. (2015), mục tiêu mềm chứa đựng kiến thức đen tối mang tính thông tin từ mô hình giáo viên. Theo đó, tổn thất chung cất đối với logit mềm có thể được viết lại mười như

$$L_{\text{ResD}}(p(z_t, T), p(z_s, T)) = LR(p(z_t, T), p(z_s, T)). \quad (3)$$

Nhìn chung, $LR(p(z_t, T), p(z_s, T))$ thường sử dụng mất mát phân kỳ Kullback-Leibler. Rõ ràng, tối ưu hóa Phương trình (1) hoặc (3) có thể làm cho logit z_s của học sinh khớp với logit z_t của giáo viên. Để dễ dàng hiểu được quá trình chất lọc kiến thức dựa trên phản hồi, mô hình chuẩn của quá trình chứng cứ kiến thức vani, đó là sự kết hợp của quá trình chứng cứ và tổn thất của sinh viên, là được đưa ra trong Hình 5. Lưu ý rằng tổn thất của sinh viên luôn được xác định như sự mất mát entropy chéo $LC E(y, p(z_s, T = 1))$ giữa nhãn giá trị thực tế và logit mềm của mô hình sinh viên.

Ý tưởng về kiến thức dựa trên phản ứng rất đơn giản và dễ hiểu, đặc biệt là trong bối cảnh “Kiến thức đen tối”. Theo một góc nhìn khác, hiệu quả của các mục tiêu mềm tương tự như việc làm mịn nhãn (Kim và Kim 2017) hoặc các chất điều chỉnh (Muller et al. 2019; Ding



Hình 6 Chất lọc kiến thức dựa trên đặc điểm chung

et al. 2019). Tuy nhiên, kiến thức dựa trên phản hồi thường dựa vào đầu ra của lớp cuối cùng, ví dụ, mục tiêu mềm, và do đó không giải quyết được vấn đề giám sát cấp trung gian từ mô hình giáo viên, điều này hóa ra lại rất quan trọng để học biểu diễn bằng cách sử dụng mạng nơ-ron rất sâu (Romero và cộng sự 2015). Vì logit mềm thực chất là phân phối xác suất lớp, kiến thức dựa trên phản hồi chứng cứ cũng bị giới hạn trong việc học có giám sát.

2.2 Kiến thức dựa trên tính năng

Mạng nơ-ron sâu có khả năng học nhiều cấp độ của biểu diễn tính năng với sự trừu tượng hóa ngày càng tăng. Điều này được gọi là học biểu diễn (Bengio và cộng sự, 2013). Do đó, cả đầu ra của lớp cuối cùng và đầu ra của các lớp trung gian, tức là, bản đồ đặc điểm, có thể được sử dụng làm kiến thức để giám sát việc đào tạo mô hình học sinh. Cụ thể, kiến thức dựa trên đặc điểm từ các lớp trung gian là sự mở rộng tốt của kiến thức dựa trên phản hồi, đặc biệt là để đào tạo các mạng mỏng hơn và sâu hơn.

Các biểu diễn trung gian lần đầu tiên được giới thiệu trong Fitnets (Romero et al. 2015), để cung cấp gợi ý để cải thiện việc đào tạo mô hình sinh viên. Ý tưởng chính là trực tiếp phù hợp với các hoạt động đặc trưng của giáo viên và học sinh vết lõm. Lấy cảm hứng từ điều này, nhiều phương pháp khác nhau đã được đưa ra được đề xuất để khớp các tính năng một cách gián tiếp (Zagoruyko và Komodakis 2017; Kim và cộng sự. 2018; Heo và cộng sự. 2019c; Passban

¹ Một gợi ý có nghĩa là đầu ra của lớp ẩn của giáo viên giám sát việc học của học sinh.

Bảng 1 Tóm tắt kiến thức dựa trên đặc điểm

Phương pháp	Các loại kiến thức	Nguồn kiến thức	Tổn thất chứng cất
Fitnet (Romero và cộng sự, 2015)	Biểu diễn tính năng	Lớp gợi ý	L2(.)
NST (Huang và Wang 2017)	Các mẫu chọn lọc nơ-ron	Lớp gợi ý	LMMD(.)
AT (Zagoruyko và Komodakis 2017)	Bản đồ chú ý	Nhóm nhiều lớp	L2(.)
FT (Kim và cộng sự 2018)	Người diễn giải	Nhóm nhiều lớp	L1(.)
Phóng tên lửa (Zhou et al. 2018)	Chia sẻ thông số	Lớp gợi ý	L2(.)
KR (Liu và cộng sự 2019c)	Phân phối tham số	Nhóm nhiều lớp	LC E (.)
AB (Heo và cộng sự 2019c)	Ranh giới kích hoạt	Trước ReLU	L2(.)
Shen và cộng sự (2019a)	Sự kết hợp kiến thức	Lớp gợi ý	L2(.)
Heo và cộng sự (2019a)	Biên độ ReLU	Trước ReLU	L2(.)
FN (Xu và cộng sự 2020b)	Biểu diễn tính năng	Lớp được kết nối đầy đủ	LC E (.)
DFA (Guan và cộng sự, 2020)	Tổng hợp tính năng	Lớp gợi ý	L2(.)
AdaIN (Yang và cộng sự 2020a)	Thống kê tính năng	Lớp gợi ý	L2(.)
FN (Xu và cộng sự 2020b)	Biểu diễn tính năng	Lớp áp chót	LC E (.)
EC-KD (Wang và cộng sự 2020b)	Biểu diễn tính năng	Lớp gợi ý	L2(.)
ALP-KD (Passban và cộng sự, 2021)	Chiều lớp dựa trên sự chú ý	Lớp gợi ý	L2(.)
SemCKD (Chen và cộng sự, 2021)	Bản đồ đặc điểm	Lớp gợi ý	L2(.)

et al. 2021; Chen et al. 2021; Wang et al. 2020b). Cụ thể hơn, Zagoruyko và Komodakis (2017) đã đưa ra “sự chú ý bản đồ” từ các bản đồ đặc trưng ban đầu để thể hiện kiến thức. Bản đồ chú ý được tổng quát hóa bởi Huang và Wang (2017) sử dụng chuyển giao chọn lọc tế bào thần kinh. Passalis và Tefas (2018) chuyển giao kiến thức bằng cách khớp xác suất phân phối trong không gian tính năng. Để dễ dàng hơn trong việc chuyển giao kiến thức của giáo viên, Kim et al. (2018) đã giới thiệu cái gọi là “các yếu tố” như một hình thức dễ hiểu hơn của các biểu diễn trung gian. Để thu hẹp khoảng cách hiệu suất giữa giáo viên và sinh viên, Jin et al. (2019) đề xuất gợi ý hạn chế tuyến đường học tập, giám sát học sinh bằng đầu ra của các lớp gợi ý của giáo viên. Gần đây, Heo et al. (2019c) đề xuất sử dụng ranh giới kích hoạt của các tế bào thần kinh ẩn cho kiến thức chuyển giao. Điều thú vị là việc chia sẻ tham số của các lớp trung gian của mô hình giáo viên cùng với phản hồi dựa trên kiến thức cũng được sử dụng như kiến thức của giáo viên (Zhou et al. 2018). Để phù hợp với ngữ nghĩa giữa giáo viên và học sinh, Chen et al. (2021) đã đề xuất phương pháp chứng cất kiến thức xuyên lớp, phương pháp này chỉ định thích ứng các lớp giáo viên phù hợp cho từng lớp học sinh thông qua phân bổ sự chú ý.

Nhìn chung, tổn thất chứng cất cho việc chuyển giao kiến thức dựa trên tính năng có thể được xây dựng như sau

$$L_{FeaD} = \text{ft}(x), \text{fs}(x) = \text{LF}(\Phi_t(\text{ft}(x)), \Phi_s(\text{fs}(x)))$$
 , (4)

trong đó $\text{ft}(x)$ và $\text{fs}(x)$ lần lượt là các bản đồ đặc trưng của các lớp trung gian của mô hình giáo viên và học sinh. các hàm biến đổi, $\Phi_t(\text{ft}(x))$ và $\Phi_s(\text{fs}(x))$, thường được áp dụng khi bản đồ đặc điểm của giáo viên và học sinh các mô hình không có cùng hình dạng. $\text{LF}(\cdot)$ biểu thị sự giống nhau

hàm larity được sử dụng để khớp với bản đồ đặc trưng của giáo viên và mô hình sinh viên. Một mô hình KD dựa trên tính năng chung được hiển thị trong Hình 6. Chúng tôi cũng tóm tắt các loại khác nhau của tính năng dựa trên kiến thức trong Bảng 1 theo quan điểm của các loại tính năng, lớp nguồn và tổn thất chứng cất. Cụ thể là $L2(\cdot)$, $L1(\cdot)$, $LC E(\cdot)$ và $LMMD(\cdot)$ biểu thị khoảng cách chuẩn l2, khoảng cách chuẩn l1, mất mát entropy chéo và độ lệch trung bình tối đa mất mát, tương ứng. Mặc dù việc chuyển giao kiến thức dựa trên tính năng cung cấp thông tin thuận lợi cho việc học tập của mô hình sinh viên, cách chọn lớp gợi ý hiệu quả từ mô hình giáo viên và các lớp hướng dẫn từ mô hình học sinh vẫn cần được nghiên cứu thêm (Romero et al. 2015). Do sự khác biệt đáng kể giữa các kích thước của các lớp gợi ý và hướng dẫn, cách khớp đúng các biểu diễn tính năng của giáo viên và học sinh cũng cần được khám phá.

2.3 Kiến thức dựa trên mối quan hệ

Cả kiến thức dựa trên phản hồi và dựa trên tính năng đều sử dụng đầu ra của các lớp cụ thể trong mô hình giáo viên. Kiến thức dựa trên mối quan hệ khám phá sâu hơn các mối quan hệ giữa các lớp hoặc mẫu dữ liệu khác nhau.

Để khám phá mối quan hệ giữa các tính năng khác nhau bản đồ, Yin et al. (2017) đã đề xuất một quy trình giải pháp dòng chảy (FSP), được xác định bởi ma trận Gram giữa hai các lớp. Ma trận FSP tóm tắt các mối quan hệ giữa cặp bản đồ đặc điểm. Nó được tính toán bằng cách sử dụng các sản phẩm bên trong giữa các đặc điểm từ hai lớp. Sử dụng các tương quan giữa các bản đồ đặc điểm như kiến thức được chất lọc, kiến thức chứng cất thông qua phân tích giá trị kỳ dị đã được đề xuất để trích xuất thông tin quan trọng trong bản đồ đặc điểm (Lee et al.

2018). Để sử dụng kiến thức từ nhiều giáo viên, Zhang và Peng (2018) đã hình thành hai biểu đồ bằng cách sử dụng logit và các đặc điểm của từng mô hình giáo viên làm các nút.

Cụ thể, tầm quan trọng và mối quan hệ của các giáo viên khác nhau được mô hình hóa bằng logit và biểu đồ biểu diễn trước khi chuyển giao kiến thức (Zhang và Peng 2018).

Chứng cất kiến thức dựa trên đồ thị nhiều đầu được đề xuất bởi Lee và Song (2019). Kiến thức đồ thị là mối quan hệ dữ liệu nội bộ giữa bất kỳ hai bản đồ đặc điểm nào thông qua mạng chú ý nhiều đầu. Để khám phá thông tin gợi ý từng cặp, mô hình học sinh cũng mô phỏng luồng thông tin tương hỗ

từ các cặp lớp gợi ý của mô hình giáo viên (Passalis et al. 2020b). Nhìn chung, tồn thất chứng cất của kiến thức dựa trên mối quan hệ dựa trên các mối quan hệ của bản đồ đặc điểm có thể được xây dựng như


$$L \text{ Rel } D(\text{ft}, \text{fs}) = \text{LR1 } \Psi \text{t}^{\wedge} \text{ft}, \sim \text{ft}, \Psi \text{s}^{\wedge} \text{fs}, \sim \text{fs} \quad , \quad (5)$$

trong đó ft và fs lần lượt là các bản đồ đặc trưng của mô hình giáo viên và học sinh. Các cặp bản đồ đặc trưng được chọn từ mô hình giáo viên, $\hat{\text{ft}}$ và $\sim \text{ft}$, và từ mô hình học sinh, $\hat{\text{fs}}$ và $\sim \text{fs}$. $\Psi \text{t}(\cdot)$ và $\Psi \text{s}(\cdot)$ là các hàm tương tự cho các cặp bản đồ đặc trưng từ mô hình giáo viên và học sinh. LR1 (.) biểu thị hàm tương quan giữa các bản đồ đặc trưng của giáo viên và học sinh.

Các phương pháp truyền đạt kiến thức truyền thống thường liên quan đến việc chứng cất kiến thức cá nhân. Các mục tiêu mềm cá nhân của giáo viên được chứng cất trực tiếp vào học sinh. Trên thực tế, kiến thức được chứng cất không chỉ chứa thông tin đặc trưng mà còn chứa các mối quan hệ tương hỗ của các mẫu dữ liệu (You et al. 2017; Park và cộng sự 2019). Cụ thể, Liu và cộng sự (2019g) đã đề xuất một phương pháp chứng cất kiến thức mạnh mẽ và hiệu quả thông qua biểu đồ quan hệ thể hiện. Kiến thức được chuyển giao trong biểu đồ quan hệ thể hiện chứa các đặc điểm thể hiện, các mối quan hệ thể hiện và các lớp chéo chuyển đổi không gian đặc điểm. Park và cộng sự (2019) đã đề xuất một phương pháp chứng cất kiến thức quan hệ, phương pháp này chuyển giao kiến thức từ các mối quan hệ thể hiện. Dựa trên ý tưởng về học tập đa dạng, mạng lưới học sinh được học bằng cách nhúng đặc điểm, phương pháp này bảo toàn các điểm tương đồng đặc điểm của các mẫu trong các lớp trung gian của mạng lưới giáo viên (Chen và cộng sự 2021).

Mối quan hệ giữa các mẫu dữ liệu được mô hình hóa như phân phối xác suất-khả năng sử dụng các biểu diễn đặc điểm của dữ liệu (Passalis và Tefas 2018; Passalis và cộng sự 2020a). Phân phối xác suất-khả năng của giáo viên và học sinh được khớp

bằng cách chuyển giao kiến thức. (Tung và Mori 2019) đã đề xuất một phương pháp chứng cất kiến thức bảo toàn tính tương đồng. Cụ thể, kiến thức bảo toàn tính tương đồng, phát sinh từ các kích hoạt tương tự của các cặp đầu vào trong mạng lưới giáo viên, được chuyển vào mạng lưới học sinh, với các tính tương đồng từng cặp được bảo toàn. Peng và cộng sự (2019a) đã đề xuất một phương pháp chứng cất kiến thức dựa trên sự phù hợp tương quan, trong



Hình 7 Chất lọc kiến thức dựa trên mối quan hệ thể hiện chung

trong đó kiến thức được chất lọc bao gồm cả thông tin cấp độ trường hợp và mối tương quan giữa các trường hợp. Sử dụng sự phù hợp tương quan để chứng cất, mạng lưới sinh viên có thể tìm hiểu mối tương quan giữa các trường hợp.

Như đã mô tả ở trên, tồn thất chứng cất của kiến thức dựa trên quan hệ dựa trên các quan hệ thể hiện có thể được xây dựng

$$L \text{ Rel } D(\text{Ft}, \text{Fs}) = \text{LR2 } \Psi \text{t}(\text{ti}, \text{tj}), \Psi \text{s}(\text{si}, \text{sj}) \quad , \quad (6)$$

trong đó (ti, tj) Ft và (si,sj) Fs, và Ft và Fs là các tập biểu diễn đặc điểm từ mô hình giáo viên và học sinh, tương ứng. $\Psi \text{t}(\cdot)$ và $\Psi \text{s}(\cdot)$ là các hàm tương tự của (ti, tj) và (si,sj). LR2 (.) là hàm tương quan giữa các biểu diễn đặc điểm của giáo viên và học sinh. Một mô hình KD dựa trên quan hệ thể hiện điển hình được thể hiện trong Hình 7.


Kiến thức chất lọc có thể được phân loại theo nhiều góc độ khác nhau, chẳng hạn như kiến thức có cấu trúc về dữ liệu (Liu và cộng sự, 2019g; Chen và cộng sự, 2021; Peng và cộng sự, 2019a; Tung và Mori , 2019; Tian và cộng sự, 2020), thông tin đặc quyền về các tính năng đầu vào (Lopez-Paz và cộng sự, 2016; Vapnik và Izmailov , 2015). Tóm tắt các loại kiến thức dựa trên quan hệ khác nhau được thể hiện trong Bảng 2. Cụ thể, LE M (.), LH (.), LAW (.) và .F lần lượt là khoảng cách Earth Mover, mất mát Huber, mất mát theo góc và chuẩn Frobenius. Mặc dù một số loại kiến thức dựa trên quan hệ đã được cung cấp gần đây, cách mô hình hóa thông tin quan hệ từ bản đồ tính năng hoặc mẫu dữ liệu dưới dạng kiến thức vẫn cần được nghiên cứu thêm.

3 Sơ đồ chứng cất

Trong phần này, chúng tôi thảo luận về các lược đồ chứng cất (tức là các lược đồ đào tạo) cho cả mô hình giáo viên và học sinh. Tùy thuộc vào việc mô hình giáo viên có được cập nhật đồng thời với mô hình học sinh hay không, các lược đồ học tập chứng cất kiến thức có thể được chia trực tiếp thành ba loại chính: chứng cất ngoại tuyến, chứng cất trực tuyến và tự chứng cất, như thể hiện trong Hình 8.

Bảng 2 Tóm tắt kiến thức dựa trên mối quan hệ

Phương pháp	Các loại kiến thức	Nguồn kiến thức	Tổn thất chứng cất
FSP (Yim và cộng sự, 2017)	Ma trận FSP	Kết thúc nhóm nhiều lớp	L2(.)
Bạn và cộng sự (2017)	Quan hệ thể hiện	Các lớp gợi ý	L2(.)
Trương và Bành (2018)	Đồ thị Logits, Đồ thị biểu diễn	Lớp Softmax, lớp Hint	LÊ M (.), LMMD(.)
DarkRank (Chen và cộng sự 2018c)	Tương tự DarkRank	Các lớp được kết nối đầy đủ	LK L (.)
MHGD (Lee và Song 2019)	Đồ thị nhiều đầu	Các lớp gợi ý	LK L (.)
RKD (Park và cộng sự, 2019)	Quan hệ thể hiện	Các lớp được kết nối đầy đủ	LH (.), LUẬT (.)
IRG (Liu và cộng sự 2019g)	Biểu đồ quan hệ thể hiện	Các lớp gợi ý	L2(.)
SP (Tung và Mori 2019)	Ma trận tương đồng	Các lớp gợi ý	.F
CCKD (Peng và cộng sự, 2019a)	Quan hệ thể hiện	Các lớp gợi ý	L2(.)
MLKD (Yu và cộng sự, 2019)	Quan hệ thể hiện	Các lớp gợi ý	.F
PKT(Passalis và cộng sự 2020a)	Phân phối xác suất tương tự	Các lớp được kết nối đầy đủ	LK L (.)
Passalis và cộng sự (2020b)	Luồng thông tin lẫn nhau	Các lớp gợi ý	LK L (.)
LP (Chen và cộng sự, 2021)	Quan hệ thể hiện	Các lớp gợi ý	L2(.)



Hình 8 Các loại chứng cất khác nhau. Màu đỏ cho “đã được đào tạo trước” có nghĩa là mạng lưới được học trước khi chứng cất và màu vàng cho “là “được đào tạo” có nghĩa là các mạng được học trong quá trình chứng cất

3.1 Chứng cất ngoại tuyến

Hầu hết các phương pháp chứng cất kiến thức trước đây đều có hiệu quả ngoại tuyến. Trong chứng cất kiến thức vani (Hinton et al. 2015), kiến thức được chuyển giao từ một mô hình giáo viên được đào tạo trước thành một mô hình sinh viên. Do đó, toàn bộ quá trình đào tạo có hai giai đoạn, cụ thể là: 1) mô hình giáo viên lớn là đầu tiên được đào tạo trên một tập hợp các mẫu đào tạo trước khi chứng cất; và 2) mô hình giáo viên được sử dụng để trích xuất kiến thức trong các dạng logit hoặc các tính năng trung gian, sau đó là được sử dụng để hướng dẫn việc đào tạo mô hình sinh viên trong quá trình chứng cất.

Giai đoạn đầu tiên trong quá trình chứng cất ngoại tuyến thường không được thảo luận như một phần của quá trình chứng cất kiến thức, tức là, nó được cho là

rằng mô hình giáo viên được xác định trước. Ít chú ý được trả đến cấu trúc mô hình giáo viên và mối quan hệ của nó với mô hình học sinh. Do đó, các phương pháp ngoại tuyến chủ yếu tập trung vào cải thiện các phần khác nhau của việc chuyển giao kiến thức, bao gồm cả việc thiết kế kiến thức (Hinton et al. 2015; Romero et al. 2015) và các hàm mất mát để khớp các tính năng hoặc phân phối phù hợp (Huang và Wang 2017; Passalis và Tefas 2018; Zagoruyko và Komodakis 2017; Mirzadeh và cộng sự. 2020; Li và cộng sự. 2020d; Heo và cộng sự. 2019b; Asif và cộng sự. 2020). các Ưu điểm chính của phương pháp ngoại tuyến là chúng đơn giản và dễ dàng để thực hiện. Ví dụ, mô hình giáo viên có thể chứa một tập hợp các mô hình được đào tạo bằng các gói phần mềm khác nhau, có thể nằm trên các máy khác nhau. Kiến thức có thể trích xuất và lưu trữ trong bộ nhớ đệm.

Các phương pháp chứng cất ngoại tuyến thường sử dụng một chiều chuyển giao kiến thức và quy trình đào tạo hai giai đoạn. Tuy nhiên, mô hình giáo viên năng lực cao phức tạp với thời gian đào tạo không thể tránh khỏi, trong khi việc đào tạo mô hình sinh viên trong chứng cất ngoại tuyến thường hiệu quả trong sự hướng dẫn của mô hình giáo viên. Hơn nữa, năng lực Khoảng cách giữa giáo viên lớn và học sinh nhỏ luôn tồn tại, và học sinh thường phụ thuộc rất nhiều vào giáo viên.

3.2 Chứng cất trực tuyến

Mặc dù các phương pháp chứng cất ngoại tuyến đơn giản và hiệu quả, một số vấn đề trong chứng cất ngoại tuyến đã thu hút sự chú ý ngày càng tăng từ cộng đồng nghiên cứu (Mirzadeh et al. 2020). Để khắc phục hạn chế của chứng cất ngoại tuyến, chứng cất trực tuyến được đề xuất để cải thiện hơn nữa hiệu suất của mô hình sinh viên, đặc biệt là khi có công suất lớn mô hình giáo viên hiệu suất cao không khả dụng (Zhang et al. 2018b; Chen et al. 2020a). Trong chứng cất trực tuyến, cả mô hình giáo viên và mô hình học sinh được cập nhật đồng thời

và toàn bộ khuôn khổ chất lọc kiến thức đều có thể đào tạo được từ đầu đến cuối.

Nhiều phương pháp chất lọc kiến thức trực tuyến đã được đề xuất, đặc biệt là trong vài năm gần đây (Zhang et al. 2018b; Chen et al. 2020a; Xie et al. 2019; Anil et al. 2018; Kim et al. 2019b; Zhou et al. 2018; Walawalkar et al. 2020; Wu và Gong 2021; Zhang et al. 2021a). Cụ thể, trong học tập lẫn nhau sâu (Zhang et al. 2018b), nhiều mạng nơ-ron hoạt động theo cách cộng tác. Bất kỳ mạng nào cũng có thể là mô hình học viên và các mô hình khác có thể là giáo viên trong quá trình đào tạo. Để cải thiện khả năng khái quát hóa, học tập lẫn nhau sâu được mở rộng bằng cách sử dụng tập hợp các logit mềm (Guo et al. 2020). Chen et al. (2020a) đã giới thiệu thêm các đồng đẳng phụ trợ và một trường nhóm vào học tập lẫn nhau sâu để hình thành một tập hợp đa dạng các mô hình đồng đẳng. Để giảm chi phí tính toán, Zhu và Gong (2018) đã đề xuất một kiến trúc đa nhánh, trong đó mỗi nhánh chỉ ra một sinh viên

mô hình và các nhánh khác nhau chia sẻ cùng một mạng xương sống làm việc. Thay vì sử dụng tập hợp các logit, Kim et al. (2019b) đã giới thiệu một mô-đun hợp nhất tính năng để xây dựng bộ phân loại giáo viên. Xie et al. (2019) đã thay thế lớp tích chập bằng các phép toán tích chập giá rẻ để tạo thành mô hình học sinh. Anil et al. (2018) đã sử dụng chứng cất trực tuyến để đào tạo mạng nơ-ron phân tán quy mô lớn và đề xuất một biến thể của chứng cất trực tuyến được gọi là chứng cất đồng thời. Chứng cất đồng thời song song đào tạo nhiều mô hình có cùng kiến trúc và bất kỳ mô hình nào cũng được đào tạo bằng cách chuyển kiến thức từ các mô hình khác. Gần đây, một phương pháp chứng cất kiến thức đối nghịch trực tuyến được đề xuất để đào tạo đồng thời nhiều mạng bằng các bộ phân biệt bằng cách sử dụng kiến thức từ cả xác suất lớp và bản đồ tính năng (Chung et al. 2020). Chứng cất đồng thời đối nghịch gần đây được thiết kế bằng cách sử dụng GAN để tạo ra các ví dụ khác nhau (Zhang et al. 2021a).

Chứng cất trực tuyến là một chương trình đào tạo một giai đoạn đầu cuối với tính toán song song hiệu quả. Tuy nhiên, các phương pháp trực tuyến hiện có (ví dụ, học tập lẫn nhau) thường không giải quyết được vấn đề giáo viên có năng lực cao trong các thiết lập trực tuyến, khiến nó trở thành một chủ đề thú vị để khám phá sâu hơn mối quan hệ giữa mô hình giáo viên và học sinh trong các thiết lập trực tuyến.

3.3 Tự chứng cất

Trong quá trình tự chứng cất, các mạng giống nhau được sử dụng cho các mô hình giáo viên và học sinh (Zhang và cộng sự 2019b; Hou và cộng sự 2019; Zhang và Sabuncu 2020; Yang và cộng sự 2019b; Lee và cộng sự 2019a; Phuong và Lampert 2019b; Lan và cộng sự 2018; Xu và Liu 2019; Mobahi và cộng sự 2020). Điều này có thể được coi là một trường hợp đặc biệt của quá trình chứng cất trực tuyến. Cụ thể, Zhang và cộng sự (2019b) đã đề xuất một phương pháp tự chứng cất mới, trong đó kiến thức từ các phần sâu hơn của mạng được chứng cất thành các phần nông của nó. Tương tự như quá trình tự chứng cất trong Zhang và cộng sự (2019b), một phương pháp chứng cất tự chủ ý đã được đề xuất

để phát hiện làn đường (Hou et al. 2019). Mạng sử dụng bản đồ chú ý của các lớp riêng của nó làm mục tiêu chứng cất cho các lớp thấp hơn. Chứng cất ảnh chụp nhanh (Yang et al. 2019b) là một biến thể đặc biệt của tự chứng cất, trong đó kiến thức trong các kỳ nguyên trước đó của mạng (giáo viên) được chuyển vào các kỳ nguyên sau đó (học sinh) để hỗ trợ quá trình đào tạo có giám sát trong cùng một mạng. Để giảm thêm thời gian suy luận thông qua thoát sớm, Phuong và Lampert (2019b) đã đề xuất sơ đồ đào tạo dựa trên chứng cất, trong đó lớp thoát sớm cố gắng mô phỏng đầu ra của lớp thoát sau trong quá trình đào tạo. Gần đây, tự chứng cất đã được phân tích về mặt lý thuyết trong Mobahi et al. (2020) và hiệu suất được cải thiện của nó đã được chứng minh bằng thực nghiệm trong Zhang và Sabuncu (2020).


Hơn nữa, một số phương pháp tự chứng cất thú vị gần đây đã được đề xuất (Yuan et al. 2020; Yun et al. 2020; Hahn và Choi 2019). Cụ thể hơn, Yuan et al. đã đề xuất các phương pháp chứng cất kiến thức không cần giáo viên dựa trên phân tích về quy tắc làm mịn nhân (Yuan et al. 2020).

Hahn và Choi đã đề xuất một phương pháp chứng cất kiến thức bản thân mới, trong đó kiến thức bản thân bao gồm các xác suất dự đoán thay vì các xác suất mềm truyền thống (Hahn và Choi 2019). Các xác suất dự đoán này được xác định bởi các biểu diễn đặc trưng của mô hình đào tạo.

Chúng phản ánh những điểm tương đồng của dữ liệu trong không gian nhúng tính năng. Yun et al. đề xuất chứng cất kiến thức tự thân theo từng lớp để khớp với phân phối đầu ra của mô hình đào tạo giữa các mẫu trong lớp và các mẫu tăng cường trong cùng một nguồn với cùng một mô hình (Yun et al. 2020). Ngoài ra, tự chứng cất do Lee et al. (2019a) đề xuất được áp dụng để tăng cường dữ liệu và tự kiến thức của quá trình tăng cường được chứng cất vào chính mô hình. Tự chứng cất cũng được áp dụng để tối ưu hóa các mô hình sâu (mạng giáo viên hoặc học sinh) với cùng một kiến trúc từng cái một (Furlanello et al. 2018; Bagherinezhad et al. 2018). Mỗi mạng sẽ chứng cất kiến thức của mạng trước đó bằng cách sử dụng tối ưu hóa giáo viên-học sinh.

Ngoài ra, offline, online và self-distilling cũng có thể được hiểu một cách trực quan từ góc nhìn của con người trong quá trình học tập giữa thầy và trò. Offline distilling có nghĩa là giáo viên hiểu biết dạy kiến thức cho học sinh; online distilling có nghĩa là cả giáo viên và học sinh cùng học với nhau; self-distilling có nghĩa là học sinh tự học kiến thức. Hơn nữa, giống như con người học tập, ba loại hình chứng cất này có thể kết hợp để bổ sung cho nhau do những ưu điểm riêng của chúng.

Ví dụ, cả chứng cất tự động và chứng cất trực tuyến đều được tích hợp đúng cách thông qua khuôn khổ chuyển giao kiến thức đa dạng (Sun et al. 2021).



Hình 9 Mối quan hệ giữa mô hình giáo viên và học sinh

4 Kiến trúc giáo viên-học sinh

Trong quá trình chất lọc kiến thức, kiến trúc giáo viên-học sinh là một phương tiện chung để hình thành quá trình chuyển giao kiến thức. Nói cách khác, chất lượng thu thập và chất lọc kiến thức từ giáo viên sang học sinh cũng được xác định bởi cách thiết kế mạng lưới giáo viên và học sinh. Về thói quen con người học tập, chúng tôi hy vọng rằng một học sinh có thể tìm thấy một giáo viên phù hợp. Vì vậy, để hoàn thành tốt việc nắm bắt và chất lọc kiến thức trong quá trình chất lọc kiến thức, làm thế nào để lựa chọn hoặc thiết kế các cấu trúc phù hợp của giáo viên và học sinh là một vấn đề rất quan trọng nhưng khó khăn. Gần đây, các thiết lập mô hình của giáo viên và học sinh hầu như được cố định trước với các kích thước và cấu trúc không thay đổi trong quá trình chất lọc, do đó dễ gây ra khoảng cách năng lực mô hình. Tuy nhiên, làm thế nào để thiết kế cụ thể các kiến trúc của giáo viên và học sinh và lý do tại sao các kiến trúc của chúng được xác định bởi các thiết lập mô hình này gần như bị thiếu. Trong phần này, chúng tôi thảo luận về mối quan hệ giữa các cấu trúc của mô hình giáo viên và mô hình học sinh như minh họa trong


Hình 9.

Quá trình chứng cất kiến thức trước đây được thiết kế để nén một tập hợp các mạng lưới nơ-ron sâu trong Hinton et al. (2015). Sự phức tạp của mạng nơ-ron sâu chủ yếu xuất phát từ hai chiều: chiều sâu và chiều rộng. Thông thường, cần phải chuyển kiến thức từ mạng nơ-ron sâu hơn và rộng hơn sang mạng nơ-ron nông hơn và mỏng hơn (Romero và cộng sự, 2015). Mạng học sinh thường được chọn là: (1) phiên bản đơn giản hóa của mạng giáo viên với ít lớp hơn và ít kênh hơn trong mỗi lớp (Wang và cộng sự, 2018a; Zhu và Gong, 2018; Li và cộng sự, 2020d); hoặc (2) phiên bản lượng tử hóa của mạng giáo viên trong đó cấu trúc của mạng được bảo toàn trước (Polino và cộng sự, 2018; Mishra và Marr, 2018; Wei và cộng sự, 2018; Shin et al. 2019); hoặc (3) một mạng nhỏ với các hoạt động cơ bản hiệu quả (Howard et al. 2017; Zhang et al. 2018a; Huang et al. 2017); hoặc (4) một mạng nhỏ với cấu trúc mạng toàn cầu được tối ưu hóa (Liu et al. 2019i; Xie et al. 2020; Gu và Tresp 2020); hoặc (5) cùng một mạng với giáo viên (Zhang et al. 2018b; Furlanello et al. 2018; Tarvainen và Valpola 2017).

Khoảng cách năng lực mô hình giữa mạng nơ-ron sâu lớn và mạng nơ-ron học sinh nhỏ có thể làm giảm khả năng truyền tải kiến thức (Mirzadeh và cộng sự, 2020; Gao và cộng sự, 2021). Để chuyển giao kiến thức hiệu quả cho các mạng lưới sinh viên, nhiều phương pháp khác nhau đã được đề xuất để giảm độ phức tạp của mô hình một cách có kiểm soát (Zhang et al. 2018b; Nowak và Corso 2018; Crowley et al. 2018; Liu et al. 2019a,i; Wang et al. 2018a; Gu và Tresp 2020). Cụ thể, Mirzadeh et al. (2020) đã giới thiệu một trợ lý giáo viên để thu hẹp khoảng cách đào tạo giữa mô hình giáo viên và mô hình sinh viên. Khoảng cách này được thu hẹp hơn nữa nhờ học tập còn lại, tức là cấu trúc trợ lý được sử dụng để học lỗi còn lại (Gao et al. 2021). Mặt khác, một số phương pháp gần đây cũng tập trung vào việc giảm thiểu sự khác biệt về cấu trúc của mô hình học sinh và mô hình giáo viên. Ví dụ, Polino và cộng sự (2018) đã kết hợp lượng tử hóa mạng với chứng cất kiến thức, tức là mô hình học sinh là phiên bản nhỏ và lượng tử hóa của mô hình giáo viên. Nowak và Corso (2018) đã đề xuất một phương pháp nén cấu trúc liên quan đến việc chuyển kiến thức học được từ nhiều lớp sang một lớp duy nhất. Wang và cộng sự (2018a) đã thực hiện dần dần việc chuyển giao kiến thức theo từng khối từ mạng giáo viên sang mạng học sinh trong khi vẫn bảo toàn trường tiếp nhận. Trong bối cảnh trực tuyến, mạng giáo viên thường là tập hợp các mạng học sinh, trong đó các mô hình học sinh chia sẻ cấu trúc tương tự (hoặc cùng một cấu trúc) với nhau (Zhang và cộng sự 2018b; Zhu và Gong 2018; Furlanello và cộng sự 2018; Chen và cộng sự 2020a).

Gần đây, tích chập tách theo chiều sâu đã được sử dụng rộng rãi để thiết kế mạng nơ-ron hiệu quả cho các thiết bị di động hoặc nhúng (Chollet 2017; Howard và cộng sự 2017; Sandler và cộng sự 2018; Zhang và cộng sự 2018a; Ma và cộng sự 2018). Lấy cảm hứng từ thành công của tìm kiếm kiến trúc nơ-ron (hay NAS), hiệu suất của các mạng nơ-ron nhỏ đã được cải thiện hơn nữa bằng cách tìm kiếm cấu trúc toàn cục dựa trên các siêu hoạt động hoặc khối hiệu quả (Wu và cộng sự 2019; Tan và cộng sự 2019; Tan và Le 2019; Radosavovic và cộng sự 2020). Hơn nữa, ý tưởng tìm kiếm động cho một chế độ chuyển giao kiến thức cũng xuất hiện trong quá trình chứng cất kiến thức, ví dụ, tự động loại bỏ các lớp dư thừa theo cách dựa trên dữ liệu bằng cách sử dụng học tăng cường (Ashok và cộng sự 2018) và tìm kiếm các mạng lưới học sinh tối ưu cho các mạng lưới giáo viên (Liu và cộng sự 2019i; Xie và cộng sự 2020; Gu và Tresp 2020).

Hầu hết các công trình trước đây tập trung vào việc thiết kế cấu trúc của mô hình giáo viên và học sinh hoặc sơ đồ chuyển giao kiến thức giữa chúng. Để tạo ra một mô hình học sinh nhỏ phù hợp với mô hình giáo viên lớn nhằm cải thiện hiệu suất chất lọc kiến thức, cần có kiến trúc học tập thích ứng giữa giáo viên và học sinh. Gần đây, ý tưởng về tìm kiếm kiến trúc thần kinh trong chất lọc kiến thức, tức là tìm kiếm chung cấu trúc học sinh và chuyển giao kiến thức dưới sự hướng dẫn của mô hình giáo viên, sẽ là một chủ đề thú vị để nghiên cứu trong tương lai.



Hình 10 Các loại khác nhau của các phương pháp chứng cất đối nghịch chính. a Generator trong GAN tạo ra dữ liệu đào tạo để cải thiện hiệu suất KD; giáo viên có thể được sử dụng như một bộ phân biệt. b Discriminator trong GAN đảm bảo rằng học sinh (cũng như là bộ tạo) bắt chước giáo viên. c Giáo viên và học sinh tạo thành một bộ tạo; chứng cất kiến thức trực tuyến được tăng cường bởi bộ phân biệt

5 Thuật toán chứng cất

Một ý tưởng đơn giản nhưng rất hiệu quả để chuyển giao kiến thức là trực tiếp khớp kiến thức dựa trên phân hồi, kiến thức dựa trên đặc điểm (Romero và cộng sự, 2015; Hinton và cộng sự, 2015) hoặc phân phối biểu diễn-phản đối trong không gian đặc điểm (Passalis và Tefas , 2018) giữa mô hình giáo viên và mô hình học sinh.

Nhiều thuật toán khác nhau đã được đề xuất để cải thiện quá trình chuyển giao kiến thức trong các thiết lập phức tạp hơn. Trong phần này, chúng tôi xem xét các loại phương pháp chứng cất điển hình được đề xuất gần đây để chuyển giao kiến thức trong lĩnh vực chứng cất kiến thức.

5.1 Chứng cất đối nghịch

Trong quá trình chất lọc kiến thức, mô hình giáo viên khó có thể học hoàn hảo từ phân phối dữ liệu thực. Đồng thời, mô hình học sinh chỉ có năng lực nhỏ và do đó không thể bắt chước chính xác mô hình giáo viên (Mirzadeh et al.

2020). Có cách nào khác để đào tạo mô hình học sinh nhằm bắt chước mô hình giáo viên không? Gần đây, học đối nghịch đã nhận được rất nhiều sự chú ý do thành công to lớn của nó trong các mạng sinh sản, tức là mạng đối nghịch sinh sản hoặc GAN (Goodfellow và cộng sự 2014). Cụ thể, bộ phân biệt trong GAN ước tính xác suất mẫu đến từ phân phối dữ liệu đào tạo trong khi bộ tạo cố gắng đánh lừa bộ phân biệt bằng cách sử dụng các mẫu dữ liệu đã tạo. Lấy cảm hứng từ điều này, nhiều phương pháp chất lọc kiến thức đối nghịch đã được đề xuất để cho phép mạng lưới giáo viên và học sinh hiểu rõ hơn về phân phối dữ liệu thực sự (Wang et al. 2018e; Xu et al. 2018a; Micaelli và Storkey 2019; Xu et al. 2018b; Liu et al. 2018; Wang et al. 2018f; Chen et al. 2019a; Shen et al. 2019d; Shu et al. 2019; Liu et al. 2020a; Belagiannis et al. 2018).

Như thể hiện trong Hình 10, các phương pháp chứng cất dựa trên học đối nghịch, đặc biệt là các phương pháp sử dụng GAN, có thể được chia thành ba loại chính như sau. Trong loại đầu tiên, một trình tạo đối nghịch được đào tạo để tạo ra dữ liệu tổng hợp, được sử dụng trực tiếp làm tập dữ liệu đào tạo (Chen và cộng sự, 2019a; Ye và cộng sự, 2020) hoặc được sử dụng để bổ sung cho tập dữ liệu đào tạo (Liu và cộng sự, 2018), được thể hiện trong Hình 10a. Hơn nữa, Micaelli và Storkey (2019) đã sử dụng một trình tạo đối nghịch để tạo ra các ví dụ khó để chuyển giao kiến thức.

Nhìn chung, tổn thất chứng cất được sử dụng trong danh mục KD dựa trên GAN này có thể được xây dựng như sau

LK D = LG Ft(G(z)), Fs(G(z)) , (7)

trong đó Ft(.) và Fs(.) lần lượt là đầu ra của mô hình giáo viên và học sinh. G(z) biểu thị các mẫu đào tạo do máy phát G tạo ra dựa trên vectơ đầu vào ngẫu nhiên z, và LG là tổn thất chứng cất để buộc phải khớp giữa phân phối xác suất dự đoán và phân phối xác suất thực tế, ví dụ, tổn thất entropy chéo hoặc tổn thất phân kỳ Kullback-Leibler (KL).

Để giúp học sinh phù hợp với giáo viên, một bộ phân biệt trong danh mục thứ hai được đưa vào để phân biệt các mẫu từ mô hình học sinh và giáo viên bằng cách sử dụng logit (Xu et al. 2018a, b) hoặc các tính năng (Wang et al. 2018f), được hiển thị trong Hình 10b. Cụ thể, Belagiannis et al. (2018) đã sử dụng các mẫu dữ liệu không có nhãn để hình thành quá trình chuyển giao kiến thức. Shen và cộng sự (2019d) đã sử dụng nhiều bộ phân biệt. Hơn nữa, một sự giám sát trung gian hiệu quả, tức là kiến thức bị bóp méo, đã được Shu và cộng sự (2019) sử dụng để thu hẹp khoảng cách năng lực giữa giáo viên và học sinh. Một mô hình đại diện do Wang và cộng sự (2018f) đề xuất nằm trong phạm trù này, có thể được xây dựng như sau


LGANK D = LC E G(Fs(x)), y + αLK L G(Fs(x)), Ft(x) + βLGAN Fs(x), Ft(x) , (8)

trong đó G là mạng học sinh và LGAN (.) biểu thị hàm mất mát điển hình được sử dụng trong mạng đối nghịch tạo sinh để làm cho đầu ra giữa học sinh và giáo viên giống nhau nhất có thể.

Trong thể loại thứ ba, quá trình chứng cất kiến thức đối nghịch được thực hiện theo cách trực tuyến, tức là giáo viên và học sinh được tối ưu hóa chung trong mỗi lần lặp (Wang et al. 2018e; Chung et al. 2020), được thể hiện trong Hình 10c. Bên cạnh đó, bằng cách sử dụng quá trình chứng cất kiến thức để nén GAN, một mạng học sinh GAN nhỏ đã học sẽ mô phỏng một mạng giáo viên GAN lớn hơn thông qua việc chuyển giao kiến thức (Aguinaldo et al. 2019; Li et al. 2020c).

Tóm lại, có thể kết luận ba điểm chính từ các phương pháp chứng cất đối nghịch ở trên như sau: GAN là

một công cụ hiệu quả để nâng cao sức mạnh học tập của học sinh thông qua việc truyền đạt kiến thức của giáo viên; GAN và KD kết hợp có thể tạo ra dữ liệu có giá trị để cải thiện hiệu suất KD



Hình 11 Khung chung cho quá trình chứng cất đa giáo viên

và khắc phục những hạn chế không sử dụng được và không thể truy cập dữ liệu; KD có thể được sử dụng để nén GAN.

5.2 Chứng cất đa giáo viên

Các kiến trúc giáo viên khác nhau có thể cung cấp những lợi ích riêng của họ kiến thức cho mạng lưới sinh viên. Nhiều mạng lưới giáo viên có thể được sử dụng riêng lẻ và toàn diện để chứng cất trong thời gian đào tạo mạng lưới sinh viên. Trong một điển hình khuôn khổ giáo viên-học sinh, giáo viên thường có một mô hình hoặc một tập hợp các mô hình lớn. Để chuyển giao kiến thức từ nhiều giáo viên, cách đơn giản nhất là sử dụng phản hồi trung bình từ tất cả giáo viên như tín hiệu giám sát (Hinton et al. 2015). Một số kiến thức đa giáo viên phương pháp chứng cất gần đây đã được đề xuất (Sau và Balasubramanian 2016; You và cộng sự 2017; Chen và cộng sự 2019b; Furlanello và cộng sự. 2018; Yang và cộng sự. 2019a; Zhang và cộng sự. 2018b; Lee và cộng sự 2019c; Park và Kwak 2020; Papernot và cộng sự 2017; Fukuda và cộng sự. 2017; Ruder và cộng sự. 2017; Wu và cộng sự. 2019a; dương và cộng sự. 2020c; Vongkulbhisal và cộng sự. 2019; Zhao và cộng sự. 2020a; Yuan et al. 2021). Một khuôn khổ chung cho nhiều giáo viên chứng cất được thể hiện ở Hình 11.


Nhiều mạng lưới giáo viên đã tỏ ra hiệu quả để đào tạo mô hình sinh viên thường sử dụng logits và tính năng biểu diễn như kiến thức. Ngoài ra, trung bình logits từ tất cả giáo viên, You et al. (2017) đã kết hợp thêm các tính năng từ các lớp trung gian để khuyến khích sự khác biệt giữa các mẫu đào tạo khác nhau. Để sử dụng cả logits và các tính năng trung gian, Chen et al. (2019b) sử dụng hai mạng lưới giáo viên, trong đó một giáo viên truyền đạt kiến thức dựa trên phản hồi cho học sinh và giáo viên kia giáo viên truyền đạt kiến thức dựa trên đặc điểm cho học sinh. Fukuda et al. (2017) đã chọn ngẫu nhiên một giáo viên từ nhóm mạng lưới giáo viên tại mỗi lần lặp lại. Để chuyển giao kiến thức dựa trên tính năng từ nhiều giáo viên, giáo viên bổ sung các nhánh được thêm vào mạng lưới sinh viên để mô phỏng các tính năng trung gian của giáo viên (Park và Kwak 2020; Asif et al. 2020). Mạng lưới Born again hướng đến nhiều giáo viên trong một theo từng bước, tức là, học sinh ở bước t được sử dụng như giáo viên của học sinh tại bước t + 1 (Furlanello et al. 2018),

Bảng 3 Tóm tắt về chứng cất đa giáo viên sử dụng các loại khác nhau của các chương trình kiến thức và chứng cất. Kiến thức dựa trên phản ứng, kiến thức dựa trên đặc điểm và kiến thức dựa trên mối quan hệ được viết tắt tương ứng là 'ResK', 'FeaK' và 'RelK'

Phương pháp	ResK	FeaK	Liên quan
Chứng cất ngoại tuyến			
Bạn và cộng sự (2017)			
Fukuda và cộng sự (2017)			
Shen và cộng sự (2019b)			
Wu và cộng sự (2019a)			
Park và Kwak (2020)			
Yang và cộng sự (2020c)			
Luo và cộng sự (2020)			
Kwon và cộng sự (2020)			
Liu và cộng sự (2020c)			
Zhao và cộng sự (2020a)			
Yuan và cộng sự (2021)			
Chứng cất trực tuyến			
Papernot và cộng sự (2017)			
Furlanello và cộng sự (2018)			
Zhang và cộng sự (2018b)			
Yang và cộng sự (2019a)			
Lee và cộng sự (2019c)			

và những ý tưởng tương tự có thể được tìm thấy trong Yang et al. (2019a). Để thực hiện chuyển giao kiến thức một cách hiệu quả và khám phá sức mạnh của nhiều giáo viên, một số phương pháp thay thế đã được đề xuất để mô phỏng nhiều giáo viên bằng cách thêm các loại khác nhau của tiếng ồn đối với một giáo viên nhất định (Sau và Balasubramanian 2016) hoặc bằng cách sử dụng các khối ngẫu nhiên và kết nối bỏ qua (Lee et al. 2019c). Sử dụng nhiều mô hình giáo viên với các tập hợp tính năng, việc kết hợp kiến thức được thiết kế trong (Shen et al. 2019a; Luo và cộng sự. 2019; Thần và cộng sự. 2019b; Luo và cộng sự. 2020). Thông qua sự kết hợp kiến thức, nhiều công chúng có thể tiếp cận các mô hình sâu được đào tạo như giáo viên có thể được tái sử dụng. Thú vị hơn, do các đặc điểm đặc biệt của nhiều giáo viên chứng cất, các phần mở rộng của nó được sử dụng để thích nghi miễn thông qua việc thích ứng kiến thức (Ruder et al. 2017) và để bảo vệ quyền riêng tư và bảo mật dữ liệu (Vongkulbhisal và cộng sự, 2019; Papernot và cộng sự 2017).

Tóm tắt các phương pháp chứng cất đa giáo viên điển hình sử dụng các loại kiến thức và chương trình chứng cất khác nhau được thể hiện trong Bảng 3. Nhìn chung, việc chất lọc kiến thức của nhiều giáo viên có thể cung cấp kiến thức phong phú và điều chỉnh một cách linh hoạt mô hình học sinh vì kiến thức đa dạng từ các giáo viên khác nhau. Tuy nhiên, làm thế nào để tích hợp hiệu quả các các loại kiến thức từ nhiều giáo viên cần được nghiên cứu sâu hơn.



Hình 12 Khung chung cho chúng cất đa phương thức. Để đơn giản, chỉ có hai phương thức được hiển thị

5.3 Chúng cất đa phương thức

Dữ liệu hoặc nhãn cho một số phương thức có thể không có sẵn trong quá trình đào tạo hoặc thử nghiệm (Gupta et al. 2016; Garcia et al. 2018; Zhao và cộng sự. 2018; Roheda và cộng sự. 2018; Zhao và cộng sự. 2020b). Vì lý do này, việc chuyển giao kiến thức giữa các phương thức khác nhau là rất quan trọng. Một số tình huống điển hình sử dụng chuyển giao kiến thức đa phương thức được xem xét như sau.

Với một mô hình giáo viên được đào tạo trước trên một phương thức (ví dụ: hình ảnh RGB) với số lượng lớn các mẫu dữ liệu được chú thích rõ ràng, Gupta et al. (2016) đã chuyển kiến thức từ mô hình giáo viên sang mô hình học sinh với một phương thức mới.

phương thức đầu vào beled, chẳng hạn như ảnh độ sâu và luồng quang học. Cụ thể, phương pháp đề xuất dựa trên các mẫu ghép không có nhãn liên quan đến cả hai phương thức, tức là cả ảnh RGB và ảnh độ sâu. Các đặc điểm thu được từ ảnh RGB của giáo viên sau đó được sử dụng để đào tạo có giám sát cho sinh viên (Gupta và cộng sự, 2016). Ý tưởng đằng sau các mẫu ghép là chuyển thông tin chú thích hoặc nhãn thông qua đăng ký mẫu từng cặp và đã được sử dụng rộng rãi cho các ứng dụng liên phương thức (Albanie và cộng sự, 2018; Zhao và cộng sự, 2018; Thoker và Gall , 2019). Để thực hiện ước tính tư thế của con người qua các bức tường hoặc với các hình ảnh bị che khuất, Zhao và cộng sự (2018) đã sử dụng tín hiệu vô tuyến đồng bộ và hình ảnh camera. Kiến thức được chuyển qua các phương thức để ước tính tư thế của con người dựa trên vô tuyến. Thoker và Gall (2019) đã thu được các mẫu ghép từ hai phương thức: video RGB và chuỗi bộ xương.

Các cặp được sử dụng để chuyển kiến thức học được trên video RGB sang mô hình nhận dạng hành động của con người dựa trên bộ xương. Để cải thiện hiệu suất nhận dạng hành động chỉ sử dụng hình ảnh RGB, Garcia và cộng sự (2018) đã thực hiện chúng cất đa phương thức trên một phương thức bổ sung, tức là hình ảnh độ sâu, để tạo luồng ảo giác cho phương thức hình ảnh RGB. Tian và cộng sự (2020) đã giới thiệu một mắt mát tương phản để chuyển mối quan hệ từng cặp trên các phương thức khác nhau.

Để cải thiện khả năng phát hiện mục tiêu, Roheda và cộng sự (2018) đã đề xuất chúng cất đa phương thức giữa các mô hình còn thiếu và có sẵn bằng cách sử dụng GAN. Khung chung của chúng cất đa phương thức được thể hiện trong Hình 12.

Hơn nữa, Do et al. (2019) đã đề xuất một phương pháp trả lời câu hỏi trực quan dựa trên chúng cất kiến thức, trong đó kiến thức từ mô hình giáo viên tương tác ba tuyến tính với hình ảnh-câu hỏi-trả lời làm đầu vào được chúng cất thành quá trình học của mô hình học sinh tương tác song tuyến tính với hình ảnh-câu hỏi làm đầu vào. Chúng cất kiến thức xác suất do Passalis và Tefas (2018) đề xuất cũng được sử dụng để chuyển giao kiến thức từ phương thức văn bản sang phương thức trực quan. Hoffman et al. (2016) đã đề xuất một kiến trúc ảo giác phương thức dựa trên chúng cất chéo phương thức để cải thiện hiệu suất phát hiện. Bên cạnh đó, các phương pháp chúng cất chéo mô hình này cũng chuyển giao kiến thức giữa nhiều miền (Kundu et al. 2019; Chen et al. 2019c; Su và Maji 2017).

Tóm tắt về chúng cất đa phương thức với các phương thức, loại kiến thức và sơ đồ chúng cất khác nhau được thể hiện trong Bảng 4. Cụ thể, có thể thấy rằng chúng cất kiến thức thực hiện tốt trong các nhiệm vụ nhận dạng trực quan trong các tình huống đa phương thức. Tuy nhiên, chuyển giao kiến thức đa phương thức là một nghiên cứu đầy thách thức khi có khoảng cách phương thức, ví dụ, thiếu các mẫu ghép giữa các phương thức khác nhau.

5.4 Chúng cất dựa trên đồ thị

Hầu hết các thuật toán chất lọc kiến thức tập trung vào việc chuyển giao kiến thức cá nhân từ giáo viên sang học sinh, trong khi một số phương pháp gần đây đã được đề xuất để khám phá các mối quan hệ dữ liệu trong bằng cách sử dụng đồ thị (Chen et al.

2021; Zhang và Peng 2018; Lee và Song 2019; Park và cộng sự. 2019; Yao và cộng sự. 2020; Mã và Mai 2019; Hou và cộng sự. 2020).


Ý tưởng chính của các phương pháp chúng cất dựa trên đồ thị này là 1) sử dụng đồ thị như phương tiện truyền tải kiến thức của giáo viên; hoặc 2) sử dụng đồ thị để kiểm soát việc truyền tải thông điệp của kiến thức của giáo viên. Một khuôn khổ chung cho chúng cất dựa trên đồ thị được thể hiện trong Hình 13. Như đã mô tả trong Phần 2.3, kiến thức dựa trên đồ thị nằm trong phạm vi của kiến thức dựa trên quan hệ. Trong phần này, chúng tôi giới thiệu các định nghĩa điển hình về kiến thức dựa trên đồ thị và các thuật toán chúng cất truyền tải thông điệp dựa trên đồ thị.

Cụ thể, trong Zhang và Peng (2018), mỗi đỉnh biểu diễn một giáo viên tự giám sát. Sau đó, hai đồ thị được xây dựng bằng cách sử dụng logit và các đặc điểm trung gian, tức là đồ thị logit và đồ thị biểu diễn, để truyền kiến thức từ nhiều giáo viên tự giám sát đến học sinh. Trong Chen và cộng sự (2021), đồ thị được sử dụng để duy trì mối quan hệ giữa các mẫu trong không gian có nhiều chiều. Sau đó, việc truyền kiến thức được thực hiện bằng cách sử dụng hàm mất mát bảo toàn vị trí được đề xuất. Lee và Song (2019) đã phân tích các mối quan hệ trong dữ liệu bằng cách sử dụng đồ thị nhiều đầu, trong đó các đỉnh là các đặc điểm từ các lớp khác nhau trong CNN. Park và cộng sự (2019) đã chuyển trực tiếp các mối quan hệ lẫn nhau của các mẫu dữ liệu, tức là để khớp các cạnh giữa đồ thị giáo viên và đồ thị học sinh.

Tung và Mori (2019) đã sử dụng ma trận tương đồng để biểu diễn

Bảng 4 Tóm tắt về chứng cất đa phương thức với các phương thức, loại kiến thức và chứng cất

Phương pháp	Phương thức dành cho giáo viên	Hình thức dành cho sinh viên	Kiến thức	chứng cất
Hoffman và cộng sự (2016)	Hình ảnh RGB	Hình ảnh độ sâu	FeaK	Ngoại tuyến
Gupta và cộng sự (2016)	Hình ảnh RGB	Hình ảnh độ sâu	ResK	Ngoại tuyến
Passalis và Tefas (2018)	Phương thức văn bản	Phương thức trực quan	Liên quan	Ngoại tuyến
Garcia và cộng sự (2018)	Video độ sâu và RGB	Video RGB	ResK, FeaK	Ngoại tuyến
Zhao và cộng sự (2018)	Khung RGB	Bản đồ nhiệt tần số vô tuyến	ResK	Ngoại tuyến
Roheda và cộng sự (2018)	Dữ liệu thời gian	Dữ liệu không gian	FeaK	Trực tuyến
Albanie và cộng sự (2018)	Tầm nhìn	Âm thanh	ResK	Ngoại tuyến
Thoker và Gall (2019)	Video RGB	Dữ liệu bộ xương	ResK	Ngoại tuyến
Do và cộng sự (2019)	Hình ảnh, câu hỏi, thông tin trả lời	Câu hỏi hình ảnh	ResK	Ngoại tuyến
Tian và cộng sự (2020)	Hình ảnh RGB	Hình ảnh độ sâu	ResK	Ngoại tuyến
Gao và cộng sự (2020)	Hình ảnh đa phương thức	Hình ảnh chế độ đơn	ResK, FeaK	Ngoại tuyến



Hình 13 Một khuôn khổ chung cho chứng cất dựa trên đồ thị

mối quan hệ tương hỗ của các hoạt động của các cặp đầu vào trong mô hình giáo viên và học sinh. Ma trận tương đồng của học sinh phù hợp với giáo viên. Hơn nữa, Peng et al. (2019a) không chỉ khớp với kiến thức dựa trên phản hồi và dựa trên tính năng, mà còn sử dụng kiến thức dựa trên đồ thị. Trong Liu et al. (2019g), các tính năng thể hiện và mối quan hệ thể hiện là được mô hình hóa tương ứng thành các đỉnh và các cạnh của đồ thị. Thay vì sử dụng kiến thức dựa trên biểu đồ, một số phương pháp kiểm soát việc chuyển giao kiến thức bằng cách sử dụng đồ thị. Cụ thể, Luo et al. (2018) đã xem xét sự khác biệt về phương thức để kết hợp thông tin đặc quyền từ nguồn miền. Một đồ thị có hướng, được gọi là đồ thị chứng cất được giới thiệu để khám phá mối quan hệ giữa các phương thức khác nhau. Mỗi đỉnh đại diện cho một phương thức và các cạnh chỉ ra cường độ kết nối giữa một phương thức và một cái khác. Minami et al. (2019) đã đề xuất một phương pháp hai chiều học tập cộng tác đa dạng dựa trên đồ thị để khám phá sự đa dạng các mô hình chuyển giao kiến thức. Yao et al. (2020) đã giới thiệu GNN xử lý việc chuyển giao kiến thức cho đồ thị dựa trên kiến thức. Bên cạnh đó, sử dụng phương pháp chứng cất kiến thức, ngữ nghĩa tô pô của mạng lưới giáo viên tích chập đồ thị như kiến thức nhận thức về cấu trúc được chuyển vào đồ thị mạng sinh viên tích chập (Yang et al. 2020b)


Chứng cất dựa trên đồ thị có thể chuyển giao thông tin cấu trúc kiến thức về dữ liệu. Tuy nhiên, làm thế nào để xây dựng đúng đồ thị để mô hình hóa cấu trúc kiến thức về dữ liệu là một vấn đề còn là một nghiên cứu đầy thách thức.

5.5 Chứng cất dựa trên sự chú ý

Vì sự chú ý có thể phản ánh tốt sự kích hoạt của tế bào thần kinh mạng lưới thần kinh tiến hóa, một số cơ chế chú ý là được sử dụng trong quá trình chứng cất kiến thức để cải thiện hiệu suất của mạng lưới sinh viên (Zagoruyko và Komodakis 2017; Huang và Wang 2017; Srinivas và Fleuret 2018; Crowley et al. 2018; Song et al. 2018). Trong số những sự chú ý dựa trên Phương pháp KD (Crowley et al. 2018; Huang và Wang 2017; Srinivas và Fleuret 2018; Zagoruyko và Komodakis 2017), các cơ chế chuyển giao sự chú ý khác nhau được xác định để chất lọc kiến thức từ mạng lưới giáo viên đến học sinh mạng lưới. Cốt lõi của việc chuyển giao sự chú ý là xác định các bản đồ sự chú ý để nhúng tính năng vào các lớp của mạng nơ-ron mạng. Nghĩa là, kiến thức về những tính năng được chuyển giao bằng cách sử dụng các hàm bản đồ chú ý. Không giống như các bản đồ chú ý, một phương pháp chứng cất kiến thức chú ý khác được đề xuất bởi Song et al. (2018). Một cơ chế chú ý được sử dụng để chỉ định các quy tắc tin cậy khác nhau (Song et al. 2018).

5.6 Chứng cất không có dữ liệu

Một số phương pháp KD không cần dữ liệu đã được đề xuất để khắc phục các vấn đề liên quan đến dữ liệu không khả dụng phát sinh từ quyền riêng tư, những lo ngại về tính hợp pháp, an ninh và bảo mật (Chen et al. 2019a; Lopes và cộng sự. 2017; Nayak và cộng sự. 2019; Micaelli và Cò Cò 2019; Haroush và cộng sự. 2020; Ye và cộng sự. 2020; Nayak et al. 2021; Chawla et al. 2021). Cũng giống như “dữ liệu miễn phí” ngụ ý, không có dữ liệu đào tạo. Thay vào đó, dữ liệu được tạo mới hoặc tổng hợp.



Hình 14 Một khuôn khổ chung cho chứng cật không có dữ liệu

Cụ thể, trong (Chen et al. 2019a; Ye et al. 2020; Micaelli và Storkey 2019; Yoo et al. 2019; Hu et al. 2020), dữ liệu chuyển được tạo bởi GAN. Trong phương pháp chứng cật kiến thức không có dữ liệu được đề xuất (Lopes et al. 2017), dữ liệu chuyển để đào tạo mạng học sinh được tái tạo bằng cách sử dụng các kích hoạt lớp hoặc các kích hoạt phổ lớp của mạng giáo viên. Yin et al. (2020) đã đề xuất DeepInversion, sử dụng chứng cật kiến thức để tạo ra các hình ảnh tổng hợp cho việc chuyển giao kiến thức không có dữ liệu. Nayak et al. (2019) đã đề xuất chứng cật kiến thức zero-shot không sử dụng dữ liệu hiện có. Dữ liệu chuyển được tạo ra bằng cách mô hình hóa không gian softmax bằng cách sử dụng các tham số của mạng giáo viên.


Trên thực tế, dữ liệu mục tiêu trong (Micaelli và Storkey 2019; Nayak và cộng sự 2019) được tạo ra bằng cách sử dụng thông tin từ các biểu diễn đặc trưng của mạng lưới giáo viên. Tương tự như phương pháp học không-bản, phương pháp chứng cật kiến thức với phương pháp học ít-bản được thiết kế bằng cách chứng cật kiến thức từ mô hình giáo viên thành mạng lưới nơ-ron học sinh (Kimura và cộng sự 2018; Shen và cộng sự 2021). Giáo viên sử dụng dữ liệu có nhãn hạn chế.

Bên cạnh đó, có một loại chứng cật mới gọi là chứng cật dữ liệu, tương tự như chứng cật không có dữ liệu (Radosavović và cộng sự, 2018; Liu và cộng sự, 2019d; Zhang và cộng sự, 2020d). Trong chứng cật dữ liệu, các chú thích đào tạo mới của dữ liệu chưa được gắn nhãn được tạo ra từ mô hình giáo viên được sử dụng để đào tạo mô hình học viên.

Tóm lại, dữ liệu tổng hợp trong quá trình chứng cật không có dữ liệu thường được tạo ra từ các biểu diễn đặc trưng từ mô hình giáo viên được đào tạo trước, như thể hiện trong Hình 14. Mặc dù quá trình chứng cật không có dữ liệu đã cho thấy tiềm năng lớn trong điều kiện dữ liệu không có sẵn, nhưng đây vẫn là một nhiệm vụ rất khó khăn, tức là làm thế nào để tạo ra dữ liệu đào tạo đa dạng chất lượng cao để cải thiện khả năng khái quát hóa của mô hình.

5.7 Chứng cật lượng tử

Lượng tử hóa mạng làm giảm độ phức tạp tính toán của mạng nơ-ron bằng cách chuyển đổi các mạng có độ chính xác cao (ví dụ:



Hình 15 Một khuôn khổ chung cho chứng cật lượng tử

32-bit dấu phẩy động) thành các mạng có độ chính xác thấp (ví dụ: 2-bit và 8-bit). Trong khi đó, chứng cật kiến thức nhằm mục đích đào tạo một mô hình nhỏ để tạo ra hiệu suất tương đương với hiệu suất của một mô hình phức tạp. Một số phương pháp KD đã được đề xuất bằng cách sử dụng quy trình lượng tử hóa trong khuôn khổ giáo viên-học sinh (Polino et al. 2018; Mishra và Marr 2018; Wei et al. 2018; Shin và cộng sự 2019; Kim và cộng sự 2019a). Khung cho các phương pháp chứng cật lượng tử được thể hiện trong Hình 15.

Cụ thể, Polino et al. (2018) đã đề xuất một phương pháp chứng cật lượng tử để chuyển kiến thức sang mạng học sinh lượng tử hóa theo trọng số. Trong Mishra và Marr (2018), KD lượng tử hóa được đề xuất được gọi là “người học việc”.

Một mạng lưới giáo viên có độ chính xác cao truyền tải kiến thức đến một mạng lưới học sinh có độ chính xác thấp nhỏ. Để đảm bảo rằng một mạng lưới học sinh nhỏ mô phỏng chính xác một mạng lưới giáo viên lớn, mạng lưới giáo viên có độ chính xác đầy đủ đầu tiên được lượng tử hóa trên các bản đồ đặc trưng, sau đó kiến thức được truyền từ giáo viên được lượng tử hóa đến một mạng lưới học sinh được lượng tử hóa (Wei et al. 2018). Kim et al. (2019a) đề xuất phương pháp chứng cật kiến thức có nhận thức lượng tử hóa, dựa trên việc tự nghiên cứu mạng lưới học sinh-sinh viên lượng tử hóa và trên việc đồng nghiên cứu mạng lưới giáo viên và học sinh với việc chuyển giao kiến thức. Hơn nữa, Shin et al. (2019) đã tiến hành phân tích thực nghiệm về mạng lưới nơ-ron sâu bằng cách sử dụng cả phương pháp chứng cật và lượng tử hóa, có tính đến các siêu tham số để chứng cật kiến thức, chẳng hạn như kích thước của mạng lưới giáo viên và nhiệt độ chứng cật.

Gần đây, không giống như các phương pháp chứng cật lượng tử ở trên, một chương trình đào tạo tự chứng cật được thiết kế để cải thiện hiệu suất của các mô hình sâu lượng tử, trong đó giáo viên chia sẻ các tham số mô hình của học sinh (Boo et al. 2021).

5.8 Chứng cật trọn đời

Học tập suốt đời, bao gồm học tập liên tục, học tập liên tục và siêu học tập, nhằm mục đích học theo cách tương tự như con người. Nó tích lũy kiến thức đã học trước đó và cũng chuyển kiến thức đã học vào quá trình học tập trong tương lai (Chen và Liu 2018). Chất lọc kiến thức cung cấp một cách hiệu quả để bảo tồn và chuyển giao kiến thức đã học mà không bị lãng quên thảm khốc. Gần đây, ngày càng có nhiều biến thể KD dựa trên học tập suốt đời

đã được phát triển (Jang et al. 2019; Flennerhag et al. 2019; Peng et al. 2019b; Liu et al. 2019e; Lee et al. 2019b; Zhai et al. 2019; Zhou et al. 2020; Shmelkov et al. 2017; Li và Hoiem 2017; Caccia et al. 2020). Các phương pháp được đề xuất trong (Jang et al. 2019; Peng et al. 2019b; Liu et al. 2019e; Flennerhag et al. 2019) áp dụng siêu học. Jang et al. (2019) đã thiết kế các mạng siêu chuyển giao có thể xác định nội dung nào và chuyển giao ở đâu trong kiến trúc giáo viên-học sinh.

Flennerhag và cộng sự (2019) đã đề xuất một khuôn khổ nhẹ có tên là Leap để học siêu dữ liệu trên các đa tập nhiệm vụ bằng cách chuyển giao kiến thức từ một quy trình học tập sang một quy trình học tập khác. Peng và cộng sự (2019b) đã thiết kế một kiến trúc mạng truyền tải kiến thức mới để nhận dạng hình ảnh ít ảnh. Kiến trúc này đồng thời kết hợp thông tin trực quan từ hình ảnh và kiến thức trước đó. Liu và cộng sự (2019e) đã đề xuất phương pháp bảo tồn kiến thức có nhận thức ngữ nghĩa để truy xuất hình ảnh. Kiến thức của giáo viên thu được từ các phương thức hình ảnh và thông tin ngữ nghĩa được bảo tồn và chuyển giao.

Hơn nữa, để giải quyết vấn đề quên lãng thảm khốc trong học tập suốt đời, phương pháp chứng cất toàn cầu (Lee và cộng sự, 2019b), phương pháp chứng cất kiến thức dựa trên GAN suốt đời (Zhai và cộng sự, 2019), phương pháp chứng cất đa mô hình (Zhou và cộng sự, 2020) và các phương pháp dựa trên KD khác (Li và Hoiem, 2017; Shmelkov và cộng sự, 2017) đã được phát triển để trích xuất kiến thức đã học và dạy cho mạng lưới sinh viên về các nhiệm vụ mới.

5.9 Chứng cất dựa trên NAS

Tìm kiếm kiến trúc nơ-ron (NAS), một trong những kỹ thuật học máy tự động (hay AutoML) phổ biến nhất, nhằm mục đích tự động xác định các mô hình nơ-ron sâu và học các cấu trúc nơ-ron sâu phù hợp một cách thích ứng. Trong quá trình chất lọc kiến thức, sự thành công của việc truyền đạt kiến thức không chỉ phụ thuộc vào kiến thức từ giáo viên mà còn phụ thuộc vào kiến trúc của học sinh. Tuy nhiên, có thể có một khoảng cách về năng lực giữa mô hình giáo viên lớn và mô hình học sinh nhỏ, khiến học sinh khó học tốt từ giáo viên.

Để giải quyết vấn đề này, tìm kiếm kiến trúc nơ-ron đã được áp dụng để tìm kiến trúc học viên phù hợp trong quá trình chứng cất kiến thức dựa trên oracle (Kang và cộng sự, 2020) và nhận thức kiến trúc (Liu và cộng sự, 2019i). Hơn nữa, chứng cất kiến thức được sử dụng để cải thiện hiệu quả của tìm kiếm kiến trúc nơ-ron, chẳng hạn như AdaNAS (Macko và cộng sự, 2019), NAS với kiến thức kiến trúc được chứng cất (Li và cộng sự, 2020a), tìm kiếm kiến trúc có hướng dẫn của giáo viên hoặc TGSA (Bashivan và cộng sự, 2019) và NAS một lần (Peng và cộng sự, 2020). Trong TGSA, mỗi bước tìm kiếm kiến trúc được hướng dẫn để mô phỏng các biểu diễn tính năng trung gian của mạng giáo viên. Các cấu trúc có thể có cho học viên được tìm kiếm hiệu quả và quá trình chuyển giao tính năng được giáo viên giám sát hiệu quả.

6 So sánh hiệu suất

Chứng cất kiến thức là một kỹ thuật tuyệt vời để nén mô hình. Thông qua việc nắm bắt kiến thức của giáo viên và sử dụng các chiến lược chứng cất với việc học tập của giáo viên-học sinh, nó cung cấp hiệu suất hiệu quả của mô hình học sinh nhẹ. Gần đây, nhiều phương pháp chứng cất kiến thức tập trung vào việc cải thiện hiệu suất, đặc biệt là trong các tác vụ phân loại hình ảnh. Trong phần này, để chứng minh rõ ràng hiệu quả của chứng cất kiến thức, chúng tôi tóm tắt hiệu suất phân loại của một số phương pháp KD điển hình trên hai tập dữ liệu phân loại hình ảnh phổ biến.

Hai tập dữ liệu là CIFAR10 và CIFAR100 (Krizhevsky và Hinton 2009) bao gồm 32 hình ảnh RGB ×32 được lấy từ lần lượt 10 và 100 lớp. Cả hai đều có 50000 hình ảnh đào tạo và 10000 hình ảnh thử nghiệm, và mỗi lớp có cùng số lượng hình ảnh đào tạo và thử nghiệm. Để so sánh công bằng, kết quả độ chính xác phân loại thử nghiệm (%) của các phương pháp KD được lấy trực tiếp từ các bài báo gốc tương ứng, như thể hiện trong Bảng 5 đối với CIFAR10 và Bảng 6 đối với CIFAR100. Chúng tôi báo cáo hiệu suất của các phương pháp khác nhau khi sử dụng các loại kiến thức, lược đồ chứng cất và cấu trúc khác nhau của các mô hình giáo viên/học sinh. Cụ thể, độ chính xác trong ngoặc đơn là kết quả phân loại của các mô hình giáo viên và học sinh, được đào tạo riêng lẻ. Cần lưu ý rằng các cặp độ chính xác của DML (Zhang và cộng sự 2018b), DCM (Yao và Sun 2020) và KDCL (Guo và cộng sự 2020) là hiệu suất của giáo viên và học sinh sau khi chứng cất trực tuyến.

Từ so sánh hiệu suất trong Bảng 5 và Bảng 6, một số quan sát có thể được tóm tắt như sau:

- Sự chứng cất kiến thức có thể được thực hiện ở nhiều độ sâu khác nhau mô hình.
- Nén mô hình của các mô hình sâu khác nhau có thể đạt được bằng cách chứng cất kiến thức.
- Chứng cất kiến thức trực tuyến thông qua học tập cộng tác (Zhang và cộng sự 2018b; Yao và Sun 2020) có thể cải thiện đáng kể hiệu suất của các mô hình sâu.
- Chứng cất kiến thức tự thân (Yang và cộng sự 2019b; Yuan và cộng sự 2020; Xu và Liu 2019; Yun và cộng sự 2020) có thể cải thiện đáng kể hiệu suất của các mô hình sâu.
- Các phương pháp chứng cất ngoại tuyến và trực tuyến thường chuyển giao kiến thức dựa trên tính năng và kiến thức dựa trên phản hồi.
- Hiệu suất của các mô hình sâu nhẹ (học sinh-học viên) có thể được cải thiện bằng cách chuyển giao kiến thức từ các mô hình giáo viên có năng lực cao.

Thông qua việc so sánh hiệu suất của các phương pháp chứng cất kiến thức khác nhau, có thể dễ dàng kết luận rằng chứng cất kiến thức là một kỹ thuật hiệu quả và hữu hiệu để nén các mô hình sâu.

Bảng 5 So sánh hiệu suất của các phương pháp chứng cất kiến thức khác nhau trên CIFAR10. Lưu ý rằng biểu thị sự cải thiện hiệu suất của mạng lưới sinh viên được học bằng từng phương pháp so sánh với mô hình cơ sở tương ứng

Phương pháp	Kiến thức	Giáo viên (cơ bản)	Học sinh (cơ sở)	Độ chính xác
Chứng cất ngoại tuyến				
FSP (Yim và cộng sự, 2017)	Liên quan	ResNet26 (91,91)	ResNet8 (87,91)	88,70 (0,79)
FT (Kim và cộng sự 2018)	FeaK	ResNet56 (93,61)	ResNet20 (92,22)	93,15 (0,93)
IRG (Liu và cộng sự 2019g)	Liên quan	ResNet20 (91,45)	ResNet20-x0.5 (88.36)	90,69 (2,33)
SP (Tung và Mori 2019)	Liên quan	WRN-40-1 (93,49)	WRN-16-1 (91,26)	91,87 (0,61)
SP (Tung và Mori 2019)	Liên quan	WRN-40-2 (95,76)	WRN-16-8 (94,82)	95,45 (0,63)
FN (Xu và cộng sự 2020b)	FeaK	ResNet110 (94,29)	ResNet56 (93,63)	94,14 (0,51)
FN (Xu và cộng sự 2020b)	FeaK	ResNet56 (93,63)	ResNet20 (92.11)	92,67 (0,56)
AdaIN (Yang và cộng sự 2020a)	FeaK	ResNet26 (93,58)	ResNet8 (87,78)	89.02 (1.24)
AdaIN (Yang và cộng sự 2020a)	FeaK	WRN-40-2 (95.07)	WRN-16-2 (93,98)	94,67 (0,69)
AE-KD (Du và cộng sự 2020)	FeaK	ResNet56 (-)	MobileNetV2 (75,97) CNN	77.07 (1.10)
JointRD (Li và cộng sự 2020b)	FeaK	ResNet34 (95,39)	34 (93,73)	94,78 (1,05)
TOFD (Zhang và cộng sự, 2020a)	FeaK	ResNet152 (-)	ResNeXt50-4 (94,49)	97.09 (2.60)
TOFD (Zhang và cộng sự, 2020a)	FeaK	ResNet152 (-)	Mạng di động V2 (90,43)	93,34 (2,91)
CTKD (Zhao và cộng sự, 2020a)	RelK, FeaK	WRN-40-1 (93,43)	WRN-16-1 (91,28)	92,50 (1,22)
CTKD (Zhao và cộng sự, 2020a)	RelK, FeaK	WRN-40-2 (94,70)	WRN-16-2 (93,68)	94,42 (0,74)
Chứng cất trực tuyến				
Rocket-KD (Zhou và cộng sự, 2018)	FeaK	WRN-40-1 (93,42)	WRN-16-1 (91,23)	92,48 (1,25)
DML (Zhang và cộng sự, 2018b)	ResK	WRN-28-10 (95.01)	ResNet32 (92,47)	95,75, 93,18 (0,71)
DML (Zhang và cộng sự, 2018b)	ResK	Mạng di động (93,59)	ResNet32 (92,47)	94,24, 93,32 (0,85)
DML (Zhang và cộng sự, 2018b)	ResK	ResNet32 (92,47)	ResNet32 (92,47)	92,68, 92,80 (0,33)
ONE (Zhu và Gong 2018)	ResK	ResNet32+MỘT	ResNet32 (93.07)	94,01 (0,84)
ONE (Zhu và Gong 2018)	ResK	ResNet110+MỘT	ResNet110 (94,44)	94,83 (0,39)
PCL (Wu và Gong 2021)	ResK	Đoàn sinh viên	ResNet110 (94,91)	95,53 (0,62)
PCL (Wu và Gong 2021)	ResK	Đoàn sinh viên	Mật độ mạng-40-12 (93,19)	94,13 (0,94)
PCL (Wu và Gong 2021)	ResK	Đoàn sinh viên	VGG16 (93,96)	94,74 (0,78)
ACN (Zhang và cộng sự, 2021a)	ResK	ResNet14 (90,66)	ResNet14 (90,66)	92.09 (1.43)
ACN (Zhang và cộng sự, 2021a)	ResK	VGG11 (91,25)	VGG11 (91,25)	92,65 (1,40)
ACN (Zhang và cộng sự, 2021a)	ResK	AlexNet (73.24)	AlexNet (73.24)	78,57 (5,33)
Tự chứng cất				
Xu và Liu (2019)	ResK, FeaK	-	ResNet32 (92,78)	93,68 (0,90)
Xu và Liu (2019)	ResK, FeaK	-	Mật độNe40(94.53)	94,80 (0,27)

7 Ứng dụng

Là một kỹ thuật hiệu quả để nén và tăng tốc các mạng nơ-ron sâu, chứng cất kiến thức đã được sử dụng rộng rãi trong các lĩnh vực khác nhau của trí tuệ nhân tạo, bao gồm nhận dạng hình ảnh, nhận dạng giọng nói, tự nhiên xử lý ngôn ngữ (NLP) và hệ thống đề xuất. Hơn nữa, chứng cất kiến thức cũng có thể được sử dụng cho các mục đích khác, chẳng hạn như quyền riêng tư dữ liệu và như một biện pháp phòng thủ chống lại các cuộc tấn công đối nghịch. Phần này tóm tắt lại các ứng dụng của quá trình chất lọc kiến thức.

7.1 KD trong Nhận dạng hình ảnh

Trong vài năm trở lại đây, nhiều phương pháp chứng cất kiến thức khác nhau đã được sử dụng rộng rãi để nén mô hình trong các ứng dụng nhận dạng hình ảnh khác nhau. Cụ thể, hầu hết phương pháp chứng cất kiến thức đã được phát triển trước đó để phân loại hình ảnh (Li và Hoiem 2017; Peng et al. 2019b; Bagherinezhad và cộng sự. 2018; Chen và cộng sự. 2018a; Vương et al. 2019b; Mukherjee et al. 2019; Zhu et al. 2019) và sau đó mở rộng sang các ứng dụng nhận dạng hình ảnh khác, bao gồm nhận dạng khuôn mặt (Luo và cộng sự 2016; Kong và cộng sự 2019; Yan và cộng sự. 2019; Ge và cộng sự. 2018; Vương và cộng sự. 2018b, 2019c; Dương và cộng sự. 2019; Wu và cộng sự. 2020; Vương và cộng sự. 2017; Zhang và cộng sự.

Bảng 6 So sánh hiệu suất của các phương pháp chứng cất kiến thức khác nhau trên CIFAR100. Lưu ý rằng biểu thị sự cải thiện hiệu suất của mạng lưới sinh viên được học bằng từng phương pháp so sánh với mô hình cơ sở tương ứng

Phương pháp	Kiến thức	Giáo viên (cơ bản)	Học sinh (cơ sở)	Độ chính xác
Chung cất ngoại tuyến				
FSP (Yim và cộng sự, 2017)	Liên quan	ResNet32 (64.06)	ResNet14 (58,65)	63,33 (4,68)
FT (Kim và cộng sự 2018)	FeaK	ResNet110 (73.09)	ResNet56 (71,96)	74,48 (2,52)
RKD (Park và cộng sự, 2019)	RelK, FeaK	ResNet50 (77,76)	VGG11 (71,26)	74,66 (3,40)
IRG (Liu và cộng sự 2019g)	Liên quan	ResNet20 (78,40)	ResNet20-x0.5 (72.51)	74,64 (2,13)
CCKD (Peng và cộng sự, 2019a)	RelK, ResK	ResNet110 (-)	ResNet20 (68,40)	72,40 (4,00)
KR (Liu và cộng sự 2019c)	FeaK	ResNet32 (64.06)	ResNet14 (58,65)	63,95 (5,30)
LKD (Li và cộng sự, 2020e)	Liên quan	ResNet110 (75,76)	ResNet20 (69,47)	72,63 (3,16)
LKD (Li và cộng sự, 2020e)	Liên quan	WRN-40-2 (75,61)	WRN-16-2 (73.10)	75,44 (2,34)
SSKD (Xu và cộng sự 2020a)	RelK, ResK	VGG13 (75,38)	MobileNetV2 (65,79)	71,53 (5,74)
SSKD (Xu và cộng sự 2020a)	RelK, ResK	ResNet50 (79,10)	MobileNetV2 (65,79)	72,57 (6,78)
FN (Xu và cộng sự 2020b)	FeaK	ResNet110 (82.01)	ResNet56 (81,73)	82,23 (0,50)
AdaIN (Yang và cộng sự 2020a)	FeaK	WRN-40-4 (78,31)	WRN-16-4 (75,68)	78,25 (2,57)
AdaIN (Yang và cộng sự 2020a)	FeaK	ResNet34 (77,26)	MobileNetV2 (68,36)	70,66 (2,30)
PAD-L2 (Zhang và cộng sự, 2020e)	FeaK	ResNet18 (75.86)	MobileNetV2 (68.16)	74.06 (5.90)
MGD (Yue và cộng sự, 2020)	FeaK	WRN-28-4 (78,91)	WRN-28-2 (75.12)	78,82 (3,70)
AE-KD (Du và cộng sự 2020)	FeaK	ResNet56 (-)	ResNet20 (69.06)	70,55 (1,49)
JointRD (Li và cộng sự 2020b)	FeaK	ResNet18 (77,92)	CNN 18 (77,44)	78,24 (0,80)
TOFD (Zhang và cộng sự, 2020a)	FeaK	ResNet152 (-)	ResNet50 (77,42)	84,74 (7,32)
TOFD (Zhang và cộng sự, 2020a)	FeaK	ResNet152 (-)	ShuffleNetV2 (72,38)	76,68 (4,30)
CTKD (Zhao và cộng sự, 2020a)	RelK, FeaK	ResNet110 (72,65)	ResNet20 (68,33)	70,75 (2,42)
CTKD (Zhao và cộng sự, 2020a)	RelK, FeaK	WRN-40-2 (75,42)	WRN-16-2 (72,27)	74,70 (2,43)
SemCKD (Chen và cộng sự, 2021)	FeaK	ResNet-32x4 (79,42)	VGG13 (74.82)	79,43 (4,61)
SemCKD (Chen và cộng sự, 2021)	FeaK	WRN-40-2 (75,61)	MobileNetV2 (65,43)	69,61 (4,18)
SemCKD (Chen và cộng sự, 2021)	FeaK	VGG13 (74,64)	ShuffleNetV2 (72,60)	76,39 (3,79)
RKD (Gao và cộng sự, 2021)	FeaK	ResNet34 (73.05)	ResNet18 (68.06)	72,82 (4,76)
Chung cất trực tuyến				
Rocket-KD (Zhou và cộng sự, 2018)	FeaK	WRN-40-1 (-)	WRN-16-1 (56.30)	67,00 (10,07)
DML (Zhang và cộng sự, 2018b)	ResK	WRN-28-10 (78,69)	Mạng di động (73,65)	80,28, 77,39 (3,74)
DML (Zhang và cộng sự, 2018b)	ResK	Mạng di động (73,65)	ResNet32 (68,99)	76,13, 71,10 (8,11)
ONE (Zhu và Gong 2018)	ResK	ResNet32+MỘT	ResNet32 (68.82)	73,39 (4,57)
ONE (Zhu và Gong 2018)	ResK	ResNet110+MỘT	ResNet110 (74,67)	78,38 (3,71)
DCM (Yao và Sun 2020)	ResK	WRN-28-10 (81.28)	ResNet110 (73,45)	82,18, 77,01 (3,56)
DCM (Yao và Sun 2020)	ResK	WRN-28-10 (81.28)	Mạng di động (73,70)	83,17, 78,57 (4,87)
KDCL (Guo và cộng sự, 2020)	ResK	WRN-16-2 (72,20)	ResNet32 (69,90)	75,50, 74,30 (4,40)
PCL (Wu và Gong 2021)	ResK	Đoàn sinh viên	ResNet110 (76,21)	79,98 (3,77)
PCL (Wu và Gong 2021)	ResK	Đoàn sinh viên	Mật độ mạng-40-12 (71.03)	73.09 (2.06)
ACN (Zhang và cộng sự, 2021a)	ResK	ResNet14 (66,88)	ResNet14 (66,88)	68,40 (1,52)
ACN (Zhang và cộng sự, 2021a)	ResK	VGG11 (67,38)	VGG11 (67,38)	70,11 (2,73)
ACN (Zhang và cộng sự, 2021a)	ResK	AlexNet (39,45)	AlexNet (39,45)	46,27 (6,82)
Tự chứng cất				
Xu và Liu (2019)	ResK, FeaK	-	Mạng dày đặc (74.80)	76,32 (1,52)
SD (Yang và cộng sự 2019b)	ResK	-	ResNet32 (68,39)	71,29 (2,90)
Tf-KD (Yuan và cộng sự, 2020)	ResK	-	ResNet18 (75,87)	77.10 (1.23)
Tf-KD (Yuan và cộng sự, 2020)	ResK	-	ShuffleNetV2 (70,34)	72,23 (1,89)
Tf-KD (Yuan và cộng sự, 2020)	ResK	-	ResNeXt29 (81.03)	82,08 (1,05)
CS-KD (Yun và cộng sự, 2020)	ResK	-	ResNet18 (75,29)	78.01 (2.72)

2020b; Wang và cộng sự. 2020b), image/video segmentation (He et al. 2019; Mullapudi et al. 2019; Dou et al. 2020; Liu et al. 2019h; Siam et al. 2019; Hou et al. 2020; Bergmann et al. 2020), action recognition (Luo et al. 2018; Hao and Zhang 2019; Thoker and Gall 2019; Garcia et al. 2018; Wang et al. 2019e; Wu et al. 2019b; Zhang et al. 2020c; Cui et al. 2020), object detection (Li et al. 2017; Shmelkov et al. 2017; Cun and Pun 2020; Wang et al. 2019d; Huang et al. 2020; Wei et al. 2018; Hong and Yu 2019; Chawla và cộng sự. 2021), phát hiện làn đường (Hou và cộng sự 2019), nhận dạng lại người (Wu và cộng sự 2019a), phát hiện người đi bộ (Shen và cộng sự 2016), phát hiện dấu vết trên khuôn mặt (Dong và Yang 2019), ước tính tư thế (Nie và cộng sự 2019; Zhang và cộng sự 2019a; Zhao và cộng sự 2018), chú thích video (Pan và cộng sự 2020; Zhang và cộng sự. 2020f), tìm kiếm người (Munjál và cộng sự 2019; Zhang và cộng sự 2021c), truy xuất hình ảnh (Liu và cộng sự 2019e), phát hiện bóng (Chen và cộng sự 2020c), ước tính độ mặn (Li và cộng sự 2019), ước tính độ sâu (Pilzer và cộng sự. 2019; Ye và cộng sự 2019), đo thị lực (Saputra và cộng sự 2019), tổng hợp văn bản thành hình ảnh (Yuan và Peng 2020; Tan và cộng sự 2021), phân loại video (Zhang và Peng 2018; Bhard-waj và cộng sự 2019), trả lời câu hỏi trực quan (Mun và cộng sự 2018; Aditya và cộng sự 2019) và phát hiện bất thường (Bergmann và cộng sự. 2020). Vì việc chất lọc kiến thức trong nhiệm vụ phân loại là nền tảng cho các nhiệm vụ khác, chúng tôi sẽ tóm tắt lại việc chất lọc kiến thức trong các bối cảnh phân loại hình ảnh đầy thách thức, chẳng hạn như nhận dạng khuôn mặt và nhận dạng hành động.

Các phương pháp nhận dạng khuôn mặt dựa trên KD hiện tại không chỉ tập trung vào việc triển khai hiệu quả mà còn vào độ chính xác nhận dạng cạnh tranh (Luo et al. 2016 ; Kong et al. 2019; Yan et al. 2019; Ge et al. 2018; Wang et al. 2018b, 2019c; Duong et al. 2019; Wang et al. 2017, 2020b; Zhang et al. 2020b). Cụ thể, trong Luo et al. (2016), kiến thức từ các nơ-ron thông tin được chọn của lớp gợi ý trên cùng của mạng giáo viên được chuyển vào mạng học sinh. Một chiến lược trọng số của giáo viên với sự mất mát của các biểu diễn đặc điểm từ các lớp gợi ý đã được thiết kế để chuyển giao kiến thức nhằm tránh sự giám sát không chính xác của giáo viên (Wang et al. 2018b). Một phương pháp chứng cất kiến thức đệ quy đã được thiết kế bằng cách sử dụng mạng học sinh trước đó để khởi tạo mạng tiếp theo (Yan et al. 2019). Vì hầu hết các phương pháp nhận dạng khuôn mặt đều thực hiện nhận dạng tập mở, nghĩa là các lớp/nhận dạng trên tập kiểm tra không được tập huấn luyện biết đến, nên tiêu chí nhận dạng khuôn mặt thường là số liệu khoảng cách giữa các biểu diễn đặc điểm của mẫu dương và mẫu âm, ví dụ: mất góc trong Duong et al. (2019) và mất nhúng tương quan trong Wu et al. (2020).

Để cải thiện độ chính xác nhận dạng khuôn mặt có độ phân giải thấp, khuôn khổ chứng cất kiến thức được phát triển bằng cách sử dụng các kiến trúc giữa giáo viên khuôn mặt có độ phân giải cao và học viên khuôn mặt có độ phân giải thấp để tăng tốc mô hình và cải thiện hiệu suất phân loại (Ge et al. 2018; Wang et al. 2019c; Kong et al. 2019; Ge et al. 2020). Cụ thể, Ge et al. (2018) đã đề xuất một phương pháp chứng cất kiến thức có chọn lọc,

trong đó mạng giáo viên để nhận dạng khuôn mặt có độ phân giải cao chuyển chọn lọc các đặc điểm khuôn mặt mang tính thông tin của nó vào mạng học sinh để nhận dạng khuôn mặt có độ phân giải thấp thông qua tối ưu hóa đồ thị thưa thớt. Trong Kong et al. (2019), nhận dạng khuôn mặt có độ phân giải chéo đã được thực hiện bằng cách thiết kế một mô hình bất biến độ phân giải thống nhất cả ảo giác khuôn mặt và các mạng con nhận dạng không đồng nhất. Để có được mô hình nhận dạng khuôn mặt có độ phân giải thấp hiệu quả và hiệu suất cao, độ lệch trung bình tối đa đa hạt nhân giữa mạng học sinh và giáo viên đã được áp dụng làm mất đặc điểm (Wang et al. 2019c). Ngoài ra, nhận dạng khuôn mặt dựa trên KD có thể được mở rộng để căn chỉnh và xác minh khuôn mặt bằng cách thay đổi các mất mát trong quá trình chứng cất kiến thức (Wang et al. 2017).

Gần đây, phương pháp chứng cất kiến thức đã được sử dụng thành công để giải quyết các vấn đề phân loại hình ảnh phức tạp (Zhu et al. 2019; Bagherinezhad et al. 2018; Peng et al. 2019b; Li và Hoiem 2017; Chen et al. 2018a; Wang et al. 2019b; Mukherjee et al. 2019). Đối với các nhãn hình ảnh không đầy đủ, mơ hồ và trùng lặp, mô hình tinh chỉnh nhãn thông qua quá trình tự chứng cất và tiến trình nhãn được đề xuất để học các nhãn mềm, nhiều thông tin, tập thể và động cho phân loại hình ảnh phức tạp (Bagherinezhad et al. 2018). Để giải quyết tình trạng quên thảm khốc với CNN trong nhiều tác vụ phân loại hình ảnh, một phương pháp học mà không quên cho CNN, bao gồm cả chứng cất kiến thức và học tập suốt đời được đề xuất để nhận ra tác vụ hình ảnh mới và bảo toàn các tác vụ ban đầu (Li và Hoiem 2017). Để cải thiện độ chính xác của phân loại hình ảnh, Chen et al. (2018a) đã đề xuất phương pháp chứng cất kiến thức dựa trên bản đồ đặc trưng với GAN.

Nó chuyển kiến thức từ bản đồ đặc điểm sang học sinh. Sử dụng phương pháp chứng cất kiến thức, một khuôn khổ chẩn đoán và diễn giải trực quan thống nhất các mô hình giáo viên-học sinh để diễn giải và một mô hình tạo sâu để chẩn đoán được thiết kế cho các bộ phân loại hình ảnh (Wang và cộng sự, 2019b). Tương tự như nhận dạng khuôn mặt có độ phân giải thấp dựa trên KD, Zhu và cộng sự, (2019) đã đề xuất phương pháp chứng cất đặc điểm sâu cho phân loại hình ảnh có độ phân giải thấp, trong đó các đặc điểm đầu ra của học sinh khớp với đặc điểm đầu ra của giáo viên.

Như đã lập luận trong Mục 5.3, chứng cất kiến thức với cấu trúc giáo viên-học sinh có thể chuyển giao và bảo tồn kiến thức liên phương thức. Nhận dạng hành động hiệu quả và hiệu suất trong các kịch bản nhiệm vụ liên phương thức của nó có thể được thực hiện thành công (Thoker và Gall 2019; Luo và cộng sự 2018 ; Gar-cia và cộng sự 2018; Hao và Zhang 2019; Wu và cộng sự 2019b; Zhang và cộng sự 2020c). Các phương pháp này là ví dụ về chứng cất phương thức không gian-thời gian với sự chuyển giao kiến thức khác nhau để nhận dạng hành động. Các ví dụ bao gồm mạng lưới giáo viên-học sinh tương hỗ (Thoker và Gall 2019), mạng lưới đa luồng (Garcia và cộng sự 2018), mạng lưới kết nối dày đặc được chứng cất theo không gian-thời gian (Hao và Zhang 2019), chứng cất đồ thị (Luo và cộng sự 2018) và mạng lưới đa giáo viên-đa học sinh (Wu và cộng sự 2019b; Zhang và cộng sự 2020c).

Trong số các phương pháp này, sinh viên nhẹ cân có thể chất lọc

và chia sẻ thông tin kiến thức từ nhiều phương thức được lưu trữ trong giáo viên.

Chúng tôi tóm tắt hai quan sát chính của quá trình chứng cất- dựa trên các ứng dụng nhận dạng hình ảnh như sau.

- Chất lọc kiến thức cung cấp hiệu quả và hiệu suất giáo viên-học sinh học tập cho nhiều hình ảnh khác nhau nhiệm vụ nhận dạng, vì một mạng lưới sinh viên nhẹ có thể dễ dàng được đào tạo dưới sự hướng dẫn của mạng lưới giáo viên có năng lực cao.
- Việc chứng cất kiến thức có thể tận dụng tối đa các loại kiến thức khác nhau trong các nguồn dữ liệu phức tạp, chẳng hạn như như dữ liệu đa phương thức, dữ liệu đa miền và dữ liệu đa nhiệm vụ dữ liệu và dữ liệu có độ phân giải thấp, vì giáo viên linh hoạt- kiến trúc sinh viên và chuyển giao kiến thức.

7.2 KD trong NLP

Các mô hình ngôn ngữ thông thường như BERT rất tốn thời gian tiêu thụ và tiêu thụ tài nguyên với các cấu trúc phức tạp công kênh. Chất lọc kiến thức được sử dụng rộng rãi được nghiên cứu trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), để có được các mô hình ngôn ngữ nhẹ, hiệu quả và hiệu suất cao. Ngày càng có nhiều phương pháp KD được đề xuất cho giải quyết nhiều nhiệm vụ NLP (Liu et al. 2019b; Gordon và Duh 2019; Haidar và Rezagholizadeh 2019; Yang và cộng sự. 2020c; Tăng và cộng sự. 2019; Hu và cộng sự. 2018; Sun và cộng sự. 2019; Nakashole và Flauger 2017; Jiao và cộng sự 2020; Wang và cộng sự. 2018d; Chu và cộng sự. 2019a; Sanh và cộng sự. 2019; Turc và cộng sự. 2019; Arora et al. 2019; Clark et al. 2019; Kim và Rush 2016; Mou và cộng sự. 2016; Lưu và cộng sự. 2019f; Hahn và Choi 2019; Tân và cộng sự. 2019; Kuncoro và cộng sự. 2016; Cui và cộng sự. 2017; Wei và cộng sự. 2019; Freitag và cộng sự. 2017; Shakeri và cộng sự. 2019; Aguilar và cộng sự. 2020; Fu và cộng sự 2021; Zhang và cộng sự 2021b; Chen và cộng sự 2020b; Wang và Du 2021). Các tác vụ NLP hiện có sử dụng KD bao gồm dịch máy thần kinh (NMT) (Hahn và Choi 2019; Zhou et al. 2019a; Li et al. 2021; Kim và Rush 2016; Gordon và Duh 2019; Tân và cộng sự. 2019; Wei và cộng sự. 2019; Freitag và cộng sự. 2017; Zhang và cộng sự 2021b), tạo văn bản (Chen và cộng sự 2020b; Haidar và Rezagholizadeh 2019), hệ thống trả lời câu hỏi (Hu et al. 2018; Wang et al. 2018d; Arora et al. 2019; Yang và cộng sự. 2020c), phát hiện sự kiện (Liu và cộng sự 2019b), truy xuất tài liệu (Shakeri và cộng sự 2019), nhận dạng văn bản (Wang và Du 2021) v.v. Trong số các phương pháp NLP dựa trên KD này, hầu hết chúng đều thuộc về hiểu ngôn ngữ tự nhiên (NLU), và nhiều phương pháp KD này dành cho NLU được thiết kế như chứng cất theo nhiệm vụ cụ thể (Tang et al. 2019; Turc et al. 2019; Mou et al. 2016) và chứng cất đa tác vụ (Liu et al. 2019f; Yang và cộng sự. 2020c; Sanh và cộng sự. 2019; Clark và cộng sự. 2019). Sau đây, chúng tôi mô tả các công trình nghiên cứu KD cho thần kinh dịch máy và sau đó mở rộng mô hình biểu diễn đa ngôn ngữ điển hình có tên là bộ mã hóa song hướng

biểu diễn từ máy biến áp (hoặc BERT) (Devlin et al. 2019) tại NLU. Trong xử lý ngôn ngữ tự nhiên, dịch máy thần kinh là ứng dụng nóng nhất. Tuy nhiên, các mô hình NMT hiện có với hiệu suất cạnh tranh là rất lớn. Để có được NMT nhẹ, có nhiều phương pháp chứng cất kiến thức mở rộng cho dịch máy thần kinh (Hahn và Choi 2019; Zhou và cộng sự 2019a; Kim và Rush 2016; Gor-don và Duh 2019; Wei và cộng sự 2019; Freitag và cộng sự 2017; Tan et al. 2019). Gần đây, Zhou et al. (2019a) đã chứng minh bằng thực nghiệm hiệu suất tốt hơn của KD dựa trên không hồi quy tự động mô hình dịch máy (NAT) phần lớn dựa vào khả năng của nó và dữ liệu được chất lọc thông qua việc chuyển giao kiến thức. Gordon và Duh (2019) đã giải thích hiệu suất tốt của việc chứng cất kiến thức cấp độ chuỗi từ góc độ dữ liệu tăng cường và điều chỉnh. Trong (Kim và Rush 2016), việc chất lọc kiến thức cấp độ từ ngữ hiệu quả được mở rộng đến trình tự cấp độ trong kịch bản tạo trình tự của NMT. Mô hình sinh viên tạo chuỗi mô phỏng phân phối trình tự của giáo viên. Để khắc phục sự đa dạng đa ngôn ngữ, Tan et al. (2019) đã đề xuất đa giáo viên chứng cất, trong đó nhiều mô hình cá nhân để xử lý các cặp song ngữ là giáo viên và một mô hình đa ngôn ngữ là sinh viên. Để cải thiện chất lượng bản dịch, một nhóm nhiều mô hình NMT khi giáo viên giám sát mô hình học sinh với phương pháp lọc dữ liệu Freitag et al. (2017). Để cải thiện hiệu suất của máy dịch và máy đọc nhiệm vụ, (Wei et al. 2019) đã đề xuất một kiến thức trực tuyến mới phương pháp chứng cất, giải quyết tình trạng không ổn định của quá trình đào tạo và hiệu suất giảm dần trên mỗi bộ xác thực. Trong KD trực tuyến này, mô hình được đánh giá tốt nhất trong đào tạo được chọn là giáo viên và được cập nhật bởi bất kỳ tiếp theo mô hình tốt hơn. Nếu mô hình tiếp theo có hiệu suất kém, mô hình giáo viên hiện tại sẽ hướng dẫn điều đó. Là một mô hình biểu diễn đa ngôn ngữ, BERT đã thu hút sự chú ý trong việc hiểu ngôn ngữ tự nhiên (Devlin et al. 2019), nhưng nó cũng là một mô hình sâu công kênh không dễ dàng được triển khai. Để giải quyết vấn đề này, một số các biến thể của BERT (gọi là nén mô hình BERT) sử dụng chứng cất kiến thức được đề xuất (Sun et al. 2019; Jiao và cộng sự. 2020; Tăng và cộng sự. 2019; Sanh và cộng sự. 2019; Vương và cộng sự. 2020a; Lưu và cộng sự. 2020b; Fu và cộng sự. 2021). Sun và cộng sự. (2019) đề xuất chứng cất kiến thức bệnh nhân cho BERT nén mô hình (BERT-PKD), được sử dụng để phân loại tình cảm, diễn giải lại sự giống nhau, tự nhiên suy luận ngôn ngữ và hiểu biết đọc của máy. Trong phương pháp KD của bệnh nhân, các biểu diễn đặc điểm của [CLS] token từ các lớp gợi ý của giáo viên được chuyển giao cho học sinh. Để tăng tốc quá trình suy luận ngôn ngữ, Jiao et al. (2020) đề xuất TinyBERT là máy biến áp hai tầng chứng cất kiến thức. Nó bao gồm chứng cất kiến thức chung và cụ thể cho từng nhiệm vụ. Đối với phân loại câu và phù hợp, Tang et al. (2019) đề xuất nhiệm vụ cụ thể

chúng cất kiến thức từ mô hình giáo viên BERT thành một mạng bộ nhớ dài hạn hai chiều (BiLSTM). Trong (Sanh et al. 2019), một mô hình sinh viên nhẹ có tên là Distil-BERT có cùng cấu trúc chung như BERT được thiết kế và học được nhiều nhiệm vụ khác nhau của NLP. Trong Aguilar et al. (2020), một BERT sinh viên đơn giản hóa được đề xuất bằng cách sử dụng biểu diễn nội bộ của một giáo viên lớn BERT thông qua nội bộ chúng cất.

Hơn nữa, một số phương pháp KD điển hình cho NLP với các góc nhìn khác nhau được trình bày dưới đây. Đối với câu hỏi trả lời, để cải thiện hiệu quả và tính mạnh mẽ của hiểu đọc máy, Hu et al. (2018) đề xuất một phương pháp chất lọc câu trả lời hướng dẫn sự chú ý, hợp nhất chúng cất chung và chúng cất câu trả lời để tránh gây nhầm lẫn câu trả lời. Đối với chúng cất theo nhiệm vụ cụ thể (Turc et al. 2019), hiệu suất của việc chất lọc kiến thức với tương tác giữa đào tạo trước, chúng cất và tinh chỉnh cho mô hình sinh viên nhỏ gọn được nghiên cứu. Đề xuất chúng cất được đào tạo trước thực hiện tốt trong phân loại tình cảm, suy luận ngôn ngữ tự nhiên, suy diễn văn bản. Đối với một sự chúng cất đa nhiệm vụ trong bối cảnh ngôn ngữ tự nhiên hiểu biết, Clark et al. (2019) đã đề xuất đơn-đa chúng cất tái sinh, dựa trên mạng lưới thần kinh tái sinh (Furlanello và cộng sự, 2018). Giáo viên có nhiệm vụ đơn lẻ dạy một học sinh đa nhiệm. Đối với các biểu diễn đa ngôn ngữ, chúng cất kiến thức chuyển giao kiến thức giữa các nhúng từ đa ngôn ngữ để tạo từ điển song ngữ (Nakashole và Flauger 2017). Đối với các ngôn ngữ có ít tài nguyên, việc chuyển giao kiến thức có hiệu quả trên nhiều nhóm mô hình đa ngôn ngữ (Cui et al. 2017).

Một số quan sát về việc chất lọc kiến thức cho quốc gia Quá trình xử lý ngôn ngữ của con người được tóm tắt như sau.

- Chất lọc kiến thức cung cấp hiệu quả và hiệu suất mô hình ngôn ngữ nhẹ sâu. Dung lượng lớn Mô hình giáo viên có thể truyền đạt kiến thức phong phú từ một số lượng lớn các loại dữ liệu ngôn ngữ khác nhau để đào tạo một Mô hình học sinh ít người, giúp học sinh có thể nhanh chóng hoàn thành nhiều bài tập ngôn ngữ với hiệu suất cao.
- Việc chuyển giao kiến thức giữa giáo viên và học sinh có thể dễ dàng và giải quyết hiệu quả nhiều nhiệm vụ đa ngôn ngữ, xem xét rằng kiến thức từ các mô hình đa ngôn ngữ có thể được chuyển giao và chia sẻ cho nhau.
- Trong các mô hình ngôn ngữ sâu, kiến thức trình tự có thể được chuyển giao hiệu quả từ các mạng lớn vào các mạng nhỏ mạng lưới.

7.3 KD trong Nhận dạng giọng nói

Trong lĩnh vực nhận dạng giọng nói, âm thanh thần kinh sâu các mô hình đã thu hút sự chú ý và quan tâm vì hiệu suất mạnh mẽ. Tuy nhiên, ngày càng có nhiều thời gian thực hệ thống nhận dạng giọng nói được triển khai trong nền tảng nhúng

các hình thức có tài nguyên tính toán hạn chế và phản hồi nhanh thời gian. Các mô hình phức tạp sâu hiện đại không thể đáp ứng được yêu cầu của các tình huống nhận dạng giọng nói như vậy. Để đáp ứng những yêu cầu này, việc chất lọc kiến thức là được nghiên cứu rộng rãi và ứng dụng trong nhiều nhiệm vụ nhận dạng giọng nói. Có nhiều hệ thống chúng cất kiến thức để thiết kế các mô hình âm thanh sâu nhẹ cho nhận dạng giọng nói (Chebotar và Waters 2016; Wong và Gales 2016; Chan và cộng sự. 2015; Giá và cộng sự. 2016; Fukuda và cộng sự. 2017; Bài và cộng sự. 2019; Ng và cộng sự. 2018; Albanie và cộng sự. 2018; Lu và cộng sự. 2017; Thạch và cộng sự. 2019a; Roheda và cộng sự. 2018; Shi và cộng sự. 2019b; Gao và cộng sự. 2019; Ghorbani và cộng sự. 2018; Takashima và cộng sự. 2018; Watanabe và cộng sự. 2017; Shi và cộng sự. 2019c; Asami và cộng sự. 2017; Hoàng và cộng sự. 2018; Thần và cộng sự. 2018; Perez và cộng sự. 2020; Thần và cộng sự. 2019c; Oord và cộng sự. 2018; Kwon và cộng sự. 2020; Thần và cộng sự. 2020). Đặc biệt, các ứng dụng nhận dạng giọng nói dựa trên KD này có khả năng nhận dạng ngôn ngữ nói (Shen et al. 2018, 2019c, 2020), phân loại âm thanh (Gao et al. 2019; Perez et al. 2020), nhận dạng người nói không phụ thuộc vào văn bản (Ng et al. 2018), tăng cường giọng nói (Watanabe et al. 2017), âm thanh phát hiện sự kiện (Price et al. 2016; Shi et al. 2019a, b), lời nói tổng hợp (Oord et al. 2018) v.v.

Hầu hết các phương pháp chúng cất kiến thức hiện có cho lời nói nhận dạng, sử dụng kiến trúc giáo viên-học sinh để cải thiện hiệu quả và độ chính xác nhận dạng của các mô hình âm thanh (Chan et al. 2015; Watanabe et al. 2017; Chebotar và Nước 2016; Thần và cộng sự. 2019c; Lu và cộng sự. 2017; Thần và cộng sự. 2018, 2020; Gao và cộng sự. 2019; Shi và cộng sự. 2019c, a; Perez và cộng sự. 2020). Sử dụng mạng nơ-ron hồi quy (RNN) để giữ thông tin thời gian từ các chuỗi lời nói, kiến thức từ mô hình âm thanh RNN của giáo viên được chuyển giao vào một mô hình DNN sinh viên nhỏ (Chan et al. 2015). Độ chính xác nhận dạng giọng nói tốt hơn đạt được bằng cách kết hợp nhiều chế độ âm thanh. Các nhóm RNN khác nhau với các tiêu chí đào tạo cá nhân khác nhau được thiết kế để đào tạo một mô hình sinh viên thông qua chuyển giao kiến thức (Chebotar và Waters 2016). Mô hình học sinh có học thức hoạt động tốt trên Nhận dạng giọng nói liên tục với vốn từ vựng lớn 2.000 giờ (LVCSR) nhiệm vụ trong 5 ngôn ngữ. Để tăng cường sự khái quát hóa của mô hình nhận dạng ngôn ngữ nói (LID) trên những câu nói ngắn, kiến thức về biểu diễn đặc điểm của mạng lưới giáo viên dựa trên phát ngôn dài được chuyển giao vào mạng lưới sinh viên dựa trên phát ngôn ngắn có thể phân biệt các phát ngôn ngắn và thực hiện tốt trên các phát ngôn ngắn nhiệm vụ LID dựa trên phát ngôn có thời lượng (Shen et al. 2018). Để cải thiện hơn nữa hiệu suất của LID dựa trên phát ngôn ngắn, một giáo viên tương tác-học sinh học tập chúng cất trực tuyến là được đề xuất để nâng cao hiệu suất của các biểu diễn đặc trưng của các phát ngôn ngắn (Shen et al. 2019c). LID hiệu suất trên các phát ngôn ngắn cũng được cải thiện bằng cách chất lọc kiến thức biểu diễn nội bộ của giáo viên trên các phát ngôn dài hơn những lời phát biểu thành một trong những lời phát biểu ngắn của học sinh (Shen và cộng sự 2020).

Trong khi đó, đối với phân loại âm thanh, một phương pháp chứng cất đặc điểm đa cấp được phát triển và một chiến lược học đối nghịch được áp dụng để tối ưu hóa việc truyền đạt kiến thức (Gao et al. 2019). Để cải thiện khả năng nhận dạng giọng nói mạnh mẽ với tiếng ồn, chứng cất kiến thức được sử dụng như một công cụ tăng cường giọng nói (Watanabe et al. 2017). Trong Perez et al. (2020), một phương pháp chứng cất kiến thức đa phương thức nghe nhìn được đề xuất. Kiến thức được chuyển từ các mô hình giáo viên trên dữ liệu hình ảnh và âm thanh sang mô hình học sinh trên dữ liệu âm thanh.

Về bản chất, quá trình chứng cất này chia sẻ kiến thức liên phương thức giữa giáo viên và học sinh (Perez et al. 2020; Albanie et al. 2018; Roheda et al. 2018). Để phát hiện sự kiện âm thanh hiệu quả, một phương pháp chứng cất lượng tử được đề xuất bằng cách sử dụng cả chứng cất kiến thức và lượng tử hóa (Shi et al. 2019a). Chứng cất lượng tử chuyển kiến thức từ mô hình giáo viên CNM lớn có độ chính xác phát hiện tốt hơn sang mô hình học sinh RNN lượng tử hóa.

Không giống như hầu hết các phương pháp KD cấp khung truyền thống hiện có, KD cấp chuỗi có thể hoạt động tốt hơn trong một số mô hình chuỗi để nhận dạng giọng nói, chẳng hạn như phân loại thời gian kết nối (CTC) (Wong và Gales 2016; Takashima và cộng sự 2018; Huang và cộng sự 2018). Trong (Huang và cộng sự 2018), KD cấp chuỗi được đưa vào phân loại thời gian kết nối, để khớp với chuỗi nhãn đầu ra được sử dụng trong quá trình đào tạo mô hình giáo viên và khung giọng nói đầu vào được sử dụng trong quá trình chứng cất. Trong Wong và Gales (2016), tác động của hiệu suất nhận dạng giọng nói đối với đào tạo giáo viên-học sinh cấp khung và cấp chuỗi được nghiên cứu và một phương pháp đào tạo giáo viên-học sinh cấp chuỗi mới được đề xuất.

Nhóm giáo viên được xây dựng bằng cách sử dụng kết hợp cấp trình tự thay vì kết hợp cấp khung. Để cải thiện hiệu suất của CTC dựa trên RNN đơn hướng cho nhận dạng giọng nói thời gian thực, kiến thức của mô hình giáo viên CTC dựa trên LSTM hai hướng được chuyển thành mô hình học sinh CTC dựa trên LSTM đơn hướng thông qua cấp khung

KD và KD cấp độ trình tự (Takashima và cộng sự, 2018). Hơn nữa, chứng cất kiến thức có thể được sử dụng để giải quyết một số vấn đề đặc biệt trong nhận dạng giọng nói (Bai và cộng sự, 2019; Asami và cộng sự, 2017; Ghorbani và cộng sự, 2018). Để khắc phục vấn đề quá khớp của các mô hình âm thanh DNN khi dữ liệu khan hiếm, chứng cất kiến thức được sử dụng như một cách chính quy hóa để đào tạo mô hình đã điều chỉnh với sự giám sát của mô hình nguồn (Asami và cộng sự, 2017). Mô hình đã điều chỉnh cuối cùng đạt được hiệu suất tốt hơn trên ba miền âm thanh thực. Để khắc phục sự suy giảm hiệu suất của nhận dạng giọng nói không phải tiếng mẹ đẻ, một mô hình học viên đa giọng năng cao được đào tạo bằng cách chứng cất kiến thức từ nhiều mô hình RNN-CTC dành riêng cho nhiều giọng (Ghorbani và cộng sự, 2018). Về bản chất, chứng cất kiến thức trong (Asami và cộng sự, 2017; Ghorbani và cộng sự, 2018) hiện thực hóa việc chuyển giao kiến thức xuyên miền. Để giải quyết sự phức tạp của việc hợp nhất mô hình ngôn ngữ bên ngoài (LM) vào mô hình chuỗi-sang-chuỗi (Seq2seq) cho nhận dạng giọng nói, phương pháp chất lọc kiến thức được sử dụng như một công cụ hiệu quả.

để tích hợp LM (giáo viên) vào mô hình Seq2seq (học sinh) (Bai và cộng sự, 2019). Mô hình Seq2seq được đào tạo có thể giảm tỷ lệ lỗi ký tự trong nhận dạng giọng nói theo trình tự.

Tóm lại, một số quan sát về nhận dạng giọng nói dựa trên sự chất lọc kiến thức có thể được kết luận như sau.

- Mô hình học sinh nhẹ có thể đáp ứng các yêu cầu thực tế của nhận dạng giọng nói, chẳng hạn như phản hồi thời gian thực, sử dụng tài nguyên hạn chế và độ chính xác nhận dạng cao.
- Nhiều kiến trúc giáo viên-học sinh được xây dựng trên các mô hình RNN và tính chất thời gian của các chuỗi lời nói. Nhìn chung, các mô hình RNN được chọn làm giáo viên, có thể bảo toàn và chuyển giao tốt kiến thức thời gian từ dữ liệu âm thanh thực tế sang mô hình học sinh.
- Chất lọc kiến thức cấp độ chuỗi có thể được áp dụng tốt cho các mô hình chuỗi có hiệu suất tốt. Trên thực tế, KD cấp độ khung luôn sử dụng kiến thức dựa trên phản hồi, nhưng KD cấp độ chuỗi thường chuyển giao kiến thức dựa trên đặc điểm từ các lớp gợi ý của các mô hình giáo viên.
- Chất lọc kiến thức bằng cách chuyển giao kiến thức giữa giáo viên và học sinh có thể dễ dàng giải quyết vấn đề nhận dạng giọng nói liên miền hoặc liên phương thức trong các ứng dụng như nhận dạng giọng nói đa giọng và đa ngôn ngữ.

7.4 KD trong các ứng dụng khác

Đòn bẩy đầy đủ và chính xác của kiến thức bên ngoài, chẳng hạn như trong đánh giá của người dùng hoặc trong hình ảnh, đóng vai trò rất quan trọng trong hiệu quả của các mô hình đề xuất sâu. Việc giảm độ phức tạp và cải thiện hiệu quả của các mô hình đề xuất sâu cũng rất cần thiết. Gần đây, chứng cất kiến thức đã được áp dụng thành công trong các hệ thống đề xuất để nén và tăng tốc mô hình sâu (Chen và cộng sự 2018b; Tang và Wang 2018; Pan và cộng sự 2019). Trong (Tang và Wang 2018), chứng cất kiến thức lần đầu tiên được đưa vào các hệ thống đề xuất và được gọi là chứng cất xếp hạng vì đề xuất được thể hiện dưới dạng một vấn đề xếp hạng. Chen và cộng sự (2018b) đã đề xuất một phương pháp chứng cất kiến thức đối kháng để đề xuất hiệu quả. Một giáo viên là mạng dự đoán đánh giá phù hợp giám sát học sinh như mạng dự đoán người dùng-mục (máy phát). Việc học của học sinh được điều chỉnh thông qua sự thích ứng đối kháng giữa mạng giáo viên và học sinh. Không giống như chứng cất trong Chen và cộng sự (2018b), Tang và Wang (2018), Pan et al. (2019) đã thiết kế một mô hình mã hóa tự động khử nhiễu cộng tác nâng cao (ECAE) cho các hệ thống đề xuất thông qua việc chứng cất kiến thức để nắm bắt kiến thức hữu ích từ phản hồi của người dùng và giảm nhiễu. Khung ECAE thống nhất chứa

mạng lưới thể hệ, mạng lưới đào tạo lại và lớp chứng cất giúp chuyển giao kiến thức và giảm nhiễu từ mạng lưới thể hệ.

Sử dụng đặc điểm tự nhiên của quá trình chứng cất kiến thức với kiến trúc giáo viên-học sinh, quá trình chứng cất kiến thức được sử dụng như một chiến lược hiệu quả để giải quyết các cuộc tấn công đối nghịch hoặc nhiễu loạn của các mô hình sâu (Papernot et al. 2016; Ross và Doshi-Velez 2018; Goldblum et al. 2020; Gil et al. 2019) và vấn đề dữ liệu không khả dụng do các lo ngại về quyền riêng tư, tính bảo mật và an ninh (Lopes et al. 2017; Papernot et al. 2017; Wang et al. 2019a; Bai et al. 2020; Vongkulbhisal et al. 2019). Cụ thể hơn, các nhiễu loạn của các mẫu đối nghịch có thể được khắc phục bằng các đầu ra mạnh mẽ của mạng lưới giáo viên thông qua quá trình chứng cất (Ross và Doshi-Velez 2018; Papernot et al. 2016). Để tránh tiết lộ dữ liệu riêng tư, nhiều giáo viên truy cập các tập hợp con của dữ liệu nhạy cảm hoặc không có nhãn và giám sát học sinh (Papernot et al. 2017; Vongkulbhisal et al. 2019). Để giải quyết vấn đề về quyền riêng tư và bảo mật, dữ liệu để đào tạo mạng học sinh được tạo ra bằng cách sử dụng các kích hoạt lớp hoặc kích hoạt phổ lớp của mạng giáo viên thông qua chứng cất không có dữ liệu (Lopes et al. 2017). Để bảo vệ quyền riêng tư dữ liệu và ngăn chặn vi phạm bản quyền trí tuệ, Wang và cộng sự (2019a) đã đề xuất một khuôn khổ nén mô hình riêng tư thông qua chứng cất kiến thức. Mô hình học sinh được áp dụng cho dữ liệu công khai trong khi mô hình giáo viên được áp dụng cho cả dữ liệu nhạy cảm và công khai. Chứng cất kiến thức riêng tư này áp dụng mất quyền riêng tư và mất hàng loạt để cải thiện quyền riêng tư hơn nữa. Để xem xét sự thỏa hiệp giữa quyền riêng tư và hiệu suất, Bai và cộng sự (2020) đã phát triển một phương pháp nén mạng lưới vài lần thông qua chứng cất kiến thức theo từng lớp mới với một vài mẫu trên mỗi lớp. Tất nhiên, còn có những ứng dụng thú vị đặc biệt khác của chứng cất kiến thức, chẳng hạn như tìm kiếm kiến trúc nơ-ron (Macko và cộng sự 2019; Bashivan và cộng sự 2019), khả năng diễn giải của mạng nơ-ron sâu (Liu và cộng sự 2018b) và học liên bang (Bistrantz và cộng sự 2020; Lin và cộng sự 2020; Seo và cộng sự 2020; He và cộng sự 2020a).

8 Kết luận và thảo luận

Chứng cất kiến thức và các ứng dụng của nó đã thu hút được sự chú ý đáng kể trong vài năm gần đây. Trong bài báo này, chúng tôi trình bày một đánh giá toàn diện về chứng cất kiến thức, từ góc độ kiến thức, các chương trình chứng cất, kiến trúc giáo viên-học sinh, thuật toán chứng cất, so sánh hiệu suất và các ứng dụng. Dưới đây, chúng tôi thảo luận về những thách thức của chứng cất kiến thức và cung cấp một số hiểu biết sâu sắc về nghiên cứu trong tương lai về chứng cất kiến thức.

8.1 Thách thức

Đối với việc chất lọc kiến thức, chìa khóa là 1) trích xuất kiến thức phong phú từ giáo viên và 2) chuyển giao kiến thức từ giáo viên để hướng dẫn đào tạo học sinh. Do đó, chúng tôi thảo luận về những thách thức trong việc chất lọc kiến thức từ các khía cạnh sau: chất lượng kiến thức, các loại

sự chứng cất, thiết kế kiến trúc giáo viên-học sinh và lý thuyết đằng sau sự chứng cất kiến thức.

Hầu hết các phương pháp KD đều tận dụng sự kết hợp của nhiều loại kiến thức khác nhau, bao gồm kiến thức dựa trên phản hồi, dựa trên đặc điểm và dựa trên mối quan hệ. Do đó, điều quan trọng là phải biết ảnh hưởng của từng loại kiến thức riêng lẻ và biết các loại kiến thức khác nhau giúp ích cho nhau theo cách bổ sung như thế nào. Ví dụ, kiến thức dựa trên phản hồi có động lực tương tự như làm mịn nhãn và chính quy hóa mô hình (Kim và Kim 2017; Muller và cộng sự 2019; Ding và cộng sự 2019); Kiến thức dựa trên đặc điểm thường được sử dụng để mô phỏng quá trình trung gian của giáo viên và kiến thức dựa trên mối quan hệ được sử dụng để nắm bắt các mối quan hệ giữa các mẫu khác nhau.

Để đạt được mục đích này, vẫn còn nhiều thách thức khi mô hình hóa các loại kiến thức khác nhau trong một khuôn khổ thống nhất và bổ sung. Ví dụ, kiến thức từ các lớp gợi ý khác nhau có thể có những ảnh hưởng khác nhau đến việc đào tạo mô hình học viên: 1) kiến thức dựa trên phản hồi đến từ lớp cuối cùng; 2) kiến thức dựa trên đặc điểm từ các lớp gợi ý/hướng dẫn sâu hơn có thể bị quá chính quy hóa (Romero và cộng sự, 2015).

Cách thức chuyển giao kiến thức phong phú từ giáo viên sang học sinh là một bước quan trọng trong quá trình chứng cất kiến thức. Nhìn chung, các phương pháp chứng cất hiện có có thể được phân loại thành chứng cất ngoại tuyến, chứng cất trực tuyến và tự chứng cất. Chứng cất ngoại tuyến thường được sử dụng để chuyển giao kiến thức từ mô hình giáo viên phức tạp, trong khi mô hình giáo viên và mô hình học sinh có thể so sánh được trong bối cảnh chứng cất trực tuyến và tự chứng cất. Để cải thiện hiệu quả của quá trình chuyển giao kiến thức, cần nghiên cứu thêm mối quan hệ giữa độ phức tạp của mô hình và các lược đồ chứng cất hiện có hoặc các lược đồ chứng cất mới lạ khác (Sun và cộng sự, 2021) .

Hiện nay, hầu hết các phương pháp KD tập trung vào các loại hàm mất kiến thức hoặc hàm mất chứng cất mới, khiến cho việc thiết kế kiến trúc giáo viên-học sinh ít được nghiên cứu (Nowak và Corso 2018; Crowley và cộng sự 2018; Kang và cộng sự 2020; Liu và cộng sự 2019i; Ashok và cộng sự 2018; Liu và cộng sự 2019a). Trên thực tế, ngoài các thuật toán kiến thức và chứng cất, mối quan hệ giữa các cấu trúc của giáo viên và học sinh cũng ảnh hưởng đáng kể đến hiệu suất chứng cất kiến thức. Ví dụ, một mặt, một số công trình gần đây nhận thấy rằng mô hình học sinh có thể học được ít từ một số mô hình giáo viên

do khoảng cách năng lực mô hình giữa mô hình giáo viên và mô hình học sinh (Zhang và cộng sự 2019b; Kang và cộng sự 2020); Mặt khác, từ một số phân tích lý thuyết ban đầu về năng lực của mạng nơ-ron, mạng nông có khả năng học cùng một biểu diễn như mạng nơ-ron sâu (Ba và Caruana 2014). Do đó, việc thiết kế một mô hình học sinh hiệu quả hoặc xây dựng một mô hình giáo viên phù hợp vẫn là những vấn đề đầy thách thức trong quá trình chất lọc kiến thức.

Mặc dù có rất nhiều phương pháp và ứng dụng chứng cất kiến thức, nhưng sự hiểu biết về chứng cất kiến thức bao gồm các giải thích lý thuyết và kinh nghiệm

đánh giá hiệu quả vẫn chưa đủ (Lopez-Paz và cộng sự [2016](#); Phuong và Lampert [2019a](#); Cho và Hariharan [2019](#)). Ví dụ, chúng cất có thể được xem như một hình thức học tập với thông tin đặc quyền (Lopez-Paz và cộng sự [2016](#)). Giả định về mô hình giáo viên và học sinh tuyến tính cho phép nghiên cứu các giải thích lý thuyết về đặc điểm học tập của học sinh thông qua chúng cất (Phuong và Lampert [2019a](#)). Hơn nữa, một số đánh giá và phân tích thực nghiệm về hiệu quả của chúng cất kiến thức đã được Cho và Hariharan ([2019](#)) **thực hiện**. Tuy nhiên, vẫn rất khó để đạt được sự hiểu biết sâu sắc về khả năng khái quát hóa của chúng cất kiến thức, đặc biệt là cách đo lường chất lượng kiến thức hoặc chất lượng của kiến trúc giáo viên-học sinh.

8.2 Hướng đi trong tương lai

Để cải thiện hiệu suất chất lọc kiến thức, các yếu tố quan trọng nhất bao gồm loại kiến trúc mạng lưới giáo viên-học sinh, loại kiến thức nào được học từ mạng lưới giáo viên và nơi được chất lọc vào mạng lưới học sinh.

Các phương pháp nén và tăng tốc mô hình cho mạng nơ-ron sâu thường thuộc bốn loại khác nhau, cụ thể là cắt tỉa và chia sẻ tham số, phân tích bậc thấp, bộ lọc tích chập nhỏ gọn được chuyển giao và chúng cất kiến thức (Cheng và cộng sự, [2018](#)). Trong các phương pháp chúng cất kiến thức hiện có, chỉ có một số ít công trình liên quan thảo luận về sự kết hợp giữa chúng cất kiến thức và các loại phương pháp nén khác. Ví dụ, chúng cất kiến thức lượng tử, có thể được coi là phương pháp cắt tỉa tham số, tích hợp lượng tử hóa mạng vào kiến trúc giáo viên-học sinh (Polino và cộng sự, [2018](#); Mishra và Marr , [2018](#); Wei và cộng sự, [2018](#)). Do đó, để tìm hiểu các mô hình sâu nhẹ hiệu quả và hiệu quả để triển khai trên các nền tảng di động, các phương pháp nén kết hợp thông qua cả chúng cất kiến thức và các kỹ thuật nén khác là cần thiết, vì hầu hết các kỹ thuật nén đều yêu cầu quy trình đào tạo lại/điều chỉnh chính xác. Hơn nữa, cách quyết định thứ tự thích hợp để áp dụng các phương pháp nén khác nhau sẽ là một chủ đề thú vị cho các nghiên cứu trong tương lai.

Ngoài việc nén mô hình để tăng tốc cho mạng nơ-ron sâu, việc chất lọc kiến thức cũng có thể được sử dụng trong các vấn đề khác do đặc điểm tự nhiên của việc truyền đạt kiến thức trên kiến trúc giáo viên-học sinh.

Gần đây, chúng cất kiến thức đã được áp dụng vào quyền riêng tư và bảo mật dữ liệu (Wang và cộng sự [2019a](#)), các cuộc tấn công đối nghịch của các mô hình sâu (Papernot và cộng sự [2016](#)), các phương thức liên mô hình (Gupta và cộng sự [2016](#)), nhiều miền (Asami và cộng sự [2017](#)), quên thảm khốc (Lee và cộng sự [2019b](#)), tăng tốc quá trình học các mô hình sâu (Chen và cộng sự [2016](#)), hiệu quả tìm kiếm kiến trúc nơ-ron (Bashivan và cộng sự [2019](#)), tự giám sát (Noroozi và cộng sự [2018](#)) và tăng cường dữ liệu (Lee và cộng sự [2019a](#); Gordon và Duh [2019](#)). Một kỳ thi thú vị khác là

Điều này có nghĩa là việc chuyển giao kiến thức từ các mạng lưới giáo viên nhỏ sang một mạng lưới học sinh lớn có thể đẩy nhanh quá trình học tập của học sinh (Chen và cộng sự, [2016](#)). Điều này rất khác so với quá trình chúng cất kiến thức thông thường. Các biểu diễn đặc điểm được học từ dữ liệu không có nhãn bởi một mô hình lớn cũng có thể giám sát mô hình mục tiêu thông qua quá trình chúng cất (Noroozi và cộng sự, [2018](#)). Vì mục đích này, việc mở rộng quá trình chất lọc kiến thức cho các mục đích và ứng dụng khác có thể là hướng đi có ý nghĩa trong tương lai.

Việc học chúng cất kiến thức cũng tương tự như việc học của con người. Có thể phổ biến việc chuyển giao kiến thức sang các phương pháp học máy cổ điển và truyền thống (Zhou et al. [2019b](#); Gong et al. [2018](#); You et al. [2018](#); Gong et al. [2017](#)). Ví dụ, phân loại hai giai đoạn truyền thống được đúc kết thành một bài toán một giáo viên một học sinh dựa trên ý tưởng chúng cất kiến thức (Zhou et al. [2019b](#)). Hơn nữa, quá trình chất lọc kiến thức có thể được triển khai linh hoạt cho nhiều chương trình học tuyệt vời khác nhau, chẳng hạn như học đối nghịch (Liu và cộng sự, [2018](#)), học máy tự động (Macko và cộng sự, [2019](#); Fakoor và cộng sự, [2020](#)), học lọc nhiễu nhãn (Xia và cộng sự, [2018](#)), học suốt đời (Zhai và cộng sự, [2019](#)) và học tăng cường (Ashok và cộng sự, [2018](#); Xu và cộng sự, [2020c](#); Zhao và Hospedales, [2020](#)).

Do đó, việc tích hợp chất lọc kiến thức với các chương trình học tập khác để giải quyết những thách thức thực tế trong tương lai sẽ rất hữu ích.

Lời cảm ơn Công trình này được hỗ trợ một phần bởi Dự án FL-170100117, IH-180100002, IC-190100 031 của Hội đồng nghiên cứu Úc và Quỹ khoa học tự nhiên quốc gia Trung Quốc 61976107.

Tài liệu tham khảo

Aditya, S., Saha, R., Yang, Y., & Baral, C. (2019). Chất lọc kiến thức không gian để hỗ trợ lý luận trực quan. Trong WACV.

Aguilar, G., Ling, Y., Zhang, Y., Yao, B., Fan, X., & Guo, E. (2020). Chất lọc kiến thức từ các biểu diễn nội bộ. Trong AAAI.

Aguinaldo, A., Chiang, PY, Gain, A., Patil, A., Pearson, K., & Feizi, S. (2019). Nén gans bằng cách chúng cất kiến thức. Bản in trước arXiv [arXiv:1902.00159](#).

Ahn, S., Hu, S., Damianou, A., Lawrence, ND, & Dai, Z. (2019). Chúng cất thông tin biến đổi để chuyển giao kiến thức. Trong CVPR.

Albanie, S., Nagrani, A., Vedaldi, A., & Zisserman, A. (2018). Nhận dạng cảm xúc trong lời nói bằng cách sử dụng chuyển giao đa phương thức trong tự nhiên. Trong ACM MM.

Allen-Zhu, Z., Li, Y., & Liang, Y. (2019). Học tập và khái quát hóa trong mạng nơ-ron tham số hóa quá mức, vượt ra ngoài hai lớp. Trong NeurIPS.

Anil, R., Pereyra, G., Passos, A., Ormandi, R., Dahl, GE, & Hinton, G. E. (2018). Đào tạo mạng nơ-ron phân tán quy mô lớn thông qua chúng cất trực tuyến. Trong ICLR.

Aroza, S., Cohen, N., & Hazan, E. (2018). Về việc tối ưu hóa mạng lưới sâu: Tăng tốc ngầm bằng cách tham số hóa quá mức. Trong ICML.

Aroza, S., Khapra, MM, & Ramaswamy, HG (2019). Về việc chất lọc kiến thức từ các mạng lưới phức tạp để dự đoán phản ứng. Trong NAACL-HLT.

Asami, T., Masumura, R., Yamaguchi, Y., Masataki, H., & Aono, Y. (2017). Thích ứng miền của các mô hình âm thanh dnn bằng cách chứng cất kiến thức. Trong ICASSP.

Ashok, A., Rhinehart, N., Beainy, F., & Kitani, KM (2018). Học N2N: Nén mạng sang mạng thông qua học tăng cường gradient chính sách. Trong ICLR.

Asif, U., Tang, J. & Harrer, S. (2020). Chất lọc kiến thức tổng hợp để học các mạng lưới được cải thiện và hiệu quả. Trong ECAI.

Ba, J., & Caruana, R. (2014). Lưới sâu có thực sự cần phải sâu không? Trong Thần kinh học

Bagherinezhad, H., Horton, M., Rastegari, M., & Farhadi, A. (2018). Nhà máy tính chính nhân: Cải thiện phân loại imagenet thông qua tiến trình nhân. Bản in trước arXiv [arXiv:1805.02641](#).

Bai, H., Wu, J., King, I., & Lyu, M. (2020). Một số mạng lưới ảnh nén sion thông qua chứng cất chéo. Trong AAAI.

Bai, Y., Yi, J., Tao, J., Tian, Z., & Wen, Z. (2019). Học chính tả từ giáo viên: chuyển kiến thức từ mô hình ngôn ngữ sang nhận dạng giọng nói theo trình tự. Trong Interspeech.

Bashivan, P., Tensen, M., & DiCarlo, JJ (2019). Tìm kiếm kiến trúc có sự hướng dẫn của giáo viên. Trong ICCV.

Belagiannis, V., Farshad, A., & Galasso, F. (2018). Nén mạng đối nghịch. Trong ECCV.

Bengio, Y., Courville, A., & Vincent, P. (2013). Học tập biểu diễn: Một đánh giá và góc nhìn mới. IEEE TPAMI, 35(8), 1798-1828.

Bergmann, P., Fauser, M., Sattlegger, D., & Steger, C. (2020). Học sinh chưa được đào tạo: Phát hiện bất thường giữa học sinh và giáo viên với những tiềm ẩn phân biệt đối xử. Trong CVPR.

Bhardwaj, S., Srinivasan, M., & Khapra, MM (2019). Video hiệu quả phân loại sử dụng ít khung hơn. Trong CVPR.

Bistrutz, I., Mann, A., & Bambos, N. (2020). Chứng cất phân tán cho Học tập trên thiết bị. Trong NeurIPS.

Bohdal, O., Yang, Y., & Hospedales, T. (2020). Chứng cất bộ dữ liệu linh hoạt: Học nhân thay vì hình ảnh. Bản in trước arXiv [arXiv:2006.08572](#).

Boo, Y., Shin, S., Choi, J., & Sung, W. (2021). Tổ hợp độ chính xác ngẫu nhiên: chứng cất kiến thức bản thân cho mạng nơ-ron sâu lượng tử. Trong AAAI.

Brutzkus, A., & Globerson, A. (2019). Tại sao các mô hình lớn hơn lại tổng quát hóa tốt hơn? Một góc nhìn lý thuyết thông qua bài toán XOR. Trong Tiếng Việt: DOL

Bucilua, C., Caruana, R. & Niculescu-Mizil, A. (2006). Nén mô hình. Trong SIGKDD.

Caccia, M., Rodriguez, P., Ostapenko, O., Normandin, F., Lin, M., Cac-cia, L., Laradji, I., Rish, I., Lacoste, A., Vazquez D., & Charlin, L. (2020). Thích ứng nhanh trực tuyến và tích lũy kiến thức (OSAKA): Một cách tiếp cận mới cho việc học liên tục. Trong NeurIPS.

Chan, W., Ke, NR, & Lane, I. (2015). Chuyển kiến thức từ RNN sang DNN. Bản in trước arXiv [arXiv:1504.01483](#).

Chawla, A., Yin, H., Molchanov, P., & Alvarez, J. (2021). Không có dữ liệu Chất lọc kiến thức để phát hiện đối tượng. Trong WACV.

Chebotar, Y. & Waters, A. (2016). Chất lọc kiến thức từ các nhóm mạng nơ-ron để nhận dạng giọng nói. Trong Interspeech.

Chen, D., Mei, JP, Wang, C., Feng, Y. & Chen, C. (2020a). Chất lọc kiến thức trực tuyến với nhiều đồng nghiệp khác nhau. Trong AAAI.

Chen, D., Mei, JP, Zhang, Y., Wang, C., Wang, Z., Feng, Y., & Chen, C. (2021). Chứng cất chéo với hiệu chuẩn ngữ nghĩa. Trong AAAI.

Chen, G., Choi, W., Yu, X., Han, T., & Chandraker, M. (2017). Học các mô hình phát hiện đối tượng hiệu quả với sự chất lọc kiến thức. Trong NeurIPS.

Chen, H., Wang, Y., Xu, C., Yang, Z., Liu, C., Shi, B., Xu, C., Xu, C., & Tian, Q. (2019a). Học tập không cần dữ liệu của mạng lưới sinh viên. Trong ICCV.

Chen, H., Wang, Y., Xu, C., Xu, C., & Tao, D. (2021). Học mạng lưới sinh viên thông qua những tính năng. IEEE TNNLS, 32(1), 25-35.

Chen, T., Goodfellow, I. & Shlens, J. (2016). Net2net: Tăng tốc học tập thông qua chuyển giao kiến thức. Trong ICLR.

Chen, WC, Chang, CC & Lee, CR (2018a). Chứng cất kiến thức với bản đồ đặc trưng để phân loại hình ảnh. Trong ACCV.

Chen, X., Zhang, Y., Xu, H., Qin, Z., & Zha, H. (2018b). Chứng cất đối nghịch để đưa ra khuyến nghị hiệu quả với kiến thức bên ngoài. ACM TOIS, 37(1), 1-28.

Chen, X., Su, J., & Zhang, J. (2019b). Một framework hai giáo viên cho chất lọc kiến thức. Trong ISNN.

Chen, Y., Wang, N., & Zhang, Z. (2018c). Darkrank: Tăng tốc học số liệu sâu thông qua chuyển giao điểm tương đồng giữa các mẫu. Trong AAAI.

Chen, YC, Gan, Z., Cheng, Y., Liu, J., & Liu, J. (2020b). Chất lọc kiến thức học được trong BERT để tạo văn bản. Trong ACL.

Chen, YC, Lin, YY, Yang, MH, Huang, JB (2019c). Crdoco: Chuyển miền cấp độ pixel với tính nhất quán giữa các miền. Trong CVPR.

Chen, Z., & Liu, B. (2018). Học máy suốt đời. Bài giảng tổng hợp về Trí tuệ nhân tạo và Học máy, 12(3), 1-207.

Chen, Z., Zhu, L., Wan, L., Wang, S., Feng, W., & Heng, PA (2020c). Một giáo viên có khả năng thực hiện nhiều nhiệm vụ để phát hiện bóng tối có giám sát bản phân. Trong CVPR.

Cheng, Y., Wang, D., Zhou, P., & Zhang, T. (2018). Nén và tăng tốc mô hình cho mạng nơ-ron sâu: Các nguyên tắc, tiến trình và thách thức. Tạp chí Xử lý tín hiệu IEEE, 35(1), 126-136.

Cheng, X., Rao, Z., Chen, Y., & Zhang, Q. (2020). Giải thích quá trình chứng cất kiến thức bằng cách định lượng kiến thức. Trong CVPR.

Cho, JH & Hariharan, B. (2019). Về hiệu quả của việc chất lọc kiến thức. Trong ICCV.

Chollet, F. (2017). Xception: Học sâu với tích chập tách biệt theo chiều sâu. Trong CVPR.

Chung, I., Park, S., Kim, J. & Kwak, N. (2020). Chất lọc kiến thức đối kháng trực tuyến ở cấp độ bản đồ tính năng. Trong ICML.

Clark, K., Lương, MT, Khandelwal, U., Manning, CD & Lê, QV (2019). Bam! mạng đa nhiệm tái sinh để hiểu ngôn ngữ tự nhiên. Trong ACL.

Courbariaux, M., Bengio, Y. & David, JP (2015). Binaryconnect: Đào tạo mạng nơ-ron sâu với trọng số nhị phân trong quá trình truyền bá. Trong NeurIPS.

Crowley, EJ, Gray, G. & Storkey, AJ (2018). Moonshine: Chứng cất với các phép tích chập giá rẻ. Trong NeurIPS.

Cui, J., Kingsbury, B., Ramabhadran, B., Saon, G., Sercu, T., Audhkhasi, K., et al. (2017). Chất lọc kiến thức trên các nhóm mô hình đa ngôn ngữ cho các ngôn ngữ có ít tài nguyên. Trong ICASSP.

Cui, Z., Song, T., Wang, Y., & Ji, Q. (2020). Mạng lưới nơ-ron sâu tăng cường kiến thức để nhận dạng biểu cảm khuôn mặt và đơn vị hành động. Trong NeurIPS.

Cun, X., & Pun, CM (2020). Phát hiện mờ mắt nét thông qua chứng cất độ sâu. Trong ECCV.

Đặng, J., Dong, W., Socher, R., Li, LJ, Li, K., & Fei-Fei, L. (2009). Imagenet: Cơ sở dữ liệu hình ảnh phân cấp quy mô lớn. Trong CVPR.

Denton, EL, Zaremba, W., Bruna, J., LeCun, Y. & Fergus, R. (2014). Khai thác cấu trúc tuyến tính trong mạng tích chập để đánh giá hiệu quả. Trong NeurIPS.

Devlin, J., Chang, MW, Lee, K. & Toutanova, K. (2019). Bert: Đào tạo trước các bộ biến đổi song hướng sâu để hiểu ngôn ngữ. Trong NAACL-HLT .

Ding, Q., Wu, S., Sun, H., Guo, J. & Xia, ST (2019). Quy trình chuẩn hóa thích ứng của nhân. Bản in trước arXiv [arXiv :1908.05474](#).

Do, T., Do, TT, Tran, H., Tjiputra, E. & Tran, QD (2019). Tương tác tam tuyến tính nhỏ gọn để trả lời câu hỏi trực quan. Trong ICCV.

Dong, X. & Yang, Y. (2019). Giáo viên hướng dẫn học sinh cách học từ hình ảnh được gắn nhãn một phần để phát hiện điểm mốc trên khuôn mặt. Trong ICCV.

Dou, Q., Liu, Q., Heng, PA, & Glocker, B. (2020). Phân đoạn đa phương thức không ghép đôi thông qua chứng cất kiến thức. IEEE TMI, 39(7), 2415-2425.

Du, S., You, S., Li, X., Wu, J., Wang, F., Qian, C., & Zhang, C. (2020). Đồng ý không đồng ý: Chất lọc kiến thức tổng hợp thích ứng trong không gian gradient. Trong NeurIPS.

Duong, CN, Luu, K., Quach, KG & Le, N. (2019.) ShrinkTeaNet: Nhận dạng khuôn mặt nhẹ quy mô hàng triệu thông qua mạng lưới giáo viên-học sinh thu hẹp. Bản in trước arXiv arXiv :1905.10620.

Fakoor, R., Mueller, JW, Erickson, N., Chaudhari, P., & Smola, AJ (2020). Các mô hình nhanh, chính xác và đơn giản cho dữ liệu dạng bảng thông qua chứng cất tăng cường. Trong NeurIPS.

Flennerhag, S., Moreno, PG, Lawrence, ND & Damianou, A. (2019). Chuyển giao kiến thức qua các quá trình học tập. Trong ICLR.

Freitag, M., Al-Onaizan, Y. & Sankaran, B. (2017). Chứng cất tổng hợp cho dịch máy thần kinh. Bản in trước arXiv arXiv:1702.01802.

Fu, H., Chu, S., Yang, Q., Tang, J., Liu, G., Liu, K., & Li, X. (2021). LRC-BERT: Chất lọc kiến thức tương phản biểu diễn tiềm ẩn để hiểu ngôn ngữ tự nhiên. Trong AAAI.

Fukuda, T., Suzuki, M., Kurata, G., Thomas, S., Cui, J. & Ramabhadran, B. (2017). Chất lọc kiến thức hiệu quả từ một nhóm giáo viên. Trong Interspeech.

Furlanello, T., Lipton, Z., Tschannen, M., Itti, L. & Anandkumar, A. (2018). Mạng nơ-ron tái sinh. Trong ICML.

Gao, L., Mi, H., Zhu, B., Feng, D., Li, Y., & Peng, Y. (2019). Một phương pháp chứng cất đặc điểm đối nghịch để phân loại âm thanh. IEEE Access, 7, 105319-105330.

Gao, M., Wang, Y., & Wan, L. (2021). Kiến thức dựa trên lỗi còn lại chứng cất. Neurocomputing, 433, 154-161.

Gao, Z., Chung, J., Abdelrazek, M., Leung, S., Hau, WK, Xian, Z., et al. (2020). Chứng cất phương thức đặc quyền để phát hiện ranh giới mạch máu trong hình ảnh chụp động mạch vành. IEEE TMI, 39(5), 1524-1534.

Garcia, NC, Morerio, P. & Murino, V. (2018). Chứng cất phương thức với nhiều mạng lưới luồng để nhận dạng hành động. Trong ECCV.

Ge, S., Zhao, S., Li, C., & Li, J. (2018). Nhận dạng khuôn mặt có độ phân giải thấp trong tự nhiên thông qua chứng cất kiến thức có chọn lọc. IEEE TIP, 28(4), 2051-2062.

Ge, S., Zhao, S., Li, C., Zhang, Y., & Li, J. (2020). Nhận dạng khuôn mặt độ phân giải thấp hiệu quả thông qua chứng cất cầu. IEEE TIP, 29, 6898-6908.

Ghorbani, S., Bulut, AE & Hansen, JH (2018). Nâng cao nhận dạng giọng nói lstm-ctc đa giọng bằng cách sử dụng mô hình học tập giáo viên-học sinh theo miền cụ thể. Trong SLTW.

Gil, Y., Chai, Y., Gorodissky, O. & Berant, J. (2019). Trắng-đen: Chất lọc hiệu quả các cuộc tấn công đối đầu hộp đen. Trong NAACL-HLT.

Goldblum, M., Fowl, L., Feizi, S. & Goldstein, T. (2020). Chứng cất mạnh mẽ đối nghịch. Trong AAAI.

Gong, C., Chang, X., Fang, M. & Yang, J. (2018). Dạy phân loại bán giám sát thông qua chứng cất tổng quát. Trong IJCAI.

Gong, C., Tao, D., Liu, W., Liu, L., & Yang, J. (2017). Sự lan truyền nhân thông qua việc dạy để học và học để dạy. TNNLS, 28(6), 1452- 1465.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Mạng adversarial sinh sản. Trong NeurIPS.

Gordon, MA & Duh, K. (2019). Giải thích quá trình chứng cất kiến thức ở cấp độ trình tự như là quá trình tăng cường dữ liệu cho dịch máy thần kinh. Bản in trước arXiv arXiv:1912.03334.

Gu, J., & Tresp, V. (2020). Tìm kiếm những sinh viên giỏi hơn để học cách chứng cất kiến thức. Trong ECAI.

Guan, Y., Zhao, P., Wang, B., Zhang, Y., Yao, C., Bian, K., & Tang, J. (2020). Tìm kiếm tổng hợp tính năng có thể phân biệt được để chứng cất kiến thức. Trong ECCV.

Guo, Q., Wang, X., Wu, Y., Yu, Z., Liang, D., Hu, X., & Luo, P. (2020). Chất lọc kiến thức trực tuyến thông qua học tập cộng tác. Trong CVPR.

Gupta, S., Hoffman, J. & Malik, J. (2016). Chứng cất chéo để chuyển giao giám sát. Trong CVPR.

Hahn, S. & Choi, H. (2019). Chứng cất tự nhận thức trong quá trình xử lý ngôn ngữ tự nhiên. Trong RANLP.

Haidar, MA & Rezagholizadeh, M. (2019). Textkd-gan: Tạo văn bản bằng cách chứng cất kiến thức và mạng đối kháng tạo ra. Trong hội nghị về trí tuệ nhân tạo của Canada.

Han, S., Pool, J., Tran, J. & Dally, W. (2015). Học cá hai trọng số và kết nối cho mạng lưới nơ-ron hiệu quả. Trong NeurIPS.

Hao, W., & Zhang, Z. (2019). Mạng kết nối dày đặc chứng cất theo không gian và thời gian để nhận dạng hành động video. Nhận dạng mẫu, 92, 13-24.

Haroush, M., Hubara, I., Hoffer, E., & Soudry, D. (2020). Kiến thức bên trong: Phương pháp nén mô hình không dữ liệu. Trong CVPR.

He, C., Annavaram, M., & Avestimehr, S. (2020a). Chuyển giao kiến thức nhóm: Học tập liên bang của các CNN lớn ở rìa. InNeurIPS.

He, F., Liu, T., & Tao, D. (2020b). Tại sao resnet lại hiệu quả? các giá trị dư được khai quát hóa. IEEE TNNLS, 31(12), 5349-5362.

He, K., Zhang, X., Ren, S. & Sun, J. (2016) Học sâu dư thừa để nhận dạng hình ảnh. Trong CVPR.

He, T., Shen, C., Tian, Z., Gong, D., Sun, C. & Yan, Y. (2019). Thích ứng kiến thức để phân đoạn ngữ nghĩa hiệu quả. Trong CVPR.

Heo, B., Kim, J., Yun, S., Park, H., Kwak, N., & Choi, JY (2019a). Một đại tu toàn diện quá trình chứng cất tính năng. Trong ICCV.

Heo, B., Lee, M., Yun, S. & Choi, JY (2019b). Chứng cất kiến thức với các mẫu đối nghịch hỗ trợ ranh giới quyết định. Trong AAAI.

Heo, B., Lee, M., Yun, S. & Choi, JY (2019c). Chuyển giao kiến thức thông qua chứng cất ranh giới kích hoạt được hình thành bởi các tế bào thần kinh ẩn. Trong AAAI.

Hinton, G., Vinyals, O. & Dean, J. (2015). Chất lọc kiến thức trong mạng nơ-ron. Bản in trước arXiv arXiv:1503.02531.

Hoffman, J., Gupta, S. & Darrell, T. (2016). Học tập với thông tin bên lề thông qua ảo giác phương thức. Trong CVPR.

Hong, W. & Yu, J. (2019). Chứng cất kiến thức Gan để phát hiện đối tượng một giai đoạn. Bản in trước arXiv arXiv:1906.08467.

Hou, Y., Ma, Z., Liu, C. & Loy, CC. (2019). Học cách phát hiện làn đường nhẹ của CNN bằng cách chứng cất sự chú ý của bản thân. Trong ICCV.

Hou, Y., Ma, Z., Liu, C., Hu, TW, & Loy, CC (2020). Chứng cất ái lực liên vùng để phân đoạn vạch đường. Trong CVPR.

Howard, AG, Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). Mobilenets: Mạng nơ-ron tích chập hiệu quả cho các ứng dụng thị giác di động. Bản in trước arXiv arXiv:1704.04861.

Hu, H., Xie, L., Hong, R., & Tian, Q. (2020). Tạo ra thứ gì đó từ hư không: Chất lọc kiến thức không giám sát để bám đa phương thức. Trong CVPR.

Hu, M., Peng, Y., Wei, F., Huang, Z., Li, D., Yang, N., et al. (2018). Chất lọc câu trả lời theo hướng chú ý để máy hiểu bài đọc. Trong EMNLP.

Huang, G., Liu, Z., Van, Der Maaten, L. & Weinberger, KQ (2017). Mạng tích chập kết nối dày đặc. Trong CVPR.

Huang, M., You, Y., Chen, Z., Qian, Y. & Yu, K. (2018). Chứng cất kiến thức cho mô hình trình tự. Trong Interspeech.

Huang, Z. & Wang, N. (2017). Bạn thích những gì: Kiến thức được chất lọc thông qua quá trình chuyển giao chọn lọc nơ-ron. Bản in trước arXiv arXiv:1707.01219.

Huang, Z., Zou, Y., Bhagavatula, V., & Huang, D. (2020). Tự chứng cất sự chú ý toàn diện để phát hiện đối tượng được giám sát yếu. Trong NeurIPS.

Ioffe, S., & Szegedy, C. (2015). Chuẩn hóa hàng loạt: Tăng tốc đào tạo mạng sâu bằng cách giảm sự dịch chuyển biến phụ thuộc nội bộ. Trong ICML Jang, Y., Lee, H., Hwang, SJ & Shin, J. (2019). Học những gì và chuyển đến đâu. Trong ICML.

Ji, G., & Zhu, Z. (2020). Chất lọc kiến thức trong mạng nơ-ron cộng: Rủi ro ràng buộc, hiệu quả dữ liệu và giáo viên không hoàn hảo. Trong NeurIPS.

Jiao, X., Yin, Y., Shang, L., Jiang, X., Chen, X., Li, L., et al. (2020). Tinybert: Chất lọc bert để hiểu ngôn ngữ tự nhiên. Trong EMNLP.

Jin, X., Peng, B., Wu, Y., Liu, Y., Liu, J., Liang, D., Yan, J., & Hu, X. (2019). Chất lọc kiến thức thông qua tối ưu hóa hạn chế tuyến đường. Trong ICCV.

Kang, M., Mun, J. & Han, B. (2020). Hướng tới việc chứng cất kiến thức oracle với tìm kiếm kiến trúc nơ-ron. Trong AAAI.

Kim, J., Park, S. & Kwak, N. (2018). Diễn giải lại mạng phức hợp: Nén mạng thông qua chuyển giao yếu tố. Trong NeurIPS.

Kim, J., Bhalgat, Y., Lee, J., Patel, C., & Kwak, N. (2019a). QKD: Chứng cất kiến thức có nhận thức về lượng tử hóa. Bản in trước arXiv [arXiv:1911.12491](#).

Kim, J., Hyun, M., Chung, I. & Kwak, N. (2019b). Hợp nhất tính năng để chứng cất kiến thức lẫn nhau trực tuyến. Trong ICPR.

Kim, SW & Kim, HE (2017). Chuyển giao kiến thức cho các mạng có mất mát khoảng cách lớp. Trong ICLRW.

Kim, Y., Rush & AM (2016). Chất lọc kiến thức theo trình tự. Trong EMNLP.

Kimura, A., Ghahramani, Z., Takeuchi, K., Iwata, T. & Ueda, N. (2018). Học ít lần các mạng nơ-ron từ đầu bằng cách tối ưu hóa ví dụ giả. Trong BMVC.

Kwon, K., Na, H., Lee, H., & Kim, NS (2020). Chứng cất kiến thức thích ứng dựa trên entropy. Trong ICASSP.

Kong, H., Zhao, J., Tu, X., Xing, J., Shen, S. & Feng, J. (2019). Nhận dạng khuôn mặt phân giải chéo thông qua ảo giác khuôn mặt được hỗ trợ trước và chứng cất kiến thức còn sót lại. Bản in trước arXiv [arXiv:1905.10777](#).

Krizhevsky, A., & Hinton, G. (2009). Học nhiều lớp tính năng từ những hình ảnh nhỏ.

Krizhevsky, A., Sutskever, I. & Hinton, GE (2012). Phân loại Imagenet với mạng nơ-ron tích chập sâu. Trong NeurIPS.

Kuncoro, A., Ballesteros, M., Kong, L., Dyer, C. & Smith, NA (2016). Chất lọc một tập hợp các trình phân tích phụ thuộc tham lam thành một trình phân tích mst. Trong EMNLP.

Kundu, JN, Lakkakula, N. & Babu, RV (2019). Um-adapt: Thích ứng đa nhiệm vụ không giám sát bằng cách chứng cất chéo nhiệm vụ đối nghịch. Trong CVPR.

Lai, KH, Zha, D., Li, Y., & Hu, X. (2020). Chứng cất chính sách kép. TRONG

Lan, X., Zhu, X., & Gong, S. (2018). Học sâu tự tham chiếu. Trong ACCV.

Lee, H., Hwang, SJ & Shin, J. (2019a). Suy nghĩ lại về việc tăng cường dữ liệu: Tự giám sát và tự chất lọc. Bản in trước arXiv [arXiv:1910.05872](#).

Lee, K., Lee, K., Shin, J. & Lee, H. (2019b). Khắc phục tình trạng quên thảm khốc bằng dữ liệu không có nhãn trong tự nhiên. Trong ICCV.

Lee, K., Nguyen, LT & Shim, B. (2019c). Tính ngẫu nhiên và kết nối bỏ qua cải thiện việc truyền tải kiến thức. Trong AAAI.

Lee, S. & Song, B. (2019). Chứng cất kiến thức dựa trên đồ thị bằng nhiều mạng lưới chú ý đầu. Trong BMVC.

Lee, SH, Kim, DH & Song, BC (2018). Chứng cất kiến thức tự giám sát bằng cách sử dụng phân tích giá trị kỳ dị. Trong ECCV.

Li, B., Wang, Z., Liu, H., Du, Q., Xiao, T., Zhang, C., & Zhu, J. (2021). Học các mô hình dịch chuyển nhẹ từ bộ chuyển đổi sâu. Trong AAAI.

Li, C., Peng, J., Yuan, L., Wang, G., Liang, X., Lin, L., & Chang, X. (2020a). Tìm kiếm kiến trúc nơ-ron được giám sát theo khối với sự chất lọc kiến thức. Trong CVPR.

Li, G., Zhang, J., Wang, Y., Liu, C., Tan, M., Lin, Y., Zhang, W., Feng, J., & Zhang, T. (2020b). Chứng cất dư: Hướng tới mạng lưới nơ-ron sâu di động không cần lỗi tắt. Trong NeurIPS.

Li, J., Fu, K., Zhao, S., & Ge, S. (2019). Chất lọc kiến thức không gian-thời gian để ước tính hiệu quả độ nổi bật của video trên không. IEEE TIP, 29, 1902-1914.

Li, M., Lin, J., Ding, Y., Liu, Z., Zhu, JY, & Han, S. (2020c). Nén Gan: Kiến trúc hiệu quả cho các gan có điều kiện tương tác. Trong CVPR.

Li, Q., Jin, S. & Yan, J. (2017). Mô phỏng mạng rất hiệu quả để phát hiện đối tượng. Trong CVPR.

Li, T., Li, J., Liu, Z., & Zhang, C. (2020d). Một số ít kiến thức mẫu chứng cất để nén mạng hiệu quả. Trong CVPR.

Li, X., Wu, J., Fang, H., Liao, Y., Wang, F., & Qian, C. (2020e). Sự nhất quán tương quan cục bộ để chứng cất kiến thức. Trong ECCV.

Li, Z., & Hoiem, D. (2017). Học mà không quên. IEEE TPAMI, 40(12), 2935-2947.

Lin, T., Kong, L., Stich, SU, & Jaggi, M. (2020). Chứng cất tổng hợp để hợp nhất mô hình mạnh mẽ trong học tập liên bang. Trong NeurIPS.

Liu, IJ, Peng, J. & Schwing, AG (2019a). Luồng kiến thức: Cải thiện giáo viên của bạn. Trong ICLR.

Liu, J., Chen, Y. & Liu, K. (2019b). Khai thác sự thật cơ bản: Một phương pháp chứng cất kiến thức dựa trên sự bất chước đối nghịch để phát hiện sự kiện. Trong AAAI.

Liu, J., Wen, D., Gao, H., Tao, W., Chen, TW, Osa, K., và cộng sự (2019c). Biểu diễn kiến thức: biểu diễn hiệu quả, thừa thớt kiến thức trước đó để chất lọc kiến thức. Trong CVPRW.

Liu, P., King, I., Lyu, MR, & Xu, J. (2019d). DDFlow: Học luồng quang học với chứng cất dữ liệu không có nhãn. Trong AAAI.

Liu, P., Liu, W., Ma, H., Mei, T. & Seok, M. (2020a). Ktan: mạng lưới đối kháng chuyển giao kiến thức. Trong IJCNN.

Liu, Q., Xie, L., Wang, H., Yuille & AL (2019e). Bảo tồn kiến thức có nhận thức ngữ nghĩa cho việc truy xuất hình ảnh dựa trên bản phác thảo zero-shot. Trong ICCV.

Liu, R., Fusì, N. & Mackey, L. (2018). Nén mô hình với mạng đối nghịch tạo ra. Bản in trước arXiv [arXiv:1812.02271](#).

Liu, W., Zhou, P., Zhao, Z., Wang, Z., Deng, H., & Ju, Q. (2020b). FastBERT: BERT tự chứng cất với thời gian suy luận thích ứng. Trong ACL.

Liu, X., Wang, X. & Matwin, S. (2018b). Cải thiện khả năng diễn giải của mạng nơ-ron sâu bằng cách chứng cất kiến thức. Trong ICDMW.

Liu, X., He, P., Chen, W. & Gao, J. (2019f). Cải thiện mạng nơ-ron sâu đa nhiệm thông qua quá trình chứng cất kiến thức để hiểu ngôn ngữ tự nhiên. Bản in trước arXiv [arXiv :1904.09482](#).

Liu, Y., Cao, J., Li, B., Yuan, C., Hu, W., Li, Y. & Duan, Y. (2019g). Chất lọc kiến thức thông qua biểu đồ quan hệ thể hiện. Trong CVPR.

Liu, Y., Chen, K., Liu, C., Qin, Z., Luo, Z. & Wang, J. (2019h). Chất lọc kiến thức có cấu trúc để phân đoạn ngữ nghĩa. Trong CVPR.

Liu, Y., Jia, X., Tan, M., Vemulapalli, R., Zhu, Y., Green, B., et al. (2019i). Tìm kiếm để chất lọc: Ngọc trai ở khắp mọi nơi nhưng không có mắt. Trong CVPR.

Liu, Y., Zhang, W., & Wang, J. (2020c). Chất lọc kiến thức đa cấp đa giáo viên thích ứng. Neurocomputing, 415, 106-113.

Lopes, RG, Fenu, S. & Stainer, T. (2017). Chất lọc kiến thức không có dữ liệu cho mạng nơ-ron sâu. Trong NeurIPS.

Lopez-Paz, D., Bottou, L., Schölkopf, B. & Vapnik, V. (2016). Thống nhất chứng cất và thông tin đặc quyền. Trong ICLR.

Lu, L., Guo, M. & Renals, S. (2017). Chất lọc kiến thức cho mạng lưới đường cao tốc có diện tích nhỏ. Trong ICASSP.

Luo, P., Zhu, Z., Liu, Z., Wang, X. & Tang, X. (2016). Nén mô hình khuôn mặt bằng cách chất lọc kiến thức từ các tế bào thần kinh. Trong AAAI.

Luo, S., Pan, W., Wang, X., Wang, D., Tang, H., & Song, M. (2020). Hợp tác thông qua cạnh tranh: Sự kết hợp kiến thức tự phối hợp để học tập cho nhiều học sinh có năng khiếu. Trong ECCV.

Luo, S., Wang, X., Fang, G., Hu, Y., Tao, D., & Song, M. (2019). Hợp nhất kiến thức từ các mạng không đồng nhất bằng cách học các đặc điểm chung. Trong IJCAI.

Luo, Z., Hsieh, JT, Jiang, L., Carlos Niebles, J. & Fei-Fei, L. (2018).
Chứng cất đồ thị để phát hiện hành động với các phương thức đặc quyền.
Trong ECCV.

Macko, V., Weill, C., Mazzawi, H. & Gonzalvo, J. (2019). Cải thiện bộ phân loại hình ảnh tìm kiếm kiến trúc thần kinh thông qua học tập tổng hợp.
Trong hội thảo NeurIPS.

Ma, J., & Mei, Q. (2019). Học biểu diễn đồ thị thông qua đa nhiệm vụ chứng cất kiến thức. bản in trước arXiv [arXiv:1911.05700](https://arxiv.org/abs/1911.05700).

Ma, N., Zhang, X., Zheng, HT, & Sun, J. (2018). Shufflenet v2: Hướng dẫn thực tế cho thiết kế kiến trúc CNN hiệu quả. Trong ECCV.

Meng, Z., Li, J., Zhao, Y. & Gong, Y. (2019). Học tập có điều kiện giữa giáo viên và học sinh. Trong ICASSP.

Micaelli, P. & Storkey, AJ (2019). Chuyển giao kiến thức Zero-shot thông qua việc khớp niềm tin đối nghịch. Trong NeurIPS.

Minami, S., Hirakawa, T., Yamashita, T. & Fujiyoshi, H. (2019). Biểu đồ chuyển giao kiến thức cho học tập cộng tác sâu. Bản in trước arXiv [arXiv:1909.04286](https://arxiv.org/abs/1909.04286).

Mirzadeh, SI, Farajtabar, M., Li, A. & Ghasemzadeh, H. (2020).
Cải thiện việc chất lọc kiến thức thông qua trợ lý giáo viên. Trong AAAI.

Mishra, A. & Marr, D. (2018). Học viên: Sử dụng các kỹ thuật chứng cất kiến thức để cải thiện độ chính xác của mạng có độ chính xác thấp. Trong ICLR.

Mobahi, H., Farajtabar, M., & Bartlett, PL (2020). Tự chứng cất khuếch đại quá trình chỉnh quã hóa trong không gian hilbert. Trong NeurIPS.

Mou, L., Jia, R., Xu, Y., Li, G., Zhang, L. & Jin, Z. (2016). Chất lọc nhúng từ: Một phương pháp mã hóa. Trong CIKM.

Mukherjee, P., Das, A., Bhunia, AK & Roy, PP (2019). Cogni-net: Học đặc điểm nhận thức thông qua nhận thức thị giác sâu. Trong ICIP.

Mullapudi, RT, Chen, S., Zhang, K., Ramanan, D. & Fatahalian, K. (2019). Chứng cất mô hình trực tuyến để suy luận video hiệu quả. Trong ICCV.

Muller, R., Kornblith, S. & Hinton, GE (2019). Khi nào thì việc làm mịn nhân có ích? Trong NeurIPS.

Mun, J., Lee, K., Shin, J. & Han, B. (2018). Học cách chuyên môn hóa với việc chất lọc kiến thức để trả lời câu hỏi trực quan. Trong NeurIPS.

Munjal, B., Galasso, F. & Amin, S. (2019). Chứng cất kiến thức cho tìm kiếm người từ đầu đến cuối. Trong BMVC.

Nakashole, N. & Flauger, R. (2017). Chứng cất kiến thức cho bilin-cảm ứng từ điển gual. Trong EMNLP.

Nayak, GK, Mopuri, KR, & Chakraborty, A. (2021). Hiệu quả của các tập chuyển giao tùy ý cho quá trình chứng cất kiến thức không có dữ liệu. Trong MACV-1000 của Úc

Nayak, GK, Mopuri, KR, Shaj, V., Babu, RV & Chakraborty, A. (2019). Chứng cất kiến thức Zero-shot trong mạng lưới sâu. Trong ICML.

Ng, RW, Liu, X. & Swietojanski, P. (2018). Đào tạo giáo viên-học sinh để nhận dạng người nói không phụ thuộc vào văn bản. Trong SLTW.

Nie, X., Li, Y., Luo, L., Zhang, N. & Feng, J. (2019). Chứng cất hạt nhân động để ước tính tư thế hiệu quả trong video. Trong ICCV.

Noroozi, M., Vinjimoor, A., Favaro, P. & Pirsiaavash, H. (2018). Tăng cường học tập tự giám sát thông qua chuyển giao kiến thức. Trong CVPR.

Nowak, TS & Corso, JJ (2018). Phân loại mạng sâu: Phân tích tầm quan trọng của các lớp mạng thông qua nén cấu trúc. Bản in trước arXiv [arXiv:1801.04651](https://arxiv.org/abs/1801.04651).

Oord, A., Li, Y., Babuschkin, I., Simonyan, K., Vinyals, O., Kavukcuoglu, K., et al. (2018). Mạng song song wavenet: Tổng hợp giọng nói độ trung thực cao nhanh. Trong ICML.

Pan, B., Cai, H., Huang, DA, Lee, KH, Gaidon, A., Adeli, E., & Niebles, JC (2020). Đồ thị không gian-thời gian cho phụ đề video với sự chất lọc kiến thức. Trong CVPR

Pan, Y., He, F., & Yu, H. (2019). Một bộ mã hóa tự động cộng tác nâng cao mới với khả năng chất lọc kiến thức cho các hệ thống đề xuất top-n.
Máy tính thần kinh, 332, 137-148.

Papernot, N., Abadi, M., Erlingsson, U., Goodfellow, I. & Talwar, K. (2017). Chuyển giao kiến thức bán giám sát cho học sâu từ dữ liệu đào tạo riêng tư. Trong ICLR.

Papernot, N., McDaniel, P., Wu, X., Jha, S. & Swami, A. (2016). Chứng cất như một biện pháp phòng thủ chống lại nhiều loạn đối kháng chống lại mạng nơ-ron sâu. Trong IEEE SP.

Park, S. & Kwak, N. (2020). Chất lọc kiến thức tổng hợp cấp độ tính năng để tổng hợp kiến thức từ nhiều mạng. Trong ECAI.

Park, W., Kim, D., Lu, Y. & Cho, M. (2019). Kiến thức quan hệ chứng cất. Trong CVPR.

Passban, P., Wu, Y., Rezagholizadeh, M., & Liu, Q. (2021). ALP-KD: Phép chiếu lớp dựa trên sự chú ý để chứng cất kiến thức. Trong AAAI.

Passalis, N. & Tefas, A. (2018). Học các biểu diễn sâu với chuyển giao kiến thức xác suất. Trong ECCV.

Passalis, N., Tzelepi, M., & Tefas, A. (2020a). Chuyển giao kiến thức xác suất cho việc học biểu diễn sâu nhẹ. TNLS. <https://doi.org/10.1109/TNLS.2020.2995884>.

Passalis, N., Tzelepi, M., & Tefas, A. (2020b). Chứng cất kiến thức không đồng nhất bằng cách sử dụng mô hình luồng thông tin. Trong CVPR.

Peng, B., Jin, X., Liu, J., Li, D., Wu, Y., Liu, Y., et al. (2019a). Sự phù hợp tương quan cho quá trình chứng cất kiến thức. Trong ICCV.

Peng, H., Du, H., Yu, H., Li, Q., Liao, J., & Fu, J. (2020). Tinh túy của mùa màng: Chất lọc các đường dẫn ưu tiên cho tìm kiếm kiến trúc thần kinh một lần. Trong NeurIPS.

Peng, Z., Li, Z., Zhang, J., Li, Y., Qi, GJ & Tang, J. (2019b). Nhận dạng hình ảnh ít lần chụp với chuyển giao kiến thức. Trong ICCV.

Perez, A., Sanguineti, V., Morerio, P. & Murino, V. (2020). Chứng cất mô hình nghe nhìn bằng hình ảnh âm thanh. Trong WACV.

Phuong, M., & Lampert, CH (2019a). Hướng tới hiểu biết về chứng cất kiến thức. Trong ICML.

Phuong, M., & Lampert, CH (2019b). Đào tạo dựa trên chứng cất cho kiến trúc đa lối thoát. Trong ICCV.

Pilzer, A., Lathuilliere, S., Sebe, N. & Ricci, E. (2019). Tinh chỉnh và chứng cất: Khai thác sự không nhất quán của chu kỳ và chứng cất kiến thức để ước tính độ sâu đơn sắc không giám sát. Trong CVPR.

Polino, A., Pascanu, R. & Alistarh, D. (2018). Mô hình nén thông qua chứng cất và lượng tử hóa. Trong ICLR.

Price, R., Iso, K., & Shinoda, K. (2016). Giáo viên thông minh đào tạo các mô hình âm thanh DNN tốt hơn. Tạp chí EURASIP về Xử lý âm thanh, giọng nói và âm nhạc, 2016(1), 10.

Radosavovic, I., Dollar, P., Girshick, R., Gkioxari, G., & He, K. (2018).
Chất lọc dữ liệu: Hướng tới học tập có giám sát toàn diện. Trong CVPR.

Radosavovic, I., Kosaraju, RP, Girshick, R., He, K., & Dollar P. (2020).
Thiết kế không gian thiết kế mạng. Trong CVPR.

Roheda, S., Riggan, BS, Krim, H. & Dai, L. (2018). Chứng cất đa phương thức: Một trường hợp cho mạng đối kháng tạo ra có điều kiện. Trong ICASSP.

Romero, A., Ballas, N., Kahou, SE, Chassang, A., Gatta, C., & Bengio, Y. (2015). Fitnets: Gợi ý cho lưới mỏng sâu. Trong ICLR.

Ross, AS & Doshi-Velez, F. (2018). Cải thiện tính mạnh mẽ đối nghịch và khả năng diễn giải của mạng nơ-ron sâu bằng cách điều chỉnh độ dốc đầu vào của chúng. Trong AAAI.

Ruder, S., Ghaffari, P. & Breslin, JG (2017). Thích ứng kiến thức: Dạy cách thích ứng. Bản in trước arXiv [arXiv:1702.02052](https://arxiv.org/abs/1702.02052).

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, LC (2018). Mobilenetv2: Dự lượng đảo ngược và nút thắt tuyến tính. Trong CVPR.

Sanh, V., Debut, L., Chaumond, J. & Wolf, T. (2019). Distilbert, phiên bản chứng cất của bert: nhỏ hơn, nhanh hơn, rẻ hơn và nhẹ hơn. Bản in trước arXiv [arXiv:1910.01108](https://arxiv.org/abs/1910.01108).

Saputra, MRU, de Gusmao, PP, Almalioglu, Y., Markham, A. & Trigoni, N. (2019). Chất lọc kiến thức từ mạng lưới hồi quy tư thế sâu. Trong ICCV.

Sau, BB & Balasubramanian, VN (2016). Nén mô hình sâu: Chất lọc kiến thức từ giáo viên ồn ào. Bản in trước arXiv [arXiv:1610.09650](https://arxiv.org/abs/1610.09650).

Seo, H., Park, J., Oh, S., Bennis, M., & Kim, SL (2020). Chứng cất kiến thức liên bang. Bản in trước arXiv [arXiv:2011.02367](#).

Shakeri, S., Sethy, A. & Cheng, C. (2019). Chứng cất kiến thức trong việc truy xuất tài liệu. Bản in trước arXiv [arXiv:1911.11065](#).

Shen, C., Wang, X., Song, J., Sun, L., & Song, M. (2019a). Kết hợp kiến thức hướng tới phân loại toàn diện. Trong AAAI.

Shen, C., Wang, X., Yin, Y., Song, J., Luo, S., & Song, M. (2021). Ghép mạng tiến bộ để chất lọc kiến thức ít lần. Trong AAAI.

Shen, C., Xue, M., Wang, X., Song, J., Sun, L., & Song, M. (2019b). Tùy chỉnh mạng lưới học sinh từ các giáo viên không đồng nhất thông qua việc kết hợp kiến thức thích ứng. Trong ICCV.

Shen, J., Vespapunt, N., Boddeti, VN & Kitani, KM (2016). In teacher we trust: Học các mô hình nên để phát hiện người đi bộ. Bản in trước arXiv [arXiv :1612.00478](#).

Shen, P., Lu, X., Li, S. & Kawai, H. (2018). Biểu diễn đặc điểm của các phát ngôn ngắn dựa trên sự chất lọc kiến thức để nhận dạng ngôn ngữ nói. Trong Interspeech.

Shen, P., Lu, X., Li, S., & Kawai, H. (2020). Học biểu diễn dựa trên chứng cất kiến thức để nhận dạng ngôn ngữ nói ngắn. Giao dịch IEEE/ACM về giọng nói và ngôn ngữ, 28, 2674-2683.

Shen, P., Lu, X., Li, S. & Kawai, H. (2019c). Học tập tương tác của mô hình giáo viên-học sinh để nhận dạng ngôn ngữ nói phát ngôn ngắn. Trong ICASSP.

Shen, Z., He, Z. & Xue, X. (2019d). Meal: Tổ hợp đa mô hình thông qua học tập đối nghịch. Trong AAAI.

Shi, B., Sun, M., Kao, CC, Rozgic, V., Matsoukas, S. & Wang, C. (2019a). Nên các mô hình phát hiện sự kiện âm thanh với chứng cất lượng tử. Trong Interspeech.

Shi, B., Sun, M., Kao, CC., Rozgic, V., Matsoukas, S. & Wang, C. (2019b). Phát hiện sự kiện âm thanh bán giám sát dựa trên tri-training. Trong ICASSP.

Shi, Y., Hwang, MY, Lei, X., & Sheng, H. (2019c). Chất lọc kiến thức cho mô hình ngôn ngữ mạng nơ-ron hồi quy với chỉnh quy hóa tin cậy. Trong ICASSP.

Shin, S., Boo, Y. & Sung, W. (2019). Phân tích thực nghiệm về kỹ thuật chứng cất kiến thức để tối ưu hóa mạng nơ-ron sâu lượng tử. Bản in trước arXiv [arXiv :1909.01688](#).

Shmelkov, K., Schmid, C., & Alahari, K. (2017). Học tập gia tăng của các máy dò đối tượng mà không quên thảm khốc. Trong ICCV.

Shu, C., Li, P., Xie, Y., Qu, Y., Dai, L., & Ma, L.(2019). Nên mạng đối nghịch bị bóp méo về mặt kiến thức. Bản in trước arXiv [arXiv :1904.05100](#).

Siam, M., Jiang, C., Lu, S., Petrich, L., Gamal, M., Elhoseiny, M., et al. (2019). Phân đoạn đối tượng video bằng cách sử dụng sự thích ứng giữa giáo viên và học sinh trong bối cảnh tương tác giữa người và robot (HRI). Trong ICRA.

Sindhwani, V., Sainath, T. & Kumar, S. (2015). Biến đổi có cấu trúc cho học sâu đầu chân nhỏ. Trong NeurIPS.

Silver, D., Huang, A., Maddison, CJ, Guez, A., Sifre, L., Van Den Driessche, G., & Dieleman, S. (2016). Làm chủ trò chơi cờ vây với mạng nơ-ron sâu và tìm kiếm cây. Nature, 529(7587), 484-489.

Song, X., Feng, F., Han, X., Yang, X., Liu, W. & Nie, L. (2018). Mô hình hóa khả năng tương thích thần kinh với sự chất lọc kiến thức có chủ ý. Trong SIGIR.

Srinivas, S. & Fleuret, F. (2018). Chuyển giao kiến thức với jacobian khớp. Trong ICML.

Su, JC & Maji, S. (2017). Điều chỉnh các mô hình để giảm tín hiệu bằng cách sử dụng chứng cất. Trong BMVC.

Sun, L., Gou, J., Yu, B., Du, L., & Tao, D. (2021) Giáo viên và học sinh hợp tác học tập thông qua việc chuyển giao nhiều kiến thức. Bản in trước arXiv [arXiv :2101.08471](#)

Sun, S., Cheng, Y., Gan, Z. & Liu, J. (2019). Chứng cất kiến thức bệnh nhân cho mô hình nên bert. Trong NEMNLP-IJCNLP.

Sun, P., Feng, W., Han, R., Yan, S., & Wen, Y. (2019). Tối ưu hóa hiệu suất mạng cho đào tạo dnn phân tán trên các cụm gpu: Đào tạo Imagenet/alexnet trong 1,5 phút. Bản in trước arXiv [arXiv:1902.06855](#).

Takashima, R., Li, S. & Kawai, H. (2018). Một cuộc điều tra về phương pháp chứng cất kiến thức cho các mô hình âm thanh CTC. Trong ICASSP.

Tan, H., Liu, X., Liu, M., Yin, B., & Li, X. (2021). KT-GAN: Mạng đối kháng sinh sản chuyển giao kiến thức để tổng hợp văn bản thành hình ảnh. IEEE TIP, 30, 1275-1290.

Tan, M., Chen, B., Pang, R., Vasudevan, V., Sandler, M., Howard, A., & Le, QV (2019). Mnasnet: Tìm kiếm kiến trúc nơ-ron nhận biết nền tảng cho thiết bị di động. Trong CVPR.

Tan, M., & Le, Q. (2019). EfficientNet: Xem xét lại việc mở rộng mô hình cho mạng nơ-ron tích chập. Trong ICML.

Tan, X., Ren, Y., He, D., Qin, T., Zhao, Z. & Liu, TY (2019). Dịch máy thần kinh đa ngôn ngữ với sự chất lọc kiến thức. Trong ICLR.

Tang, J., Shivanna, R., Zhao, Z., Lin, D., Singh, A., Chi, EH, & Jain, S. (2020). Hiểu và cải thiện quá trình chứng cất kiến thức. Bản in trước arXiv [arXiv :2002.03532](#).

Tang, J., & Wang, K. (2018). Chứng cất thứ hạng: Học các mô hình xếp hạng nhỏ gọn với hiệu suất cao cho hệ thống đề xuất. Trong SIGKDD.

Tang, R., Lu, Y., Liu, L., Mou, L., Vechtomova, O. & Lin, J. (2019). Chất lọc kiến thức chuyên biệt về nhiệm vụ từ bert thành mạng nơ-ron đơn giản. Bản in trước arXiv [arXiv:1903.12136](#).

Tarvainen, A., & Valpola, H. (2017). Giáo viên trung bình là mô hình vai trò tốt hơn: Mục tiêu nhất quán trung bình theo trọng số cải thiện kết quả học sâu bán giám sát. Trong NeurIPS.

Thoker, FM & Gall, J. (2019). Chất lọc kiến thức đa phương thức để nhận dạng hành động. Trong ICIP.

Tian, Y., Krishnan, D. & Isola, P. (2020). Biểu diễn tương phản chứng cất. Trong ICLR.

Tu, Z., He, F., & Tao, D. (2020). Hiểu khái quát hóa trong mạng nơ-ron hồi quy. Trong Hội nghị quốc tế về biểu diễn học tập. ICLR.

Tung, F., & Mori, G. (2019). Chứng cất kiến thức bảo tồn sự tương đồng tion. Trong ICCV.

Turc, I., Chang, MW, Lee, K. & Toutanova, K. (2019). Học sinh đọc nhiều học tốt hơn: Tác động của việc khởi tạo học sinh đối với quá trình chất lọc kiến thức. Bản in trước [arXiv arXiv:1908.08962](#).

Urban, G., Geras, KJ, Kahou, SE, Aslan, O., Wang, S., Caruana, R., (2017). Các mạng tích chập sâu có thực sự cần phải sâu và tích chập không? Trong ICLR.

Vapnik, V., & Izmailov, R. (2015). Học tập bằng cách sử dụng thông tin đặc quyền: Kiểm soát sự tương đồng và chuyển giao kiến thức. Tạp chí nghiên cứu học máy, 16(1), 2023-2049.

Vongkulbhisal, J., Vinayavekhin, P. & Visentini-Scarzanella, M. (2019). Thống nhất các bộ phân loại không đồng nhất với chứng cất. Trong CVPR.

Walawalkar, D., Shen, Z., & Savvides, M. (2020). Nên mô hình tổng hợp trực tuyến bằng cách chứng cất kiến thức. Trong ECCV.

Wang, C., Lan, X. & Zhang, Y. (2017). Chứng cất mô hình với chuyển giao kiến thức từ phân loại khuôn mặt sang căn chỉnh và xác minh. Bản in trước arXiv [arXiv:1709.02929](#).

Wang, L., & Yoon, KJ (2020). Chất lọc kiến thức và học tập giữa giáo viên và học sinh để có trí thông minh thị giác: Một đánh giá và triển vọng mới. Bản in trước arXiv [arXiv :2004.05937](#).

Wang, H., Zhao, H., Li, X. & Tan, X. (2018a). Chứng cất kiến thức theo khối tiến bộ để tăng tốc mạng nơ-ron. Trong IJCAI.

Wang, J., Bao, W., Sun, L., Zhu, X., Cao, B., & Philip, SY (2019a). Nên mô hình riêng tư thông qua chứng cất kiến thức. Trong AAAI.

Wang, J., Gou, L., Zhang, W., Yang, H., & Shen, HW (2019b). Deep-vid: Giải thích và chẩn đoán trực quan sâu cho bộ phân loại hình ảnh thông qua chứng cất kiến thức. TVCG, 25(6), 2168-2180.

Wang, M., Liu, R., Abe, N., Uchida, H., Matsunami, T., & Yamada, S. (2018b). Khám phá chiến lược hiệu quả để nén mô hình nhận dạng khuôn mặt bằng cách chùng cất kiến thức được cải thiện. Trong ICIP.

Wang, M., Liu, R., Hajime, N., Narishige, A., Uchida, H. & Matsunami, T.(2019c). Cải thiện quá trình chùng cất kiến thức để đào tạo mô hình nhận dạng khuôn mặt độ phân giải thấp nhanh. Trong ICCVW.

Wang, T., Yuan, L., Zhang, X. & Feng, J. (2019d). Chùng cất các máy dò vật thể với mô phỏng đặc điểm chi tiết. Trong CVPR.

Wang, T., Zhu, JY, Torralba, A., & Efros, AA (2018c). Chùng cất tập dữ liệu. bản in trước arXiv [arXiv:1811.10959](#).

Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., & Zhou, M. (2020a). Minilm: Chùng cất sự chú ý sâu sắc để nén không phụ thuộc vào tác vụ của các bộ biến đổi được đào tạo trước. Trong NeurIPS.

Wang, W., Zhang, J., Zhang, H., Hwang, MY, Zong, C. & Li, Z. (2018d). Một khuôn khổ giáo viên-học sinh cho trình quản lý đối thoại có thể duy trì. Trong EMNLP.

Wang, X., Fu, T., Liao, S., Wang, S., Lei, Z., & Mei, T. (2020b). Chất lọc kiến thức chuẩn hóa tính độc quyền-nhất quán để nhận dạng khuôn mặt. Trong ECCV.

Wang, X., Hu, JF, Lai, JH, Zhang, J. & Zheng, WS (2019e). Học tập tiến bộ giữa giáo viên và học sinh để dự đoán hành động sớm. Trong CVPR.

Wang, X., Zhang, R., Sun, Y. & Qi, J. (2018e) Kdgan: Chất lọc kiến thức với mạng đối nghịch tạo sinh. Trong NeurIPS.

Wang, Y., Xu, C., Xu, C., & Tao, D. (2019f). Đóng gói mạng nơ-ron tích chập trong miền tần số. IEEE TPAMI, 41(10), 2495-2510.

Wang, Y., Xu, C., Xu, C. & Tao, D. (2018f). Học tập đối nghịch của mạng lưới sinh viên di động. Trong AAAI.

Wang, ZR, & Du, J. (2021). Kiến trúc chung và chất lọc kiến thức trong CNN để nhận dạng văn bản tiếng Trung. Nhận dạng mẫu, 111, 107722.

Watanabe, S., Hori, T., Le Roux, J. & Hershey, JR (2017). Học tập mạng lưới giáo viên-học sinh với các tính năng nâng cao. Trong ICASSP.

Wei, HR, Huang, S., Wang, R., Dai, X. & Chen, J. (2019). Chứng cất trực tuyến từ các điểm kiểm tra cho dịch máy thần kinh. Trong NAACL-HLT.

Wei, Y., Pan, X., Qin, H., Ouyang, W. & Yan, J. (2018). Mô phỏng lượng tử hóa: Hướng tới CNN cực nhỏ để phát hiện đối tượng. Trong ECCV.

Wong, JH & Gales, M. (2016). Trình tự đào tạo giáo viên-học sinh của mạng lưới nơ-ron sâu. Trong Interspeech.

Wu, B., Dai, X., Zhang, P., Wang, Y., Sun, F., Wu, Y., và cộng sự (2019). Fbnet: Thiết kế convnet hiệu quả nhận biết phản cứng thông qua tìm kiếm kiến trúc nơ-ron có thể phân biệt được. Trong CVPR.

Wu, A., Zheng, WS, Guo, X. & Lai, JH (2019a). Nhận dạng lại người tình chế: Hướng tới một hệ thống có khả năng mở rộng hơn. Trong CVPR.

Wu, G., & Gong, S. (2021). Học tập cộng tác ngang hàng để chất lọc kiến thức trực tuyến. Trong AAAI.

Wu, J., Leng, C., Wang, Y., Hu, Q. & Cheng, J. (2016). Mạng nơ-ron tích chập lượng tử cho thiết bị di động. Trong CVPR.

Wu, MC, Chiou, CT & Wu, KH (2019b). Chất lọc kiến thức của nhiều giáo viên để nhận dạng hành động video nén trên mạng nơ-ron sâu. Trong ICASSP.

Wu, X., He, R., Hu, Y., & Sun, Z. (2020). Học những tiến hóa thông qua chùng cất kiến thức lớn.Tạp chí quốc tế về thị giác máy tính, 1-18.

Xia, S., Wang, G., Chen, Z., & Duan, Y. (2018). Học lọc nhiều lớp dựa trên rừng ngẫu nhiên hoàn chỉnh để cải thiện khả năng tổng quát hóa của bộ phân loại. IEEE TKDE, 31(11), 2063-2078.

Xie, J., Lin, S., Zhang, Y. & Luo, L. (2019). Đào tạo mạng nơ-ron tích chập với tích chập giá rẻ và chùng cất trực tuyến. Bản in trước arXiv arXiv :1909.13063.

Xie, Q., Hovy, E., Luong, MT, & Le, QV (2020). Tự đào tạo với Noisy Student cải thiện phân loại ImageNet. Trong CVPR.

Xu, G., Liu, Z., Li, X., & Loy, CC (2020a). Chứng cất kiến thức đáp ứng sự tự giám sát. Trong ECCV.

Xu, K., Rui, L., Li, Y., & Gu, L. (2020b). Chất lọc kiến thức chuẩn hóa đặc điểm để phân loại hình ảnh. Trong ECCV.

Xu, Z., Wu, K., Che, Z., Tang, J., & Ye, J. (2020c). Chuyển giao kiến thức trong học tăng cường sâu đa nhiệm vụ để kiểm soát liên tục. Trong NeurIPS.

Xu, Z., Hsu, YC & Huang, J. (2018a). Đào tạo mạng lưới nông và mỏng để tăng tốc thông qua chùng cất kiến thức với mạng lưới đối nghịch có điều kiện. Trong hội thảo ICLR.

Xu, Z., Hsu, YC & Huang, J. (2018b). Đào tạo mạng lưới sinh viên để tăng tốc với mạng lưới đối nghịch có điều kiện. Trong BMVC.

Xu, TB, & Liu, CL (2019). Tự chùng cất hướng dẫn sự bóp méo dữ liệu cho mạng nơ-ron sâu. Trong AAAI.

Yan, M., Zhao, M., Xu, Z., Zhang, Q., Wang, G. & Su, Z. (2019). Vargfacenet: Một mạng nơ-ron tích chập nhóm biến hiệu quả cho nhận dạng khuôn mặt nhẹ. Trong ICCVW.

Yang, C., Xie, L., Qiao, S. & Yuille, A. (2019a). Sự chất lọc kiến thức qua nhiều thế hệ: Những giáo viên khoan dung hơn sẽ giáo dục học sinh tốt hơn. Trong AAAI.

Yang, C., Xie, L., Su, C. & Yuille, AL (2019b). Chất lọc ảnh chụp nhanh: Tối ưu hóa giáo viên-học sinh trong một thế hệ. Trong CVPR.

Yang, J., Martinez, B., Bulat, A., & Tzimiropoulos, G. (2020a). Chứng cất kiến thức thông qua chuẩn hóa trường hợp thích ứng. Trong ECCV.

Yang, Y., Qiu, J., Song, M., Tao, D. & Wang, X. (2020b). Chất lọc kiến thức từ mạng tích chập đồ thị. Trong CVPR.

Yang, Z., Shou, L., Gong, M., Lin, W. & Jiang, D. (2020c). Nén mô hình với chùng cất kiến thức đa giáo viên hai giai đoạn cho hệ thống trả lời câu hỏi trên web. Trong WSDM.

Yao, A., & Sun, D. (2020). Chuyển giao kiến thức thông qua chùng cất lẫn nhau lớp chéo dày đặc. Trong ECCV.

Yao, H., Zhang, C., Wei, Y., Jiang, M., Wang, S., Huang, J., Chawla, NV, & Li, Z. (2020). Biểu đồ học tập ít lần thông qua chuyển giao kiến thức. Trong AAAI.

Ye, J., Ji, Y., Wang, X., Gao, X., & Song, M. (2020). Sự kết hợp kiến thức không có dữ liệu thông qua GAN kép nhóm-xếp chồng. Trong CVPR.

Ye, J., Ji, Y., Wang, X., Ou, K., Tao, D. & Song, M. (2019). Học sinh trở thành bậc thầy: Sự kết hợp kiến thức để phân tích cảnh chung, ước tính độ sâu và nhiều hơn nữa. Trong CVPR.

Yim, J., Joo, D., Bae, J. & Kim, J. (2017). Một món quà từ quá trình chùng cất kiến thức: Tối ưu hóa nhanh, giảm thiểu mạng lưới và học chuyển giao. Trong CVPR.

Yin, H., Molchanov, P., Alvarez, JM, Li, Z., Mallia, A., Hoiem, D., Jha, Niraj K., & Kautz, J. (2020). Mơ ước chùng cất: Chuyển giao kiến thức không có dữ liệu thông qua DeepInversion. Trong CVPR.

Yoo, J., Cho, M., Kim, T., & Kang, U. (2019). Trích xuất kiến thức không có dữ liệu quan sát được. Trong NeurIPS.

You, S., Xu, C., Xu, C., & Tao, D. (2017). Học hỏi từ nhiều mạng lưới giáo viên. Trong SIGKDD.

You, S., Xu, C., Xu, C. & Tao, D. (2018). Học tập với một giáo viên nhiều học sinh. Trong AAAI.

Bạn, Y., Li, J., Reddi, S., Hseu, J., Kumar, S., Bhojanapalli, S., et al. (2019). Tối ưu hóa lô lớn cho học sâu: Đào tạo bert trong 76 phút. Trong ICLR.

Yu, L., Yazici, VO, Liu, X., Weijer, J., Cheng, Y. & Ramisa, A. (2019). Số liệu học tập từ giáo viên: Mạng nhỏ gọn để nhúng hình ảnh. Trong CVPR.

Yu, X., Liu, T., Wang, X., & Tao, D. (2017). Về nén sâu mô hình theo thứ hạng thấp và phân tích thừa thớt. Trong CVPR.

Yuan, F., Shou, L., Pei, J., Lin, W., Gong, M., Fu, Y., & Jiang, D. (2021). Tăng cường lựa chọn nhiều giáo viên để chất lọc kiến thức. Trong AAAI.

Yuan, L., Tay, FE, Li, G., Wang, T. & Feng, J. (2020). Xem lại quá trình chất lọc kiến thức: một khuôn khổ không cần giáo viên. Trong CVPR.

Yuan, M., & Peng, Y. (2020). CKD: Chất lọc kiến thức liên nhiệm vụ để tổng hợp văn bản thành hình ảnh. IEEE TMM, 22(8), 1955-1968.

Yue, K., Deng, J., & Zhou, F. (2020). Phù hợp chùng cất có hướng dẫn. Trong Bệnh viện ECCV.

Yun, S., Park, J., Lee, K. & Shin, J. (2020). Chuẩn hóa dự đoán theo từng lớp thông qua chứng cất kiến thức bản thân. Trong CVPR.

Zagoruyko, S. & Komodakis, N. (2017). Chú ý nhiều hơn đến sự chú ý: Cải thiện hiệu suất của mạng nơ-ron tích chập thông qua chuyển giao sự chú ý. Trong ICLR.

Zhai, M., Chen, L., Tung, F., He, J., Nawhal, M. & Mori, G. (2019). Gan trộn đời: Học tập liên tục để tạo ra hình ảnh có điều kiện. Trong ICCV.

Zhai, S., Cheng, Y., Zhang, ZM & Lu, W. (2016). Cuộn kép mạng nơ-ron nhân tạo. Trong NeurIPS.

Zhao, C., & Hospedales, T. (2020). Học tăng cường ngẫu nhiên miễn mạnh mẽ thông qua chứng cất ngang hàng. Trong NeurIPS.

Zhao, H., Sun, X., Dong, J., Chen, C., & Dong, Z. (2020a). Làm nổi bật từng bước: Chất lọc kiến thức thông qua giảng dạy hợp tác.

Hội đồng Kỹ thuật Điện tử và Truyền thông IEEE. <https://doi.org/10.1109/TCYB.2020.3007506>.

Zhao, L., Peng, X., Chen, Y., Kapadia, M., & Metaxas, DN (2020b). Kiến thức như là tiên nghiệm: Tổng quát hóa kiến thức đa phương thức cho các tập dữ liệu không có kiến thức cao cấp. Trong CVPR.

Zhao, M., Li, T., Abu Alsheikh, M., Tian, Y., Zhao, H., Torralba, A. & Katabi, D. (2018). Ước tính tư thế con người xuyên tường bằng tín hiệu vô tuyến. Trong CVPR.

Zhang, C. & Peng, Y. (2018). Tốt hơn và nhanh hơn: chuyển giao kiến thức từ nhiều nhiệm vụ học tự giám sát thông qua chứng cất đồ thị để phân loại video. Trong IJCAI.

Zhang, F., Zhu, X. & Ye, M. (2019a). Ước tính tư thế con người nhanh chóng. Trong CVPR.

Zhang, J., Liu, T., & Tao, D. (2018). Quan điểm lý thuyết thông tin về học sâu. Bản in trước arXiv [arXiv:1804.09060](https://arxiv.org/abs/1804.09060).

Zhang, H., Hu, Z., Qin, W., Xu, M., & Wang, M. (2021a). Học đồng chứng cất đối nghịch để nhận dạng hình ảnh. Nhận dạng mẫu, 111, 107659.

Zhang, L., Shi, Y., Shi, Z., Ma, K., & Bao, C. (2020a). Hướng đến nhiệm vụ chứng cất tính năng. Trong NeurIPS.

Zhang, L., Song, J., Gao, A., Chen, J., Bao, C. & Ma, K. (2019b). Hãy là giáo viên của chính mình: Cải thiện hiệu suất của mạng nơ-ron tích chập thông qua quá trình tự chứng cất. Trong ICCV.

Zhang, M., Song, G., Zhou, H., & Liu, Y. (2020b). Chứng cất khả năng phân biệt trong học tập biểu diễn nhóm. Trong ECCV.

Zhang, S., Feng, Y., & Li, L. (2021b). Bộ chuyển đổi gia tăng hướng dẫn tương lai cho dịch đồng thời. Trong AAAI.

Zhang, S., Guo, S., Wang, L., Huang, W., & Scott, MR (2020c). Mạng lưới tích hợp kiến thức để nhận dạng hành động. Trong AAAI.

Zhang, W., Miao, X., Shao, Y., Jiang, J., Chen, L., Ruas, O., & Cui, B. (2020d). Chứng cất dữ liệu đáng tin cậy trên mạng tích chập đồ thị. Trong ACM SIGMOD.

Zhang, X., Wang, X., Bian, JW, Shen, C., & You, M. (2021c). Chất lọc kiến thức đa dạng để tìm kiếm người từ đầu đến cuối. Trong AAAI.

Zhang, X., Zhou, X., Lin, M. & Sun, J. (2018a). Shufflenet: Một mạng nơ-ron tích chập cực kỳ hiệu quả cho các thiết bị di động. Trong CVPR.

Zhang, Y., Lan, Z., Dai, Y., Zeng, F., Bai, Y., Chang, J., & Wei, Y. (2020e). Chứng cất thích ứng nhận biết chính xác. Trong ECCV.

Zhang, Y., Xiang, T., Hospedales, TM & Lu, H. (2018b). Học tập lẫn nhau sâu sắc. Trong CVPR.

Zhang, Z., & Sabuncu, MR (2020). Tự chứng cất như làm mịn nhân cụ thể cho từng trường hợp. Trong NeurIPS.

Zhang, Z., Shi, Y., Yuan, C., Li, B., Wang, P., Hu, W., & Zha, ZJ (2020f). Đồ thị quan hệ đối tượng với việc học tập do giáo viên đề xuất cho phụ đề video. Trong CVPR.

Zhou C, Neubig G, Gu J (2019a) Hiểu về quá trình chất lọc kiến thức trong dịch máy không tự hồi quy. Trong ICLR.

Zhou, G., Fan, Y., Cui, R., Bian, W., Zhu, X. & Gai, K. (2018). Phóng tên lửa: Một khuôn khổ phổ quát và hiệu quả để đào tạo lưới ảnh sáng hoạt động tốt. Trong AAAI.

Zhou, J., Zeng, S. & Zhang, B. (2019b) Phân loại hình ảnh hai giai đoạn được giám sát bởi một mô hình giáo viên duy nhất - một học sinh duy nhất. Trong BMVC.

Chu, P., Mai, L., Zhang, J., Xu, N., Wu, Z. & Davis, LS (2020). M2KD: Chất lọc kiến thức đa mô hình và đa cấp độ để học tập gia tăng. Trong BMVC.

Zhu, M., Han, K., Zhang, C., Lin, J., & Wang, Y. (2019). Nhận dạng hình ảnh độ phân giải thấp thông qua chứng cất tính năng sâu. Trong ICASSP.

Zhu, X., & Gong, S. (2018). Chứng cất kiến thức bằng người bản xứ ngay lập tức quần thể. Trong NeurIPS.

Ghi chú của nhà xuất bản Springer Nature vẫn giữ thái độ trung lập đối với các khiếu nại về mặt pháp lý trong các bản đồ đã xuất bản và các liên kết tổ chức.