

# TRUY VẤN DỮ LIỆU


## Bài 1. Tìm kiếm kiểu so khớp

**PGS.TS. Lê Thanh Hương**  
**Trường Công nghệ thông tin và Truyền thông**  
**Đại Học Bách Khoa Hà Nội**

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Tìm kiếm thông tin

# Khái niệm Truy vấn dữ liệu

- Truy vấn dữ liệu (Data retrieval) là quá trình **trích xuất** những thông tin, dữ liệu cụ thể từ một nguồn **dữ liệu lớn** dựa trên **nhu cầu tìm kiếm** của người dùng.




# Các dạng dữ liệu

- **Dữ liệu có cấu trúc**, tiêu biểu như CSDL quan hệ. Ví dụ câu query:
  - `SELECT * FROM business-catalogue WHERE category = florist AND city-zip = cb1`
- **Dữ liệu phi cấu trúc**: thiếu một cấu trúc chính thức, rõ ràng về mặt ngữ nghĩa và dễ dàng cho máy tính xử lý. Ví dụ: văn bản
- **Dữ liệu bán cấu trúc**: ví dụ HTML, XML...

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Tìm kiếm thông tin

# Một số bài toán truy vấn dữ liệu

- Tìm kiếm văn bản/đoạn văn bản
- Tìm kiếm đa ngôn ngữ (cross-lingual)



- Tìm kiếm trên dữ liệu có cấu trúc



# Một số bài toán truy vấn dữ liệu

- Tìm kiếm đa thể thức (multimodal). Ví dụ:
  - Tìm các mẫu thiết kế
  - Tìm người/hình ảnh theo mô tả
  - Hỏi thông tin trên hình ảnh




Figure 1: Multi-Modal Knowledge Retrieval. Prior studies use multiple retrievers for separate purposes, while we retrieve knowledge through an end-to-end generative model.

# Một số bài toán truy vấn dữ liệu

- Tìm kiếm đa thể thức. Ví dụ (tiếp):
  - Lúc em đăng ký môn NLP của GenAI thì bị lỗi này. Làm thế nào để xử lý?



## TRANG ĐĂNG KÝ LỚP HỌC

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI

[Thoát đăng nhập](#)

♦ Mã sinh viên:                       
♦ Họ tên SV:                       
♦ Lớp: **KS-GenAI (tạm thời)-K69**  
♦ Chương trình: **GenAI**  
♦ Số tín chỉ tối đa: **24**  
♦ [Thông tin Danh sách lớp mở](#)

### TRANG ĐĂNG KÝ SINH VIÊN

Đăng ký mã lớp:

**Chưa đủ điều kiện chọn học phần: Không được đăng ký học phần IT4772 do IT3160**

Các lớp đăng ký

| Mã lớp ↑ | Mã lớp kèm | Tên lớp                              | Mã HP ↑ | Loại lớp | TT lớp             | Yêu cầu | Trạng thái ĐK | loại ĐK | Thực hiện | TC |
|----------|------------|--------------------------------------|---------|----------|--------------------|---------|---------------|---------|-----------|----|
| 156543   | 156543     | Nhập môn Học máy và khai phá dữ liệu | IT3190  | ĐA       | Điều chỉnh đăng ký |         | Thành công    | Online  |           | 3  |
| 152113   | 152113     | Nền tảng AI tạo sinh                 | IT5410  | LT+BT    | Điều chỉnh đăng ký |         | Thành công    | Online  |           | 3  |
| 152114   | 152114     | Truy vấn dữ liệu                     | IT5411  | LT+BT    | Điều chỉnh đăng ký |         | Thành công    | Online  |           | 2  |
| 152115   | 152115     | Mô hình ngôn ngữ lớn                 | IT5412  | LT+BT    | Điều chỉnh đăng ký |         | Thành công    | Online  |           | 3  |
| 152116   | 152116     | Mô hình tạo sinh hình ảnh và video   | IT5413  | LT+BT    | Điều chỉnh đăng ký |         | Thành công    | Online  |           | 3  |
| 152117   | 152117     | Vận hành hệ thống học máy            | IT5414  | LT+BT    | Điều chỉnh đăng ký |         | Thành công    | Online  |           | 2  |



**ĐẠI HỌC BÁCH KHOA HÀ NỘI**

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY



1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Tìm kiếm thông tin
  - 4.1. Đánh giá kết quả truy vấn
  - 4.2. Giải pháp Boolean

# Đánh giá kết quả truy vấn

- Các tài liệu trả về có:
  - liên quan đến chủ đề tìm kiếm không?
  - cập nhật mới nhất không?
  - từ một nguồn tin cậy không?
  - đáp ứng nhu cầu của người dùng không?
- Các độ đo:
  - **Precision** : tỉ lệ giữa số tài liệu trả về liên quan đến nhu cầu tìm kiếm / số tài liệu trả về
  - **Recall** : tỉ lệ giữa số tài liệu trả về liên quan đến nhu cầu tìm kiếm / số tài liệu liên quan nhu cầu tìm kiếm

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Tìm kiếm thông tin
  - 4.1. Đánh giá kết quả truy vấn
  - 4.2. Giải pháp Boolean

# Phân tích câu truy vấn

- Tìm những vở kịch của *Shakespeare* chứa các từ *Brutus* VÀ *Caesar* nhưng KHÔNG chứa từ *Calpurnia*?
- Có thể lấy tất cả các vở kịch của *Shakespeare* chứa *Brutus* và *Caesar*, sau đó loại bỏ các vở có chứa *Calpurnia*?
- Tại sao cách đó không tốt?
  - Chậm (đối với corpora lớn)
  - NOT *Calpurnia* không dễ
  - Các vấn đề khác (ví dụ: tìm từ *Romans* đứng gần *countrymen*) không khả thi
  - Xếp hạng kết quả truy vấn

# Ma trận thuật ngữ - tài liệu (term-document matrices)

| <b>Doc.</b><br><b>Term</b> | <b>Antony and<br/>Cleopatra</b> | <b>Julius<br/>Caesar</b> | <b>The<br/>Tempest</b> | <b>Hamlet</b> | <b>Othello</b> | <b>Macbeth</b> |
|----------------------------|---------------------------------|--------------------------|------------------------|---------------|----------------|----------------|
| <b>Antony</b>              | 1                               | 1                        | 0                      | 0             | 0              | 1              |
| <b>Brutus</b>              | 1                               | 1                        | 0                      | 1             | 0              | 0              |
| <b>Caesar</b>              | 1                               | 1                        | 0                      | 1             | 1              | 1              |
| <b>Calpurnia</b>           | 0                               | 1                        | 0                      | 0             | 0              | 0              |
| <b>Cleopatra</b>           | 1                               | 0                        | 0                      | 0             | 0              | 0              |
| <b>mercy</b>               | 1                               | 0                        | 1                      | 1             | 1              | 1              |
| <b>worser</b>              | 1                               | 0                        | 1                      | 1             | 1              | 0              |

***Brutus AND Caesar BUT NOT Calpurnia***

# Vecto biểu diễn sự xuất hiện thuật ngữ

- Với mỗi **thuật ngữ**, ta có 1 vectơ 0/1.
- Để thực hiện truy vấn, lấy các vectơ có chứa ***Brutus, Caesar*** và NOT ***Calpurnia*** → bitwise AND.

- 110100 AND
- 110111 AND
- 101111
- **100100**

| Doc.<br>Term | Antony and<br>Cleopatra | Julius<br>Caesar | The<br>Tempest | Hamlet | Othello | Macbeth |
|--------------|-------------------------|------------------|----------------|--------|---------|---------|
| Antony       | 1                       | 1                | 0              | 0      | 0       | 1       |
| Brutus       | 1                       | 1                | 0              | 1      | 0       | 0       |
| Caesar       | 1                       | 1                | 0              | 1      | 1       | 1       |
| Calpurnia    | 0                       | 1                | 0              | 0      | 0       | 0       |
| Cleopatra    | 1                       | 0                | 0              | 0      | 0       | 0       |
| mercy        | 1                       | 0                | 1              | 1      | 1       | 1       |
| worser       | 1                       | 0                | 1              | 1      | 1       | 0       |

# Với bộ dữ liệu lớn hơn

- Xét  $N = 1$  triệu tài liệu, mỗi tài liệu có 1000 từ.
  - Trung bình 6 bytes/từ bao gồm dấu cách/chấm
    - 6GB để lưu tài liệu
  - Có  $M = 500K$  các thuật ngữ khác nhau trong các tài liệu đó
  - Không thể xây dựng ma trận vì quá lớn và quá thưa
- Sử dụng danh mục chỉ mục đảo (Inverted Index)

# Chỉ mục ngược (Inverted index)

- Với mỗi thuật ngữ  $t$ , lưu danh sách các tài liệu chứa  $t$ 
  - Mỗi tài liệu được xác định bởi **docID**


|                         |    |                                                                                                                 |     |    |    |     |     |    |     |     |
|-------------------------|----|-----------------------------------------------------------------------------------------------------------------|-----|----|----|-----|-----|----|-----|-----|
| <b><i>Brutus</i></b>    | ⇒  | <table><tr><td>1</td><td>2</td><td>4</td><td>11</td><td>31</td><td>45</td><td>173</td><td>174</td></tr></table> | 1   | 2  | 4  | 11  | 31  | 45 | 173 | 174 |
| 1                       | 2  | 4                                                                                                               | 11  | 31 | 45 | 173 | 174 |    |     |     |
| <b><i>Caesar</i></b>    | ⇒  | <table><tr><td>1</td><td>2</td><td>4</td><td>5</td><td>6</td><td>16</td><td>57</td><td>132</td></tr></table>    | 1   | 2  | 4  | 5   | 6   | 16 | 57  | 132 |
| 1                       | 2  | 4                                                                                                               | 5   | 6  | 16 | 57  | 132 |    |     |     |
| <b><i>Calpurnia</i></b> | ⇒  | <table><tr><td>2</td><td>31</td><td>54</td><td>101</td><td></td><td></td><td></td><td></td></tr></table>        | 2   | 31 | 54 | 101 |     |    |     |     |
| 2                       | 31 | 54                                                                                                              | 101 |    |    |     |     |    |     |     |

Nếu từ **Caesar** được thêm vào tài liệu 14 thì sao?




# Chỉ mục ngược

- Sử dụng danh sách kết nối động hoặc mảng có độ dài thay đổi



# Xây dựng bảng chỉ mục ngược



# Các bước đánh chỉ mục

- Tạo các bộ (từ, docID)

Doc 1

I did enact Julius  
Caesar I was killed  
i' the Capitol;  
Brutus killed me.

Doc 2

So let it be with  
Caesar. The noble  
Brutus hath told you  
Caesar was ambitious



| Term      | docID |
|-----------|-------|
| I         | 1     |
| did       | 1     |
| enact     | 1     |
| julius    | 1     |
| caesar    | 1     |
| I         | 1     |
| was       | 1     |
| killed    | 1     |
| i'        | 1     |
| the       | 1     |
| capitol   | 1     |
| brutus    | 1     |
| killed    | 1     |
| me        | 1     |
| so        | 2     |
| let       | 2     |
| it        | 2     |
| be        | 2     |
| with      | 2     |
| caesar    | 2     |
| the       | 2     |
| noble     | 2     |
| brutus    | 2     |
| hath      | 2     |
| told      | 2     |
| you       | 2     |
| caesar    | 2     |
| was       | 2     |
| ambitious | 2     |
|           |       |
|           |       |
|           |       |

# Các bước đánh chỉ mục

- Sắp xếp theo từ, rồi theo docID

| Term      | docID | Term      | docID |
|-----------|-------|-----------|-------|
| I         | 1     | ambitious | 2     |
| did       | 1     | be        | 2     |
| enact     | 1     | brutus    | 1     |
| julius    | 1     | brutus    | 2     |
| caesar    | 1     | capitol   | 1     |
| I         | 1     | caesar    | 1     |
| was       | 1     | caesar    | 2     |
| killed    | 1     | caesar    | 2     |
| i'        | 1     | did       | 1     |
| the       | 1     | enact     | 1     |
| capitol   | 1     | hath      | 1     |
| brutus    | 1     | I         | 1     |
| killed    | 1     | I         | 1     |
| me        | 1     | i'        | 1     |
| so        | 2     | it        | 2     |
| let       | 2     | julius    | 1     |
| it        | 2     | killed    | 1     |
| be        | 2     | killed    | 1     |
| with      | 2     | let       | 2     |
| caesar    | 2     | me        | 1     |
| the       | 2     | noble     | 2     |
| noble     | 2     | so        | 2     |
| brutus    | 2     | the       | 1     |
| hath      | 2     | the       | 2     |
| told      | 2     | told      | 2     |
| you       | 2     | you       | 2     |
| caesar    | 2     | was       | 1     |
| was       | 2     | was       | 2     |
| ambitious | 2     | with      | 2     |
|           |       |           |       |
|           |       |           |       |
|           |       |           |       |



- Tạo từ điển. Mỗi từ trong từ điển đi kèm tổng số tài liệu chứa từ và posting list lưu list các tài liệu chứa từ. Posting list sắp theo docID

| term      | doc. freq. | → | postings lists |
|-----------|------------|---|----------------|
| ambitious | 1          | → | 2              |
| be        | 1          | → | 2              |
| brutus    | 2          | → | 1 → 2          |
| capitol   | 1          | → | 1              |
| caesar    | 2          | → | 1 → 2          |
| did       | 1          | → | 1              |
| enact     | 1          | → | 1              |
| hath      | 1          | → | 2              |
| i         | 1          | → | 1              |
| i'        | 1          | → | 1              |
| it        | 1          | → | 2              |
| julius    | 1          | → | 1              |
| killed    | 1          | → | 1              |
| let       | 1          | → | 2              |
| me        | 1          | → | 1              |
| noble     | 1          | → | 2              |
| so        | 1          | → | 2              |
| the       | 2          | → | 1 → 2          |
| told      | 1          | → | 2              |
| you       | 1          | → | 2              |
| was       | 2          | → | 1 → 2          |
| with      | 1          | → | 2              |


# Triển khai hệ thống tìm kiếm thông tin

- Làm thế nào để lập chỉ mục hiệu quả?
  - Chúng ta cần bao nhiêu dung lượng lưu trữ?
- Liên quan đến:
- Số lượng thuật ngữ
  - Inverted index
  - Cấu trúc dữ liệu

- Xét truy vấn:


- Brutus AND Caesar***

- Định vị ***Brutus*** trong từ điển
      - Lấy posting list tương ứng.
    - Định vị ***Caesar*** trong từ điển;
      - Lấy posting list tương ứng.
    - Lấy giao của 2 posting list.



# Phép trộn

- Duyệt qua 2 danh sách, thời gian tỉ lệ với số nút
  - Nếu 2 danh sách có độ dài là  $x$  và  $y$ , phép trộn có độ phức tạp  $O(x+y)$ .
  - Vấn đề cốt yếu: các danh sách sắp theo docID



# Thuật toán lấy giao của 2 posting list

INTERSECT( $p_1, p_2$ )

```
1  answer  $\leftarrow \langle \rangle$ 
2  while  $p_1 \neq \text{NIL}$  and  $p_2 \neq \text{NIL}$ 
3  do if  $\text{docID}(p_1) = \text{docID}(p_2)$ 
4      then ADD(answer,  $\text{docID}(p_1)$ )
5           $p_1 \leftarrow \text{next}(p_1)$ 
6           $p_2 \leftarrow \text{next}(p_2)$ 
7      else if  $\text{docID}(p_1) < \text{docID}(p_2)$ 
8          then  $p_1 \leftarrow \text{next}(p_1)$ 
9          else  $p_2 \leftarrow \text{next}(p_2)$ 
10 return answer
```



# Câu truy vấn logic: so khớp

- Mô hình phản hồi Boolean có thể trả lời câu truy vấn ở dạng biểu thức Boolean
  - Câu truy vấn sử dụng *AND*, *OR* và *NOT* để kết nối các thuật ngữ
    - Coi mỗi tài liệu là 1 tập các từ
    - Chính xác: tài liệu thỏa điều kiện hoặc không
  - Đây là mô hình IR đơn giản nhất

# Bài tập 1

- Viết thuật toán thực hiện phép giao cho các câu truy vấn:

***Brutus AND NOT Caesar***

***Brutus OR NOT Caesar***

Thời gian thực hiện còn là  $O(x+y)$ ?

## Bài tập 2: Phép giao

Viết thuật toán thực hiện phép giao cho các câu truy vấn:


***(Brutus OR Caesar) AND NOT***

***(Antony OR Cleopatra)***

- Có thể luôn thực hiện trong thời gian tuyến tính?
- Có thể làm tốt hơn không?

# Tối ưu hóa truy vấn


- Đây là trật tự tốt nhất để xử lý truy vấn?
- Xét 1 câu truy vấn là phép AND của n thuật ngữ
- Với mỗi thuật ngữ, lấy danh sách của nó , sau đó làm phép AND.



**Query: *Brutus AND Calpurnia AND Caesar***

# Tối ưu hóa truy vấn – Ví dụ

- Xử lý theo trật tự tăng của tần suất:
  - *khởi đầu với tập nhỏ, sau đó tiếp tục loại bỏ*



Thực hiện câu truy vấn (***Calpurnia AND Brutus***) AND ***Caesar***.

- vd., (*madding OR crowd*) AND (*ignoble OR strife*)
- Lấy tần suất xuất hiện cho mọi thuật ngữ
- Đánh giá kích thước của mỗi câu lệnh OR bằng cách tính tổng các tần suất của nó
- Xử lý theo trật tự tăng của kích thước các danh sách trong phép *OR*

# Bài tập 3

- Đưa ra trình tự xử lý truy vấn cho

*(tangerine OR trees) AND  
(marmalade OR skies) AND  
(kaleidoscope OR eyes)*

| Term         | Freq   |
|--------------|--------|
| eyes         | 213312 |
| kaleidoscope | 87009  |
| marmalade    | 107913 |
| skies        | 271658 |
| tangerine    | 46653  |
| trees        | 316812 |

## Bài tập 4

- Cho câu truy vấn ***friends AND romans AND (NOT countrymen)***, ta sử dụng tần suất của ***countrymen*** như thế nào?
- Mở rộng phép trộn cho câu truy vấn ngẫu nhiên. Có thể đảm bảo thực hiện trong thời gian tuyến tính với tổng kích thước các danh sách không



Cho các văn bản sau:

- **Doc1:** [Lập trình Hướng đối tượng với C++]
- **Doc2:** [Xây dựng dịch vụ Web với C++]
- **Doc3:** [Kiến trúc nguyên khối và kiến trúc dịch vụ nhỏ]
- **Doc4:** [Kiến trúc hệ thống thông tin]

a) Vẽ biểu diễn chỉ mục ngược;

b) Các văn bản nào sẽ được trả về cho truy vấn:

- Lập trình AND C++
- Xây dựng AND (Dịch vụ OR Hệ thống)

# Các kỹ thuật nâng cao

- Cụm từ: **Stanford University**
- Xấp xỉ: Tìm **Gates NEAR Microsoft**.
  - Cần đánh chỉ số để lấy thông tin về vị trí trong các tài liệu
- Vị trí trong tài liệu: Tìm các tài liệu có (*author = **Ullman***) AND (text contains **automata**).
- Từ khóa tìm kiếm xuất hiện trong 1 tài liệu nhiều hơn thì tốt hơn
  - Cần thông tin về tần suất của thuật ngữ trong các tài liệu
- Cần độ đo tương đồng giữa câu truy vấn với tài liệu
- Cần quyết định trả về 1 tài liệu thỏa câu truy vấn hay một nhóm tài liệu phủ các khía cạnh khác nhau của câu truy vấn

- IR quan tâm đến thuật ngữ
- VD: câu truy vấn
  - What kind of monkeys live in Costa Rica?
  - Open-domain Named Entity Recognition for Low-resource Languages

- What kind of monkeys live in Costa Rica?
- Open-domain Named Entity Recognition for Low-resource Languages
  - từ?
  - từ nội dung?
  - gốc từ?
  - các cụm từ?
  - các đoạn?

# Cụm từ (các từ thường đi liền nhau)

- kick the bucket
- directed graph
- Osama bin Laden
- United Nations
- real estate
- quality control
- international best practice
- ... có ý nghĩa riêng, cách dịch riêng.

# Tìm cụm từ

- Sử dụng bigrams?
- Không tốt:
  - 80871 of the
  - 58841 in the
  - 26430 to the
  - ...
  - 15494 to be
  - ...
  - 12622 from the
  - 11428 New York
  - 10007 he said
- Giải quyết: bỏ các từ dừng

- Sử dụng bigrams?
- Tốt hơn: lọc theo thẻ : <tính từ> <danh từ>, <danh từ> <danh từ>, <danh từ> <giới từ> <danh từ>...
  - 11487 New York
  - 7261 United States
  - 5412 Los Angeles
  - 3301 last year
  - ...
  - 1074 chief executive
  - 1073 real estate
  - ...

- Vẫn muốn bỏ “new companies”
- Các từ này thường xuất hiện nhưng chỉ vì cả 2 từ đều thường xuất hiện
- Quan sát xác suất của từng từ và xác suất của cụm từ
  - $p(\text{new}) p(\text{companies})$
  - $p(\text{new companies})$
  - thông tin tương hỗ =  $p(\text{new}) p(\text{companies} \mid \text{new})$



# Thông tin tương hỗ

- $p(\text{new companies}) = p(\text{new}) p(\text{companies})$  ?
- $MI = \log_2 p(\text{new companies}) / p(\text{new})p(\text{companies})$   
 $= \log_2 (8/N) / ((15828/N)(4675/N)) = \log_2 1.55 = 0.63$
- $MI > 0$  nhưng nhỏ. Với các cụm từ thường xuất hiện, giá trị này lớn hơn

|                 | new ____ | ¬new ____                      | TOTAL      |
|-----------------|----------|--------------------------------|------------|
| ____ companies  | 8        | 4,667<br>("old companies")     | 4,675      |
| ____ ¬companies | 15,820   | 14,287,181<br>("old machines") | 14,303,001 |
| TOTAL           | 15,828   | 14,291,848                     | 14,307,676 |

↖ N