

TRUY VẤN DỮ LIỆU

Bài 7. Truy vấn dựa trên ngữ nghĩa

PGS.TS. Lê Thanh Hương
Trường Công nghệ thông tin và Truyền thông
Đại học Bách Khoa Hà Nội

Contents

- Các mô hình bi-encoder nâng cao
- Hạn chế của Bi-Encoder
- Contrastive learning
- Reranking query results
- Cross encoder
- BGE-M3

- **Condenser**: cải thiện chất lượng biểu diễn câu và tài liệu thông qua việc “tập trung thông tin” (information condensation) trong mô hình BERT → nắm bắt tốt hơn thông tin ngữ nghĩa cốt lõi của văn bản.
- **coCondenser**: bổ sung thêm **contrastive learning** vào quá trình pre-training. giúp đưa các câu hoặc tài liệu có ngữ nghĩa tương tự lại gần nhau trong không gian nhúng và đẩy các câu không liên quan ra xa nhau.

Izacard, Gautier, et al. "Unsupervised dense information retrieval with contrastive learning." *arXiv preprint arXiv:2112.09118* (2021).


- **Mẫu dương:** (câu hỏi, tài liệu), lấy từ các bộ có sẵn như MS MARCO.
- **Mẫu âm ngẫu nhiên** (Random Negative Sampling): chọn ngẫu nhiên từ tập dữ liệu mà không có quan hệ ngữ nghĩa với câu hỏi → giúp học cách phân biệt các tài liệu hoàn toàn không liên quan.
- **Học tương phản:** 1 mẫu học gồm (câu hỏi, 1 mẫu dương, 1 hay nhiều mẫu âm). Mô hình học cách tối đa hóa khoảng cách giữa các mẫu dương và mẫu âm
- **Loss function:** contrastive InfoNCE loss

$$\mathcal{L}(q, k_+) = - \frac{\exp(s(q, k_+)/\tau)}{\exp(s(q, k_+)/\tau) + \sum_{i=1}^K \exp(s(q, k_i)/\tau)}$$


- **Fine-tuning:** nén các biểu diễn của tài liệu và câu hỏi để giảm số chiều, giúp cải thiện cả độ chính xác và tốc độ tính toán

Hạn chế của Bi-Encoder

- Bi-encoder tối ưu hóa tốc độ nhưng hy sinh độ chính xác
 - chỉ tính toán tương đồng cosine giữa các vector đã được mã hóa sẵn.
 - không nắm bắt được hoàn toàn các mối quan hệ ngữ nghĩa phức tạp giữa truy vấn và tài liệu
- Cross-encoder xem xét các ngữ cảnh, giúp xác định mức độ liên quan chi tiết hơn.
- Bi-encoder thường được dùng để lọc nhanh ra danh sách top-K tài liệu liên quan từ một tập dữ liệu lớn. Rerank giúp cải thiện độ chính xác của top-K này, đảm bảo rằng các tài liệu có liên quan nhất sẽ được xếp hạng cao hơn.



Retrieve và Re-rank



<https://www.sbert.net/docs/pretrained-models/ce-msmarco.html>

Cross-encoder

- Truy vấn và tài liệu được nối với nhau thành một chuỗi đầu vào duy nhất, thường được phân tách bởi token đặc biệt (ví dụ: [SEP] trong BERT).
- Cross-encoder tính điểm mức độ liên quan giữa truy vấn và tài liệu.
- **Ưu** : Do không mã hóa riêng lẻ từng phần, cross-encoder có khả năng xem xét chính xác ngữ cảnh cụ thể giữa các từ trong truy vấn và tài liệu, giúp phân biệt những tài liệu có sự tương đồng ngữ nghĩa cao nhất.
- **Nhược**: tính toán lâu

Contrastive learning

- Contrastive Learning là một kỹ thuật học máy nhằm học vector embeddings sao cho các điểm dữ liệu tương tự nhau nằm gần nhau, còn các điểm dữ liệu không liên quan thì bị đẩy xa nhau.
- **Các mẫu dữ liệu:** là các cặp:
 - **Positive Pair:** Hai mẫu dữ liệu giống nhau hoặc có liên quan về ngữ nghĩa (ví dụ: cùng một câu với các phép biến đổi ngẫu nhiên, hoặc hai câu diễn tả nội dung tương tự).
 - **Negative Pair:** Hai mẫu dữ liệu không liên quan hoặc khác biệt về ngữ nghĩa.

- **Loss Function:**

- **Contrastive Loss:** Khoảng cách giữa các cặp positive được tối thiểu hóa, và khoảng cách giữa các cặp negative được tối đa hóa.
- **Triplet Loss:** Dựa trên ba mẫu (anchor, positive, và negative) và tối ưu hóa sao cho positive gần anchor hơn negative.
- **InfoNCE Loss:** Một dạng cross-entropy loss giúp tối ưu hóa việc phân biệt positive khỏi negative trong một batch lớn.


- **Data Augmentation:**

- Sinh thêm dữ liệu từ dữ liệu ban đầu mà vẫn giữ nguyên ý nghĩa. Ví dụ: loại bỏ từ, thay đổi cấu trúc câu, v.v.

- **SimCSE (Simple Contrastive Learning of Sentence Embeddings)**
- **Ý tưởng:** huấn luyện để kéo các câu tương tự lại gần, đẩy những câu khác nhau ra xa nhau
- Pretrained embeddings + **Contrastive Learning** = SOTA sentence embeddings
 - **Unsupervised SimCSE:** sử dụng kỹ thuật **dropout** (bỏ một số neuron trong mạng) để tạo ra các câu giống nhau nhưng có sự khác biệt nhỏ trong biểu diễn.
 - **Supervised SimCSE:** các cặp câu giống nhau được lấy từ dữ liệu song ngữ hoặc từ các tập dữ liệu paraphrase
- **Mục tiêu:** cải thiện chất lượng biểu diễn ngữ nghĩa của câu, dựa trên các mô hình ngôn ngữ được huấn luyện trước như BERT, RoBERTa, và GPT

Gao, Tianyu, Xingcheng Yao, and Danqi Chen. "Simcse: Simple contrastive learning of sentence embeddings." *EMNLP* (2021).

- InfoNCE loss:



The diagram illustrates the InfoNCE loss formula with the following components and annotations:


- Similarity function:** An arrow points to the $\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)$ term in the numerator.
- Sentence embedding:** An arrow points to the $\mathbf{h}_i$ term in the numerator.
- Temperature:** An arrow points to the τ term in the denominator.
- Positive pairs:** A green arrow points to the numerator term $e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau}$.
- Negative pairs:** A red arrow points to the denominator term $e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_j^+)/\tau}$.

$$\ell_i = -\log \frac{e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau}}{\sum_{j=1}^N e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_j^+)/\tau}}$$

- Các mẫu dương và âm lấy ở đâu?
- Data augmentation

Unsupervised SimCSE

- Mẫu dương: các embedding của cùng 1 câu, sử dụng các dropout mask khác nhau, để ra các biểu diễn khác nhau $\rightarrow$ cặp câu tương đồng
- Mẫu âm: các embedding của các câu khác trong cùng 1 batch



$$\ell_i = -\log \frac{e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau}}{\sum_{j=1}^N e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_j^+)/\tau}}$$

Supervised SimCSE

- Sử dụng dữ liệu có nhãn để cải thiện chất lượng biểu diễn. Các cặp câu giống nhau (positive pair) được lấy từ dữ liệu song ngữ hoặc từ các tập dữ liệu paraphrase (câu có nghĩa giống nhau).
- Mô hình học để phân biệt giữa các câu tương tự và không tương tự, dựa trên các nhãn có sẵn.
- **Loss function:** Thông thường sử dụng **cross-entropy loss** để tối ưu hóa sự khác biệt giữa các cặp câu có nhãn.

Given one premise,

- Premise: *There are two dogs running.*


Annotators are required to write hypotheses of

- Entailment: *There are animals outdoors.*
- Contradiction: *The pets are sitting on a couch.*
- Neutral: *The dogs are catching a ball.*

Positive pairs


Hard negatives

Supervised SimCSE



Unsupervised SimCSE

Semantic textual similarity (STS) tasks: Spearman's correlation




~10% higher than previous SOTA

~20% higher than avg. BERT embeddings

Supervised SimCSE

Semantic textual similarity (STS) tasks: Spearman's correlation



Even unsupervised SimCSE matches supervised SentenceBERT
6.7% higher than SentenceBERT using the same NLI datasets

Điểm khác biệt

Different unsupervised positive pairs

- SimCSE (dropout)

Compare it to

- Next sentence
- Synonym replacement
- Crop
- Delete one word

Different dropout

NLP is interesting. — NLP is interesting.

I do NLP. — NLP is interesting.


The movie is **great**. — The movie is **fantastic**.

~~Two dogs~~ **are running**. — ~~Two dogs~~ **are running**.

Two dogs are **running**. — Two dogs **are** running.

Điểm khác biệt

Unsupervised SimCSE




Default setting: 1 million sentences randomly sampled from English Wikipedia, N=64, evaluated on STS-B development set (Spearman's correlation)

- Predicting sentence itself $\gg$ predicting next sentence
- Using dropout as data augmentation $\gg$ discrete data augmentation (!!)

Self-Contrastive Learning (SSCL)

- Trong học biểu diễn câu không giám sát, các mô hình ngôn ngữ tiền huấn luyện (PLMs) và học tương phản cho kết quả khả quan.
- Vấn đề over-smoothing: biểu diễn câu giữa hai tầng liên kề tương đồng đáng kể khi số tầng mã hóa tăng sâu hơn
- Chiến lược học tương phản mới: sử dụng biểu diễn câu ở lớp trung gian thứ M của PLMs làm mẫu âm, chọn các mẫu khác biểu diễn của lớp cuối



Self-Contrastive Learning (SSCL)

$$\mathcal{L}_{\text{hne}} = -\log \frac{\exp(\Psi(\mathbf{h}_i, \mathbf{h}_i^+)/\tau)}{\sum^N ((\exp(\Psi(\mathbf{h}_i, \mathbf{h}_j)/\tau) + \exp(\Psi(\mathbf{h}_i, \mathbf{h}_i^-)/\tau))}$$

các mẫu âm ban đầu trong batch

các mẫu âm trung gian

- Mẫu dương: $(\mathbf{h}_i, \mathbf{h}_i^+)$ được tạo ra bằng 1 phương pháp tăng cường dữ liệu nào đó
- Mẫu âm $(\mathbf{h}_i, \mathbf{h}_i^-)$
- $\Psi(\)$: hàm tương đồng cosin

<i>Base Version</i>								
GloVe embeddings (avg.) [♡]	55.14	70.66	59.73	68.25	63.66	58.02	53.76	61.32
BERT (cls.)	29.70	49.38	39.67	56.03	56.19	43.87	52.06	46.70
SSCL-BERT (cls.)	49.21	67.59	58.96	69.94	68.00	62.87	60.43	62.42
BERT (avg.)	48.26	47.72	46.83	52.30	59.88	54.27	56.41	52.24
SSCL-BERT (avg.)	53.93	63.10	56.41	68.00	70.46	64.85	61.15	62.56
BERT-flow [♡]	58.40	67.10	60.85	75.16	71.22	68.66	64.47	66.55
BERT-whitening [♡]	57.83	66.90	60.90	75.08	71.31	68.24	63.73	66.28
IS-BERT [♡]	56.77	69.24	61.21	75.23	70.16	69.21	64.25	66.58
CT-BERT [♡]	61.63	76.80	68.47	77.50	76.48	74.31	69.19	72.05
SimCSE	68.40	82.41	74.38	80.91	78.56	76.85	72.23	76.25
SSCL-SimCSE	71.68	83.50	76.42	83.46	78.39	79.03	71.76	77.90
<i>Large Version</i>								
BERT _{large} (cls.)	33.06	57.64	47.95	55.83	62.42	49.66	53.87	51.49
BERT _{large} -flow	65.20	73.39	69.42	74.92	77.63	72.26	62.50	70.76
BERT _{large} -whitening	64.35	74.64	69.64	74.68	75.94	60.81	72.47	70.35
Consert _{large}	70.69	82.96	74.13	82.78	76.66	77.53	70.47	76.45
SimCSE _{large}	69.17	84.36	75.09	83.99	78.61	79.54	71.97	77.53
SSCL-SimCSE_{large}	71.98	85.74	77.94	85.94	80.08	81.20	74.28	79.69