

# TRUY VẤN DỮ LIỆU


## Bài 10. Sử dụng LLM trong truy vấn thông tin

PGS.TS. Lê Thanh Hương  
Trưởng Công nghệ thông tin và Truyền thông  
Đại học Bách Khoa Hà Nội

# Contents

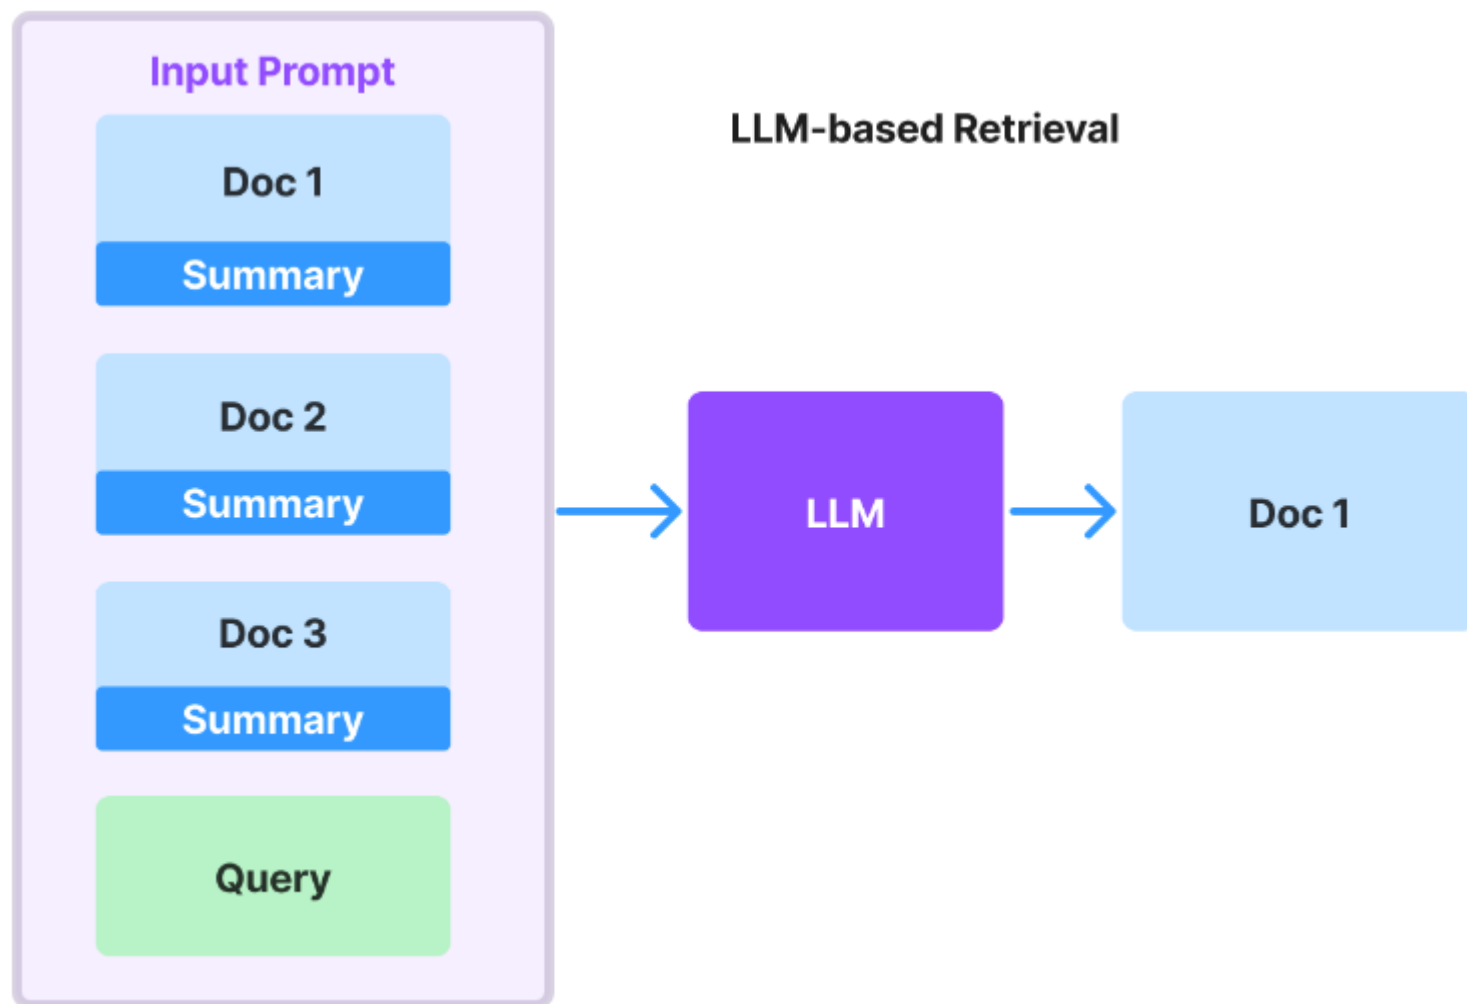
1. Sử dụng LLM cho tìm kiếm và xếp hạng lại
2. Cải thiện text embeddings với LLMs
3. LLM2VEC
4. NV-Embed
5. Các kỹ thuật RAG tiên tiến

# 1. Sử dụng LLM cho tìm kiếm và xếp hạng lại



Two-stage retrieval pipeline: 1) Top-k embedding retrieval, then 2) LLM-based reranking

# Sử dụng LLM cho xếp hạng lại



Simple diagram of how LLM-based retrieval works

## Prompt:

A list of documents is shown below. Each document has a number next to it along with a summary of the document. A question is also provided.

Respond with the numbers of the documents you should consult to answer the question, in order of relevance, as well

as the relevance score. The relevance score is a number from 1–10 based on how relevant you think the document is to the question.

Do not include any documents that are not relevant to the question.

Example format:

Document 1:

<summary of document 1>

Document 2:

<summary of document 2>

...

Document 10:

<summary of document 10>

Question: <question>

Answer:

Doc: 9, Relevance: 7

Doc: 3, Relevance: 4

Doc: 7, Relevance: 3

Let's try this now:

{context\_str}

Question: {query\_str}

Answer:

## 2. Cải thiện text embeddings với LLMs

- Các kỹ thuật retriever – reranker có một số vấn đề sau:
  - Cần các kỹ thuật để tạo ra lượng lớn cặp câu hỏi – đoạn văn bản liên quan.
  - Phụ thuộc vào tập dữ liệu thu thập thủ công, thường bị giới hạn bởi sự đa dạng của các tác vụ và phạm vi ngôn ngữ.
  - Hầu hết sử dụng bộ mã hóa dựa trên BERT, không tận dụng được các tiến bộ gần đây trong việc huấn luyện LLM tốt hơn và các kỹ thuật liên quan như mở rộng độ dài ngữ cảnh.
- Sử dụng LLMs để sinh dữ liệu nhân tạo cho nhiều tác vụ sinh biểu diễn nhúng của văn bản cho 93 ngôn ngữ
- Áp dụng chiến lược prompt hai bước:
  1. Tạo danh sách các tác vụ ứng viên
  2. Tạo dữ liệu cho các tác vụ trên.
- Fine-tune các open-source LLMs thay vì các mô hình nhỏ dựa trên BERT → mô hình E5

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). Improving text embeddings with large language models. *ACL* 2024.

# Sinh dữ liệu nhân tạo với GPT4

Brainstorm a list of potentially useful text retrieval tasks.

*Here are a few examples for your reference:*

- Provided a scientific claim as query, retrieve documents that help verify or refute the claim.
- Search for documents that answers a FAQ-style query on children's nutrition.

*Please adhere to the following guidelines:*

- Specify what the query is, and what the desired documents are.
- Each retrieval task should cover a wide range of queries, and should not be too specific.

Your output should always be a python list of strings only, with about 20 elements, and each element corresponds to a distinct retrieval task in one sentence. Do not explain yourself or output anything else. Be creative!



["Retrieve company's financial reports for a given stock ticker symbol.",  
"Given a book name as a query, retrieve reviews, ratings and summaries of that book.",  
"Search for scientific research papers supporting a medical diagnosis for a specified disease."  
... (omitted for space)]

# Sinh dữ liệu nhân tạo với GPT4

new session

You have been assigned a retrieval task: *{task}*

Your mission is to write one text retrieval example for this task in JSON format. The JSON object must contain the following keys:

- **"user\_query"**: a string, a random user search query specified by the retrieval task.
- **"positive\_document"**: a string, a relevant document for the user query.
- **"hard\_negative\_document"**: a string, a hard negative document that only appears relevant to the query.

Please adhere to the following guidelines:

- The "user\_query" should be *{query\_type}*, *{query\_length}*, *{clarity}*, and diverse in topic.
- All documents should be at least *{num\_words}* words long.
- Both the query and documents should be in *{language}*.

... *(omitted some for space)*

Your output must always be a JSON object only, do not explain yourself or output anything else. Be creative!

**"user\_query"**: "How to use Microsoft Power BI for data analysis",

**"positive\_document"**: "Microsoft Power BI is a sophisticated tool that requires time and practice to master. In this tutorial, we'll show you how to navigate Power BI ... *(omitted)* ",

**"hard\_negative\_document"**: "Excel is an incredibly powerful tool for managing and analyzing large amounts of data. Our tutorial series focuses on how you...*(omitted)*" }







# Finetune Mistral7B

- Tạo 500k mẫu sử dụng 150k instructions với Azure OpenAI Service 2: 25% tạo bởi GPT-35-Turbo, còn lại bởi GPT-4

distribution of task types



distribution of languages



# Finetune Mistral7B

- Thêm token [EOS] vào cuối truy vấn và tài liệu, sau đó đưa vào LLM để thu được các vector nhúng cho (truy vấn, tài liệu) bằng cách lấy tầng cuối cùng của vec tơ [EOS]
- Contrastive loss

$$\min \mathbb{L} = -\log \frac{\phi(q_{\text{inst}}^+, d^+)}{\phi(q_{\text{inst}}^+, d^+) + \sum_{n_i \in \mathbb{N}} (\phi(q_{\text{inst}}^+, n_i))}$$

- Hàm đo độ tương đồng

$$\phi(q, d) = \exp\left(\frac{1}{\tau} \cos(\mathbf{h}_q, \mathbf{h}_d)\right)$$

# Model finetuning and Evaluation

- Pretrained Mistral-7b checkpoint được fine-tuned 1 epoch, dùng LoRA với rank 16.
- Để giảm GPU memory, sử dụng gradient checkpoint, mixed precision training, DeepSpeed ZeRO-3.
- Training data (1.8M examples): dữ liệu nhân tạo + 13 bộ dữ liệu public
- Đánh giá: sử dụng MTEB benchmark với 15 bộ dữ liệu public
- Đánh giá 1 mô hình mất 3 ngày trên 8 V100 GPUs do cần mã hóa nhiều tài liệu
- Để hiệu quả, mặc dù mô hình có thể nhận sâu > 512 tokens, chỉ sử dụng 512 token đầu

# Leaderboard: MTEB

- MTEB: Massive Text Embedding Benchmark
- Leaderboard: <https://huggingface.co/spaces/mteb/leaderboard>

| Rank ▲ | Model ▲                                 | Model Size<br>(Million<br>Parameters) ▲ | Memory<br>Usage<br>(GB,<br>fp32) ▲ | Embedding<br>Dimensions ▲ | Max<br>Tokens ▲ | Average<br>(56<br>datasets) ▲ | Classification<br>Average (12<br>datasets) ▲ | Clustering<br>Average (11<br>datasets) |
|--------|-----------------------------------------|-----------------------------------------|------------------------------------|---------------------------|-----------------|-------------------------------|----------------------------------------------|----------------------------------------|
| 1      | <a href="#">bge-en-icl</a>              | 7111                                    | 26.49                              | 4096                      | 32768           | 71.67                         | 88.95                                        | 57.89                                  |
| 2      | <a href="#">stella_en_1.5B_v5</a>       | 1543                                    | 5.75                               | 8192                      | 131072          | 71.19                         | 87.63                                        | 57.69                                  |
| 3      | <a href="#">SFR-Embedding-2_R</a>       | 7111                                    | 26.49                              | 4096                      | 32768           | 70.31                         | 89.05                                        | 56.17                                  |
| 4      | <a href="#">gte-Qwen2-7B-instruct</a>   | 7613                                    | 28.36                              | 3584                      | 131072          | 70.24                         | 86.58                                        | 56.92                                  |
| 5      | <a href="#">stella_en_400M_v5</a>       | 435                                     | 1.62                               | 8192                      | 8192            | 70.11                         | 86.67                                        | 56.7                                   |
| 6      | <a href="#">bge-multilingual-gemma2</a> | 9242                                    | 34.43                              | 3584                      | 8192            | 69.88                         | 88.08                                        | 54.65                                  |
| 7      | <a href="#">NV-Embed-v1</a>             | 7851                                    | 29.25                              | 4096                      | 32768           | 69.32                         | 87.35                                        | 52.8                                   |
| 8      | <a href="#">voyage-large-2-instruct</a> |                                         |                                    | 1024                      | 16000           | 68.23                         | 81.49                                        | 53.35                                  |
| 9      | <a href="#">Linq-Embed-Mistral</a>      | 7111                                    | 26.49                              | 4096                      | 32768           | 68.17                         | 80.2                                         | 51.42                                  |
| 10     | <a href="#">SFR-Embedding-Mistral</a>   | 7111                                    | 26.49                              | 4096                      | 32768           | 67.56                         | 78.33                                        | 51.67                                  |

# Leaderboard: MTEB

| Rank ▲ | Model ▲                                                | Model Size<br>(Million<br>Parameters) ▲ | Memory<br>Usage<br>(GB,<br>fp32) ▲ | Embedding<br>Dimensions ▲ | Max<br>Tokens ▲ | Average<br>(56<br>datasets) ▲ | Classification<br>Average (12<br>datasets) ▲ | Clustering<br>Average (11<br>datasets) |
|--------|--------------------------------------------------------|-----------------------------------------|------------------------------------|---------------------------|-----------------|-------------------------------|----------------------------------------------|----------------------------------------|
| 16     | <a href="#">GritLM-7B</a>                              | 7242                                    | 26.98                              | 4096                      | 32768           | 66.76                         | 79.46                                        | 50.61                                  |
| 17     | <a href="#">e5-mistral-7b-instruct</a>                 | 7111                                    | 26.49                              | 4096                      | 32768           | 66.63                         | 78.47                                        | 50.26                                  |
| 18     | <a href="#">google-gecko.text-embedding-ff</a><br>◀ ▶  | 1200                                    | 4.47                               | 768                       | 2048            | 66.31                         | 81.17                                        | 47.48                                  |
| 19     | <a href="#">IDTE</a>                                   |                                         |                                    |                           |                 | 65.96                         | 77.17                                        | 47.86                                  |
| 20     | <a href="#">GritLM-8x7B</a>                            | 46703                                   | 173.98                             | 4096                      | 32768           | 65.66                         | 78.53                                        | 50.14                                  |
| 21     | <a href="#">gte-large-en-v1.5</a>                      | 434                                     | 1.62                               | 1024                      | 8192            | 65.39                         | 77.75                                        | 47.96                                  |
| 22     | <a href="#">LLM2Vec-Meta-Llama-3-supervised</a><br>◀ ▶ | 7505                                    | 27.96                              | 4096                      | 8192            | 65.01                         | 75.92                                        | 46.45                                  |
| 23     | <a href="#">LLM2Vec-Mistral-supervised</a>             | 7111                                    | 26.49                              | 4096                      | 32768           | 64.8                          | 76.63                                        | 45.54                                  |
| 24     | <a href="#">echo-mistral-7b-instruct-last</a><br>◀ ▶   | 7111                                    | 26.49                              | 4096                      | 32768           | 64.68                         | 77.43                                        | 46.32                                  |

# Results

| # of datasets →                                  | Class.<br>12 | Clust.<br>11 | PairClass.<br>3 | Rerank<br>4 | Retr.<br>15 | STS<br>10   | Summ.<br>1  | Avg<br>56   |
|--------------------------------------------------|--------------|--------------|-----------------|-------------|-------------|-------------|-------------|-------------|
| <i>Unsupervised Models</i>                       |              |              |                 |             |             |             |             |             |
| Glove (Pennington et al., 2014)                  | 57.3         | 27.7         | 70.9            | 43.3        | 21.6        | 61.9        | 28.9        | 42.0        |
| SimCSE <sub>bert-unsup</sub> (Gao et al., 2021)  | 62.5         | 29.0         | 70.3            | 46.5        | 20.3        | 74.3        | 31.2        | 45.5        |
| <i>Supervised Models</i>                         |              |              |                 |             |             |             |             |             |
| SimCSE <sub>bert-sup</sub> (Gao et al., 2021)    | 67.3         | 33.4         | 73.7            | 47.5        | 21.8        | 79.1        | 23.3        | 48.7        |
| Contriever (Izacard et al., 2021)                | 66.7         | 41.1         | 82.5            | 53.1        | 41.9        | 76.5        | 30.4        | 56.0        |
| GTR <sub>xxl</sub> (Ni et al., 2022b)            | 67.4         | 42.4         | 86.1            | 56.7        | 48.5        | 78.4        | 30.6        | 59.0        |
| Sentence-T5 <sub>xxl</sub> (Ni et al., 2022a)    | 73.4         | 43.7         | 85.1            | 56.4        | 42.2        | 82.6        | 30.1        | 59.5        |
| E5 <sub>large-v2</sub> (Wang et al., 2022b)      | 75.2         | 44.5         | 86.0            | 56.6        | 50.6        | 82.1        | 30.2        | 62.3        |
| GTE <sub>large</sub> (Li et al., 2023)           | 73.3         | 46.8         | 85.0            | 59.1        | 52.2        | 83.4        | 31.7        | 63.1        |
| BGE <sub>large-en-v1.5</sub> (Xiao et al., 2023) | 76.0         | 46.1         | 87.1            | 60.0        | 54.3        | 83.1        | 31.6        | 64.2        |
| <i>Ours</i>                                      |              |              |                 |             |             |             |             |             |
| E5 <sub>mistral-7b</sub> + full data             | <b>78.5</b>  | 50.3         | <b>88.3</b>     | <b>60.2</b> | <b>56.9</b> | <b>84.6</b> | 31.4        | <b>66.6</b> |
| w/ synthetic data only                           | 78.2         | <b>50.5</b>  | 86.0            | 59.0        | 46.9        | 81.2        | 31.9        | 63.1        |
| w/ synthetic + msmarco                           | 78.3         | 49.9         | 87.1            | 59.5        | 52.2        | 81.2        | <b>32.7</b> | 64.5        |

Table 1: Results on the MTEB benchmark (Muennighoff et al., 2023) (56 datasets in the English subset). The numbers are averaged for each category. Please refer to Table 17 for the scores per dataset.

# Is Contrastive Pre-training Necessary?




Figure 3: Effects of contrastive pre-training.

### 3. LLM2VEC

- Cách tiếp cận đơn giản để chuyển LLMs thành mô hình text embedding
- Dùng bidirectional attention thay vì causal self-attention
- Để học bidirectional attention, dùng next token prediction objective





Figure 1: The 3 steps of LLM2Vec. First, we enable bidirectional attention to overcome the restrictions of causal attention (**Bi**). Second, we adapt the model to use bidirectional attention by masked next token prediction training (**MNTP**). Third, we apply unsupervised contrastive learning with mean pooling to learn better sequence representations (**SimCSE**).

BehnamGhader, P., Adlakha, V., Mosbach, M., Bahdanau, D., Chapados, N., & Reddy, S. (2024). Llm2vec: Large language models are secretly powerful text encoders. *arXiv preprint arXiv:2404.05961*.



# Causal self-attention



Attention weight between the tokens corresponding to "Life" and "short"

|        | Life | is   | short | eat  | desert | first |
|--------|------|------|-------|------|--------|-------|
| Life   | 0.17 | 0.13 | 0.18  | 0.16 | 0.15   | 0.18  |
| is     | 0.03 | 0.68 | 0.02  | 0.08 | 0.14   | 0.02  |
| short  | 0.19 | 0.06 | 0.25  | 0.14 | 0.11   | 0.23  |
| eat    | 0.15 | 0.21 | 0.14  | 0.16 | 0.17   | 0.14  |
| desert | 0.13 | 0.27 | 0.11  | 0.16 | 0.18   | 0.12  |
| first  | 0.19 | 0.02 | 0.31  | 0.11 | 0.07   | 0.27  |

Attention weights calculated in the previous "Self-Attention" section

In the row for corresponding to "Life", mask out all words that come after "Life"

|        | Life | is   | short | eat  | desert | first |
|--------|------|------|-------|------|--------|-------|
| Life   | 0.17 | 0.13 | 0.18  | 0.16 | 0.15   | 0.18  |
| is     | 0.03 | 0.68 | 0.02  | 0.08 | 0.14   | 0.02  |
| short  | 0.19 | 0.06 | 0.25  | 0.14 | 0.11   | 0.23  |
| eat    | 0.15 | 0.21 | 0.14  | 0.16 | 0.17   | 0.14  |
| desert | 0.13 | 0.27 | 0.11  | 0.16 | 0.18   | 0.12  |
| first  | 0.19 | 0.02 | 0.31  | 0.11 | 0.07   | 0.27  |

Figure 1: The Transformer - model architecture.

# Transforming decoder-only LLMs with LLM2Vec

- **Models:** Sheared-LLaMA-1.3B, Llama-2-7B-chat, Mistral-7B-Instruct-v0.2, fine-tune với LoRA
- **Huấn luyện:** MNTP, unsupervised SimCSE sử dụng dữ liệu từ English Wikipedia.
- **Masked next token prediction:** che ngẫu nhiên một số từ đầu vào.
- **Unsupervised contrastive learning:**
  - Mẫu dương: áp dụng LLM's dropout 2 lần trên cùng đầu vào
  - Mẫu âm: các đầu khác trong batch
  - Trộn MNTP LoRA weights với mô hình cơ sở để đảm bảo mô hình còn nhớ thông tin ở các bước trước

| Categories →<br># of datasets → | Retr.<br>15  | Rerank.<br>4 | Clust.<br>11 | PairClass.<br>3 | Class.<br>12 | STS<br>10    | Summ.<br>1   | Avg<br>56    |
|---------------------------------|--------------|--------------|--------------|-----------------|--------------|--------------|--------------|--------------|
| Encoder-only                    |              |              |              |                 |              |              |              |              |
| BERT                            | 10.59        | 43.44        | 30.12        | 56.33           | 61.66        | 54.36        | 29.82        | 38.33        |
| BERT + SimCSE                   | 20.29        | 46.47        | 29.04        | 70.33           | 62.50        | 74.33        | 31.15        | 45.45        |
| S-LLaMA-1.3B                    |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                   | 9.47         | 38.02        | 28.02        | 42.19           | 59.79        | 49.15        | 24.98        | 35.05        |
| LLM2Vec (w/o SimCSE)            | 15.48        | 40.99        | 31.83        | 50.63           | 64.54        | 62.06        | 26.82        | 41.43        |
| LLM2Vec                         | 25.93        | 47.70        | 37.45        | 72.21           | 67.67        | 71.61        | 31.23        | 49.42        |
| Echo                            | 10.36        | 41.52        | 30.03        | 52.08           | 63.75        | 59.36        | 22.79        | 39.10        |
| LLaMA-2-7B                      |              |              |              |                 |              |              |              |              |
| Ui + w. Mean                    | 15.16        | 46.94        | 36.85        | 61.41           | 69.05        | 63.42        | 26.64        | 44.54        |
| LLM2Vec (w/o SimCSE)            | 19.86        | 44.74        | 35.31        | 61.60           | 67.94        | 66.74        | 26.83        | 45.70        |
| LLM2Vec                         | 36.75        | 52.95        | 40.83        | 77.89           | 71.57        | 76.41        | 31.38        | 55.36        |
| Echo                            | 16.16        | 46.84        | 34.25        | 63.54           | 69.82        | 67.95        | 25.57        | 45.36        |
| Mistral-7B                      |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                   | 10.43        | 45.11        | 35.82        | 60.28           | 71.14        | 58.59        | 26.57        | 42.46        |
| Bi + Mean                       | 15.84        | 47.40        | 35.55        | 66.53           | 72.18        | 71.04        | 29.93        | 46.86        |
| LLM2Vec (w/o SimCSE)            | 19.74        | 50.43        | 40.06        | 70.95           | 72.51        | 71.90        | 27.84        | 49.43        |
| LLM2Vec                         | 38.05        | <b>53.99</b> | 40.63        | <b>80.94</b>    | <b>74.07</b> | <b>78.50</b> | 30.19        | <b>56.80</b> |
| Echo                            | 22.68        | 51.07        | 36.78        | 75.87           | 72.69        | 73.60        | 29.54        | 50.26        |
| Meta-LLaMA-3-8B                 |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                   | 15.17        | 46.22        | 36.84        | 60.94           | 67.41        | 62.80        | 25.51        | 43.98        |
| Bi + Mean                       | 3.90         | 34.56        | 14.27        | 42.71           | 57.89        | 51.15        | 23.26        | 30.56        |
| LLM2Vec (w/o SimCSE)            | 24.75        | 49.20        | 39.74        | 65.91           | 69.00        | 67.85        | 25.59        | 48.84        |
| LLM2Vec                         | <b>39.19</b> | 53.09        | <b>41.99</b> | 78.01           | 71.88        | 75.86        | <b>31.45</b> | 56.23        |
| Echo                            | 12.58        | 49.79        | 36.32        | 68.95           | 70.22        | 67.43        | 26.44        | 45.32        |

Table 1: Unsupervised results on MTEB. We compare S-LLaMA-1.3B, LLaMA-2-7B, Mistral-7B, and Meta-LLaMA-3-8B with and without LLM2Vec to the unsupervised BERT models of Gao et al. (2021) as well as Echo embeddings (Springer et al., 2024).

| Categories →<br># of datasets →               | Retr.<br>15  | Rerank.<br>4 | Clust.<br>11 | PairClass.<br>3 | Class.<br>12 | STS<br>10    | Summ.<br>1   | Avg<br>56    |
|-----------------------------------------------|--------------|--------------|--------------|-----------------|--------------|--------------|--------------|--------------|
| Previous work w/ public data only             |              |              |              |                 |              |              |              |              |
| Instructor-xl                                 | 49.26        | 57.29        | 44.74        | 86.62           | 73.12        | 83.06        | <b>32.32</b> | 61.79        |
| BGE <sub>large-en-v1.5</sub>                  | 54.29        | 60.03        | 46.08        | 87.12           | 75.97        | 83.11        | 31.61        | 64.23        |
| GritLM <sub>Mistral-7b-v1</sub> + public data | 53.10        | <b>61.30</b> | <b>48.90</b> | 86.90           | 77.00        | 82.80        | 29.40        | 64.70        |
| E5 <sub>Mistral-7b-v1</sub> + public data     | 52.78        | 60.38        | 47.78        | <b>88.47</b>    | 76.80        | 83.77        | 31.90        | 64.56        |
| Echo <sub>Mistral-7b-v1</sub>                 | 55.52        | 58.14        | 46.32        | 87.34           | <b>77.43</b> | 82.56        | 30.73        | 64.68        |
| S-LLaMA-1.3B                                  |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                                 | 51.02        | 54.65        | 39.90        | 83.57           | 71.64        | 82.16        | 30.05        | 60.44        |
| LLM2Vec (w/o SimCSE)                          | 51.44        | 55.38        | 43.57        | 86.20           | 72.21        | 83.58        | 30.01        | 61.85        |
| LLM2Vec                                       | 51.49        | 55.58        | 43.24        | 85.80           | 72.98        | 83.62        | 30.12        | 61.96        |
| LLaMA-2-7B                                    |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                                 | 54.33        | 58.01        | 40.57        | 87.01           | 75.60        | 83.47        | 29.68        | 62.96        |
| LLM2Vec (w/o SimCSE)                          | 54.60        | 57.38        | 45.24        | 88.03           | 76.33        | 83.73        | 28.49        | 64.14        |
| LLM2Vec                                       | 54.34        | 57.70        | 45.04        | 87.87           | 76.53        | 83.43        | 28.82        | 64.04        |
| Mistral-7B                                    |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                                 | 54.81        | 57.37        | 41.07        | 86.05           | 76.01        | 83.44        | 30.74        | 63.20        |
| LLM2Vec (w/o SimCSE)                          | 55.99        | 58.42        | 45.54        | 87.99           | 76.63        | <b>84.09</b> | 29.96        | <b>64.80</b> |
| LLM2Vec                                       | 56.05        | 58.59        | 45.12        | 88.18           | 76.72        | 83.69        | 30.66        | 64.72        |
| Meta-LLaMA-3-8B                               |              |              |              |                 |              |              |              |              |
| Uni + w. Mean                                 | 55.42        | 58.60        | 43.19        | 86.29           | 75.56        | 83.95        | 30.59        | 63.87        |
| LLM2Vec (w/o SimCSE)                          | 56.63        | 59.68        | 46.45        | 87.80           | 75.92        | 83.58        | 30.94        | <b>65.01</b> |
| LLM2Vec                                       | <b>56.71</b> | 59.02        | 45.86        | 87.95           | 76.67        | 82.98        | 29.67        | 64.90        |

Table 2: Supervised results on full MTEB benchmark. The best performing LLM2Vec model Meta-LLaMA-3-8B + LLM2Vec (w/o SimCSE) achieves a new SOTA performance among models trained only on publicly available data.

## 4. NV-Embed

- Đề xuất sử dụng latent attention layer để thu được pooled embeddings, cho phép cải thiện độ chính xác của retrieval và các task khác so với sử dụng mean pooling hoặc last token embedding của LLMs.
- Bỏ causal attention mask of LLMs trong quá trình huấn luyện
- Phương pháp instruction-tuning 2 giai đoạn:
  1. Sử dụng contrastive training with instructions cho bộ dữ liệu retrieval, sử dụng các mẫu in-batch negatives và hard negative.
  2. Sử dụng instruction tuning cho các bộ dữ liệu khác


Lee, C., Roy, R., Xu, M., Raiman, J., Shoenybi, M., Catanzaro, B., & Ping, W. (2024). NV-Embed: Improved Techniques for Training LLMs as Generalist Embedding Models. *arXiv preprint arXiv:2405.17428*.

# Latent Attention Layer

- Cách thông thường để tạo text embedding:
  - **Bidirectional embedding models:** Sử dụng **mean pooling**, tức là tính trung bình các embedding của các token trong chuỗi.
  - **Decoder-only LLM based embedding models:** Sử dụng embedding của token **<EOS> cuối cùng** trong chuỗi làm đại diện.
- Nhược điểm:
  - **Mean pooling** có thể làm mất thông tin quan trọng từ các cụm từ chính do tính trung bình tất cả các token.
  - **Embedding của token cuối cùng (<EOS>)** có thể chịu ảnh hưởng quá nhiều bởi token cuối cùng, dẫn đến giảm độ chính xác.
- Đề xuất **latent attention layer**, nhằm cải thiện khả năng tổng hợp thông tin từ toàn bộ chuỗi dữ liệu.




# Latent Attention Layer




- Final Representations attend into a “learnable dictionary” before mean pooling  
⇒ sparse dictionary learning  
⇒ improve performance on retrieval tasks

# Nhắc lại Query-Key-Value (1)





# Nhắc lại Query-Key-Value (2)



# Nhắc lại Query-Key-Value (3)

- **Mục tiêu:** xác định từ nào cần được chú ý và mức độ chú ý là bao nhiêu

1. Tính Attention Scores:

$$\text{score}(Q_i, K_j) = \frac{Q_i \cdot K_j^\top}{\sqrt{d_k}}$$

2. Áp dụng hàm Softmax lên các điểm này để chuyển đổi thành xác suất:

$$\text{Attention Weight}_{ij} = \text{Softmax}(\text{score}(Q_i, K_j))$$

3. Kết hợp các Value

$$\text{Output}_i = \sum_j \text{Attention Weight}_{ij} \cdot V_j$$

# Latent Attention Layer (con't)

- Query  $\hat{Q} \in \mathbb{R}^{l \times d}$  : đầu ra ẩn từ lớp cuối cùng của decoder, với  $l$  là độ dài câu;  $d$  là số chiều của vector ẩn
- Latent array  $K = V \in \mathbb{R}^{\tilde{r} \times d}$  , là “trainable dictionary”, giúp tạo ra biểu diễn tốt hơn,  $r$  (=512) là số phần tử trong từ điển
- Đầu ra của cross-attention  $\hat{O} \in \mathbb{R}^{l \times d}$

$$O = \text{softmax}(QK^T)V$$

- $O$  được đưa qua một mạng nơ-ron nhiều lớp MLP gồm hai lớp biến đổi tuyến tính với hàm kích hoạt **GELU** xen giữa, sử dụng 8 đầu attention trong multi-head attention
- Áp dụng mean pooling trên đầu ra của các lớp MLP để tạo embedding biểu diễn cho toàn bộ chuỗi.

# Two-stage tuning

1. Huấn luyện với bộ retrieval sử dụng in-batch trick
  - In-batch trick tốt cho task retrieval nhưng không tốt cho các task khác như phân cụm hoặc phân loại
2. Huấn luyện với bộ retrieval và các bộ khác không dùng in-batch trick
  - Mẫu âm được chọn trước thay vì khai phá các mẫu in-batch

# Thử nghiệm

- Sử dụng Mistral 7B với LoRA.
- Thay thế causal attention mask thành bidirectional
- Bổ sung latent attention layer với 512 latents, 4096 hidden dimension size, và 8 multi-head attentions.

Table 1: Top MTEB leaderboard models as of 2024-05-22. We use the original model names on the leaderboard for clarity.

| Embedding Task              | Retrieval (15) | Rerank (4) | Cluter. (11) | PairClass. (3) | Class. (12) | STS (10) | Summ.( 1) | Avg. (56)    |
|-----------------------------|----------------|------------|--------------|----------------|-------------|----------|-----------|--------------|
| Mertric                     | nDCG@10        | MAP        | V-Meas.      | AP             | Acc.        | Spear.   | Spear.    |              |
| NV-Embed                    | <b>59.36</b>   | 60.59      | 52.80        | 86.91          | 87.35       | 82.84    | 31.2      | <b>69.32</b> |
| NV-Embed (mean pool)        | 58.71          | 60.75      | 52.80        | 85.85          | 87.06       | 82.53    | 30.49     | 68.98        |
| Voyage-large-2-instruct     | 58.28          | 60.09      | 53.35        | 89.24          | 81.49       | 84.58    | 30.84     | 68.28        |
| SFR-Embedding               | 59.00          | 60.64      | 51.67        | 88.54          | 78.33       | 85.05    | 31.16     | 67.56        |
| Gte-Qwen1.5-7B-instruct     | 56.24          | 60.13      | 55.83        | 87.38          | 79.6        | 82.42    | 31.46     | 67.34        |
| Voyage-lite-02-instruct     | 56.6           | 58.24      | 52.42        | 86.87          | 79.25       | 85.79    | 31.01     | 67.13        |
| GritLM-7B                   | 57.41          | 60.49      | 50.61        | 87.16          | 79.46       | 83.35    | 30.37     | 66.76        |
| E5-mistral-7b-instruct      | 56.9           | 60.21      | 50.26        | 88.34          | 78.47       | 84.66    | 31.4      | 66.63        |
| Google-gecko                | 55.7           | 58.9       | 47.48        | 87.61          | 81.17       | 85.07    | 32.63     | 66.31        |
| LLM2Vec-Meta-Llama-3        | 56.63          | 59.69      | 46.45        | 87.79          | 75.92       | 83.58    | 30.94     | 65.01        |
| Text-embed-3-large (OpenAI) | 55.44          | 59.16      | 49.01        | 85.72          | 75.45       | 81.73    | 29.92     | 64.59        |

# 5. Các kỹ thuật RAG tiên tiến

