

TRUY VẤN DỮ LIỆU

Bài 10. Truy vấn thông tin đa ngữ *Cross-Language Information Retrieval*

PGS.TS. Lê Thanh Hương
Trường Công nghệ thông tin và Truyền thông
Đại học Bách Khoa Hà Nội

- Truy vấn thông tin đa ngữ - Cross-Language Information Retrieval (CLIR): *tìm kiếm tài liệu viết bằng một ngôn ngữ khác với ngôn ngữ của truy vấn.*
- 2 thành phần:
 - Dịch máy
 - Truy vấn thông tin đơn ngữ

Tiếp cận dựa trên việc dịch

- Dịch tài liệu
 - Ưu điểm: Cung cấp nhiều ngữ cảnh để dịch từ chính xác
 - Nhược điểm: Tốn kém về tính toán và thời gian
- Dịch truy vấn
 - Ưu điểm: Dịch nhanh
 - Nhược điểm: Không có nhiều ngữ cảnh trong bản thân truy vấn
- Dịch cả hai thành một ngôn ngữ liên ngôn ngữ
 - Ưu điểm:
 - Interlingua có thể hỗ trợ truy xuất tốt hơn ngôn ngữ của con người;
 - Hỗ trợ CLIR đa chiều
 - Nhược điểm: Yêu cầu dịch nhiều hơn

Tiếp cận dựa trên dịch máy

- Chất lượng dịch máy cải tiến vượt bậc thời gian gần đây
- Tuy nhiên, phần lớn cải thiện tính trôi chảy của bản dịch. Chưa rõ có lợi gì cho IR.

- Các điểm mấu chốt:
 - Từ điển phù hợp
 - Tương thích với miền của truy vấn
 - Phương pháp lựa chọn bản dịch
 - Mở rộng truy vấn

Các kiểu từ điển/dữ liệu mẫu

- Từ điển được tạo thủ công:
 - . Từ điển theo miền đất đỏ
 - . Khó xác định cách chọn từ phù hợp từ các bản dịch có thể có.
- Dựa trên tập dữ liệu (bản dịch từ MT):
 - . Ít tập dữ liệu song ngữ theo lĩnh vực cụ thể
 - . Kết quả dịch có thể bị thiên lệch bởi lĩnh vực của văn bản nguồn.

Các bước dịch thuật ngữ:

- Cho các tài liệu song ngữ và một thuật ngữ cụ thể cần dịch:
 1. Tìm tập hợp các tài liệu trong ngôn ngữ nguồn chứa thuật ngữ đó.
 2. Lấy các tài liệu tương ứng bằng ngôn ngữ đích.
 3. Trích xuất các bản dịch ứng viên “tốt” cho thuật ngữ.
 4. Mức độ "tốt" có thể được đánh giá dựa trên các đo độ thuật ngữ tương đồng (như Dice, PMI, IBM Model 1, v.v.).

Vấn đề trong CLIR sử dụng tiếp cận dịch từ

- Vấn đề:
 - Không dịch được các từ khóa tìm kiếm do giới hạn của từ điển tổng quát
 - Xử lý các từ biến tố
 - Nhận diện và dịch cụm từ
 - Nhập nhằng ngữ nghĩa trong ngôn ngữ nguồn và ngôn ngữ đích.
- Subword và Embedding có thể giải quyết:
 - Các từ ngoài từ vựng (Out-of-Vocabulary - OOV).
 - Biến thể hình thái từ (Morphological Variation).
 - (Tạm thời) dịch cụm từ.

A. Pirkola, T. Hedlund, H. Keskusalo, and K. Järvelin, 'Dictionary-Based Cross-Language Information Retrieval: Problems, Methods, and Research Findings.' *Information Retrieval*, 4:209- 230, 2001.


Multilingual Embedding

- **Embedding:** ánh xạ các indexed token vào không gian vector (300-1000) chiều
- Thể hiện mối quan hệ giữa các thuật ngữ.
- Thường được gọi là **CLWEs** (cross-language word embeddings) hoặc **CLEs** (cross-language embeddings).
- Có thể xác định các bản dịch tiềm năng bằng thuật toán **approximate nearest neighbors** (hàng xóm gần nhất xấp xỉ).
- Embeddings có thể là:
 - **Tĩnh** (static): Ví dụ, Word2Vec hoặc GloVe.
 - **Ngữ cảnh** (contextual): Ví dụ, BERT.

2 dạng Multilingual Embedding


Không gian embedding chung:

- Học có giám sát sử dụng bộ dữ liệu cặp câu/vấn bản song ngữ
- Pseudo-mixing:
 - Embeddings được xây dựng từ các tài liệu, trong đó một số từ đã được thay thế bằng bản dịch tương ứng
- Giống hàng không gian nhúng:
 - Không giám sát
 - Giống hàng dựa trên thuật ngữ chung:
 - Ví dụ: so khớp sâu, số, từ cùng gốc
 - Giống hàng dựa trên từ điển.



Mở rộng dựa trên tiền/hậu xử lý việc dịch

- Thêm các thuật ngữ mới vào truy vấn trước/sau khi dịch.



- Trục X:** Tỷ lệ giảm kích thước của từ điển dịch

McNamee and Mayfield, *Comparing Cross-Language Query Expansion Techniques by Degrading Translation Resources*, SIGIR-2002.

Xác suất của bản dịch câu truy vấn

- Các bản dịch của câu truy vấn được tạo ra dựa trên việc học từ văn bản song ngữ.
- Mỗi bản dịch đều có xác suất dịch được ước tính.
- Term frequency và document frequency của query term e được tính dựa trên tf và df của các bản dịch của nó.

$$TF(e, D_k) = \sum_{f_i} p(e|f_i) \times TF(f_i, D_k)$$

$$DF(e) = \sum_{f_i} p(e|f_i) \times DF(f_i)$$

Cross-lingual Information Retrieval with BERT

- Sử dụng BERT để học mối liên quan giữa các truy vấn tiếng Anh và tài liệu ngôn ngữ tiếng khác
- Trọng tâm: tăng cường chất lượng việc ánh xạ ngôn ngữ nguồn - đích
- Đề xuất kiến trúc cross-lingual deep relevance dựa trên mBERT

Zhuolin Jiang et al. 2020. [Cross-lingual Information Retrieval with BERT](#). In *Proceedings of the workshop on Cross-Language Search and Summarization of Text and Speech (CLSSTS2020)*

Kiến trúc BERT gốc




Figure 1: BERT pretraining architecture (Devlin et al., 2019). FFNN denotes feed-forward neural network.




Figure 2: Fine-tuned CLIR BERT model architecture.

Mức độ liên quan của tài liệu với truy vấn

- Q = query, Doc = tài liệu ngôn ngữ khác
- Mức độ liên quan của tài liệu được tính bằng cách tổng hợp các điểm số cấp độ câu bằng mô hình Noisy-OR

$$\begin{aligned}P(\text{Doc is } R|Q) &= P(Q \text{ occurs at least in one sentence in } Doc) \\&= 1 - \prod_{s \in Doc} (1 - P(Q|s)) \\&= 1 - \prod_{s \in Doc} (1 - \prod_{q \in Q} p(q|s))\end{aligned}$$

- Truy vấn nhiều từ sẽ được chia thành nhiều truy vấn 1 từ khi tính mức độ liên quan ở cấp độ tài liệu. Các từ truy vấn riêng lẻ $q \in Q$ được mô hình hóa một cách độc lập.

- Tạo bộ dữ liệu huấn luyện từ bộ dữ liệu cặp câu song ngữ:
 - Mẫu (+): lấy 1 từ không phải từ dừng trong câu ngôn ngữ A ghép cặp với câu trong ngôn ngữ B. Lấy từ vì các query trong tập đó ngắn và dựa từ khóa, nhưng có thể mở rộng ra multi-word queries hoặc query phrases
 - Mẫu (-): các từ khác **không** trong câu ngôn ngữ A ghép với câu ở ngôn ngữ B
 - Tỷ lệ mẫu dương – âm: 1-2
 - Tạo ra 500 triệu mẫu từ 2.6 triệu cặp song ngữ
- Fine tune mBERT với bộ dữ liệu trên để học độ tương đồng song ngữ

Finetuning sử dụng BERT

Approach	phrase query subset	entire query set
Prob. CLIR	57.4	61.2
Prob. Occurrence	51.4	56.9
BERT	61.3	56.8
Dot-Product	50.8	39.2
QRANN	55.8	45.5

Table 3: Performance of MAP scores on the MATERIAL analysis set and Q1 queries.


- Dữ liệu:
 - Mỗi bài viết trên Wikipedia thường có link đến bài tương tự ở ngôn ngữ khác.
 - Lấy tiêu đề các bài viết tiếng Anh làm truy vấn + các bài viết liên quan bằng tiếng Anh, sau đó sử dụng các liên kết ngược trên Wikidata (Wikidata backlinks) để tìm các bài viết liên quan bằng các ngôn ngữ khác
- Các phương pháp:
 - BM25
 - mDPR: thay BERT = mBERT trong Dense Passage Retriever (DPR)
 - Hybrid: kết hợp BM25 và mDPR

[AfriCLIRMatrix: Enabling Cross-Lingual Information Retrieval for African Languages](#) (Ogundepo et al., EMNLP 2022)

Language	ISO	Family	Script	# Docs	# Total Queries	# Total Judgments	# Test Queries	# Test Judgments
Afrikaans	afr	Indo-European	Latin	102,675	1,061,394	1,756,005	1,500	2,557
Amharic	amh	Afro-Asiatic	Ge'ez	15,458	248,672	264,690	1,500	1,582
Moroccan Arabic	ary	Afro-Asiatic	Arabic	5,074	101,222	116,475	500	586
Egyptian Arabic	arz	Afro-Asiatic	Arabic	1,568,079	3,041,535	18,598,398	1,500	9,188
Hausa	hau	Afro-Asiatic	Latin	16,003	216,623	274,135	1,500	1,876
Igbo	ibo	Niger-Congo	Latin	4,066	66,835	78,126	500	586
Northern Sotho	nso	Niger-Congo	Latin	8,320	77,505	112,022	500	804
Shona	sna	Niger-Congo	Latin	8,258	118,120	122,483	500	515
Somali	som	Afro-Asiatic	Latin	9,860	193,088	206,431	1,000	1,049
Swahili	swa	Niger-Congo	Latin	70,808	697,511	883,657	1,500	1,891
Tigrinya	tir	Afro-Asiatic	Ge'ez	378	15,738	15,884	50	50
Twi	twi	Niger-Congo	Latin	1,838	43,527	45,849	250	258
Wolof	wol	Niger-Congo	Latin	1,693	67,621	69,865	250	255
Yorùbá	yor	Niger-Congo	Latin	33,456	323,368	430,533	1,000	1,268
Zulu	zul	Niger-Congo	Latin	10,808	99,987	164,415	1,000	1,442
Total				1,856,566	6,372,746	23,138,969	13,050	23,907

Table 1: Dataset information: number of documents, number of English queries, and number of relevance judgments for each language. Table also contains other relevant information such as the language script and family. The total number of documents is equal to the number of Wikipedia articles for each language.

AfriCLIRMatrix




[AfriCLIRMatrix: Enabling Cross-Lingual Information Retrieval for African Languages](#) (Ogundepo et al., EMNLP 2022)

- MIRACL Challenge tập trung vào việc tìm kiếm thông tin trên 18 ngôn ngữ khác nhau.
- Tìm kiếm dựa trên mô hình cơ sở lai kết hợp giữa so khớp từ khóa và tương đồng ngữ nghĩa
- Xếp hạng lại bằng mạng nơ ron
- Kết hợp các danh sách xếp hạng để ra danh sách cuối


Huang, Zhiqi, Puxuan Yu and James Allan. “[Cross-lingual Knowledge Transfer via Distillation for Multilingual Information Retrieval](#).” ArXiv abs/2302.13400 (2023)

Cross-lingual Knowledge Transfer via Distillation for Multilingual Information Retrieval



(a) Model training pipeline.

Cross-lingual Knowledge Transfer via Distillation for Multilingual Information Retrieval



(b) Model evaluation pipeline.

- **Bi-encoder:** dựa kiến trúc ColBERT, với query và document encoder riêng.
- **Multilingual Pre-training:** Mô hình được khởi tạo với XLM-R, là mô hình đa ngữ
- **Cross-lingual Distillation:** Kiến thức từ tiếng Anh được chuyển giao sang ngôn ngữ đích thông qua kiến trúc OPTICAL, giúp mô hình hoạt động tốt hơn trên ngôn ngữ ít tài nguyên
- Mô hình thầy M gồm bộ mã hóa query encoder EM_q and document encoder EM_d . Cho query q và tài liệu UCV d ,

$$S_{q,d} = \sum_{i=1}^{|q|} \max_{j=1}^{|d|} E_{M_q}(q_i) \cdot E_{M_d}^T(d_j)$$

- **Fine-tuning:** Mô hình tiếp tục được tinh chỉnh trên tập dữ liệu huấn luyện của MIRACL.

Cross-lingual Distillation with OPTICAL

- **Giống hàng token:** Khung OPTICAL giống hàng các biểu diễn token của ngôn ngữ đích với các biểu diễn của tiếng Anh
- **Chuyển giao kiến thức:** Kiến thức truy xuất được học từ tiếng Anh được chuyển giao sang ngôn ngữ đích.
- **Mô hình trò:** Một mô hình trò được xây dựng cho mỗi ngôn ngữ đích, chưng cất kiến thức từ mô hình thầy tiếng Anh.
-

Cross-encoder Re-ranker


- Mô hình cross-encoder được huấn luyện trên mMARCO (bộ dữ liệu xếp hạng đoạn văn đa ngữ). Bộ dữ liệu này cung cấp các cặp truy vấn và đoạn văn liên quan
- Sau khi huấn luyện trên mMARCO, mô hình được tiếp tục tinh chỉnh trên tập dữ liệu huấn luyện của MIRACL, nhằm cải thiện hiệu suất trong các bài toán tìm kiếm thông tin ngẫu nhiên trên nhiều ngôn ngữ.
- Phương pháp kết hợp này tận dụng được cả dữ liệu huấn luyện đa ngôn ngữ lớn (mMARCO) và dữ liệu đặc thù của bài toán (MIRACL).

Table 3: Average performance on two test splits.

Test Splits (Private Score)	nDCG@10			
	BM25	mDPR	Hybrid	Fusion
Test-A	0.449	0.398	0.635	0.759
Test-B	0.347	0.378	–	0.718

Augmenting Passage Representations with Query Generation for Enhanced Cross-Lingual Dense Retrieval

Doc2query (Nogueira et al., 2019)

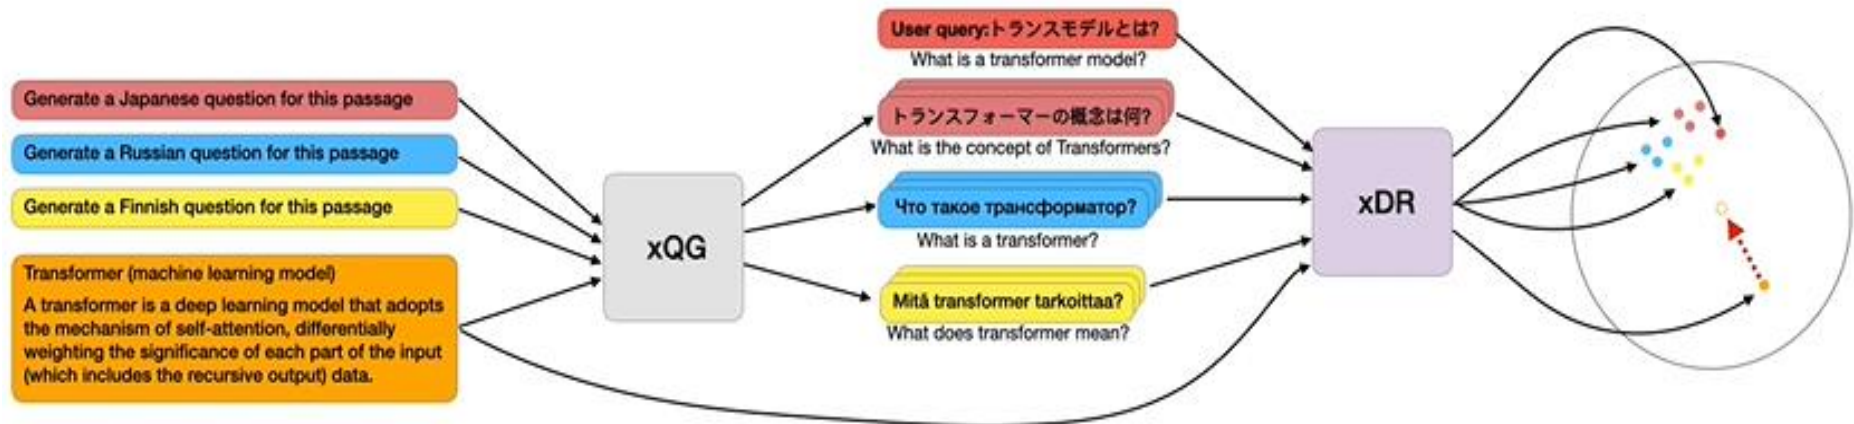


Nogueira, Rodrigo, Wei, Yang, Jimmy, Lin, and Kyunghyun, Cho. "Document expansion by query prediction". *arXiv preprint*, 2019.

Zhuang, Shengyao, Linjun Shou and G. Zuccon. "[Augmenting Passage Representations with Query Generation for Enhanced Cross-Lingual Dense Retrieval](#)." *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* (2023)

Augmenting Passage Representations with Query Generation for Enhanced Cross-Lingual Dense Retrieval

- **Cross-lingual Query Generation:** Fine-tunes a multilingual T5 model to generate queries in different languages.
- **Embedding Aggregation:** Augments the original passage embedding with the embeddings of the generated queries.



$$p_{new} = (1 - \alpha) \cdot p + \alpha \sum_{\hat{q} \in Q_p} \hat{q}$$

Zhuang, Shengyao, Linjun Shou and G. Zuccon. “[Augmenting Passage Representations with Query Generation for Enhanced Cross-Lingual Dense Retrieval](#).” *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* (2023)

- Dataset: XOR-TyDi (Akari et al., 2021)
 - Query: 7 typologically diverse languages (Ar, Bn, Fi, Ja, Ko, Ru, Te).
 - Corpus: 18M En passages from wikipedia pages.
 - Training data: 15k
 - Cross-lingual DR: mBERT-base
 - Cross-lingual QG: mT5-base
 - Eval data: 2k
 - Metrics: Recall@2kt, Recall@5kt.

Asai, Akari, Jungo, Kasai, Jonathan, Clark, Kenton, Lee, Eunsol, Choi, and Hannaneh, Hajishirzi. "XOR QA: Cross-lingual Open-Retrieval Question Answering." ACL, 2021.

(a) R@2kt

Model	Ar	Bn	Fi	Ja	Ko	Ru	Te	Average
XLM-R	28.5	26.3	29.3	22.4	34.0	17.3	34.9	27.5
XLM-R + xQG	30.1	29.6	31.2	23.7	36.1	19.4	38.2	29.8[★]
mBERT	41.1	49.0	52.2	37.3[★]	48.1	33.3	47.9	44.1
mBERT + xQG	42.4	54.9[★]	54.1	33.6	52.3[★]	33.8	52.5[★]	46.2[★]
mBERT (zero-shot)	32.6	25.0	38.2	29.5	38.9	27.0	39.9	33.0
mBERT (zero-shot) + XQG	33.9	28.9[★]	43.0[★]	32.8[★]	41.4	29.5	42.0	36.0[★]

(b) R@5kt

Model	Ar	Bn	Fi	Ja	Ko	Ru	Te	Average
XLM-R	38.5	33.6	37.9	32.8	42.8	28.3	47.5	37.3
XLM-R + xQG	38.8	41.1[★]	39.8	32.8	43.2	30.8	49.6	39.4[★]
mBERT	49.2	57.6	58.6	42.7	57.5	41.4	55.9	51.8
mBERT + xQG	51.5	60.9[★]	58.3	43.6	58.6	41.4	60.1[★]	53.5[★]
mBERT (zero-shot)	38.5	36.5	47.5	38.2	48.1	35.0	48.7	41.8
mBERT (zero-shot) + xQG	43.7[★]	40.8[★]	50.0[★]	40.2	49.8	39.7[★]	51.7	45.1[★]

- Ảnh hưởng của α và số query sinh ra

