

## Truy vấn dữ liệu – Bài tập lần 1

Giảng viên: Lê Thanh Hương

**Hạn nộp bài: 18/10/2024** (*Nộp muộn 1 ngày trừ 1 điểm. Nộp muộn 1 tuần 0 điểm*)

**Bài 1.** Dưới đây là một phần của file chỉ mục đảo (inverted index):

mô\_hình: 2: (36,174,252,651); 4: (12,22,102,432); 7: (17);  
truy\_vấn: 2: (1,17,74,222); 4: (8,78,108,458); 7: (3,13,23,193);  
bi-encoder: 2: (87,704,722,901); 4: (13,43,113,433); 7: (18,328,528);  
với: 2: (3,37,76,444,851); 4: (10,20,110,470,500); 7: (5,15,25,195);  
thông\_tin: 2: (2,66,194,321,702); 4: (9,69,149,429,569); 7: (4,14,404);  
và: 2: (47,86,234,999); 4: (14,24,774,944); 7: (199,319,599,709);  
cross-encoder: 2: (57,94,333); 4: (15,35,155); 7: (20,320);  
phương\_pháp: 2: (67,124,393,1001); 4: (11,41,101,421,431); 7: (15,35,735);

Giải thích: “mô\_hình: 7: (17)” nghĩa là từ “mô\_hình” xuất hiện trong tài liệu có docID = 7 và là từ ở vị trí 17 trong tài liệu đó.

Dựa trên nội dung file trên, tìm các tài liệu khớp với truy vấn sau, trong đó mỗi biểu thức trong dấu nháy là một truy vấn cụm từ:

- "truy\_vấn thông\_tin với". Cho biết chỉ số của tài liệu (docID) và vị trí khớp với truy vấn.
- "mô\_hình bi-encoder và cross-encoder". Cho biết vị trí khớp với truy vấn.
- "truy\_vấn thông\_tin với" AND "mô\_hình bi-encoder và cross-encoder". Cho biết chỉ số của tài liệu (docID) và vị trí khớp với truy vấn.

**Bài 2.** Giả sử các đại lượng tính  $g(d)$  cho các văn bản d1, d2, d3 lần lượt là 0.25, 0.5 và 1. Cho tần suất thuật ngữ (tf) thuộc các tài liệu đó trong bảng bên trái sau:

| tf       |    |    |    |
|----------|----|----|----|
|          | d1 | d2 | d3 |
| xe máy   | 27 | 4  | 24 |
| tốt nhất | 3  | 33 | 0  |
| ô tô     | 0  | 33 | 29 |
| bảo hiểm | 14 | 0  | 17 |

| $tf_{norm}$ |      |    |    |
|-------------|------|----|----|
|             | d1   | d2 | d3 |
| xe máy      | 0.88 |    |    |
| tốt nhất    | 0.10 |    |    |
| ô tô        | 0    |    |    |
| bảo hiểm    | 0.46 |    |    |

Điền nốt các giá trị  $tf_{norm}$  vào bảng bên phải. Hãy đưa ra bảng chỉ mục ngược với các thuật ngữ được sắp xếp theo  $g(d) + tf_{norm}(t, d)$ .

**Bài 3.** Tính độ tương đồng  $Inc.ltn$  giữa truy vấn “John Miller” và tài liệu “John Miller, John Fisher, and one other John” bằng cách điền vào các cột trống trong bảng dưới đây. Coi “and”,

“one”, và “other” là các từ dừng.  $N = 100,000,000$ .  $df_{John} = 50000$ ,  $df_{Fisher} = 100000$ ,  $df_{Miller} = 10000$ . Giá trị độ tương đồng cuối cùng  $RSV(d, q)$  là bao nhiêu?

|        | Document |                 |   |      | Query |                 |    |     |   |      |
|--------|----------|-----------------|---|------|-------|-----------------|----|-----|---|------|
|        | tf       | <sup>w</sup> tf | w | norm | tf    | <sup>w</sup> tf | df | idf | w | norm |
| John   |          |                 |   |      |       |                 |    |     |   |      |
| Miller |          |                 |   |      |       |                 |    |     |   |      |
| Fisher |          |                 |   |      |       |                 |    |     |   |      |

**Bài 4.** Giả sử bạn có tập dữ liệu sau với các thông tin sau:

- **Tài liệu 1:** "Machine learning is a field of artificial intelligence"
- **Tài liệu 2:** "Machine learning algorithms use statistical models to learn from data"

Cho số tài liệu trong tập dữ liệu  $N = 10.000$ , trong đó có 500 tài liệu chứa từ “machine”, 700 tài liệu chứa từ “learning”. Độ dài trung bình của các tài liệu trong tập dữ liệu  $avgdl = 8$  từ. Cho  $k1 = 1.5$ ,  $b = 0.75$

1. Tính điểm BM25 của tài liệu 1 và tài liệu 2 đối với truy vấn "machine learning".
2. Tài liệu nào phù hợp với truy vấn hơn dựa trên điểm BM25. Tại sao?

**Bài 5.** Giả sử bạn có tập dữ liệu sau với các thông tin sau:

- **Tài liệu 1:** "Deep learning is a subset of machine learning"
- **Tài liệu 2:** "Neural networks are a key part of deep learning"

Số lượng tài liệu trong tập dữ liệu  $N = 1.000$ . Độ dài trung bình tài liệu trên cả tập là 10.

Số tài liệu chứa các từ "deep", "learning", "neural", "networks" lần lượt là 100, 200, 150, 120.

Số lần xuất hiện của các từ trong các tài liệu:

- Tài liệu 1: "deep": 1 lần, "learning": 2 lần
- Tài liệu 2: "deep": 1 lần, "neural": 1 lần, "networks": 1 lần

1. Sử dụng BM25 (với  $k1 = 1.5$  và  $b = 0.75$ ) để tính điểm cho từng tài liệu đối với hai truy vấn “machine learning” và “deep learning”.
2. So sánh kết quả với phương pháp tf.idf.
3. Dựa trên các kết quả BM25 và tf.idf, đưa ra ưu và nhược điểm của hai phương pháp trong việc xếp hạng tài liệu.