

Hệ thống học máy


ONE LOVE. ONE FUTURE.

1


1

Hệ thống học máy


1. Học máy trong sản xuất còn hơn cả việc thực hiện mô hình ML



2. Học máy trong sản xuất là một chu trình



so vôi



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

2

2



3

Dữ liệu là cần thiết.

Cuộc tranh luận ở đây là liệu dữ liệu hữu hạn* có đủ hay không.


* Nếu chúng ta có dữ liệu vô hạn, chúng ta có thể giải quyết các vấn đề phức tạp tùy ý chỉ bằng cách tra cứu câu trả lời.

Dữ liệu lớn  dữ liệu vô hạn


 **ĐẠI HỌC BÁCH KHOA HÀ NỘI**
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

4

4




5



6

Nhiều dữ liệu hơn (nói chung) cần nhiều tính toán hơn

“Lượng tính toán được sử dụng trong các đợt đào tạo AI lớn nhất đã tăng gấp đôi sau mỗi 3,5 tháng”



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

AI và tính toán (OpenAI 2018)

7

⚠ Dữ liệu: tiềm ẩn nhiều khả năng sai lệch ⚠

• sai lệch trong chọn mẫu/lựa chọn • đại

diện thiếu/quá mức các nhóm phụ • sai lệch của con người ẩn chứa trong dữ liệu lịch sử • sai lệch trong dán nhãn


• ...

Những sai lệch về thuật toán chưa được đề cập (chưa a)!



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

8



9

Nhãn hiệu

1. Ghi nhãn thủ công
2. Ghi nhãn theo chương trình
3. Giám sát yếu, giám sát bán phần, học tập chủ động, học tập chuyển giao




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

10

10

⚠️ Nhiều dữ liệu hơn không phải lúc nào cũng tốt hơn ⚠️



Ý tưởng thu thập dữ liệu từ cộng đồng để có được 1 triệu nhãn!




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

11

11

⚠️ Nhiều dữ liệu hơn không phải lúc nào cũng tốt hơn ⚠️



Tại sao mô hình ngày càng tệ hơn?




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

12

12

⚠ Nhãn nguồn với độ chính xác khác nhau ⚠



• 100K nhãn: được gán nhãn nội bộ, độ chính xác cao • 1M nhãn: được gán cộng đồng
đóng góp, có nhiều



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

13

13

Đa dạng nhãn: ví dụ

Nhiệm vụ: dán nhãn tất cả các thực thể trong câu sau:

Darth Sidious, được biết đến với cái tên đơn giản là Hoàng đế, là Chúa tể bóng tối của Sith, người trị vì thiên hà với tư cách là Hoàng đế Thiên hà của Đế chế Thiên hà đầu tiên.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

14

14

Đa dạng nhãn: ví dụ

Nhiệm vụ: dán nhãn tất cả các thực thể trong câu sau:

Darth Sidious, đư ợc biết đến đơ n giản là Hoàng đế, là Chúa tể bóng tối của Sith
ngư ời trị vì thiên hà với tư cách là Hoàng đế Thiên hà của Đế chế Thiên hà đầu tiên.

Ngư ời chú thích	# thực thể	Chú thích
1	3	[Darth Sidious], đư ợc biết đến đơ n giản là Hoàng đế, là một [Chúa tể bóng tối của Sith], ngư ời trị vì thiên hà với tư cách là [Hoàng đế thiên hà của Đế chế thiên hà đầu tiên]
2	6	[Darth Sidious], đư ợc biết đến đơ n giản là [Hoàng đế], là một [Chúa tể bóng tối] của [Sith], ngư ời trị vì thiên hà với tư cách là [Hoàng đế thiên hà] của [Đế chế thiên hà đầu tiên].
3	4	[Darth Sidious], đư ợc biết đến đơ n giản là [Hoàng đế], là [Chúa tể bóng tối của Sith], ngư ời trị vì thiên hà với tư cách là [Hoàng đế thiên hà của Đế chế thiên hà đầu tiên].



Đa dạng nhãn

Cần nhiều chuyên môn hơn n (khó dán nhãn hơn n), nhiều chỗ cho sự bất
đồng quan điểm hơn n!

Nếu các chuyên gia không thể thống nhất về một nhãn hiệu, đã đến lúc phải xem xét lại hiệu suất ở cấp độ con ngư ời



Đa dạng nhãn: giải pháp

- Xác định vấn đề rõ ràng
 - Chọn thực thể bao gồm chuỗi con dài nhất

Người chỉ thích	# thực thể Chỉ thích	
1	3	[Darth Sidious], đư ợc biết đến đơ n giản là Hoàng đế, là một [Chúa tể bóng tối của Sith], người trị vì thiên hà với tư cách là [Hoàng đế thiên hà của Đế chế thiên hà đầu tiên]
2	6	[Darth Sidious], đư ợc biết đến đơ n giản là [Hoàng đế], là một [Chúa tể bóng tối] của [Sith], người trị vì thiên hà với tư cách là [Hoàng đế thiên hà] của [Đế chế thiên hà đầu tiên].
3	4	[Darth Sidious], đư ợc biết đến đơ n giản là [Hoàng đế], là [Chúa tể bóng tối của Sith], người trị vì thiên hà với tư cách là [Hoàng đế thiên hà của Đế chế thiên hà đầu tiên].



17

Đa dạng nhãn: giải pháp

- Xác định vấn đề rõ ràng
- Đào tạo chú thích
- Đồng đối dữ liệu: theo dõi nguồn gốc của dữ liệu/nhãn



18

Đa dạng nhãn: giải pháp

• Định nghĩa vấn đề rõ ràng •

Đào tạo chú thích • Dòng

dữ liệu: theo dõi nguồn gốc của dữ liệu/nhãn •

Phương pháp học với nhãn nhiễu • Học với

nhãn nhiễu (Natarajan và cộng sự, 2013) • Phân tích tổn thất,

học có giám sát yếu và độ mạnh của nhãn nhiễu (Patrini và cộng sự, 2016)

• Học tập nhảy cảm với chi phí với nhãn nhiễu (Natarajan và cộng sự, 2018) •

Học tập tự tin: Ước tính sự không chắc chắn trong nhãn tập dữ liệu (Northcutt và cộng sự, 2019)




19

Nhãn chữ ở ng trình



20

Dữ liệu đào tạo là nút thắt cổ chai




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

21

21

Dữ liệu đào tạo là nút thắt cổ chai




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

22

22

Dữ liệu đào tạo là nút thắt cổ chai



Làm thế nào để có được dữ liệu đào tạo trong vài ngày?



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

23

[Lập trình dữ liệu đa phương thức cho phép học máy y tế nhanh chóng \(Dunmon et al., 2019\)](#)

23

Dữ liệu dán nhãn thủ công là ...



- **Đắt tiền:** Đặc biệt là khi cần có chuyên môn về chủ đề
- **Không riêng tư:** Cần phải chuyển dữ liệu cho người chú thích
- **Chậm:** Thời gian cần thiết tăng theo tỷ lệ tuyến tính với số nhãn cần thiết
- **Không thích ứng:** Mỗi thay đổi đều yêu cầu phải dán nhãn lại cho tập dữ liệu




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

24

24

Giao tiếp đa chức năng




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

25

25

SME như chức năng dán nhãn



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

26

26

LF: có thể thể hiện nhiều loại phương pháp tìm kiếm khác nhau

Phù hợp mẫu	Nếu một cụm từ như "gửi tiền" có trong email
Tìm kiếm Boolean	Nếu <code>unknown_sender</code> VÀ <code>foreign_source</code>
Tra cứu DB	Nếu người gửi nằm trong <code>Blacklist.db</code> của chúng tôi
Phương pháp tìm kiếm	Nếu <code>SpellChecker</code> tìm thấy 3+ lỗi chính tả
Hệ thống di sản	Nếu <code>LegacySystem</code> bỏ phiếu spam
Mô hình của bên thứ ba	Nếu <code>BERT</code> dán nhãn một thực thể là "chế độ an ninh"
Nhãn đám đông	Nếu <code>Cộng nhân #23</code> bỏ phiếu spam




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

27

27

LF: có thể thể hiện nhiều loại phương pháp tìm kiếm khác nhau



Chức năng ghi nhớ: Đơn giản, linh hoạt, dễ hiểu, dễ thích ứng, nhanh chóng




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

28

28

LF: mạnh mẽ như ng ồn ào



- Ổn ào: Không xác định, không chính xác
- Trùng lặp: Các LF có thể tư ơng quan
- Xung đột: các LF khác nhau đư a ra các nhãn khác nhau


Hep: Không khai quát hóa tốt

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

29

29

Nhãn LF đư ợc kết hợp để tạo ra sự thật cơ bản



[Ratner và cộng sự. NeurIPS '16;
Bach và cộng sự. ICML '17;
Ratner và cộng sự. AAAI '19;
Varma và cộng sự. ICML '19;
Sala và cộng sự. NeurIPS '19;
Fu và cộng sự. ICML '20]

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

30


30

Nhãn thủ công	Nhãn chương trình
Đắt tiền: đặc biệt là khi cần chuyên môn về một chủ đề nào đó	Tiết kiệm chi phí: Chuyên môn có thể được phân phối bản, chia sẻ, tái sử dụng trên toàn tổ chức
Không riêng tư: Cần chuyển dữ liệu đến người chú thích	Quyền riêng tư: Tạo LF bằng cách sử dụng mẫu dữ liệu đã xóa, sau đó áp dụng LF cho dữ liệu khác mà không cần xem xét từng mẫu riêng lẻ.
Chậm: Thời gian cần thiết tỷ lệ tuyến tính với # nhãn cần thiết	Nhanh: Dễ dàng mở rộng quy mô mẫu 1K -> 1M
Không thích ứng: Mỗi thay đổi đều yêu cầu phải dán nhãn lại tập dữ liệu	Thích ứng: Khi có thay đổi, chỉ cần áp dụng lại LF!



31

Nhãn theo chương trình: Mở rộng quy mô với dữ liệu không có nhãn




32

Giám sát yếu, giám sát bán phần, học tập
chủ động, học
tập chuyển giao



33


How to get more labeled training data?



34

Giám sát yếu

- Tận dụng các nguồn nhiều, không chính xác để tạo nhãn
 - ví dụ nếu "tiền" có trong email thì có thể đó là thư rác



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

[Khai thác kiến thức tổ chức cho máy học](#) (Ratner và cộng sự, Google AI Blog 2019)

35

35

Bán giám sát

- Sử dụng các giả định về cấu trúc để tận dụng một lượng lớn dữ liệu chưa được gắn nhãn cùng với một lượng nhỏ dữ liệu đã được gắn nhãn
 - Các hashtag trong cùng một hồ sơ /tweet có thể có chủ đề tương tự



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

36

36

Bán giám sát

- Sử dụng các giả định về cấu trúc để tận dụng một lượng lớn dữ liệu chưa được gắn nhãn cùng với một lượng nhỏ lượng dữ liệu được gắn nhãn
- Có thể yêu cầu các thuật toán phức tạp như phân cụm để khám phá sự tương đồng



37

Bán giám sát: tự đào tạo

1. Đào tạo mô hình trên một tập dữ liệu được gắn nhãn nhỏ
2. Sử dụng mô hình này để tạo dự đoán cho dữ liệu chưa được gắn nhãn 3. Sử dụng dự đoán có xác suất thô cao làm nhãn 4. Lặp lại bước 1 với dữ liệu được gắn nhãn mới



38

Bán giám sát: phương pháp dựa trên nhiễu loạn

Giả định: nhiễu loạn nhỏ sẽ không làm thay đổi nhãn của mẫu

- Thêm tiếng ồn trắng vào hình ảnh
- Thêm các giá trị nhỏ vào nhúng từ

Cũng là một phương pháp tăng cường dữ liệu!




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

39

39

Thử thách bán giám sát: kích thước tập hợp hợp lệ

- Bộ hợp lệ lớn: ít dữ liệu để đào tạo •
- Bộ hợp lệ nhỏ: không đủ tín hiệu để chọn mô hình tốt nhất



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

40

Đánh giá thực tế các thuật toán học bán giám sát sâu (Oliver et al., 2018)

40

Chuyển giao học tập

Áp dụng mô hình được đào tạo cho một nhiệm vụ cho một nhiệm vụ khác

1. Tinh chỉnh
2. Dựa trên lời nhắc



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Mô hình ngôn ngữ là người đi học ít lần (OpenAI 2020)

41

41

Chuyển giao học tập: tinh chỉnh

- tinh chỉnh chỉ một số lớp • tinh chỉnh toàn bộ mô hình

Fine-tuning

The model is trained via repeated gradient updates using a large corpus of example tasks.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Mô hình ngôn ngữ là người đi học ít lần (OpenAI 2020)

42

42

Chuyển giao học tập: Dựa trên lời nhắc

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 cheese => ..... ← prompt
```

One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← example
3 cheese => ..... ← prompt
```

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← examples
3 peppermint => menthe poivrée ← examples
4 plush girafe => girafe peluche ← examples
5 cheese => ..... ← prompt
```



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Mô hình ngôn ngữ là người học ít lần. (OpenAI 2020)

43

43

Học tập tích cực

- Mục tiêu: Tăng hiệu quả của nhãn • Các mẫu nhãn được ước tính là có giá trị nhất đối với mô hình theo một số số liệu



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Khảo sát tài liệu học tập tích cực. (Burr Settles, 2010)

44

44

Số liệu học tập tích cực

- Đo lường sự không chắc chắn •
ví dụ mẫu nhãn có xác suất thấp nhất cho lớp dự đoán



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Khảo sát tài liệu học tập tích cực (Burr Settles, 2010)

45

45

Số liệu học tập tích cực

- Đo lường sự không chắc chắn •
- Sự bất đồng của các mô hình ứng viên
- Có một số mô hình ứng viên (ví dụ các mô hình có các tham số siêu việt khác nhau)
 - Mỗi mô hình đưa ra dự đoán riêng của mình
 - Dân nhãn các mẫu có nhiều sự bất đồng nhất nhất



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Khảo sát tài liệu học tập tích cực (Burr Settles, 2010)

46

46

Học tập tích cực




Figure 2: An illustrative example of pool-based active learning. (a) A toy data set of 400 instances, evenly sampled from two class Gaussians. The instances are represented as points in a 2D feature space. (b) A logistic regression model trained with 30 labeled instances randomly drawn from the problem domain. The line represents the decision boundary of the classifier (70% accuracy). (c) A logistic regression model trained with 30 actively queried instances using uncertainty sampling (90%).



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Khảo sát tài liệu học tập tích cực. (Burr Settles, 2010)

47

47

Phương pháp	Làm sao	Có cần sự thật không?
Giám sát yếu	Tận dụng các phương pháp tìm kiếm (thường gây nhiễu) để tạo nhãn	Không, nhưng một số ít nhãn hữu ích để hướng dẫn phát triển các phương pháp tìm kiếm
Bán giám sát	Tận dụng các giả định về cấu trúc để tạo nhãn	Có. Một số lượng nhỏ nhãn ban đầu như hạt giống để tạo ra nhiều nhãn hơn
Chuyển giao học tập	Tận dụng các mô hình được đào tạo trước trên một tác vụ khác cho tác vụ mới của bạn	Không học bằng không Có thể điều chỉnh tốt, mặc dù số GT cần thiết thường ít hơn nhiều so với số GT cần thiết nếu đào tạo từ đầu.
Học tập tích cực	Nhãn các mẫu dữ liệu hữu ích nhất cho mô hình của bạn	Đúng



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

48

48



49

Các loại lấy mẫu

- Lấy mẫu không xác suất • Lấy mẫu thuận

tiện: lựa chọn dựa trên tính khả dụng ■ Yêu cầu phản hồi ■ Chọn các tập dữ liệu hiện

có ■ Xem các đánh giá có sẵn trên

Amazon

- Lấy mẫu theo kiểu lăn cầu tuyết: các mẫu trong tư ơng lai đ ợc chọn dựa trên các mẫu hiện có

■ Ví dụ để thoát khỏi các tài khoản Twitter hợp pháp, hãy bắt đầu với các tài khoản hạt giống sau đó thu thập dữ liệu của họ

sau • Lấy mẫu

theo phán đoán: các chuyên gia quyết định những gì cần đ ư a vào • Lấy mẫu theo hạn

ngạch: hạn ngạch cho một số phần dữ liệu nhất định (không ngẫu nhiên)

-



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

50

50

Dữ liệu được sử dụng trong ML chủ yếu được thúc đẩy bởi sự tiện lợi

- Mô hình ngôn ngữ: BookCorpus, CommonCrawl, Wikipedia, liên kết Reddit • Phân tích tình cảm: IMDB, Amazon • Chỉ những người dùng có quyền truy cập Internet và sẵn sàng đưa ra bài đánh giá trực tuyến
- Xe tự lái: hầu hết dữ liệu đến từ Bay Area (CA) và Phoenix (AZ) • Rất ít dữ liệu về thời tiết mưa và tuyết

! Có rất nhiều sự thiên vị trong dữ liệu!



51

Các loại lấy mẫu

- Lấy mẫu phi xác suất • Lấy mẫu ngẫu nhiên • Lấy mẫu ngẫu nhiên đơn giản • Lấy mẫu phân tầng • Lấy mẫu có trọng số • Lấy mẫu quan trọng • Lấy mẫu dự trữ
- ...



52

Lấy mẫu ngẫu nhiên đơn giản


- Mỗi mẫu trong quần thể có cơ hội được chọn như nhau
 - Ví dụ chọn 10% tổng số mẫu trong quần thể

Ưu điểm	Nhược điểm
• Đơn giản (loại lấy mẫu ngẫu nhiên dễ nhất)	• Không đảm bảo đại diện: có thể loại trừ các lớp hiếm (thiên nga đen!)

53

Lấy mẫu phân tầng

- Chia dân số theo nhóm nhỏ
 - Các lát dữ liệu
 - 20% mỗi nhóm tuổi: 18-24, 25-34, 35+, v.v.
- Các lớp học
 - 2% của mỗi lớp



Ưu điểm	Nhược điểm
Các nhóm nhỏ được đại diện	Không thể sử dụng khi: • mẫu không thể được đưa vào nhóm phụ • mẫu có thể thuộc về nhiều nhóm con (đa nhân)

54

Lấy mẫu có trọng số

- Mỗi phần tử được gán một trọng số, quyết định khả năng được chọn.
 - Nếu bạn muốn chọn một mẫu 30% thời gian, hãy cho nó trọng số 3/10 • Có thể nhúng kiến thức về miền • Ví dụ: biết phân phối dân số mục tiêu của bạn hoặc muốn ưu tiên các mẫu gần đây

```
random.choices(dân số=[1, 2, 3, 4, 100, 1000],
               trọng số=[0,2, 0,2, 0,2, 0,2, 0,1, 0,1],
               k=2)
```



```
random.choices(dân số=[1, 1, 2, 2, 3, 3, 4, 4, 100, 1000], k=2)
```



Lấy mẫu quan trọng

- Hữu ích khi việc lấy mẫu từ $P(x)$ tốn kém, chậm hoặc không khả thi • Lấy mẫu $x \sim Q(x)$ để lấy mẫu từ $P(x)$ • Trọng số theo $P(x)/Q(x)$ • Tính toán $P(x)/Q(x)$ có thể tốn kém



$$E_{P(x)}[x] = \sum_x P(x) x = \sum_x Q(x) x \frac{P(x)}{Q(x)} = E_{Q(x)}[x \frac{P(x)}{Q(x)}]$$



Lấy mẫu quan trọng

- Hữu ích khi việc lấy mẫu từ $P(x)$ tốn kém, chậm hoặc không khả thi • Lấy mẫu x Dễ lấy mẫu hơn từ $Q(x)$ • Trọng số theo $\frac{P(x)}{Q(x)}$ • Tính toán $P(x)/Q(x)$ có thể tốn kém

Ví dụ, điều cần thiết cho RL •

Quá tốn kém để ước tính phần thưởng theo chính sách mới, vì vậy
hãy sử dụng chính sách cũ

$$E_{P(x)}[x] = \sum_x P(x) x = \sum_x Q(x) x \frac{P(x)}{Q(x)} = E_{Q(x)}[x \frac{P(x)}{Q(x)}]$$

$$\nabla_{\theta} J(\theta) = E_{\tau \sim \bar{\pi}_{\theta}(\tau)} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(\mathbf{a}_t | \mathbf{s}_t) \left(\prod_{t'=1}^t \frac{\pi_{\theta}(\mathbf{a}_{t'} | \mathbf{s}_{t'})}{\bar{\pi}_{\theta}(\mathbf{a}_{t'} | \mathbf{s}_{t'})} \right) \left(\sum_{t'=t}^T r(\mathbf{s}_{t'}, \mathbf{a}_{t'}) \right) \right]$$



use old policy to sample data

old policy

57

57

Lấy mẫu hồ chứa: vấn đề

- Cần chọn k mẫu từ luồng n mẫu với xác suất bằng nhau • n không xác định

- không thể/không hiệu quả để đưa tất cả vào bộ nhớ • Có

thể dừng luồng bất cứ lúc nào và lấy các mẫu cần thiết




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

58

58

Lấy mẫu hồ chứa: giải pháp

1. k phần tử đầu tiên được đưa vào hồ chứa
2. Đối với mỗi phần tử thứ i đi vào, tạo một số ngẫu nhiên j giữa 1 và i
 Nếu $1 \leq j \leq k$: thay thế jth trong hồ chứa bằng i
3. Mỗi phần tử đến đều có k/i cơ hội xuất hiện trong bể chứa!



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Ngoài ra hãy kiểm tra thuật toán L (dựa trên phân phối hình học)

59

59

Có vs. không có sự thay thế

Với sự thay thế	Không thay thế
Cùng một mục có thể được chọn nhiều lần	Không thể chọn cùng một mục nhiều hơn một lần
• Không có sự khác biệt giữa hai mẫu được chọn • Phân bố dân số thực tế gần đúng	• Hiệp phương sai giữa hai mẫu được chọn • Phương sai giảm khi kích thước tập dữ liệu trở nên lớn
Đóng bao	Giảm dần độ dốc theo lô nhỏ

Tại sao chúng ta sử dụng kỹ nguyên thay vì chỉ lấy mẫu

với sự thay thế từ toàn bộ tập dữ liệu?




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

60

60

Có vs. không có sự thay thế

Bởi vì theo kinh nghiệm, nó hội tụ nhanh hơn n được chứng minh cho các hàm mất mát lỗi mạnh



ĐẠI HỌC BÁCH KHOA HÀ NỘI

SU/HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY toán giảm dần độ dốc ngẫu nhiên (Leon Bottou, 2009)
 Tại sao việc xáo trộn ngẫu nhiên lại giúp hai được sự giảm dần độ dốc ngẫu nhiên (Gurbuzbalaba và cộng sự, 2015)

61

61

Phong thí nghiệm

<https://colab.research.google.com/github/GokuMohandas/Made-With-ML/blob/main/notebooks/madewithml.ipynb>



ĐẠI HỌC BÁCH KHOA HÀ NỘI
 HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

62

62


Sự mất cân bằng của lớp

63


Sự mất cân bằng của lớp

Small data and rare occurrences

ML works well when
the data distribution
is this:



Not so well when it
is this:



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Andrew Ng: Kết nối bằng chứng khái niệm của AI với khoảng cách sản xuất (2020)

64

64

Tại sao mất cân bằng giai cấp lại khó khăn?

- Không đủ tín hiệu để tìm hiểu về các lớp hiếm



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

65

65

Tại sao mất cân bằng giai cấp lại khó khăn?

- Không đủ tín hiệu để tìm hiểu về các lớp hiếm • Về mặt

thống kê, dự đoán nhãn đa số có khả năng đúng cao hơn

- Nếu một lớp chiếm đa số chiếm 99% dữ liệu, thì việc luôn dự đoán nó sẽ mang lại độ chính xác 99%



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

66

66

Tại sao mất cân bằng giai cấp lại khó khăn?

- Không đủ tín hiệu để tìm hiểu về các lớp hiếm • Về mặt thống kê, dự đoán nhân đa số có nhiều khả năng đúng hơn • Chi phí lỗi không đối xứng: chi phí khác nhau của các dự đoán sai



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

67

67

Tại sao mất cân bằng giai cấp lại khó khăn?

- Không đủ tín hiệu để tìm hiểu về các lớp hiếm • Về mặt thống kê, dự đoán nhân đa số có nhiều khả năng đúng hơn • Chi phí lỗi không đối xứng: chi phí khác nhau của các dự đoán sai



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

68


68

Chi phí lỗi không đối xứng: hồi quy

• Phần trăm thứ 95: 10.000 đô la

• Trung vị:

250 đô la



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Cảm ơn Eugene Yan vì ví dụ này!

69

69

Chi phí lỗi không đối xứng: hồi quy


Sai số 100%

Không ổn

• Từ 10.000 đô la: giảm 10.000 đô

la • Từ 250 đô la: giảm 250 đô la

được rồi



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Cảm ơn Eugene Yan vì ví dụ này!

70

70

Sự mất cân bằng giai cấp là chuẩn mực

- Phát hiện gian lận
- Phát hiện thư rác
- Kiểm tra bệnh tật • Dự đoán sự xáo trộn •

Kiểm tra sơ yếu lý lịch

- Ví dụ: 2% sơ yếu lý lịch vượt qua kiểm

tra • Phát hiện đối tượng

- Hầu hết các hộp giới hạn không chứa bất kỳ đối tượng nào

Mọi người quan tâm nhiều hơn đến các sự kiện bất thường/có khả năng gây thảm họa



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Hình ảnh từ [PyImageSearch](#)

71

71

Nguồn gốc của sự mất cân bằng giai cấp

- Sai lệch mẫu
 - Khu vực địa lý hẹp (xe tự lái) • Sai lệch lựa chọn
- Tên miền cụ thể
 - Tốn kém, chậm hoặc không khả thi để thu thập dữ liệu của một số lớp nhất định
- Lỗi ghi nhãn



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

72

72

Làm thế nào để giải quyết tình trạng mất cân bằng giai cấp

1. Chọn số liệu phù hợp
2. Phương pháp cấp dữ liệu
3. Phương pháp cấp thuật toán



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

73

73

1. Chọn số liệu phù hợp

Ma trận nhầm lẫn giữa Mô hình A và Mô hình B

Cuộc thăm dò trên Zoom:

Bạn sẽ chọn mẫu nào?

Mô hình A	Thật sự BỆNH UNG THƯ	Thật sự BÌNH THƯỜNG
Đã dự đoán BỆNH UNG THƯ	10	10
Đã dự đoán BÌNH THƯỜNG	90	890

Mô hình B	Thật sự BỆNH UNG THƯ	Thật sự BÌNH THƯỜNG
Đã dự đoán BỆNH UNG THƯ	90	90
Đã dự đoán BÌNH THƯỜNG	10	810



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

74

74

Chọn số liệu phù hợp

Ma trận nhầm lẫn giữa Mô hình A và Mô hình B

Mô hình B có khả năng cho biết bạn có bị ung thư hay không tốt hơn

Mô hình A	Thật sự BỆNH UNG THƯ	Thật sự BÌNH THƯỜNG
Đã dự đoán BỆNH UNG THƯ	10	10
Đã dự đoán BÌNH THƯỜNG	90	890

Mô hình B	Thật sự BỆNH UNG THƯ	Thật sự BÌNH THƯỜNG
Đã dự đoán BỆNH UNG THƯ	90	90
Đã dự đoán BÌNH THƯỜNG	10	810

Cả hai đều có độ chính xác như nhau: 90%



Số liệu đối xứng so với số liệu không đối xứng

Số liệu đối xứng	Số liệu không đối xứng
Đối xử với tất cả các lớp như nhau	Đo lường hiệu suất của mô hình so với một lớp

$$\text{Accuracy} = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

$$F_1\text{-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

- TP: Kết quả dự đoán tính thật
- TN: Âm tính thật

- FP: Kết quả dự đoán tính giả
- FN: Kết quả âm tính giả



Sự mất cân bằng của lớp: số liệu không đối xứng

- Hiệu suất mô hình của bạn liên quan đến một lớp

	UNG THƯ (1)	BÌNH THƯ ỜNG (0)	Độ chính xác	Độ chính xác	Thu hồi	F1
Mô hình A 10/100		890/900	0,9	0,5	0,1	0,17
Mẫu B 90/100		810/900	0,9	0,5	0,9	0,64

⚠ Điểm F1 cho CANCER là 1 khác
với điểm F1 cho
BÌNH THƯ ỜNG như ⚠




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

77

77

2. Phương pháp cấp dữ liệu: Lấy mẫu lại

Lấy mẫu dư ới mức	Lấy mẫu quá mức
Loại bỏ các mẫu khỏi lớp đa số	Thêm nhiều ví dụ hơn n vào lớp thiểu số




78

78

2. Phương pháp cấp dữ liệu: Lấy mẫu lại


Lấy mẫu dư thừa mức	Lấy mẫu quá mức
Loại bỏ các mẫu khỏi lớp đa số	Thêm nhiều ví dụ hơn vào lớp thiểu số
Có thể gây ra tình trạng quá khớp	Có thể gây mất thông tin



79

Lấy mẫu dư thừa mức: Liên kết Tomek


- Tìm cặp mẫu gần nhau của các lớp đối diện
- Loại bỏ mẫu của lớp đa số trong mỗi cặp
 - Ưu điểm: Làm cho ranh giới quyết định rõ ràng hơn
 - Nhược điểm: Làm cho mô hình kém mạnh mẽ hơn



80

Lấy mẫu quá mức: SMOTE

- Tổng hợp các mẫu của lớp thiểu số dư ở dạng tổ hợp lồi (tuyến tính) của các điểm hiện có và những người ở hàng xóm gần nhất cùng lớp.




81

Lấy mẫu quá mức: SMOTE

Cả liên kết SMOTE và Tomek đều chỉ hoạt động trên dữ liệu có chiều thấp!

- Tổng hợp các mẫu của lớp thiểu số dư ở dạng tổ hợp lồi (tuyến tính) của các điểm hiện có và những người ở hàng xóm gần nhất cùng lớp.



82

3. Phương pháp cấp thuật toán

- Mất mát ngây thơ: tất cả các mẫu đều đóng góp như nhau vào mất mát • Ý
- tư ớng: các mẫu đào tạo mà chúng ta quan tâm nên đóng góp nhiều hơn vào mất mát

$$L(X; \theta) = \sum_x L(x; \theta)$$



83

3. Phương pháp cấp thuật toán

- Học tập nhạy cảm với chi phí • Mất
- mất cân bằng lớp • Mất mát tiêu
- điểm



84

Học tập tiết kiệm chi phí

- C_{ij} : chi phí nếu lớp i được phân loại là lớp j

	Actual NEGATIVE	Actual POSITIVE
Predicted NEGATIVE	$C(0, 0) = C_{00}$	$C(1, 0) = C_{10}$
Predicted POSITIVE	$C(0, 1) = C_{01}$	$C(1, 1) = C_{11}$

- Tổng thất do trư ờng hợp x của lớp i gây ra sẽ trở thành trung bình có trọng số của tất cả các trư ờng hợp có thể xảy ra phân loại trư ờng hợp x .

$$L(x; \theta) = \sum_j C_{ij} P(j | x; \theta)$$



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

85

85

Mất cân bằng lớp

- Tăng thêm trọng lượng cho các lớp hiếm

Mất mát không có trọng số

$$L(X; \theta) = \sum_i L(x_i; \theta)$$

Giảm cân có trọng lượng

$$L(X; \theta) = \sum_i W_{y_i} L(x_i; \theta)$$

$$W_c = \frac{N}{\text{number of samples of class } C}$$



`model.fit(tính năng, nhãn, kỳ nguyên=10, batch_size=32, class_weight={"gian lận": 0,9, "bình thường": 0,1})`

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

86

86

Mất tiêu cự

- Đánh giá cao hơn các mẫu khó:
 - làm giảm giá trị các mẫu được phân loại tốt

$$p_t = \begin{cases} p & \text{if } y = 1 \\ 1 - p & \text{otherwise,} \end{cases}$$

$$\text{CE}(p_t) = -\log(p_t)$$

$$\text{FL}(p_t) = -(1 - p_t)^\gamma \log(p_t)$$



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

[Mất tiêu cự để phát hiện đối tượng dây đặc](#) (Lin et al., 2017)

87

87

Phong Vũ Nguyễn

<https://colab.research.google.com/github/GokuMohandas/Made-With-ML/blob/main/notebooks/madewithml.ipynb>



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

88

88

Kỹ thuật tính năng

89

89

Tăng cường dữ liệu

“Tăng cường dữ liệu là
kỹ thuật tính năng mới”

- Josh Wills, cựu Giám đốc Kỹ thuật Dữ liệu @ Slack



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

90

90

Tăng cường dữ liệu: mục tiêu

- Cải thiện hiệu suất của mô hình nói chung hoặc trên một số lớp nhất định
- Tổng quát hóa tốt hơn
- Thực thi một số hành vi nhất định



91

Tăng cường dữ liệu

1. Biến đổi bảo toàn nhãn đơn giản
2. Nhiễu loạn
3. Tổng hợp dữ liệu



92

Bảo quản nhãn:
Tầm nhìn máy tính

Cắt xén ngẫu nhiên, lật, xóa, v.v.



Bảo vệ nhãn: NLP

Câu gốc	Tôi rất vui khi đư ợc gặp bạn.
Đã tạo ra câu	Tôi rất vui khi đư ợc gặp bạn. Tôi rất vui khi đư ợc gặp mọi ngư ời. Tôi rất vui khi đư ợc gặp bạn.

Sự nhiễu loạn: mạng lưới nơ-ron có thể nhạy cảm với tiếng ồn

- 67,97% hình ảnh thử nghiệm CIFAR-10 của Kaggle
- 16,04% hình ảnh thử nghiệm ImageNet

có thể bị phân loại sai bằng cách chỉ thay đổi một pixel

[\(Su và cộng sự, 2017\)](#)

AllConv	NiN	VGG
 SHIP CAR(99.7%)	 HORSE FROG(99.9%)	 DEER AIRPLANE(85.3%)
 HORSE DOG(70.7%)	 DOG CAT(75.5%)	 BIRD FROG(86.5%)
 CAR AIRPLANE(82.4%)	 DEER DOG(86.4%)	 CAT BIRD(66.2%)
 DEER AIRPLANE(49.8%)	 BIRD FROG(88.8%)	 SHIP AIRPLANE(88.2%)
 HORSE DOG(88.0%)	 SHIP AIRPLANE(62.7%)	 CAT DOG(78.2%)



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

95

Sự nhiễu loạn:


Tầm nhìn máy tính

- Tiếng ồn ngẫu nhiên
- Chiến lược tìm kiếm
 - DeepFool (Moosavi-Dezfooli và cộng sự, 2016): tìm mức nhiễu tối thiểu cần thiết để gây ra phân loại sai với độ tin cậy cao.


Cá voi



Con rùa
tiếng ồn bởi
Sâu Fool



Con rùa
tiếng ồn do dấu
hiệu độ dốc nhanh





ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

96

Sự nhiễu loạn: NLP

- Thay thế ngẫu nhiên • ví
dụ BERT ($10\% * 15\% = 1,5\%$)

- 80% of the time: Replace the word with the [MASK] token, e.g., my dog is hairy → my dog is [MASK]
- 10% of the time: Replace the word with a random word, e.g., my dog is hairy → my dog is apple
- 10% of the time: Keep the word unchanged, e.g., my dog is hairy → my dog is hairy. The purpose of this is to bias the representation towards the actual observed word.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

BERT: Đào tạo trước các bộ biến đổi song hướng sâu để hiểu ngôn ngữ (Devlin và cộng sự, 2018)

97

97

Tổng hợp dữ liệu: NLP

- Dựa trên mẫu • Rất
phổ biến trong AI đàm thoại • Dựa trên mô
hình ngôn ngữ

Mẫu Tìm cho tôi một nhà hàng [ẨM THỰC] trong phạm vi [SỐ] dặm của [VỊ TRÍ].	
Các truy vấn được tạo ra	• Tìm cho tôi một nhà hàng Việt Nam trong vòng 2 dặm từ văn phòng của tôi. • Tìm cho tôi một nhà hàng Thái trong vòng 5 dặm nhà của tôi. • Tìm cho tôi một nhà hàng Mexico trong vòng 3 dặm từ trụ sở chính của Google.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

98

98

Tổng hợp dữ liệu: Tầm nhìn máy tính

- Trộn lẫn
 - Tạo tổ hợp lỗi của các mẫu thuộc các lớp khác nhau ■ Nhân: mèo [3], chó [4] ■ Trộn lẫn: 30% chó, 70% mèo $[0,3 * 3 + 0,7 * 4 = 3,7]$



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY


[mixup: Vượt xa ngoài việc giảm thiểu rủi ro thực nghiệm](#) (Zhang và cộng sự, 2017)

99

99

Tổng hợp dữ liệu: Tầm nhìn máy tính

- Trộn lẫn
 - Khuyến khích các mô hình học các mối quan hệ tuyến tính
 - Cải thiện khả năng khái quát hóa trên dữ liệu dạng bảng và giọng nói
 - Có thể được sử dụng để ổn định quá trình đào tạo GAN



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY


<https://forums.fast.ai/t/mixup-data-augmentation/22764>

100

100

Tăng cường dữ liệu: GAN

Ví dụ: phân đoạn thận với dữ liệu
tăng cường bằng CycleGAN



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Tăng cường dữ liệu bằng cách sử dụng mạng đối nghịch tạo sinh (CycleGAN) để cải thiện khả năng khái quát hóa trong các tác vụ phân đoạn CT (Sandfort et al., 2019)

101

101




Fig. 2 A taxonomy of image data augmentations covered; the colored lines in the figure depict which data augmentation method the corresponding meta-learning scheme uses, for example, meta-learning using Neural Style Transfer is covered in neural augmentation [36]



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Khảo sát về Tăng cường dữ liệu hình ảnh cho Học sâu (Connor Shorten & Taghi M. Khoshgohar, 2019)

102

102

Các tính năng đã học

so với

các tính năng được thiết kế



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

103

103

Kỹ thuật tính năng

Đợi đã, học sâu không hứa hẹn sẽ không có thêm kỹ thuật thiết kế tính năng nào nữa sao?



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

104

104

Kỹ thuật tính năng

Đợi đã, học sâu không hứa hẹn sẽ không có thêm kỹ thuật thiết kế tính năng nào nữa sao?

- Chúng ta vẫn còn rất xa điểm đó
- Nhiều mô hình ML trong ngành không phải là học sâu



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

105

105

Các tính năng được thiết kế: văn bản

Xóa từ dư thừa

Tôi có **một** con chó. Nó đang ngủ.

Lemmat hóa

Tôi có một con chó. Nó đang ngủ.

Sự co lại

Tôi có một con chó. **Nó** đang ngủ.

Đấu câu

Tôi có một con chó. Nó đang ngủ.

Chữ thủ ông

Tôi có một con chó Nó đang ngủ

N-gram

tôi có một con chó, nó đang ngủ

mẫu

đặc trưng

0	3	0	0	...
1	0	0	0	...
0	0	1	0	...
...	...	...	...	...

Phân loại
(ví dụ LogReg)




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

	bạn	có 1	chó	mèo	anh	có		họ ngủ 0 1	Tôi có 1	có, chó 1	tốt, chó 0	...
	0	1	1	0	0	1	0	0	1	1	0	...

106

106

Các tính năng đã học: văn bản



Chữ Tôi có một con chó. Nó đang ngủ.

Một nóng	bạn	có 1	chó	mèo	anh	có	họ	ngủ	đang	thức	có	...
...	0	1	1	0	0	0	0	0	0	0	0	...



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

107

107

Các tính năng đã học: phân loại thư rác

Bình luận	Thời gian	Văn bản người dùng	# ▲	# ▼	Liên kết	# img	Chủ đề	Trả lời #	Trả lời ...	
93880839	2020-10-30 T 10:45 UTC	gitrekt Me ban là một người phụ nữ tốt bụng.	1	0	0	0	2332332	n0tab0t	1	...

ID người dùng	Tạo	Người dùng đăng ký	# ▲	# ▼	Trả lời	Nghị luận chủ đề	# chủ đề	Email đã xác minh	Giải thưởng ...	
4402903	2015-01-57 T 3:09 PST	gitrekt	15	90	28	304	776	KHÔNG	...	

Chủ đề	Thời gian	Văn bản người dùng	# ▲	# ▼	Liên kết	# img	# trả lời	# lượt xem	Giải thưởng ...	
93883208	2020-10-30 T 2:45 PST	tổng trấn	120	50	1	0	32	2405	1	...



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

108

108

Kỹ thuật tính năng: phân loại thư rác

Thậm chí còn có nhiều tính năng hơn nữa:

- Tần suất đăng bài, số bài đăng tối đa mỗi ngày
- Độ lặp lại của bài đăng
- Phát hiện ngôn ngữ, lỗi đánh máy, dấu câu bất thường, tỷ lệ chữ hoa/chữ thường
- IP, người dùng khác từ cùng IP
- Từ ngữ không an toàn cho công việc, liên kết bị đưa vào danh sách đen
- Người dùng mục tiêu
- ...



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

109

109

Kỹ thuật tính năng

- Đối với các tác vụ phức tạp, số lượng tính năng có thể lên tới hàng triệu!
- Rất nhiều công việc sản xuất ML liên quan đến việc đưa ra các tính năng mới
 - Kế hoạch nghĩ ra các kỹ thuật mới rất nhanh, vì vậy cần phải nghĩ ra các tính năng mới rất nhanh để đối phó
- Thư ờng đòi hỏi chuyên môn về chủ đề này



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

110

110

Hoạt động kỹ thuật tính năng chung

1. Xử lý các giá trị bị thiếu
2. Chia tỷ lệ
3. Phân biệt
4. Các tính năng phân loại
5. Giao thoa tính năng
6. Những vị trí



111

Xử lý các giá trị bị thiếu

- Không phải tất cả các giá trị bị thiếu đều bằng nhau
 - Thiếu không ngẫu nhiên (MNAR)
 - Thiếu ngẫu nhiên (MAR)
 - Thiếu hoàn toàn ngẫu nhiên (MCAR)



112

Xử lý các giá trị bị thiếu

Thiếu không phải ngẫu nhiên - khi một giá trị bị thiếu do chính giá trị đó

STT	Tuổi	Giới tính	Thu nhập hàng năm	Hôn nhân trạng thái	Số lượng trẻ em	Công việc	Mua?
1		MỘT	150.000		1	Kỹ sư Không	
2	27	B	50.000			Giáo viên	KHÔNG
3		MỘT	100.000	Đã cư ới	2		Đúng
4	40	B	(350.000 đô la?)		2	Kỹ sư Vàng	
5	35	B	(350.000 đô la?)	Đơ n	0	Bác sĩ	Đúng
6		MỘT	50.000		0	Giáo viên	KHÔNG
7	33	B	60.000	Đơ n		Giáo viên	KHÔNG
8	20	B	10.000			Học sinh	KHÔNG



Xử lý các giá trị bị thiếu

Thiếu ngẫu nhiên - khi một giá trị bị thiếu do một biến quan sát khác

STT	Tuổi	Giới tính	Thu nhập hàng năm	Hôn nhân trạng thái	Số lượng trẻ em	Công việc	Mua?
1		MỘT	150.000		1	Kỹ sư Không	
2	27	B	50.000			Giáo viên	KHÔNG
3		MỘT	100.000	Đã cư ới	2		Đúng
4	40	B			2	Kỹ sư Vàng	
5	35	B		Đơ n	0	Bác sĩ	Đúng
6		MỘT	50.000		0	Giáo viên	KHÔNG
7	33	B	60.000	Đơ n		Giáo viên	KHÔNG
8	20	B	10.000			Học sinh	KHÔNG



Xử lý các giá trị bị thiếu

Thiếu hoàn toàn ngẫu nhiên - không có mẫu nào mà giá trị bị thiếu

Mã số	Tuổi	Giới tính	Thu nhập hàng năm	Hôn nhân trạng thái	Số lượng trẻ em	Công việc	Mua?
1		NỮ	150.000		1	Kỹ sư Không	
2	27	B	50.000			Giáo viên	KHÔNG
3		NỮ	100.000	Đã cư ời	2		Đúng
4	40	B			2	Kỹ sư Vàng	
5	35	B		Đơ n	0	Bác sĩ	Đúng
6		NỮ	50.000		0	Giáo viên	KHÔNG
7	33	B	60.000	Đơ n		Giáo viên	KHÔNG
8	20	B	10.000			Học sinh	KHÔNG

115

115

Xử lý các giá trị bị thiếu

- Xóa - xóa dữ liệu có mục bị thiếu
- Quy kết - điền các trường còn thiếu bằng các giá trị nhất định

Nhiều người thích xóa không phải vì nó tốt hơn mà vì nó dễ thực hiện hơn



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

116

116

Xử lý các giá trị bị thiếu

- Xóa
 - Xóa cột - xóa các cột có quá nhiều mục bị thiếu
 - Như ợc điểm - ngay cả khi một nửa giá trị bị thiếu, dữ liệu còn lại vẫn có khả năng là thông tin hữu ích cho dự đoán ■ Ví dụ, ngay cả khi hơn một nửa cột 'Tình trạng hôn nhân' bị thiếu, tình trạng hôn nhân vẫn có mối tư ơ ng quan cao với việc mua nhà
 - Xóa hàng

Tình trạng hôn nhân
Đã cư ới
Đợ n
Đợ n



117

Xử lý các giá trị bị thiếu

- Xóa
 - Xóa cột
 - Xóa hàng



118

Xử lý các giá trị bị thiếu

- Xóa hàng
 - Tốt cho: dữ liệu bị thiếu hoàn toàn ngẫu nhiên (MCAR) và thiếu một vài giá trị

STT	Tuổi	Giới tính	Thu nhập hàng năm	Tình trạng hôn nhân	Số lượng con	Công việc	Mua?
1	39	NỮ	150.000	Đã cưới	1	Kỹ sư	KHÔNG
2	27	B	50.000	Độc thân	0	Giáo viên	KHÔNG
3		NỮ	100.000	Đã cưới	2		Đúng
4	40	B	75.000	Đã cưới	2	Kỹ sư	Đúng
5	35	B	35.000	Độc thân	0	Bác sĩ	Đúng
6	32	NỮ	50.000	Đã cưới	0	Giáo viên	KHÔNG
7	33	B	60.000	Độc thân	2	Giáo viên	KHÔNG
8	20	B	10.000	Độc thân	1	Học sinh	KHÔNG

119

119

Xử lý các giá trị bị thiếu

- Xóa hàng
 - Không tốt khi nhiều ví dụ thiếu trùng

STT	Tuổi	Giới tính	Thu nhập hàng năm	Tình trạng hôn nhân	Số lượng con	Công việc	Mua?
1		NỮ	150.000		1	Kỹ sư	KHÔNG
2	27	B	50.000			Giáo viên	KHÔNG
3		NỮ	100.000	Đã cưới	2		Đúng
4	40	B			2	Kỹ sư	Đúng
5	35	B		Độc thân	0	Bác sĩ	Đúng
6		NỮ	50.000		0	Giáo viên	KHÔNG
7	33	B	60.000	Độc thân		Giáo viên	KHÔNG
8	20	B	10.000			Học sinh	KHÔNG

120

120

Xử lý các giá trị bị thiếu

- Xóa hàng
 - Không tốt cho: các giá trị bị thiếu không phải là ngẫu nhiên (MNAR)
 - Thông tin bị thiếu chính là thông tin đó

STT	Tuổi	Giới tính	Thu nhập hàng năm	Tình trạng hôn nhân	Số lượng con	Công việc	Mua?
1		NỮ	150.000		1	Kỹ sư	KHÔNG
2	27	B	50.000			Giáo viên	KHÔNG
3		NỮ	100.000	Đã cư ới	2		Đúng
4	40	B	(350.000 đô la?)		2	Kỹ sư	Đúng
5	35	B	(350.000 đô la?)	Đơ n	0	Bác sĩ	Đúng
6		NỮ	50.000		0	Giáo viên	KHÔNG
7	33	B	60.000	Đơ n		Giáo viên	KHÔNG
8	20	B	10.000			Học sinh	KHÔNG

121

121

Xử lý các giá trị bị thiếu

- Xóa hàng
 - Không tốt cho: dữ liệu bị thiếu ngẫu nhiên (MAR)
 - Có khả năng làm sai lệch dữ liệu - chúng tôi đã vô tình xóa tất cả các ví dụ có giới tính 'A'

STT	Tuổi	Giới tính	Thu nhập hàng năm	Tình trạng hôn nhân	Số lượng con	Công việc	Mua?
1		NỮ	150.000		1	Kỹ sư	KHÔNG
2	27	B	50.000			Giáo viên	KHÔNG
3		NỮ	100.000	Đã cư ới	2		Đúng
4	40	B			2	Kỹ sư	Đúng
5	35	B		Đơ n	0	Bác sĩ	Đúng
6		NỮ	50.000		0	Giáo viên	KHÔNG
7	33	B	60.000	Đơ n		Giáo viên	KHÔNG
8	20	B	10.000			Học sinh	KHÔNG

122

122

Sự quy kết

- Điền các trường còn thiếu bằng các giá trị

nhất định • Mặc

định ■ Ví dụ 0 hoặc chuỗi trống, v.v. •

Các biện pháp thống kê - trung bình, trung vị, mốt

- Ví dụ nếu một ngày trong tháng 7 thiếu giá trị nhiệt độ, hãy điền vào đó nhiệt độ trung bình

vào tháng 7



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

123

123

Sự quy kết

- Điền các trường còn thiếu bằng các giá trị

nhất định • Mặc

định ■ Ví dụ 0 hoặc chuỗi trống, v.v. •

Các biện pháp thống kê - trung bình, trung vị, mốt

- Ví dụ nếu một ngày trong tháng 7 thiếu giá trị nhiệt độ, hãy điền vào đó nhiệt độ trung bình

vào tháng 7

Tránh điền các giá trị còn thiếu bằng các giá trị có thể!



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

124

124

Tỷ lệ



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

125

125

Các loại tỷ lệ

loại tỷ lệ	trường hợp sử dụng
chuẩn hóa min/max	Bất kỳ -- không có giả định nào về các biến
chuẩn hóa điểm z	Khi các biến tuân theo phân phối chuẩn
thang đo logarit	Khi các biến tuân theo phân phối mũ



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY


126

126

Quy mô logarit

- Trợ giúp với dữ liệu bị lệch •

Thường mang lại hiệu suất tăng



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

127

127

Tỷ lệ

loại tỷ lệ	trường hợp sử dụng
chuẩn hóa min/max	Bất kỳ -- không có giả định nào về các biến
điểm z chuẩn hóa	Khi các biến tuân theo phân phối chuẩn
thang đo logarit	Khi các biến tuân theo phân phối mũ

- việc mở rộng quy mô có thể là một nguồn rò rỉ dữ liệu phổ biến •

việc mở rộng quy mô các biến đòi hỏi số liệu thống kê toàn cầu



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

128

128

Rời rạc

- Biến một tính năng liên tục thành một tính năng rời rạc (lượng tử hóa)



129

Rời rạc

- Biến một tính năng liên tục thành một tính năng rời rạc (lượng tử hóa) •

Tạo các nhóm cho các phạm vi khác nhau •

Kết hợp kiến thức/chuyên môn về từng biến bằng cách xây dựng các nhóm cụ thể



130

Rời rạc

• Biến một tính năng liên tục thành một tính năng rời rạc (lượng tử hóa) • Tạo các nhóm cho các phạm vi

khác nhau • Kết hợp kiến thức/chuyên môn về từng biến bằng

cách xây dựng các nhóm cụ thể • Ví dụ • Thu nhập ■ Thu nhập thấp: $x < \$35.000$ ■ Thu nhập trung bình: $\$35.000 < x < \100.000 ■ Thu nhập cao:

$x > \$100.000$



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

131

131

Rời rạc

• Biến một tính năng liên tục thành một tính năng rời rạc (lượng tử hóa) • Tạo các nhóm cho các phạm vi

khác nhau • Kết hợp kiến thức/chuyên môn về từng biến bằng

cách xây dựng các nhóm cụ thể • Ví dụ • Thu nhập ■ Thu nhập thấp: $x < \$35.000$ ■ Thu nhập trung bình: $\$35.000 \leq x < \100.000 ■ Thu nhập cao:

$x \geq \$100.000$ • Tuổi

■ Trẻ vị thành

niên: $x < 18$

■ Cao đẳng: $18 \leq x < 22$ ■ Thanh

niên: $22 \leq x < 30$ ■ $30 \leq x < 40$

■ $40 \leq x < 65$

■ Người cao tuổi: $x \geq 65$



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

132

132

Mã hóa các tính năng phân loại

- Ví dụ: bạn muốn xây dựng một hệ thống đề xuất cho Amazon
 - Có hơn 2 triệu thư ơ ng hiệu mà chúng tôi cần giới thiệu



133

Mã hóa các tính năng phân loại

Làm thế nào chúng ta mã hóa các khác nhau
thư ơ ng hiệu/nhà cung cấp?



134

Mã hóa các tính năng phân loại

- mã hóa một lần!

Làm thế nào chúng ta mã hóa các khác nhau
thư ơ ng hiệu/nhà cung cấp?



135

Mã hóa các tính năng phân loại

- mã hóa một lần!

Chúng ta xử lý một thư ơ ng hiệu mới như thế nào
muốn tham gia Amazon?



136

Mã hóa các tính năng phân loại

- mã hóa one-hot! • mã hóa
- các thư ơ ng hiệu chưa biết với "UNKNOWN"

Chúng ta xử lý một thư ơ ng hiệu mới như thế nào
muốn tham gia Amazon?



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

137

137

Mã hóa các tính năng phân loại

- mã hóa one-hot! • mã hóa
- các thư ơ ng hiệu chưa biết với "UNKNOWN"

Vấn đề! "UNKNOWN" không đ ợc nhìn thấy trong quá trình đào tạo, do đó không có
sản phẩm nào trong danh mục này đ ợc đề xuất



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

138

138

Mã hóa các tính năng phân loại

- mã hóa one-hot! • mã hóa các
- thư ơ ng hiệu chữ a biết với "UNKNOWN"

Sửa lỗi - mã hóa các thư ơ ng hiệu thành chính chúng, nhóm 1% thư ơ ng hiệu có hiệu suất kém nhất thành "KHÔNG BIẾT"



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

139

139

Mã hóa các tính năng phân loại

- mã hóa one-hot! • mã hóa các
- thư ơ ng hiệu chữ a đư ợc biết đến với "UNKNOWN" • Nhóm 1% thư ơ ng hiệu và ngư ời mới đến cuối danh mục "UNKNOWN"



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

140

140

Mã hóa các tính năng phân loại

- mã hóa one-hot! • mã hóa
- các thư ơ ng hiệu chưa đư ợc biết đến với "UNKNOWN" • Nhóm
- 1% thư ơ ng hiệu và ngư ời mới đến cuối danh mục "UNKNOWN"

Cảnh báo! Nike muốn tham gia Amazon với tư cách là nhà cung cấp mới



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

141

141

Mã hóa các tính năng phân loại

- mã hóa one-hot! • mã hóa
- các thư ơ ng hiệu chưa đư ợc biết đến với "UNKNOWN" • Nhóm
- 1% thư ơ ng hiệu và ngư ời mới đến cuối cùng vào danh mục "UNKNOWN" • Vấn đề - điều này đối xử với
- tất cả ngư ời mới đến giống như các thư ơ ng hiệu không đư ợc ư a chuộng trên nền tảng



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

142

142

Mã hóa các tính năng phân loại

Làm thế nào để chúng ta triển khai phương pháp linh hoạt để xử lý các thuộc tính hiệu mới khi chúng được đưa vào hệ thống của chúng ta?



143

Mã hóa các danh mục mới

1. Biểu diễn từng danh mục với thuộc tính của nó a. Ví dụ
để biểu diễn một thuộc tính hiệu, hãy sử dụng các tính năng: doanh thu hàng năm, quy mô công ty, v.v.
2. Thủ thuật băm



144

Mã hóa các tính năng phân loại

- Băm - sử dụng hàm băm để băm các danh mục thành các chỉ mục khác nhau



145

Mã hóa các tính năng phân loại

- Băm - sử dụng hàm băm để băm các danh mục thành các chỉ mục khác nhau • ví
dụ: $\text{hash}(\text{"Nike"}) = 0$, $\text{hash}(\text{"Adidas"}) = 27$, v.v.



146

Mã hóa các tính năng phân loại

- Băm - sử dụng hàm băm để băm các danh mục thành các chỉ mục khác nhau • ví
dụ: $\text{hash}(\text{"Nike"}) = 0$, $\text{hash}(\text{"Adidas"}) = 27$, v.v.
- Lợi ích - bạn có thể chọn không gian băm lớn như thế nào



147


Mã hóa các tính năng phân loại

- Băm - sử dụng hàm băm để băm các danh mục thành các chỉ mục khác nhau • ví
dụ: $\text{hash}(\text{"Nike"}) = 0$, $\text{hash}(\text{"Adidas"}) = 27$, v.v.
- Lợi ích - bạn có thể chọn không gian băm lớn như thế nào •
Như ợc điểm - hai danh mục đư ợc băm vào cùng một chỉ mục



148

Mã hóa các tính năng phân loại



149

Mã hóa các tính năng phân loại

- Chọn không gian băm đủ lớn để giảm va chạm • Chọn các hàm có thuộc tính có lợi cho truy cập hợp sử dụng của bạn
 - Băm theo vị trí nhẩy cảm

150

Mẹo bắ

- Thủ thuật bắ đư ợc các học giả coi là "hacky"
- Đư ợc sử dụng rộng rãi trong ngành công nghiệp và trong các khuôn khổ học máy
- Hữu ích trong thực tế cho việc học tập liên tục trong sản xuất



151

Giao cắt đặc điểm

- Kết hợp hai hoặc nhiều tính năng để tạo ra một tính năng mới

Kết hôn	Đơ n	Đã cư ới	Đơ n	Đơ n	Đã cư ới
Những đứa trẻ	0	2	1	0	1
Hôn nhân và con cái	Độc thân, 0	Đã kết hôn, 2	Độc thân, 1	Độc thân, 0	Đã kết hôn, 1



152

Giao cắt đặc điểm

- Giúp các mô hình tìm hiểu mối quan hệ phi tuyến tính giữa các biến • **Cảnh báo** - việc giao thoa các đặc điểm có thể làm nổ tung không gian đặc điểm của bạn • ví dụ: Đặc điểm A và B đều có 100 danh mục • Đặc điểm A x B sẽ có 10.000 danh mục • Cần nhiều dữ liệu hơn nữa để tìm hiểu không gian đặc điểm mới này
- Việc làm nổ tung không gian đặc điểm có thể làm tăng nguy cơ quá khớp


Rất phổ biến trong RecSys & CTR với các mô hình như DeepFM và xDeepFM

153

Nhúng vị trí

- Phổ biến trong bài báo Chú ý là tất cả những gì bạn cần • Tư duy tự như nhúng từ • Có thể là


đã học hoặc cố định



154

Nhúng vị trí

- Tính năng Fourier



155

Nhúng vị trí

Tại sao chúng ta cần nhúng vị trí?



156

Nhúng vị trí

Tại sao chúng ta cần nhúng vị trí?

- Kiến trúc truyền thống (RNN, LSTM) xử lý mã thông báo theo trình tự • Bộ chuyển đổi xử lý mã thông báo song song cần truyền đạt bản chất tuần tự của ngôn ngữ con người tới mô hình



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

157

157

Phong Vũ Nghĩa

<https://colab.research.google.com/github/GokuMohandas/Made-With-ML/blob/main/notebooks/madewithml.ipynb>



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

158

158

Rò rỉ dữ liệu



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

159

159

Rò rỉ dữ liệu

- Một số dạng nhãn “rò rỉ” vào các tính năng
- Thông tin này không có sẵn trong quá trình suy luận



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

160

160

Rò rỉ dữ liệu: ví dụ 1

- Vấn đề: phát hiện ung thư phổi từ chụp CT
- Dữ liệu: thu thập từ bệnh viện A
- Thực hiện tốt trên dữ liệu thử nghiệm từ bệnh viện A
- Thực hiện kém trên dữ liệu thử nghiệm từ bệnh viện B

Kiên nhẫn	Ngày Bác sĩ	Hồ sơ	Loại máy	Chụp CT
kiên nhẫn	ghi chú	bệnh án	quét	

Rò rỉ dữ liệu: ví dụ 1

- Vấn đề: phát hiện ung thư phổi từ chụp CT
- Dữ liệu: thu thập từ bệnh viện A
- Thực hiện tốt trên dữ liệu thử nghiệm từ bệnh viện A
- Thực hiện kém trên dữ liệu thử nghiệm từ bệnh viện B

Kiên nhẫn	Ngày Bác sĩ	Hồ sơ	Loại máy	Chụp CT
kiên nhẫn	ghi chú	bệnh án	quét	

Tại bệnh viện A, khi các bác sĩ nghi ngờ bệnh nhân bị ung thư phổi, họ sẽ chuyển bệnh nhân đó đến một máy quét chất lượng cao hơn

Rò rỉ dữ liệu: ví dụ 2

• Vấn đề: dự đoán số lượt xem một bài viết sẽ nhận được • Dữ liệu: dữ liệu lịch sử trên trang web • Rò rỉ dữ liệu có thể đến từ đâu?

Bài báo	Ngày Tiêu đề	Bài viết	Tác giả	Ngôn ngữ	Bản dịch
hình ảnh		và	và	r	và



163

Rò rỉ dữ liệu: ví dụ 2

• Vấn đề: dự đoán số lượt xem một bài viết sẽ nhận được • Dữ liệu: dữ liệu lịch sử trên trang web

Không rõ vì mức độ phổ biến của tác giả cũng có sẵn trong quá trình suy luận

Bài báo	Ngày Tiêu đề	Bài viết	Tác giả	Ngôn ngữ	Bản dịch
hình ảnh		và	và	r	và

Trang web chỉ dịch các bài viết đang thu hút sự chú ý



164

Rò rỉ dữ liệu: Phiên bản Kaggle

**What will be done about data leaks?**
Louka Ewington-Pitsos · Last comment 2Y ago by Gunes Evitan

23
7 comments

**Time for Kaggle to clarify**
bluetrain · Last comment 2Y ago by Vishal

56
8 comments

**There is something new about Leaks ?**
Haythem Teillii · Last comment 2Y ago by Oskin Nikita

4
1 comment

**New leakage web finded**
Zhang Yunfei · Last comment 2Y ago by Zhang Yunfei

19
19 comments

**The leak explained!**
Posted in [liverpool-ion-switching](#) 2 years ago

Zidmie
Topic Author
3rd place

The cat5 data (category with 10 open channels) is very similar to the addition of two signals of cat4 data, as several teams noticed. But also, we can find that the data from 4000001 to 4100000 (cat4) was used to create the data from 5700001 to 5800000 : $\text{openchannels}(5700001:5800000) = \text{openchannels}(4000001 \text{ to } 4100000) + \text{openchannels of other cat4 data (that I didn't really look for)}$. So we can just subtract data $\text{openchannels}(4000001 \text{ to } 4100000)$ from the private LB data. Then we have cat4 data, much easier to predict. By using this method, we just reached a score of 0.9543. I guess by digging further, it can lead to the score of 0.985!

60

[ASHRAE - Năng lượng vĩ đại Dự đoán III](#)

[Đại học Liverpool - Ion Chuyển đổi](#)

165

Nguyên nhân rò rỉ dữ liệu

1. Phân chia dữ liệu tư ơng quan thời gian một cách ngẫu nhiên thay vì theo thời gian

**ĐẠI HỌC BÁCH KHOA HÀ NỘI**
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

166

Phân vùng: xáo trộn rồi chia nhỏ

	Tuần 1	Tuần 2	Tuần 3	Tuần 4	Tuần 5
Kiểm tra phân chia	X11	X21	X31	X41	X51
Phân chia hợp lệ	X12	X22	X32	X42	X52
Tàu tách ra	X13	X23	X33	X43	X53
	X14	X24	X34	X44	X54
	...	...	...	...	...

Mục tiêu là phân phối nhân tố ngẫu nhiên trên các phân chia
ví dụ mỗi lần chia có 90% ÂM, 10% DƯ Ơ NG



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

167

167

Phân vùng: xáo trộn rồi chia nhỏ

	Tuần 1	Tuần 2	Tuần 3	Tuần 4	Tuần 5
Kiểm tra phân chia	X11	X21	X31	X41	X51
Phân chia hợp lệ	X12	X22	X32	X42	X52
Tàu tách ra	X13	X23	X33	X43	X53
	X14	X24	X34	X44	X54
	...	...	...	...	...

⚠ Không đại diện cho cách sử dụng thực tế ⚠



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

168

168

Phân vùng: xáo trộn rồi chia nhỏ

	Tuần 1	Tuần 2	Tuần 3	Tuần 4	Tuần 5
Kiểm tra phân chia	X11	X21	X31	X41	X51
Phân chia hợp lệ	X12	X22	X32	X42	X52
Tàu tách ra	X13	X23	X33	X43	X53
	X14	X24	X34	X44	X54

Một nguồn rò rỉ dữ liệu. Ví dụ:...

• dự đoán giá cổ phiếu

• nội xuất bài hát



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

169

169

Một phân vùng tốt hơn

	Tuần 1	Tuần 2	Tuần 3	Tuần 4	Tuần 5	
	X11	X21	X31	X41	X51	Phân chia hợp lệ
	X12	X22	X32	X42	X52	
	X13	X23	X33	X43	X53	Kiểm tra phân chia
	X14	X24	X34	X44	X54	
	...	...	...	...	...	



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

170

170

Giải pháp: chia dữ liệu theo thời gian

Tàu tách ra					
Tuần 1	Tuần 2	Tuần 3	Tuần 4	Tuần 5	
X11	X21	X31	X41	X51	Phân chia hợp lệ
X12	X22	X32	X42	X52	
X13	X23	X33	X43	X53	Kiểm tra phân chia
X14	X24	X34	X44	X54	
...	Cũng buộc bạn phải suy nghĩ về vấn đề khởi động lạnh			...	...



171

Nguyên nhân rò rỉ dữ liệu


- 1. Phân chia dữ liệu tương quan thời gian một cách ngẫu nhiên thay vì theo thời gian
- 2. Xử lý dữ liệu trước khi chia tách
 - a. Sử dụng toàn bộ tập dữ liệu (bao gồm cả hợp lệ/kiểm tra) để tạo số liệu thống kê/thông tin toàn cầu



172

2. Xử lý dữ liệu trước khi chia tách

- Sử dụng toàn bộ tập dữ liệu (bao gồm cả hợp lệ/kiểm tra) để tạo số liệu thống kê/thông tin toàn cầu
 - giá trị trung bình, phương sai, giá trị min, giá trị max, số lượng n-gram, từ vựng, v.v.
- Sau đó, thống kê được sử dụng để xử lý dữ liệu thử nghiệm
 - tính tỷ lệ, điền giá trị còn thiếu, v.v.



ĐẠI HỌC BÁCH
HANOI UNIVERSITY OF SCIENCE

173

173

2. Xử lý dữ liệu trước khi chia tách

- Sử dụng toàn bộ tập dữ liệu (bao gồm cả hợp lệ/kiểm tra) để tạo số liệu thống kê/thông tin toàn cầu
- Giải pháp:**
 - Chia nhỏ dữ liệu của bạn trước khi chia tỷ lệ/điền vào các giá trị còn thiếu
 - Chia đều trước bất kỳ EDA nào để đảm bảo bạn không biết đến bộ thử nghiệm



ĐẠI HỌC BÁCH
HANOI UNIVERSITY OF SCIENCE

174

174

Nguyên nhân rò rỉ dữ liệu

- 1. Phân chia dữ liệu có tư ơng quan thời gian một cách ngẫu nhiên thay vì theo thời gian
 - 2. Xử lý dữ liệu trư ớc khi phân chia
 - 3. Xử lý dữ liệu trùng lặp kém trư ớc khi phân chia
- a. Bộ kiểm tra bao gồm dữ liệu từ bộ huấn luyện

175

3. Xử lý dữ liệu trùng lặp kém trư ớc khi chia tách

- Bộ dữ liệu có các bản sao và gần trùng lặp • 3,3% hình ảnh thử nghiệm
- CIFAR-10 và 10% hình ảnh thử nghiệm CIFAR-100 có bản sao trong bộ dữ liệu huấn luyện • Việc loại bỏ bản sao làm tăng lỗi từ 17,05% -> 19,38% trên CIFAR-100 [PyramidNet-272-200]

	Exact Duplicate	Near-Duplicate	Very Similar
Test	  	  	  
Training	  	  	  

176

3. Xử lý dữ liệu trùng lặp kém trước khi chia tách

- Bộ dữ liệu có các bản sao và gần trùng lặp • Lấy mẫu quá mức có thể gây ra sự trùng lặp



177

3. Xử lý dữ liệu trùng lặp kém trước khi chia tách

- Bộ kiểm tra bao gồm dữ liệu từ bộ huấn luyện
- Giải pháp: •
 - Loại bỏ dữ liệu trùng lặp trước khi chia tách •
 - Lấy mẫu quá mức sau khi chia tách



178

Nguyên nhân rò rỉ dữ liệu

1. Phân chia dữ liệu có tư ơ ng quan thời gian một cách ngẫu nhiên thay vì theo thời gian
2. Xử lý dữ liệu trư ớc khi phân chia
3. Xử lý dữ liệu trùng lặp kém trư ớc khi phân chia
4. Rò rỉ nhóm
 - a. Một nhóm các ví dụ có nhữn tư ơ ng quan mạnh như ng đư ợc chia thành các phần khác nhau



Nguyên nhân rò rỉ dữ liệu

1. Phân chia dữ liệu có tư ơ ng quan thời gian một cách ngẫu nhiên thay vì theo thời gian
2. Xử lý dữ liệu trư ớc khi phân chia
3. Xử lý dữ liệu trùng lặp kém trư ớc khi phân chia
4. Rò rỉ nhóm
 - a. Một nhóm ví dụ có nhữn tư ơ ng quan mạnh như ng đư ợc chia thành các phần khác nhau
 - b. Ví dụ: Chụp CT của cùng một bệnh nhân cách nhau một tuần
 - c. **Giải pháp:** Hiểu dữ liệu của bạn và theo dõi siêu dữ liệu của nó



Nguyên nhân rò rỉ dữ liệu

1. Phân chia dữ liệu có tương quan thời gian một cách ngẫu nhiên thay vì theo thời gian
2. Xử lý dữ liệu trước khi phân chia
3. Xử lý dữ liệu trùng lặp kém trước khi phân chia
4. Rò rỉ nhóm
5. Rò rỉ từ quá trình tạo và thu thập dữ liệu
 - a. Ví dụ: bác sĩ chuyển bệnh nhân có nguy cơ cao đến máy quét tốt hơn
 - b. Giải pháp: Chuẩn hóa dữ liệu + chuyên môn về chủ đề



Nguyên nhân rò rỉ dữ liệu

1. Phân chia dữ liệu có tương quan thời gian một cách ngẫu nhiên thay vì theo thời gian
2. Xử lý dữ liệu trước khi phân chia
3. Xử lý dữ liệu trùng lặp kém trước khi phân chia
4. Rò rỉ nhóm
5. Rò rỉ từ quá trình tạo và thu thập dữ liệu



Làm thế nào để phát hiện rò rỉ?



183

Làm thế nào để phát hiện rò rỉ?

1. Đo lường mối tương quan của một tính năng với nhân

a. Một tính năng riêng lẻ có thể không gây rò rỉ, nhưng 2 tính năng kết hợp với nhau có thể



184

Làm thế nào để phát hiện rò rỉ?

1. Đo lường mối tương quan của một tính năng với nhân

2. Nghiên cứu cắt bỏ đặc điểm

HOI. Nếu việc loại bỏ một tính năng khiến hiệu suất của mô hình giảm đáng kể, hãy tìm hiểu lý do.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

185

185

Làm thế nào để phát hiện rò rỉ?

1. Đo lường mối tương quan của một tính năng với nhân

2. Nghiên cứu loại bỏ tính năng 3.

Theo dõi hiệu suất mô hình khi thêm nhiều tính năng hơn

a. Tăng đột ngột: hoặc là tính năng rất tốt hoặc là rò rỉ!



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

186

186

Làm thế nào để thiết kế các
tính năng tốt



187

Đánh giá một tính năng

1. Tầm quan trọng của
tính năng
2. Tổng quát tính năng



188

Đo lường tầm quan trọng của một tính năng

Hiệu suất của mô hình sẽ giảm đi bao nhiêu nếu một tính năng
hoặc một tập hợp các tính năng có chứa tính năng đó bị xóa khỏi mô
hình?



189

Đo lường tầm quan trọng của một tính năng

- Tăng cường XG

```
get_score(fmap="", importance_type='weight')
```

Get feature importance of each feature. For tree model Importance type can be defined as:


- 'weight': the number of times a feature is used to split the data across all trees.
- 'gain': the average gain across all splits the feature is used in.
- 'cover': the average coverage across all splits the feature is used in.
- 'total_gain': the total gain across all splits the feature is used in.
- 'total_cover': the total coverage across all splits the feature is used in.



190

Đo lường tầm quan trọng của một tính năng

- Tăng cường XG




Nhiều mặt của 'Tầm quan trọng của tính năng' trong XGBoost (Amjad Abu-Rmileh, 2019)

191

SHAP: Giải thích về phép cộng SHAPley

- Đo lường sự đóng góp của một tính năng vào một dự đoán duy nhất




Hình ảnh của Scott Lundberg từ <https://github.com/slundberg/shap>

192

SHAP: Giải thích về phép cộng SHapley


- Đo lường sự đóng góp của một tính năng vào **toàn bộ mô hình**



193

Đo lường tầm quan trọng của tính năng @ Facebook

- 10 tính năng hàng đầu: 50% tổng mức độ quan trọng của tính năng
- 300 tính năng cuối cùng: <1% tổng mức độ quan trọng của tính năng



194

<https://github.com/interpretml/interpret>

```
ebm = ExplainableBoostingClassifier()  
I
```

195

195

Kỹ thuật thiết kế tính năng: càng nhiều càng tốt?

- Việc thêm nhiều tính năng hơn có xu hướng cải thiện hiệu suất của mô hình

Tại sao có quá nhiều tính năng lại có hại?



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

196

196

Quá nhiều tính năng có thể không tốt.

- Đào tạo: • Quá
phù hợp • Nhiều
tính năng hơn, nhiều khả năng rò rỉ dữ liệu hơn



197

Quá nhiều tính năng có thể không tốt.

- Đào tạo: • Quá
phù hợp • Nhiều
tính năng hơn, nhiều cơ hội rò rỉ dữ liệu hơn • Suy luận

• Tăng độ trễ suy luận với dự đoán trực tuyến • Có thể làm tăng mức
sử dụng bộ nhớ -> yêu cầu phiên bản đất tiền hơn



198

Quá nhiều tính năng có thể không tốt.

- Đào tạo: • Quá phù hợp • Nhiều tính năng hơn, nhiều cơ hội rò rỉ dữ liệu hơn • Suy luận
- Tăng độ trễ suy luận với dự đoán trực tuyến • Có thể làm tăng mức sử dụng bộ nhớ -> yêu cầu phiên bản đắt tiền hơn
- Các tính năng cũ trở thành nợ kỹ thuật
 - Ví dụ nếu mã bư u chính không còn đư ợc phép dự đoán, tất cả các tính năng sử dụng mã bư u chính sẽ cần đư ợc cập nhật



199

Quá nhiều tính năng có thể không tốt.

- Đào tạo: • Quá phù hợp • Nhiều tính năng hơn, nhiều cơ hội rò rỉ dữ liệu hơn • Suy luận
- Tăng độ trễ suy luận với dự đoán trực tuyến • Có thể làm tăng mức sử dụng bộ nhớ -> yêu cầu phiên bản đắt tiền hơn
- Các tính năng cũ trở thành nợ kỹ thuật

Giải pháp:

- Dọn dẹp các tính năng cũ/không hiệu quả • Lưu trữ các tính năng trong trữ ờng hợp bạn muốn sử dụng lại chúng • Quản lý tính năng



200

9 phương pháp hay nhất cho kỹ thuật tính năng

1. Phân chia dữ liệu theo thời gian thay vì phân chia ngẫu nhiên.
2. Nếu bạn lấy mẫu quá mức dữ liệu, hãy thực hiện sau khi chia tách.
3. Sử dụng số liệu thống kê/thông tin từ dữ liệu phân tách, thay vì toàn bộ dữ liệu, để thiết kế tính năng: mở rộng quy mô, chuẩn hóa, xử lý các giá trị bị thiếu, tạo số lượng n-gram, mã hóa mục, v.v.
4. Hiểu cách dữ liệu của bạn được tạo ra, thu thập và xử lý. Tham gia chuyên gia trong lĩnh vực này nếu cần thiết.
5. Theo dõi dòng dữ liệu.
6. Hiểu được tầm quan trọng của tính năng đối với mô hình của bạn.
7. Đo lường mối tương quan giữa các tính năng và nhãn.
8. Sử dụng các tính năng có khả năng khái quát tốt.
9. Xóa bỏ các tính năng cũ khỏi mô hình của bạn.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

201

201

Lựa chọn mô hình

202

202

Thuật toán ML

- Chức năng cần học
 - Ví dụ kiến trúc mô hình, số lớp ẩn • Hàm mục tiêu để tối ưu hóa (tối thiểu hóa) • Hàm mất mát
- Quy trình học tập (tối ưu hóa) • Adam, Momentum



203

6 mẹo để đánh giá thuật toán ML



204

1. Tránh bẫy công nghệ tiên tiến

• Lời hứa của SOTA • Tại

sao phải sử dụng giải pháp cũ khi đã có giải pháp mới hơn?

- Thật thú vị khi làm việc với những thứ sáng bóng • Tiếp thị



Replying to @chipro

This is how every conversation went when someone present the SOTA Transformer in a meeting with stakeholders.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

205

205

1. Tránh bẫy công nghệ tiên tiến

• Thực tế của SOTA •

SOTA trên dữ liệu nghiên cứu $\neq$ SOTA trên dữ liệu của bạn • Chi phí

• Độ trễ •

Thành công đã được chứng minh trong ngành • Hỗ trợ cộng đồng



Replying to @chipro

This is how every conversation went when someone present the SOTA Transformer in a meeting with stakeholders.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

206

206

2. Bắt đầu với những mô hình đơn giản nhất

- Dễ dàng triển khai hơn
 - Triển khai sớm cho phép xác thực đường ống
- Dễ gỡ lỗi hơn • Dễ cải thiện hơn



207

2. Bắt đầu với những mô hình đơn giản nhất

- Dễ dàng triển khai hơn
 - Triển khai sớm cho phép xác thực đường ống
- Dễ gỡ lỗi hơn • Dễ cải thiện hơn • Các mô hình đơn giản nhất $\models$ các mô hình tốn ít công sức nhất
 - BERT dễ dàng bắt đầu với mô hình được đào tạo trước, nhưng không phải là đơn giản nhất



208

3. Tránh sự thiên vị của con người trong việc lựa chọn mô hình

- Một câu chuyện về sự thiên vị của con người

- Các bài báo đề xuất các biến thể LSTM cho thấy các biến thể này cải thiện LSTM gốc. • Có đúng vậy không?



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

209

209

3. Tránh thiên vị của con người trong việc lựa chọn mô hình

- Một câu chuyện về sự thiên vị của con người

- Các bài báo đề xuất các biến thể LSTM cho thấy các biến thể này cải thiện LSTM gốc. • Có đúng vậy không?

LSTM: A Search Space Odyssey

Klaus Greff, Rupesh K. Srivastava, Jan Koutník, Bas R. Steunebrink, Jürgen Schmidhuber

We conclude that the most commonly used LSTM architecture (vanilla LSTM) performs reasonably well on various datasets. None of the eight investigated modifications significantly improves performance.

210

3. Tránh sự thiên vị của con người trong việc lựa chọn mô hình

- Điều quan trọng là phải đánh giá các mô hình trong điều kiện có thể so sánh được
 - Thật hấp dẫn khi chạy nhiều thử nghiệm hơn cho X vì bạn hào hứng hơn về X
- Gần như không thể đưa ra tuyên bố bao quát rằng X luôn tốt hơn Y



211


Tốt hơn bây giờ so với tốt hơn sau này

- Mẫu tốt nhất **hiện nay** ≠ mẫu tốt nhất **trong 2 tháng**
 - Tiềm năng cải thiện với nhiều dữ liệu hơn • Dễ dàng cập nhật



212

Đường cong học tập



Tốt cho việc ước tính hiệu suất có thể cải thiện với nhiều dữ liệu hơn không



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

213

https://scikit-learn.org/stable/auto_examples/model_selection/plot_learning_curve.html

213

5. Đánh giá sự đánh đổi

- Kết quả dự đoán tính giả so với kết quả âm tính giả
- Độ chính xác so với tính toán/độ trễ
- Độ chính xác so với khả năng diễn giải



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

214

214

6. Hiểu giả định của mô hình của bạn

- Tôi là ai?
 - Mạng nơ-ron giả định rằng các ví dụ là độc lập và phân phối giống hệt nhau
- Độ mịn
 - Các thuật toán có giám sát giả định rằng có một tập hợp các hàm có thể chuyển đổi đầu vào thành đầu ra sao cho các đầu vào tương tự được chuyển đổi thành các đầu ra tương tự
- tương tự • Khả năng xử lý
 - Giả sử X là đầu vào và Z là biểu diễn tiềm ẩn của X . Các mô hình sinh sản cho rằng có thể tính toán được $P(Z|X)$.
- Ranh giới
 - Bộ phân loại tuyến tính cho rằng ranh giới quyết định là tuyến tính.
- Độc lập có điều kiện
 - Bộ phân loại Naive Bayes cho rằng các giá trị thuộc tính độc lập với nhau khi xét đến lớp học.



215

6 mẹo để đánh giá thuật toán ML

1. Tránh bẫy của công nghệ tiên tiến
2. Bắt đầu với các mô hình đơn giản nhất
3. Tránh sự thiên vị của con người khi lựa chọn mô hình
4. Đánh giá hiệu suất tốt hiện tại so với hiệu suất tốt sau này
5. Đánh giá sự đánh đổi
6. Hiểu các giả định của mô hình của bạn



216

Các nhóm nhạc



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

217

217

Tổng hợp

- Tạo ra một mô hình mạnh từ một tập hợp các mô hình yếu

Người học cơ bản




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

218

218

Các nhóm: cực kỳ phổ biến trong các dự án theo phong cách bảng xếp hạng

- 20/22 giải pháp chiến thắng trên Kaggle trong tháng 1 - tháng 8 năm 2021 sử dụng ensembles
- Một giải pháp sử dụng 33 mô hình!



219

Tại sao phương pháp tổng hợp lại có hiệu quả?

- Nhiệm vụ: phân loại email (SPAM / KHÔNG PHẢI SPAM) • 3 mô hình không tương quan, mỗi mô hình có độ chính xác là 70% • Tổng hợp: đa số phiếu bầu của 3 mô hình này • Tổng hợp là đúng khi có ít nhất 2 mô hình đúng

220

Tại sao phương pháp tổng hợp lại có hiệu quả?

- 3 mô hình, mỗi mô hình có độ chính xác 70%
- Ensemble là đúng nếu ít nhất 2 mô hình là đúng
- Xác suất có ít nhất 2 mô hình đúng: $34,3\% + 44,1\% = 78,4\%$

Đầu ra của 3 mô hình	Xác suất	Đầu ra của Ensemble
Cả 3 đều đúng	$0,7 * 0,7 * 0,7 = 0,343$	Đúng
Chỉ có 2 câu đúng	$(0,7 * 0,7 * 0,3) * 3 = 0,441$	Chính xác
Chỉ có 1 là đúng	$(0,3 * 0,3 * 0,7) * 3 = 0,189$	Sai
Không có câu nào đúng	$0,3 * 0,3 * 0,3 = 0,027$	Sai



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

221

221

Tại sao phương pháp tổng hợp lại có hiệu quả?

- 3 mô hình, mỗi mô hình có độ chính xác 70%
- Ensemble là đúng nếu ít nhất 2 mô hình là đúng
- Xác suất có ít nhất 2 mô hình đúng: $34,3\% + 44,1\% = 78,4\%$

- Sự tương quan giữa những người học cơ bản càng ít thì càng tốt
- Phổ biến cho người học cơ bản có kiến trúc khác nhau



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

222

222

Tổng hợp

- Đóng bao • Tăng cường • Xếp chồng




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

223

223

Đóng bao

- Lấy mẫu **với sự thay thế** để tạo ra các tập dữ liệu khác nhau • Đào tạo một bộ phân loại với mỗi tập dữ liệu
- Tổng hợp các dự đoán từ các bộ phân loại ví dụ như trung bình, đa số phiếu bầu



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY


Mình họa bởi [Sirakorn](#)

224

224

Đóng bao

- Lấy mẫu **với sự thay thế** để tạo ra các tập dữ liệu khác nhau
- Đào tạo một bộ phân loại với mỗi tập dữ liệu
- Tổng hợp các dự đoán từ các bộ phân loại ví dụ như trung bình, đa số phiếu bầu



- Nói chung cải thiện các phương pháp không ổn định như mạng nơ-ron, cây
- Có thể làm suy giảm các phương pháp ổn định như kNN

[Dự đoán đóng bao](#) (Leo Breiman, 1996)


225

Tăng cường

- Đào tạo một bộ phân loại yếu

Cung cấp các mẫu bị phân loại sai bởi bộ phân loại yếu với trọng số cao hơn. Lặp lại (1) trên dữ liệu được trọng số lại này nhiều lần lặp lại nếu cần. Bộ phân loại mạnh cuối cùng: sự kết hợp có trọng số của các bộ phân loại hiện có

- bộ phân loại có lỗi đào tạo nhỏ hơn có trọng số cao hơn



226

Tăng cường


1. Đào tạo một bộ phân loại yếu 2.

Cung cấp các mẫu bị phân loại sai bởi bộ phân loại yếu với trọng số cao hơn 3. Lặp lại

(1) trên dữ liệu được trọng số lại này nhiều lần lặp lại nếu cần 4. Bộ phân loại mạnh cuối


cùng: sự kết hợp có trọng số của các bộ phân loại hiện có

a. bộ phân loại có lỗi đào tạo nhỏ hơn n có trọng số cao hơn n



227

Xếp chồng



Biểu quyết đa số, hồi quy
logistic, NN đơn giản

228

Tự động ML




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

229

229

Tự động ML

- Một nhà nghiên cứu ML giỏi là người có thể tự động hóa công việc của mình • Google: nếu chúng ta thay thế các chuyên gia ML bằng máy tính có khả năng tính toán gấp 100 lần thì sao?



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

230

230

Tự động ML

- AutoML mềm:
 - điều chỉnh siêu tham số •
- Hard AutoML • tìm kiếm kiến trúc nơ-ron
 - đã học được trình tối ưu hóa

Đắt hơn về mặt tính toán



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

231

231

Soft AutoML: Điều chỉnh siêu tham số

- Các mô hình yếu hơn với các siêu tham số được điều chỉnh tốt có thể hoạt động tốt hơn mô hình •
[Về tình trạng nghệ thuật đánh giá trong các mô hình ngôn ngữ thần kinh \(Melis et al. 2018\)](#)



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

232

232

Soft AutoML: Điều chỉnh siêu tham số

- Nhiều siêu tham số để điều chỉnh

```
model_type = "bert"

def __init__(
    self,
    vocab_size=30522,
    hidden_size=768,
    num_hidden_layers=12,
    num_attention_heads=12,
    intermediate_size=3072,
    hidden_act="gelu",
    hidden_dropout_prob=0.1,
    attention_probs_dropout_prob=0.1,
    max_position_embeddings=512,
    type_vocab_size=2,
    initializer_range=0.02,
    layer_norm_eps=1e-12,
    pad_token_id=0,
    position_embedding_type="absolute",
    use_cache=True,
    classifier_dropout=None,
    **kwargs
):
```



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY


https://github.com/huggingface/transformers/blob/master/src/transformers/models/bert/configuration_bert.py

233

233

Soft AutoML: Điều chỉnh siêu tham số

- Sinh viên tốt nghiệp (GSD)
 - Một sinh viên tốt nghiệp loay hoay với các siêu tham số cho đến khi mô hình hoạt động



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

<https://twitter.com/GuyZys/status/592847074170896384/photo/1>

234

234

Soft AutoML: Điều chỉnh siêu tham số

- Điều chỉnh Hyperparam đã trở thành một phần tiêu chuẩn của quy trình làm việc ML • Được tích hợp với các khuôn khổ • TensorFlow:

Keras Turner

- scikit-learn: tự động sklearn
- Ray Tune • Các

thuật toán phổ biến:

- Tìm kiếm ngẫu nhiên
- Tìm kiếm dạng lưới
- Tối ưu hóa Bayesian



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

235

235

NAS: Tìm kiếm kiến trúc thần kinh

- Không gian tìm kiếm
 - Tập hợp các phép toán ví dụ như tích chập, kết nối đầy đủ, gộp nhóm •

Cách thức các phép toán có thể được kết nối




Figure 3. Controller model architecture for recursively constructing one block of a convolutional cell. Each block requires selecting 5 discrete parameters, each of which corresponds to the output of a softmax layer. Example constructed block shown on right. A convolutional cell contains B blocks, hence the controller contains $5B$ softmax layers for predicting the architecture of a convolutional cell. In our experiments, the number of blocks B is 5.



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

236

Học các kiến trúc có thể chuyển giao để nhận dạng hình ảnh có thể mở rộng (Zoph và cộng sự, 2017)

236

NAS: Tìm kiếm kiến trúc thần kinh

- Không gian tìm kiếm
- Chiến lược ước tính hiệu suất • Làm thế nào để đánh giá **nhiều** kiến trúc ứng viên? • Lý tư ờng: nên đư ợc thực hiện mà không cần phải xây dựng lại hoặc đào tạo lại chúng từ đầu.



237

NAS: Tìm kiếm kiến trúc thần kinh

- Không gian tìm kiếm •
- Chiến lược ước tính hiệu suất • Chiến lược tìm kiếm
- Ngẫu nhiên
 - Học tăng cường ■ thư ờng cho những lựa chọn cải thiện ước tính hiệu suất • Tiến hóa
 - đột biến một kiến trúc
 - chọn những con có thành tích tốt nhất
 - vãn vãn




238

NAS: Tìm kiếm kiến trúc thần kinh

- Không gian tìm kiếm
- Chiến lược ước tính hiệu suất
- Chiến lược tìm kiếm

Rất thành công



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

EfficientNet: Xem xét lại việc mở rộng mô hình cho mạng nơ-ron tích chập (Tan et Le., 2019)

239

239

Học tập: kiến trúc + thuật toán học tập

- Thuật toán học tập:
 - Một tập hợp các hàm chỉ định cách cập nhật trọng số.
 - Còn được gọi là trình tối ưu hóa
 - Adam, Động lực, SGD



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

240

240

Đã học tối ưu hóa

Học sâu

tính năng kỹ thuật

SIFT (Lowe và cộng sự 1999)
HOG (Dalal và cộng sự 2005)

tính năng học tập

LeNet (LeCun và cộng sự 1998)
AlexNet (Krizhevsky và cộng sự 2012)

Học siêu hình

kỹ thuật để học

SGD (Robbins và cộng sự 1951, Bottou 2010)
Bộ mã hóa tự động (Hinton và cộng sự 2006)

học cách học

Học cách học (Hochreiter và cộng sự 2001)
Trình tối ưu hóa đã học (Andriychowicz và cộng
sự dd2016, Li và cộng sự 2016, Wichrowska và
cộng sự dd2017, Metz và cộng sự 2018, 2019)



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Slide được cung cấp bởi Luke Metz

241

241

Đã học tối ưu hóa

- Học cách học trên một tập hợp các nhiệm vụ
- Tổng quát hóa **các nhiệm vụ mới**



Using a thousand optimization tasks to learn hyperparameter search strategies



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Slide được cung cấp bởi Luke Metz

Luke Metz¹ Niru Maheswaranathan¹ Ruoxi Sun¹ C. Daniel Freeman¹ Ben Poole¹ Jascha Sohl-Dickstein¹

242

242

Đã học tối ưu hóa

- Học cách học trên một tập hợp các nhiệm vụ
- Tổng quát hóa thành **các nhiệm vụ mới**
- Trình tối ưu hóa đã học sau đó có thể được sử dụng để đào tạo phiên bản tốt hơn của chính nó!



Using a thousand optimization tasks to learn hyperparameter search strategies



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Luke Metz¹ Niru Maheswaranathan¹ Ruoxi Sun¹ C. Daniel Freeman¹ Ben Poole¹ Jascha Sohl-Dickstein¹

243

Slide được cung cấp bởi Luke Metz